

中图分类号: V328.1
论文编号: 10624S20220201005

中国民用航空飞行学院 硕士学位论文

论文题目 基于认知负荷与飞行数据的模拟飞行训练评价

作者姓名 余盼盼

专业类别(领域) 交通运输 (航空交通运输)

指导教师 周文刚 副教授

企业方导师 刘龙 高级工程师

培养学院 飞行技术学院

完成日期 2025 年 4 月 06 日

Evaluation of simulated flight training based on cognitive load and flight data

A Dissertation Submitted for the Degree of Master

Candidate: Yu Panpan

Supervisor: Associate Professor Zhou Wengang

Civil Aviation Flight University of China

April, 2025

摘 要

随着民航业的快速发展,飞行员的培养对飞行安全和效率的影响不容忽视。飞行训练作为培养飞行员的关键环节,其质量和效率的提升越来越受到整个行业的重视。但目前,对飞行训练质量的评价方法大多停留在主观经验层面,缺少系统客观的评价方法。本文从认知负荷量化评价和飞行训练质量两方面进行了探索,多维度融合对飞行员培养质量的提升具有重要意义。本文开展了以下研究工作。

首先,基于心率变异性(HRV)构建了飞行员认知负荷评估模型。基于飞行员初筛阶段的真实飞行训练科目设计实验科目进行模拟飞行实验。本研究对采集的飞行员生理数据进行特征提取,基于递归特征消除结合随机森林重要度(RF-RFE)筛选出20项关键HRV特征。结合飞行员主观评价,得到不同飞行阶段的认知负荷等级排序为着陆>起飞>下降>爬升>转弯>平飞,建立多个深度学习模型进行飞行品质评估,CNN-BiLSTM-BGRU在多个模型中表现最佳,性能指标中准确度为95.59%,精确度为95.61%,F1分数为95.60%,Cohen's Kappa为94.71%,召回率为95.59%,显著优于其他分类模型。

其次,基于飞行数据构建了训练品质评价系统。采集飞行员飞行数据并进行预处理,结合专家意见和科目训练过程,筛选出高度、航向、俯仰角、速度等核心飞行参数。结合飞行科目的标准进行阶段识别,采用K-Means聚类分析方法筛选优秀飞行员,并基于其均值数据分阶段分参数绘制参考曲线。通过序关系分析法确定不同飞行阶段及其关键指标的权重,形成了由轨迹匹配度、轨迹误差、飞行稳定性组成的综合评价体系。此外,计算核心飞行参数的均方误差,并提取误差的最大值、最小值及均值等统计特征,构建新的数据集。以飞行误差特征作为自变量,现有评估方法的得分(Y_1)与新模型的评分(Y_2)作为因变量,进行回归分析,结果表明:相比于 Y_1 , Y_2 的MSE和RMSE均显著降低,在误差评估方面表现更优。

最后,融合生理数据与飞行操作数据构建了品质评价模型。通过特征融合建立新的数据集,对样本进行均衡处理,并采用多种机器学习算法进行训练与评估。结果表明,在起飞、爬升、平飞、下降和着陆阶段,多层感知机(MLP)模型表现最优,F1分数为0.9790,而在转弯阶段,支持向量机(SVM)模型表现最佳,F1分数达到0.961。除此之外,统计分析结果揭示了认知负荷与飞行表现之间存在显著的负相关关系:在高负

荷环境下，飞行员的表现波动性明显增加，导致飞行得分整体下降，且得分较低的人群比例显著增长。这意味着，低负荷任务对于飞行员维持稳定表现更为有利，而高负荷任务则使得个体能力差异被放大。

综上所述，本研究对象不是传统矩形起落航线，而是基于飞行员初筛阶段的真实飞行训练科目构建贴合实际训练需求的实验设计，采用HRV数据与飞行数据的深度融合，结合统计方法与机器学习算法，分阶段建立了科学的飞行训练品质评价体系，为提升飞行员培训质量提供了有力支撑。

关键词：航空安全，飞行训练，认知负荷，训练品质评估，深度学习

Abstract

With the rapid development of the civil aviation industry, the impact of pilot training on flight safety and efficiency cannot be ignored. Flight training, as a key link in the training of pilots, has been increasingly emphasized by the whole industry in terms of its quality and efficiency. However, at present, most of the evaluation methods of flight training quality remain at the subjective experience level, lacking a systematic and objective evaluation method. This paper explores the two aspects of quantitative evaluation of cognitive load and flight training quality, and the multidimensional integration is of great significance to the improvement of pilot training quality. The following research work was carried out in this paper.

First, a pilot cognitive load evaluation model was constructed based on heart rate variability (HRV). Experimental subjects were designed for simulated flight experiments based on real flight training subjects at the initial pilot screening stage. In this study, the collected pilot physiological data were subjected to feature extraction, and 20 key HRV features were screened based on recursive feature elimination combined with random forest importance (RF-RFE). Combined with the pilot's subjective evaluation, the cognitive load level ranking of different flight phases was obtained as landing>takeoff>descent>climbing>turning>leveling off. Multiple deep learning models were built for flight quality assessment, and CNN-BiLSTM-BGRU performed the best among the multiple models, with an accuracy of 95.59%, a precision of 95.61%, and an F1 score of 95.60% in the performance indexes, the Cohen's Kappa of 94.71%, and recall of 95.59%, which are significantly better than other classification models.

Second, a training quality evaluation system was constructed based on flight data. Pilot flight data were collected and preprocessed, and core flight parameters such as altitude, heading, pitch angle, speed, etc., were screened by combining expert opinions and the subject training process. Combined with the standards of flight subjects for stage identification, the K-Means cluster analysis method was used to screen excellent pilots, and reference curves

were drawn based on their mean value data by stage and parameter. The weights of different flight stages and their key indicators were determined by the ordinal relationship analysis method, and a comprehensive evaluation system consisting of trajectory matching degree, trajectory error, and flight stability was formed. In addition, the mean-square errors of the core flight parameters are calculated, and the statistical features, such as the maximum value, minimum value, and mean value of the errors, are extracted to construct a new data set. Using the flight error characteristics as the independent variables, the score of the existing evaluation method (Y_1) and the score of the new model (Y_2) as the dependent variables, regression analysis was performed, and the results showed that compared with Y_1 , Y_2 had significantly lower MSE and RMSE, and performed better in error evaluation.

Finally, the quality evaluation model was constructed by fusing physiological data and flight operation data. A new dataset was established by feature fusion, the samples were equalized, and multiple machine learning algorithms were used for training and evaluation. The results show that the multilayer perceptron machine (MLP) model performs optimally in the takeoff, climb, leveling, descent, and landing phases, with an F1 score of 0.9790, while the support vector machine (SVM) model performs optimally in the turn phase, with an F1 score of 0.961. In addition, the statistical analysis results show that the cognitive load has a significant negative correlation with the flight performance: the pilots' performances are more stable in the low load condition, while the pilots' performances are more stable in the high load condition. Was more stable, while under high load conditions, the volatility of pilot performance increased, flight scores decreased overall, and the proportion of low groupings increased significantly. This suggests that the low-load task is more conducive to maintaining stable pilot performance, while the high-load task amplifies individual differences in ability.

In summary, the object of this study is not the traditional rectangular takeoff and landing routes, but the experimental design based on the real flight training subjects in the initial screening stage of the pilots to build the experimental design that meets the actual training needs, adopts the in-depth fusion of the HRV data and the flight data, combines the statistical methods and machine learning algorithms, and establishes the scientific evaluation system of the quality of the flight training in phases.

Key words: aviation safety, flight training, cognitive load, training quality assessment,

deep learning

目 录

第 1 章 绪论.....	1
1.1 研究背景与意义.....	1
1.2 国内外研究现状.....	2
1.2.1 基于飞行数据的飞行训练品质评价研究进展	2
1.2.2 基于生理数据的认知负荷评价研究进展	3
1.2.3 基于生理数据与飞行数据融合的飞行训练品质评价研究进 展	4
1.3 研究内容.....	5
1.4 技术路线图.....	6
第 2 章 模拟飞行实验介绍	7
2.1 实验目的.....	7
2.2 实验设计及数据采集.....	7
2.3 实验设备与人员.....	9
2.4 实验科目设计.....	10
2.5 本章小结.....	11
第 3 章 基于心率变异性的飞行员认知负荷分析	12
3.1 心率变异性理论基础.....	12
3.2 认知负荷主观评估.....	12
3.3 实验数据处理.....	13
3.3.1 数据预处理.....	13
3.3.2 心率变异性特征提取.....	14
3.3.3 心率变异性特征筛选.....	15
3.3.4 模型输入数据处理.....	17
3.4 飞行员认知负荷识别模型构建	18
3.4.1 模型基础.....	19
3.4.2 单结构模型.....	22
3.4.3 双结构融合模型.....	22
3.4.4 三结构融合模型.....	24
3.5 模型结果分析.....	26
3.6 本章小结.....	31
第 4 章 基于飞行数据的飞行员训练评价	33
4.1 飞行数据的获取.....	33
4.2 飞行参数指标筛选.....	34
4.3 飞行阶段划分.....	35

4.4 飞行数据预处理.....	36
4.4.1 数据清洗.....	37
4.4.2 平滑处理.....	37
4.4.3 时间归一化处理.....	37
4.5 参考曲线的获取.....	38
4.6 指标比重的确定.....	43
4.6.1 一级指标权重确定.....	43
4.6.2 二级指标权重确定.....	44
4.7 飞行训练品质评估.....	45
4.7.1 轨迹匹配度.....	45
4.7.2 轨迹误差.....	46
4.7.3 飞行稳定性.....	46
4.7.4 飞行训练品质评估模型建立.....	48
4.8 飞行训练品质评估模型的验证.....	49
4.8.1 现有飞行品质评分系统.....	49
4.8.2 回归模型构建与评价.....	49
4.9 本章小结.....	51
第5章 融合生理数据与飞行数据的飞行训练品质评估.....	52
5.1 数据集建立.....	52
5.2 数据处理.....	52
5.3 模型构建.....	54
5.4 模型结果分析.....	57
5.4.1 起飞阶段.....	57
5.4.2 爬升阶段.....	59
5.4.3 平飞阶段.....	60
5.4.4 转弯阶段.....	61
5.4.5 下降阶段.....	63
5.4.6 着陆阶段.....	63
5.5 不同飞行阶段的认知负荷与飞行表现分析.....	65
5.6 本章小结.....	68
结论与展望.....	69
参考文献.....	71

第 1 章 绪论

1.1 研究背景与意义

随着民航运输量的逐年递增,飞行安全已成为世界航空业最重要的研究课题。飞行事故发生的因素有很多,包括机械故障、人为差错、天气条件、人为破坏、故意击落以及飞行员失误等^[1]。近年来,根据国际民用航空组织(International Civil Aviation Organization, ICAO)和其他航空安全机构的数据,全球民航的安全记录持续改善,机械故障所致事故的比例已大幅下降,但人为错误依然是导致事故的主要原因,75%以上的民航飞行事故是人为因素造成的^[2]。其中,缺乏有效训练导致的人机交互障碍,是诱发人为差错的重要因素^[3]。安全是民航的生命,而飞行员的安全培训正是其生命线。

在现代航空领域,高度自动化的驾驶舱导致人机交互界面复杂程度日益提高,飞行员执行的任务日益复杂,飞行员面临的认知负荷不断增加。研究表明,若认知负荷过载,会导致飞行员任务绩效降低,甚至出现飞行员失能,对飞行安全造成严重威胁^[4]。在人机交互环节,飞行操纵的稳定性和可靠性与飞行员所承受的认知负荷之间存在密切的联系^[6]。有效的飞行训练则是改善这一问题的关键手段,通过系统化的训练,可有效降低飞行员在复杂环境中的认知负荷。经过反复训练,飞行员能够将关键操作转化为自动化反应,这样在高压环境下便能保持较高的注意力和决策质量。所以科学高效的飞行训练是提升飞行员技术水平的重要手段。

飞行学员的训练成绩评估是其培养过程中的关键环节。然而,传统的飞行训练评估依赖教员的主观评价,且对能力的量化评估标准模糊,难以保证评估的一致性和有效性^[6]。飞行训练品质分析评价是飞行训练领域关注度提高的领域,在飞行训练评估方面,客观评价手段、评价模型的建立等尤为重要,确保对学员的训练品质做出精确和有效的评价。

本研究借助模拟飞行实验采集飞行学员的心率数据与飞行数据。基于心率数据提取 HRV 特征,构建深度学习模型对飞行员认知负荷进行评估;选取关键飞行参数指标,采用序关系分析法(G1 法)确定指标权重,并基于飞行标准分阶段分参数建立参考曲线,从轨迹匹配度、轨迹误差和飞行稳定性等方面评估飞行员的训练质量;HRV 特征与飞行参数融合构建飞行训练质量评估指标,并采用随机森林、支持向量机、K 近邻、逻辑回归及多层感知机等多种机器学习算法进行分类预测,建立飞行训练评分模型;通过统计

分析探索飞行人员的认知负荷与飞行训练质量关联性,研究认知负荷对飞行训练结果的影响,为下一步提高飞行训练质量提供理论依据。

1.2 国内外研究现状

飞行训练是培训飞行员的重要环节,训练的质量关系到飞行员的操作技能,进而影响航空安全的整体水平。传统上,飞行品质的评估主要依赖于教员对飞行员操作技巧和任务完成情况的主观评分。为保证训练质量评估的一致性和客观性,飞行数据与生理数据在飞行品质评估中的应用变得愈加普遍,成为国内外研究的热点之一。基于客观的飞行数据与生理数据能够量化飞行员的训练质量,为飞行训练提供了客观科学的评价方法,进而对保证航空安全起到了非常关键的作用^[7]。

1.2.1 基于飞行数据的飞行训练品质评价研究进展

近年来,随着航空技术的快速发展,国内外研究者在飞行品质评估领域实现了显著突破。刘伟等^[8]提出了一个基于飞行员控制飞机幅度和频率的评价体系,并融合天气条件影响因素,结合人工评分对飞行品质进行了评估。孙宝嵩等^[9]采用灰色关联分析,确定了与飞行品质紧密相关的飞行参数。他们进一步建立了融合灰色关联分析和 XGBoost 算法的飞机飞行品质评价方法,并通过飞行训练数据的评估来验证该方法的有效性。王帅等^[10]则针对某型号飞机 G1000 航电系统在 14 个月内的 SD 卡超限事件数据进行了分析。他们将超限事件作为飞行品质评估的指标,通过运用 CRITIC-G1 法来确定最优权重,并与 TOPSIS 法结合分析不同样本数据的相对接近程度,运用秩和比法对飞行训练品质进行了等级划分。祝祯祯等^[11]集中研究了飞行起降阶段,特别关注曲线角、高度、空速等五个关键参数。他们通过拟合出这些参数的目标曲线,来评估实际的飞行参数是否接近目标值。为了进一步量化飞行品质,构建了一种基于时间序列分析的模型。孙宏等^[12]分析单人飞行训练的进近阶段的飞行技术误差曲线,关注速度偏差、高度偏差和横向偏差等关键的技术误差,以此来量化飞行员的操作能力。

邓永恒等^[13]对矩形起落航线做了分段处理,设立一级、二级指标,逐级加权求和建立指标模型。姜迪^[14]等结合决策树模型建立了进近阶段识别算法;结合飞行技术误差的思想选取评价指标,设定阈值及分数,利用熵值法确定每个指标的权重,建立了评估模型并进行验证。孙赫等^[15]基于飞行规则与时间序列相似性度量的矩形起落航线阶段划分与品质分析,计算时间序列距离,得出两者之间的时间序列相似性度量;最后采用基于

时间序列距离的飞行训练品质评价。卢飞等^[16]整合了可视化百分位数法与时间序列相似度理论,涵盖过程指标、结果指标和难度系数指标 3 个维度,基于航班数据建立了综合评价体系。Qi Bian 等^[17]提出了一种改进的粒子群优化方法来优化系统参数,解决了侧风着陆中底层优化问题。Wang L 等^[18]基于 QAR 数据研究长距离着陆事件的关键飞行参数特征,建立 Logistic 和线性回归模型,分析着陆距离与飞行参数变量之间的联系,对长距离着陆事件性能进行评价。

但是这些研究也有不足,这些研究大多都是基于单一来源的数据,且大多针对飞机起飞着陆阶段等特殊阶段或特定机型进行分析,没有针对整个飞行阶段进行评价,不具备泛化能力。

1.2.2 基于生理数据的认知负荷评价研究进展

认知负荷是个体在执行认知任务时所消耗的认知资源。认知负荷的变化直接影响个体的认知能力、工作效率及决策质量。在飞行过程中发生的许多事故中,飞行员认知负荷过高是导致事故发生的关键原因之一^[19]。近年来,随着生理传感技术的发展,基于生理数据的认知负荷评价方法成为研究热点。相比传统的主观问卷和行为测量方法,生理测量具有客观、实时、连续监测等优势。基于生理数据的认知负荷评价研究较早起步,并在多个学科领域取得了重要进展。王驰翔等^[20]基于心率变异性 and 脉率变异性等数据,通过预处理、特征工程、线性特征依赖建模的特征融合,建立 XGBoost 分类器用于高认知负荷检测。罗诗涵等^[21]使用 FaceReader 提取面部表情特征进行特征分析,并使用多种分类模型对认知负荷水平分类。李葳宁等^[22]基于动态图卷积网络提取脑电的空间拓扑特征,并通过 LSTM 网络在时间维度上融合特征在不同时刻的时序信息,最终融合特征信息利用全连接层构建分类器,进行认知负荷状态的评估。李文斌等^[23]比较 4 类脑电微状态参数在不同脑力负荷下的变化,得到高负荷任务下的 NASA-TLX 评分升高、任务绩效降低的结论。朱通等^[24]发现随着飞行训练的深入,完成同样飞行科目的认知负荷会降低,情境意识水平会提升,而眼动指标没有明显差异。周勇邦等^[25]验证了生理检测在人为因素适航审定中应用的可行性,筛选出眨眼间期、眨眼用时、心率、呼吸率和活动度等关键指标,对认知负荷进行评估。王深深等^[26]基于飞行员的心电和眼动数据,使用 CRITIC 法建立任务负荷量化模型,根据量化的客观综合评分建立样本数据集标签,将任务负荷映射为六个等级。Mohanavelu 等^[27]在心电图和脑电图的基础上,通过机器学习算法构建分类器,对飞行员在起飞、巡航和着陆阶段的认知负荷进行了有效的识别。

Arutyunova 等^[28]研究发现尤其是高速公路与城市驾驶以及高速公路驾驶期间,认知负荷的增加伴随着较高的心率和低的 HRV。Huynh 等^[29]验证了用深度学习算法来训练使用 EEG 数据对大脑状态进行分类的模型的可行性。Ghaderi 等^[30]发现瞳孔扩张和 EEG 可以一起用来检查飞行员的行为。Wang 等^[31]设计了机场交通模式飞行模拟实验,基于心电图生理数据和 NASA-TLX 心理数据,结合 RNN 和 LSTM 构建了飞行员认知负荷识别模型,为预防和减少飞行任务中认知负荷引起的人为失误提供有益的参考。

基于生理数据评价可以评价飞行员飞行时认知负荷的等级。但缺少了飞行数据,很难真实全面地反应飞行训练情况。为了更加评价飞行训练的品质,还需结合飞行数据进行评价。

1.2.3 基于生理数据与飞行数据融合的飞行训练品质评价研究进展

近年来,随着航空业的快速发展,飞行员训练品质的重要性日益凸显。传统的飞行品质评价往往依赖于飞行数据单一指标,而近年来,越来越多的研究者开始关注融合生理数据与飞行数据的综合评价方法。这一研究方向在国内外均受到广泛关注,并取得了诸多进展。

张龙等^[32]基于模糊逻辑理论通过采集模拟飞行数据和塞斯纳 172 实际飞行数据构建了飞行品质评价模型。论文根据飞行训练中获得的飞行参数以及生理信号数据,结合专家建议选取下降率、偏航、着陆速度等 5 项飞行参数和心率、呼吸频率 2 项生理指标作为评价指标,作为模型的输入变量为飞行训练中的飞行学员构建了基于模糊逻辑的数学模型进行飞行品质评价。仇志凡^[33]等基于受试人员生理参数和主观评价等级建立线性的回归模型,研究主观评价等级与生理参数的关系,然后又基于飞机飞行参数和主观操纵品质评价等级建立 BP 神经网络,以飞行参数作为神经网络的输入,受试人员主观评价作为输出,分析评价等级与飞行参数之间的关系。利用该网络评估飞行参数对于操纵品质的贡献率,分析不同参数对操纵品质等级的影响程度。孙瑞山和柳忠起^[34-35]两个团队分别利用操作行为的心理学原理、眼动数据和 BP 神经网络算法建立了评价模型对飞行员操纵水平和飞行绩效进行了专业评估。孙敬周^[36]设计实验获取飞行学员的飞行参数和生理信号数据,选取下降率、偏航、垂直速度变化、襟翼角度和着陆速度五个飞行参数,心率和皮肤温度两个生理信号作为飞行品质评估指标,数据处理之后,专家进行打分,打分分为优秀,良好和差三个类别。

上述研究为数据融合研究奠定了基础,但也存在诸多问题。在数据融合方面,上述

研究大多采用简单的融合方式,较少涉及数据间的深层次关系。甚至有些研究将飞行参数和生理指标视为两个独立的数据,简单叠加直接作为输入数据,未考虑飞行训练过程中两者之间的深层潜藏的关系。

针对上述问题,本文研究提出以下改进措施:单一数据源下,利用更优的特征选择算法与深度学习模型,更好的捕获的飞行数据的动态变化;多数据源融合下,融合生理数据与飞行数据,构建飞行员多维度评价体系,弥补单一数据源的局限性。

1.3 研究内容

本研究旨在从生理数据与飞行数据的双重维度出发,探索飞行员在不同飞行阶段的认知负荷水平,并建立科学、有效的飞行训练品质评估体系。

从研究背景以及国内外研究动态出发,清晰界定本文的研究范围,并对技术路径进行了概述。并进行模拟飞行实验设计,其涵盖了实验的整体规划,包括实验所需设备、人员配置、实验流程的具体步骤,以及飞行科目的具体安排。

在认知负荷评估方面,为进一步探究不同飞行阶段的认知负荷水平,本研究采用了主观评估分析方法,对收集到的数据进行了预处理,并基于深度学习技术构建了飞行员认知负荷识别模型。最后,还对不同模型在识别效果上的表现进行了比较分析,为深入理解认知负荷提供了更为精确的科学依据。

在飞行品质评估方面,对飞行数据预处理,包括数据清洗、异常值处理、平滑处理和时间归一化等步骤,依据飞行标准分阶段分参数获取参考曲线。并通过序关系分析法确定一、二级指标的权重,构建了飞行训练品质评估模型,并建立回归模型对所构建的评估模型进行了验证,以确保其有效性和可靠性。

本研究还融合 HRV 数据与飞行参数,构建了一个新的数据集,并对其进行了数据清洗、标准化及对异常值的处理,运用了低方差筛选、相关性筛选以及基于 F 值的特征选择方法,提取出对飞行训练品质具有显著影响的特征。在此基础上,采用了不同类型的分类模型进行训练,并对这些模型的分类性能进行了比较分析。此外,本研究还通过 ANOVA 和 Tukey HSD 等事后检验统计方法,深入分析了不同飞行阶段认知负荷水平对飞行员表现所产生的影响。

1.4 技术路线图

本研究围绕飞行训练中的认知负荷识别与飞行品质评估，构建以多源数据融合为核心的技术路线，涵盖数据采集、特征提取、模型构建与性能验证等关键环节。研究首先通过飞行模拟实验获取高质量的飞行操作数据与生理数据，为后续分析提供基础支撑。结合其主观评价结果，利用统计学和深度学习等方法，建立驾驶员的认知负荷模型。针对飞行品质的评估，依据所采集的飞行数据，结合标准飞行标准，分阶段分参数构建了参考曲线，以此开展飞行品质的定量评估。在多源数据融合阶段，构建新的数据集，并运用机器学习算法实现飞行品质的分类与预测，研究的技术路线如图 1.1 所示。




图 1.1 技术路线图

第2章 模拟飞行实验介绍

2.1 实验目的

随着飞行任务的日益复杂,飞行员在执行任务时面临的认知负荷不断增加。认知负荷过高或者过低不仅影响飞行员的决策制定和工作绩效,还对飞行安全产生潜在威胁。而飞行训练是减小飞行员认知负荷,提高飞行员技能水平的重要手段。模拟机训练可将飞机的大部分故障和失效情况进行模拟,使飞行训练可以从空中转到地面来进行,可以避免实际飞行时可能存在的一些潜在的安全和天气的因素。因此,本研究主要通过模拟飞行实验,利用飞行数据记录装置和生理数据记录装置同步采集飞行人员在执行不同飞行任务时的飞行数据与生理数据,建立飞行训练评估模型,为飞行训练质量评估、个性化训练提供参考和依据,为提高飞行安全性提供保障。

飞行参数能够有效评估飞行员操作的精确性、飞行的稳定性以及任务完成的程度。与此同时,生理数据的分析有助于了解飞行员在飞行不同阶段所承受的认知负荷,从而有助于我们深入探究认知负荷与飞行训练质量之间存在的关联。通过对多模态数据进行融合,构建科学完善的飞行训练评估体系,为优化训练策略提供可靠的科学依据。

总的来说,本实验构建了数据融合的训练评估体系,不仅有助于深化对飞行员认知负荷特征的理解,还为改进飞行训练方案和提升飞行安全性提供了重要的科学依据。

2.2 实验设计及数据采集

本次实验分为预实验、正式实验和数据采集三个部分,以确保受试者对实验环境的熟悉程度,同时保障数据采集的稳定性。

(1) 预实验

在预实验阶段,研究人员会对所有参与者进行详尽的讲解,包括实验的宗旨、执行步骤以及飞行科目的特定要求。参与者将全面了解实验的整体架构,这包括明确的具体任务、评估的基准,以及在实验进程中需关注的安全要点。

在受试者进行预实验的同时,操作人员会对心率采集设备进行调试,并协助受试者佩戴设备,确保每位受试者的心率监测设备正常工作,调整到测试人员觉得舒适的位置、反馈力度;检查模拟飞行设备安装无误,检查微软模拟飞行 2020 软件无异常;检查数据采集软件无异常,这一步骤对于实验数据的准确性至关重要,出现失误可能会导致数

据缺失。预实验结束后，所有受试者需要进行静息 5 分钟，让飞行员生理指标恢复至平稳状态。

（2）正式实验

在实验的正式阶段，操作人员将遵照既定流程执行各项实验任务。实验参与者将通过随机分组的方式进入实验场所，并且按照指定的时间启动实验。在实验过程中，参与者需要在飞行模拟器上执行一系列飞行操作任务，同时，研究人员将对参与者的飞行操作数据以及生理数据采集情况进行实时监视，从而确保实验的顺利进行。

（3）数据采集

每位受试者在完成实验后，研究人员将统一进行飞行数据与心率数据的采集工作，具体流程如图 2.1 所示。飞行结束后，数据采集软件上将数据进行储存，飞行数据在数据提取插件 CAFUC Flight Sim Test 中提取，心率数据通过 Polar Verity Sense 运动臂带式心率表配备的 Polar Equire 软件上进行提取。所有数据收集完毕后，研究人员会对数据质量进行严格检查，确保无误后，将每位受试者的数据分别存储至单独的文件夹中，以便后续分析使用。




图 2.1 数据采集流程图

2.3 实验设备与人员

本实验选用搭载微软模拟飞行 2020 的桌面式飞行训练器，该训练器配备了三联屏幕、操作盘、油门杆和刹车装置等。操作盘使用 Honeycomb Aeronautical 公司生产的 ALPHA Flight Controls 阿尔法飞行控制器，可以提供真实 180°舵盘旋转，左右手柄均配备 8 向圆形视图开关、垂直和水平双向摇杆开关、三个按钮和一个通话按钮，该设备可以改变飞机的俯仰姿态和横滚角度；脚蹬使用 Logitech 公司生产的飞行方向舵踏板，支持完全可调流畅运动，支持左右脚尖制动的独立控制，可调阻力使控制更精细；油门杆使用 Logitech 公司生产的 X52PRO 手动油门，具有渐进式功能可提高飞机响应水平，提供张力调整盘，可更改油门阻力。

心率数据采集设备选择 Polar Verity Sense 运动臂带式心率表，是一款由芬兰 Polar Electro Oy 公司推出的高精度光学心率监测设备。该设备能够实时连续地采集飞行员的心率数据，并输出包括心率（HR）、光学脉搏信号（PPG）和脉冲间隔（PPI）数据。数据以时间序列保存，导出为 Excel 文件进行后续的分析处理。该设备采用 6 LED 光学传感技术，结合光学容积描记法进行心率监测，能够精准追踪血流变化，计算实时心率数据。其佩戴方式灵活，可通过可调节臂带固定于手臂，以确保运动过程中的稳定性和舒适性，被测者能够最大限度地自由运动，对飞行学员的影响更小。模拟设备及测试环境如图 2.2 所示。



(a) 模拟飞行平台



(b) Polar Verity Sense 运动臂带式心率表

图 2.2 实验设备

本研究招募了来自中国民用航空飞行学院的 110 名健康男性飞行学员作为试验对象，平均年龄为 22.5 (± 1.5) 岁，所有参与者均为右利手，身体健康，均无相关病史且全部

具备正常的视力和听力，以避免个体差异对实验结果的影响。为了最大程度地减少外部因素对实验数据的干扰。

在验证研究假设过程中，采用了 G-Power3.1.9.7 软件进行数据分析。根据预定的标准，设定显著性水平为 $\alpha=0.05$ ，以确保检测效果达到 $1-\beta=0.8$ 。通过效应量 $f=0.25$ 的设置，运用重复测量方差分析，对实验设计中的组内和组间变量进行了分析，确定了每组至少需要 24 名参与者的样本量。然而，鉴于实验过程中可能出现的数据缺失等问题，为确保实验数据的可靠性，最终将参与样本数量扩展至 110 名。

在试验开始的 24 小时内，所有学生均未饮用功能性饮料，不服用任何药品，不进行剧烈运动，不吸烟，无主观不适。实验前保障充分的睡眠。实验开始前，为确保所有参与者能够熟练掌握实验操作流程，研究团队在实验正式开始前安排了模拟飞行平台的熟悉与试操。通过这一过程，受试者能够充分适应实验环境、熟悉飞行任务，减少因操作不熟练导致的无关变量，从而提高数据的稳定性和可重复性。

2.4 实验科目设计

本研究基于民航飞行员初始选拔阶段的真实训练科目，设计的还原典型飞行场景和关键操作节点的评估科目。考虑到测试人员下阶段将进入真机训练，选取机场为广汉机场，使用跑道为广汉机场常年训练主用跑道 13 号，飞机选择使用由美国塞斯纳飞机制造公司生产的 Cessna-172 型单发螺旋桨飞机，天气条件为：适当侧风，风速在 5kts 左右，气象条件为 CAVOK（晴空万里），飞行计划如下：

- （1）从广汉本场 13 号跑道起飞，航向 127°，解除停留刹车，全油门，55kt 抬轮；
- （2）一边保持飞机姿态+7.5°，爬升速度 75kt，高度 1800ft 时关着陆灯、滑行灯；
- （3）距广汉 VOR1NM 时进行一转弯，坡度 20°，航向 040 改出；
- （4）高度 3000ft 改平，保持航向 330°，爬升速度 75kt 上高度 4000ft 改平，速度 90kt；
- （5）保持航向 330，保持高度 4000ft，距广汉 VOR5 海里调速至 65kt 平飞，7 海里恢复至 95kt；
- （6）距广汉 VOR8 海里时保持速度 95kt，高度 4000ft，坡度 30°左转半圈至航向 150；
- （7）航向 150°，下降保持高度 3000ft，速度 90kt；

(8) 距广汉 VOR5 海里时保持速度 90kt, 转到航向 180°

(9) XTK 小于 0.5 时, 重新进入广汉机场第一边航向 127°, 同时下降高度 2500, 3 海里后, 进行起落航线一转弯, 航向 37°, 距 XTK1.0NM 时进行起落航线二转弯, 转到 307 切入三边, 三边保持 XTK1.5NM, 高度 2500ft, 速度 90kt;

(10) 切跑道头时放 10°襟翼, 调速至 85kt;

(11) 距广汉 2NM 时起落航线三转弯, 坡度 20°, 下高度至 2400ft 边转弯边下降, 速度减至 75kt, 航向 217 改出;

(12) 转弯完成后放襟翼 20°, 保持速度 75kt, 到达四转弯点时高度 2200ft, 进入四转弯;

(13) 四转弯坡度 20°, 改出时高度 2000ft (边转弯边下降), 速度 70kt;

(14) 四转弯完成后放襟翼 30°, 参考跑道目视进近, 保持稳定进近, 速度 65kt, 入口速度 62kt 进行落地; 模拟飞行轨迹如图 2.3 所示。




图 2.3 模拟飞行路径图

2.5 本章小结

本章介绍模拟飞行实验的具体内容, 招募了 110 名健康男性学员, 利用模拟飞行器 和 Polar Verity Sense 手环, 记录数据。阐述了实验的具体流程, 包括实验准备、正式实验及数据采集等环节, 并且对飞行科目的具体参数标准进行了说明。

第3章 基于心率变异性的飞行员认知负荷分析

3.1 心率变异性理论基础

HRV 指的是相邻心搏间 RR 间期的波动,是评判人类自主神经系统副交感神经和交感神经活动的重要指标^[37]。飞行员会承受各种压力源,这些压力源可能会影响他们在飞行的所有阶段的表现,HRV 可用于表征飞行员在飞行过程中的交感神经应激反应^[38]。在平静、放松的状态下,副交感神经系统的活动相对增强,在身体和精神活动负荷增加的情况下,交感神经系统的活动增加,两个系统协同工作以维持生理自主神经功能的调节平衡^[39]。HRV 被广泛用于评估压力水平、疲劳状态和认知负荷。在飞行过程中,飞行员需要在短时间内接收大量信息,会导致过高的认知负荷。长时间的高度紧张和复杂任务需求往往导致交感神经占主导地位,从而导致 HRV 下降,这种变化可能影响飞行员的生理稳定性,甚至影响其决策能力^[40]。因此,HRV 作为飞行员生理反应的指标,能够反映飞行员在面对高压工作环境时的应激水平和恢复状态。

飞行员的认知负荷是指飞行员用于集中注意力、感知情境、合理决策及行动所需的认知资源,即飞行员在单位时间内承受的工作量和处理信息所需的精力总和。飞行员经常会承受较大的工作负荷而导致应激紧张、记忆力下降、反应停滞、失误增加等情况,对机动决策响应时间造成影响。测量飞行员的认知负荷对于提高航空安全至关重要,HRV 已成为在实际飞行中检测飞行员认知负荷的潜在工具^[41]。多项研究表明,HRV 在高认知负荷状态下会出现显著的下降,这表明较高的认知负荷与低 HRV 之间有着密切的关联^[42]。因此,通过实时监测飞行员的 HRV,可以有效评估其认知负荷水平,帮助其在飞行任务中更好地调节认知负荷,确保飞行安全。

3.2 认知负荷主观评估

认知负荷的波动往往引发多种生理反应,其中 HRV 在评估飞行员认知负荷时展现出更高的信度和效度。故本研究提出假设,在起飞、爬升、转弯、平飞、下降以及着陆这一系列阶段,飞行员的认知负荷可能会有所不同。以下将结合飞行人员在不同飞行阶段所承担的任务特征,深入探讨他们在不同阶段所经历的认知负荷。

起飞阶段是飞行员需要高度集中注意力的阶段。飞行员需要设定起飞推力,确保发动机参数在安全范围内,同时保持飞机航向。当飞机达到一定高度后,飞行员要收起起

落架、襟翼，并进行系统检查，使飞机进入安全爬升状态。由于起飞阶段需要执行多重操作，处理大量的信息，因此认知负荷较高^[43]。

进入爬升阶段后，飞行员主要是在控制爬升推力，即对飞机高度和速度进行控制。此时，飞机的飞行状态较为稳定，飞行员操控飞机所需的信息输入较少，操作需求较低，因此相对起飞阶段飞行员认知负荷有所降低。

巡航阶段是整个飞行过程中认知负荷最小的阶段。在这一阶段，飞机状态较为稳定，飞行员主要负责保持曲线和监控飞机速度，同时调整油门以维持适当的飞行高度。需要关注的飞行参数较少，操作量最小，因此巡航阶段的飞行员负荷相对较轻^[44]。

当飞机进入下降阶段后，操作需求再次增加。飞行员需调整飞机姿态，精确控制油门，确保飞机下降速度适中。在此过程中，飞行员还需不断监测航向、高度、速度等核心数据。同时，根据仪表显示，飞行员还需准确把握转弯的最佳时刻，保证飞机始终沿着正确的下降轨迹飞行。尽管与起飞和着陆阶段相比，下降阶段的操作量有所减少，但飞行员仍需持续监控飞机的状态，这属于一个中等负荷的阶段。

转弯阶段通常发生在飞行过程中调整航向时。在此阶段，飞行员需要确保转弯时机和倾角合适，同时保持高度和速度稳定。虽相比下降阶段，转弯阶段的操作需求较低，信息处理量也较小，因此认知负荷较轻。

最后，在着陆阶段，飞行员需对正跑道，不断调整速度、高度和坡度等飞行参数，同时，还需要控制航向偏差，调整飞行路径。此外，飞行员必须保持高度警觉，随时准备执行复飞程序，以应对可能出现的突发情况。由于这一阶段需要处理的信息量大，操作最为密集，飞行员的工作负荷较高^[45-46]。

综合来看，从任务复杂性和飞行员的主观评价的角度，各飞行阶段的认知负荷从高到低依次为：着陆>起飞>下降>爬升>转弯>平飞。

3.3 实验数据处理

3.3.1 数据预处理

在 HRV 分析中，数据的质量直接影响分析结果的准确性。在数据收集阶段，若传感器安装位置不稳固或受试者运动幅度过大，均可能引发数据波动，进而导致异常和离群数值的产生。

首先，为了去除离群值，设定了合理的心率间隔范围。具体而言，低阈值设定为 250ms，

高阈值设定为 1800ms ^[47]。通过设定合理的范围,可以有效过滤掉这些不合常理的数据,避免其影响 HRV 分析的稳定性和可靠性。在数学上,设 RR 间隔序列为 $RR=\{RR_1, RR_2, \dots, RR_n\}$, 定义有效范围为:

$$250\text{ms} \leq RR_i \leq 1800\text{ms} \#(3.1)$$

去除极端异常值,确保数据的合理性,使后续 HRV 分析更加稳定和可靠。

实际测量数据中存在部分心率间隔数据缺失。若对此类缺失数据直接忽略,将影响 HRV 分析的连贯性。因此,为保持数据的连续性,本研究使用了线性插值法来填补缺失的数据。具体来说,首先会删除离群值和异常值,将其标记为缺失值,然后再进行线性插值处理。在插值中若连续出现 $n-1$ 个空值,并且这些聚集的空值的最邻近的两个非空数据为 y_i 和 y_{i+n} , 则空值 y_{i+k} 可线性插值为:

$$y_{i+k} = y_i + \frac{k(y_{i+n} - y_i)}{(n-1)} \#(3.2)$$

通过上述数据预处理步骤,可以有效提升 HRV 分析的可靠性。

3.3.2 心率变异性特征提取

在 Python 环境中,本研究使用 `hrvanalysis` 库对经过预处理的 PP-interval 数据进行特征提取,设置的时间窗口为 30 秒,相邻时间窗口之间的重叠率为 40%。经过处理,共提取出 `mean_nni`、`sdnn`、`sdsd`、`pnni_20`、`rmssd`、`median_nni`、`range_nni`、`cvsd`、`cvnni` 等 30 个 HRV 指标,如表 3.1 所示。

表 3.1 HRV 指标

	特征	定义
时域	<code>mean_nni</code>	心跳间隔的均值
	<code>sdnn</code>	NN 间隔的标准差
	<code>sdsd</code>	相邻 NN 间隔之间的标准差
	<code>pnni_20</code>	NN 间隔大于 20 毫秒百分比
	<code>pnni_50</code>	NN 间隔大于 20 毫秒百分比
	<code>nni_20</code>	相邻 NN 间期相差超过 20 毫秒的次数
	<code>nni_50</code>	相邻 NN 间期相差超过 50 毫秒的次数
	<code>rmssd</code>	相邻 NN 间隔之间均方根差

表 3.1 HRV 指标 (续)

	特征	定义
时域	median_nni	NN 间隔的中位数
	range_nni	NN 间隔的范围
	cvsd	连续差异的变异系数
	cvnni	NN 间隔的变异系数
	mean_hr	平均心率
	max_hr	最大心率
	min_hr	最小心率
	std_hr	心率的标准差
	lf	低频功率
	hf	高频功率
频域	lf_hf_ratio	低频功率与高频功率的比率
	lfnu	归一化低频功率
	hfnu	归一化高频功率
	total_power	频谱的总能量
	vlf	功率谱的能量
	sd1	PoincaréPlot 中的标准差 1
	sd2	PoincaréPlot 中的标准差 2
非线性	ratio_sd2_sd1	标准差 2 与标准差 1 的比率
	csi	交感神经指数
	cvi	迷走神经指数
	Modified_csi	交感神经指数
	triangular_index	三角指数

3.3.3 心率变异性特征筛选

为了增强模型的性能和解释能力, 增强 HRV 特征对不同认知负荷等级的识别, 本研究对关键生理指标先进行了正态检验和显著性分析, 基于 K-S 正态性检验得出 HRV 特征均服从非正态分布, 克鲁斯卡尔-沃利斯检验 (Kruskal-Wallis test, K-W test) 进行检

验, 差异性显著性设为 $p < 0.05$, 检验结果显示 HRV 特征均有显著性差异。最后, 采用递归特征消除 (Recursive Feature Elimination, RFE) 结合随机森林 (Random Forest, RF) 的方法评估了各 HRV 特征的重要性, 完成特征筛选。

RFE 基本思路是通过反复构建训练模型, 不断移除特定的特征变量从而获得能模型性能的最优特征组合。在遍历特征子集的过程中, 特征被消除的次序就是特征的重要性排序, 旨在通过递归地移除不重要的特征, 最终筛选出最有价值的特征子集^[48]。

在初始状态下, 使用所有 n 个特征训练一个随机森林基模型, 并计算每个特征的重要性。假设数据集包含 m 个样本和 n 个特征, 可以表示为:

$$X = [x_1, x_2, \dots, x_n] \in R^{m \times n} \quad (3.3)$$

$$y = [y_1, y_2, \dots, y_n] \in R^m \quad (3.4)$$

其中, X 是特征矩阵, y 是标签向量。在随机森林模型中, 每个特征的重要性可以通过基尼指数的减少量计算:

$$Importance(x_i) = \sum_{t=1}^T I_t(x_i) \quad (3.5)$$

其中, T 是随机森林中的决策树总数, $I_t(x_i)$ 代表特征 x_i 在第 t 棵树中的重要性。在每次迭代中, 选出权重最小或最不重要的 k 个特征, 并将它们从数据集中移除, 得到新的特征子集, 然后, 在新的特征子集 X' 上重新训练基模型, 重复上面步骤直到剩下预设的特征数量。

RFE 会在满足预设的特征数量时停止, 通常设定目标特征数量为 k 。

$$stop \text{ when } |X'| = k \quad (3.6)$$

在随机森林模型中, 特征的重要性反映该特征在决策过程中对分类准确性的影响程度。重要度的数据越大, 特征重要性越高, 说明该 HRV 指标对状态分类的贡献越大, HRV 特征的重要度如表 3.2 所示。通过 RF-RFE 进行特征筛选, 筛选出 20 个最重要的特征, 经过筛选后得到 mean_nni、sdsd、pnni_20、median_nni、range_nni、cvsd、cvnni、mean_hr、max_hr、min_hr、std_hr、lf、hf、lf_hf_ratio、lfnu、total_power、vlf、ratio_sd2_sd1、csi、Modified_csi 特征。

表 3.2 特征重要度

排序	HRV 特征	重要度	排序	HRV 特征	重要度
1	max_hr	0.044966	16	lf_hf_ratio	0.033479
2	vlf	0.040462	17	hfnu	0.033335
3	median_nni	0.039909	18	lfnu	0.032324
4	min_hr	0.038194	19	cvnni	0.032084
5	csi	0.038124	20	sd1	0.031575
6	hf	0.037771	21	sdsd	0.031133
7	mean_hr	0.037751	22	rmssd	0.031017
8	mean_nni	0.037595	23	sd2	0.030832
9	ratio_sd2_sd1	0.03684	24	cvi	0.030473
10	total_power	0.036766	25	sdnn	0.029743
11	cvsd	0.036606	26	pnni_20	0.028932
12	lf	0.036357	27	triangular_index	0.027409
13	std_hr	0.035953	28	nni_20	0.025036
14	range_nni	0.035394	29	pnni_50	0.019793
15	Modified_csi	0.03426	30	nni_50	0.015884

3.3.4 模型输入数据处理

模型中输入变量为 HRV 特征，目标变量为负荷等级。为了准确预测不同飞行阶段的负荷等级，需要对原始数据进行系统的预处理，包括特征筛选、归一化、样本平衡、时间序列构造及数据集划分等步骤。

由于不同特征的数值范围存在较大差异，采用 Min-Max 归一化方法，将筛选后的 HRV 特征缩放到[0,1]区间，以提高模型的训练稳定性和收敛速度。

$$X_{\text{norm}} = \frac{X - X_{\min}}{X_{\max} - X_{\min}} \quad \#(3.7)$$

由于数据不均衡，直接训练会导致模型对少数类别的预测效果较差。为了平衡数据分布，采用 SMOTE 对少数类别进行过采样，使所有类别的样本数量趋于均衡。

在时间序列构造方面，设定时间窗口长度 $T=12$ ，即每个样本由连续 12 个时间步的

数据组成。针对每个类别的数据，按时间顺序提取长度为 T 的连续特征片段作为输入样本，其对应的负荷等级作为标签。

$$X_{input} = (N, T, F) \# (3.8)$$

其中： N 为样本数量， T 为时间步长， F 为特征维度。最终，输入数据的张量形状为 $(N, 12, 20)$ ，即每个样本是一个 12 个时间步、20 个特征的时序矩阵。为了评估模型的泛化能力，数据集进行划分，其中 80% 的数据用于训练，20% 用于测试。

3.4 飞行员认知负荷识别模型构建

考虑到不同飞行阶段中 HRV 数据的时间序列、非线性交互等特性，本研究介绍了基于 LSTM 的深度学习模型，并结合 Transformer、CNN 和 BGRU 等不同的架构来增强对序列数据的建模能力，模型特性及适用原因如表 3.3 所示。并通过筛选后的 HRV 指标进行识别，构建分类模型，准确对模拟飞行中不同阶段的认知负荷进行分类。基于此，针对性调整模型网络结构与参数，以适配数据及飞行训练场景需求。

表 3.3 不同模型特性和适用原因

模型	特性	适用原因
BiLSTM	同时考虑时间序列数据的前后依赖，提高特征提取能力 ^[49]	BiLSTM 能有效捕捉时序特征，提高分类准确度
BiLSTM-Transformer	BiLSTM 提取时序特征 Transformer 增强关键时间步的全局关联 ^[50]	动态分配注意力权重；突出高负荷阶段的 HRV 突变
CNN-BiLSTM	CNN 提取局部 HRV 特征，BiLSTM 用于学习时间序列依赖关系 ^[51]	适用于既需要局部特征提取，又需要长期时序建模的任务，提升模型对 HRV 局部异常的鲁棒性
BiLSTM-BGRU	BiLSTM 学习复杂时序模式，BGRU 轻量化门控优化计算效率 ^[52]	实时监测场景，平衡精度与实时性
CNN-BiLSTM-	CNN 提取局部特征，LSTM 负责时序建模，Transformer 增强全局关系 ^[53]	适用于复杂认知负荷分类任务
CNN-BiLSTM-BGRU	CNN 捕获局部细节，BiLSTM 建模双向依赖，BGRU 优化长期记忆 ^[54]	最大化分类精度，支持精细化训练反馈

3.4.1 模型基础

(1) BiLSTM

长短期记忆网络 (Long- and short-term memory, LSTM) 是对传统循环神经网络 (Recurrent Neural Network, RNN) 的改进, 具有沿时间序列展开并传递信息的能力。LSTM 通过设置输入门、遗忘门和输出门来调控信息的流动, 从而能够有效地保持重要的长期信息。LSTM 算法从时间维度提取特征信息, 送入后续网络中进行处理、预测等操作^[55], 在 t 时刻。

$$f_t = \sigma(W_f[h_{t-1}, x_t] + b_f) \quad (3.9)$$

$$i_t = \sigma(W_i[h_{t-1}, x_t] + b_i) \quad (3.10)$$

$$\tilde{a}_t = \tanh(W_a[h_{t-1}, x_t] + b_a) \quad (3.11)$$

$$C_t = f_t C_{t-1} + i_t \tilde{a}_t \quad (3.12)$$

$$o_t = \sigma(W_o[h_{t-1}, x_t] + b_o) \quad (3.13)$$

$$h_t = o_t \tan(C_t) \quad (3.14)$$

其中, f_t , i_t , o_t 分别为遗忘门、输入门和输出门, C_t 为单元格的内部状态值, sigmoid 和 tanh 分别为 sigmoid 激活函数和双曲正切激活函数, W_f 、 W_i 、 W_a 、 W_o 分别为遗忘门、输入门、候选值向量、输出门的矩阵权重, b_f 、 b_i 、 b_a 、 b_o 为相应的偏差。

但是 LSTM 只能从前向传递信息, 无法利用未来上下文的信息, 为了克服这一局限性, 双向 LSTM (Bidirectional long- and short-term memory networks, BiLSTM) 应运而生。BiLSTM 由两个独立的 LSTM 网络构成: 一个按时间顺序处理输入序列, 另一个则反向处理, 这样可以同时捕捉过去和未来的信息, 从而增强模型的表达能力。BiLSTM 由前向 LSTM 和后向 LSTM 组合而成。对于输入序列, 每个时间步的数据都会分别通过两个 LSTM 网络, 一个从前向后处理, 一个从后向前处理。前向 LSTM 计算当前时间步的隐藏状态, 后向 LSTM 计算相同时间步但反向的信息流。最终, 两个方向的隐藏状态被拼接在一起, 形成完整的双向表示。

在 BiLSTM 中, 每个时间步 t 由两个 LSTM 计算^[56]:

$$\vec{h}_t = LSTM_{forward}(x_t, h_{t-1}^{forward}) \quad (3.15)$$

$$\vec{h}_t = \text{LSTM}_{\text{backward}}(x_t, h_{t+1}^{\text{backward}}) \# (3.16)$$

最终输出为:

$$h_t = [h_t^{\text{forward}}, h_t^{\text{backward}}] \# (3.17)$$

(2) Transformer

BiLSTM 只能捕获输入序列的上下文信息,无法自动关注输入序列中哪些时间步更加重要。而 Attention 的原理是允许模型在处理不同的任务时,动态地关注输入数据中该任务需要的部分而忽略其他部分。因此,与该机制的结合有利于提升模型的效果。

Self-Attention 机制是注意力机制的变体,减少了对外部信息的依赖,能更好的捕捉数据或特征之间的内部关系,并且能同时考虑序列中的所有元素^[57-58]。假设 LSTM 网络一个样本的隐层输出向量为:

$$H = (h_1, h_2, h_3, \dots, h_d)^T \# (3.18)$$

其中, $h_i \in R^n$, n 为特征的序列步数。

通过随机初始化注意力机制权重矩阵 w 和偏差向量 b ,进而与进行点乘运算,第 i 个输入特征 h_i 的不同顺序步骤的重要性可以表示为:

$$s_i = \phi(W^T h_i + b) \# (3.19)$$

其中, $\phi(\cdot)$ 是得分函数。

并对其使用 Softmax 进行归一化操作,得到权重系数矩阵:

$$a_t = \text{softmax}(s_i) = \frac{\exp(s_i)}{\sum_i \exp(s_i)} \# (3.20)$$

将 a_t 和 H_t 经过注意力机制得到最终输出向量 V_t , 如下式所示:

$$V_t = \sum a_t H_t \# (3.21)$$

Attention 计算的核心在于权重分配,通过计算当前隐藏状态与输入序列中各个时间步的相似度分数,再通过 softmax 归一化,得到每个时间步的注意力权重。最终,模型利用加权和的方式聚合信息,从而生成更具针对性的特征表示。

(3) CNN

卷积层的核心是卷积运算,其计算公式如下:

$$Y[i] = \sum_{j=0}^{k-1} X[i+j]W[j] + b \# (3.22)$$

其中: X 是输入数据、 W 是卷积核、 b 是偏置项、 k 是卷积核的大小、 $Y[i]$ 是卷积操作

后的输出、 i 是时间步索引。卷积运算后，经过 ReLU 激活函数：

$$f(x) = \max(0, x) \quad (3.23)$$

用于引入非线性，同时避免梯度消失问题。

池化层的作用是对特征进行降维，提取主要信息，同时减少计算量，防止过拟合。该模型使用的是最大池化（Max Pooling），计算方式如下：

$$Y[i] = \max(X[i:i+p]) \quad (3.24)$$

p 是池化窗口大小、 $X[i:i+p]$ 表示池化窗口内的值、 $Y[i]$ 是池化后的值。这样可以减少特征图的长度，同时保留关键特征^[59]。

（4）BGRU

门控循环单元（Gate Recurrent Unit, GRU）是一种循环神经网络的变体，主要由重置门和更新门组成。更新门决定要保留的信息，重置门丢弃不需要的信息，GRU 通过门控机制控制信息流，用来提取负荷数据的时间序列特征，既保证高精度也有效减少训练时间，计算过程如式（3.25）~式（3.28）所示^[60]。

$$z_t = \sigma(W_z x_t + U_z h_{t-1} + b_z) \quad (3.25)$$

$$r_t = \sigma(W_r x_t + U_r h_{t-1} + b_r) \quad (3.26)$$

$$\tilde{h}_t = \tanh(W_h x_t + U_h (r_t * h_{t-1}) + b_h) \quad (3.27)$$

$$h_t = z_t * h_{t-1} + (1 - z_t) * \tilde{h}_t \quad (3.28)$$

其中， z_t 和 r_t 是更新门和重置门， W_z 和 U_z 是权重矩阵， b_z 、 b_r 、 b_h 是偏置项， $\sigma(\cdot)$ 与 $\tanh(\cdot)$ 代表激活函数， x_t 为当前时刻的输入， h_t 为隐藏状态在当前时刻的输出， h_{t-1} 为在上一时刻的隐藏状态， $\tilde{h}_t$ 为上一时刻的候选隐藏状态。

在双向 GRU（BGRU）中，神经网络同时训练正向和反向两个 GRU 层，前向 GRU：

$$\vec{h}_t = GRU_{forward}(x_t, \vec{h}_{t-1}) \quad (3.29)$$

$$\overleftarrow{h}_t = GRU_{backward}(x_t, \overleftarrow{h}_{t-1}) \quad (3.30)$$

最终隐藏状态 h_t ：

$$h_t = \text{concat}(\vec{h}_t, \overleftarrow{h}_t) \quad (3.31)$$

其中， $\text{concat}(\cdot)$ 代表拼接操作，将前向和后向的隐藏状态拼接在一起作为最终表示，使得 BGRU 能够在短期依赖和长期依赖之间实现动态权衡。BGRU 能够从正向和反向

两个方向进行学习,使得当前状态的信息可以由输入、前一时刻的顺向状态和逆向状态共同决定。

3.4.2 单结构模型

BiLSTM 模型该模型由输入层、BiLSTM 层、Dropout 层、LSTM 层、Dense 层和输出层组成,结构如图 3.1 所示。模型的第一层是 BiLSTM 层,设置为包含 128 个单元,设置为返回序列,以便后续的 LSTM 层能够处理序列数据,在 BiLSTM 层之后,紧接着是 Dropout 层,用于随机丢弃 30% 的神经元,接下来是第二层 BiLSTM,拥有 64 个隐藏单元,同样返回所有时间步的输出,之后再次进行 Dropout,Dropout 率仍保持在 0.3。第三层为单向 LSTM,隐藏单元数同样为 64,但只返回最后一个时间步的输出。此层后也加入了一个 0.3 的 Dropout 层。随后,模型进入全连接层,此层具有 128 个隐藏单元,并使用 ReLU 激活函数,以增加模型的非线性特性。最终的输出层由 6 个单元组成,且使用 softmax 激活函数,适用于多分类问题的输出,从而实现精确的多类预测。




图 3.1 BiLSTM 模型结构图

3.4.3 双结构融合模型

BiLSTM+Transformer 模型主要由 BiLSTM 模块、Transformer 模块组成,结构如图 3.2 所示。第一层 BiLSTM 层,该层具有 128 个单元,返回所有时间步,第二层 BiLSTM 层,具有 64 个单元,继续对序列信息进行处理,增强提取的特征。还增加了两个 Transformer 编码器块,以进一步提升特征提取的能力。第一个 Transformer 编码器块使用多头注意力机制,允许模型为每个时间步骤计算多个不同的注意力模式。并且通过层归一化来保持数值稳定性,第二个 Transformer 编码器块则基于第一个块的输出,进行进一步的特征整合和处理,以加强模型对时间序列中复杂模式的捕捉能力。随后,数据进入了 BiLSTM 层,这一层具有 64 个单元,只返回序列的最后一个时间步的输出,随

后，模型进入全连接层，此层具有 128 个隐藏单元，并使用 ReLU 激活函数，以增加模型的非线性特性。最终输出层是全连接层，将模型的输出映射到多个类别。




图 3.2 BiLSTM+Transformer 模型结构图

CNN-BiLSTM 模型主要由 CNN 模块、BiLSTM 模块组成，结构如图 3.3 所示。首先是一个卷积层（Conv1D），使用了 64 个过滤器和大小为 3 的卷积核，同时采用 ReLU 作为激活函数，接着，模型通过一个大小为 2 的最大池化层进行下采样，第二个 Conv1D 继续提取特征，增加到了 128 个过滤器和大小为 3 的卷积核，激活函数使用 ReLU，随后，第二个最大池化层以大小为 2 进行下采样，最终通过展平层将其转化为一维数据，以便传递给后续。接下来，引入一个 BiLSTM 层，配置了 256 个隐藏单元，并设置返回序列为 True，以便输出每个时间步的隐藏状态。为了防止过拟合，添加了一个 0.5 的 Dropout 层。接着是第二个 BiLSTM，包含 128 个隐藏单元，并将返回序列的选项设置为 False，表示只返回最后一个时间步的输出。同样，为了进一步防止过拟合，添加了 0.5 的 Dropout 层。随后，模型进入全连接层，此层具有 256 个隐藏单元，并使用 ReLU 激活函数，以增加模型的非线性特性。输出层激活函数为 Softmax，以便对多类进行分类。




图 3.3 CNN-BiLSTM 模型结构图

BiLSTM-BGRU 模型主要由 BiLSTM 模块、Transformer 模块组成, 结构如图 3.4 所示。第一层为 BiLSTM 层, 隐藏单元数量设定为 128, 并开启返回序列的选项 True, 以输出所有时间步的隐藏状态。为防止过拟合, 添加了一个 0.4 的 Dropout 层, 随后, 模型继续通过 BiLSTM, 这一层的隐藏单元数量减至 64, 依然设置为返回所有时间步的输出, 并在其后附加了 0.4 的 Dropout 层, 接下来, 模型引入 BGRU 层, 设置隐藏单元数量为 64, 此层的返回序列选项设定为 False, 意味着只返回最后一个时间步的输出。为了进一步控制过拟合, 该层后同样包含了 0.4 的 Dropout 层, 接下来为全连接层, 该层拥有 128 个隐藏单元, 激活函数使用 ReLU, 以增强模型的非线性表达能力。最后, 模型以一个具有 6 个节点的全连接输出层结束, 每个节点对应一个分类, 采用 softmax 激活函数。




图 3.4 BiLSTM-BGRU 模型结构图

3.4.4 三结构融合模型

CNN-LSTM-Transformer 模型主要由 CNN 模块、BiLSTM 模块、Transformer 模块组成, 结构如图 3.5 所示。模型首先通过 Conv1D 使用 64 个大小为 3×1 的卷积核, 并采用 ReLU 激活函数, 通过 MaxPooling1D 进一步降维, 保留关键信息, 添加了一个 0.3 的 Dropout 层。接着, 模型引入了两层 BiLSTM 以更好地处理时间序列的双向依赖, 第一层 BiLSTM 包含 128 个单元, 第二层为 64 个单元, 保证每个时间步的特征都能被后续层利用, 添加了一个 0.3 的 Dropout 层。在此基础上, 模型通过 Transformer 编码器块捕捉全局依赖关系, Transformer 中的 Multi-Head Attention 机制采用 4 个头, 前馈神经网络则包含 128 个神经元, 添加了一个 0.3 的 Dropout 层。模型再经过一个 64 单元的 LSTM 层, 进一步提取时序特征, 随后, 模型进入全连接层, 此层具有 128 个隐藏单元,

并使用 ReLU 激活函数,以增加模型的非线性特性,最后输出 6 类的 Softmax 分类结果。




图 3.5 CNN-BiLSTM-Transformer 模型结构图

CNN-BiLSTM-BGRU 主要由 CNN 模块、BiLSTM 模块、BGRU 模块组成,结构如图 3.6 所示。在 CNN 部分,模型通过两个 Conv1D 进行特征提取。第一层卷积包含 64 个过滤器,卷积核大小为 3,激活函数为 ReLU。然后经过批归一化,接着通过最大池化层特征降维,随后,第二个 Conv1D 含 128 个过滤器,再经过批归一化和最大池化层处理。模型使用 Flatten 层将 CNN 提取的特征展平,为后续的 LSTM 和 BGRU 模块提供输入。在 LSTM 部分,模型首先通过 BiLSTM 提取时间序列的长期依赖关系。第一层 LSTM 具有 128 个单元,为了防止过拟合,后续使用了 0.2 的 Dropout。随后,第二层为 BiLSTM,但单元数减少到 64,用于进一步提取高阶时间依赖关系,并再次使用 0.2 的 Dropout 以提高模型泛化能力。在 BGRU 部分,数据经过一个 BGRU 层,该层具有 64 个单元,只输出最后一个时间步的信息,作为整个序列的最终表示。随后,使用 0.4 的 Dropout 继续防止过拟合。随后,模型进入全连接层,此层具有 128 个隐藏单元,并使用 ReLU 激活函数,进一步整合特征,然后通过 softmax 激活的输出层完成分类。




图 3.6 CNN-BiLSTM-BGRU 模型结构图

3.5 模型结果分析

模型训练过程中，使用 Focal Loss 作为损失函数，并采用 Adam 优化器，批量大小设为 128，最多训练轮数设定为 100 轮，以保证模型有充分的迭代空间学习特征分布。并使用早停（Early Stopping）回调函数防止过拟合，当模型在验证集上的性能在连续 10 轮训练中未出现提升时，自动停止训练，保留性能最优的模型参数。针对提取的 HRV 特征，结合研究将不同的分类算法以识别不同飞行阶段的负荷等级。

在模型评估方面，综合使用准确率（Accuracy）、精确率（Precision）、召回率（Recall）、F1 分数（F1 Score）作为评价指标，如表 3.4 所示。

表 3.4 模型性能评价指标

指标	描述	计算公式
准确率 (Accuracy)	衡量模型预测结果的整体正确性	$\text{Accuracy} = \frac{\text{TP} + \text{TN}}{\text{TP} + \text{TN} + \text{FP} + \text{FN}}$
精确率 (Precision)	衡量模型在预测为正类的样本中，有多少比例是真正的正类	$\text{Precision} = \frac{\text{TP}}{\text{TP} + \text{FP}}$
召回率 (Recall)	模型正确预测为正类样本占实际正类样本的比例	$\text{Recall} = \frac{\text{TP}}{\text{TP} + \text{FN}}$
F1 分数 (F1 Score)	精确率和召回率的加权调和平均值	$\text{F1} = \frac{2 * \text{Precision} * \text{Recall}}{\text{Precision} + \text{Recall}}$

考虑到数据的不均衡性以及负荷水平的差异，本研究在模型性能评估方面主要基于 F1 分数作为核心指标，其他分类指标仅作为参考，以更全面、准确地评估模型对不同负荷分类的性能。本研究中模型按照单结构、双结构融合和三结构融合对识别效果进行对比，不同模型之间有着明显差异如表 3.5 所示。以更直观的看出不同组合模式下的性能。

表 3.5 不同模型评价结果

模型	准确度	精确度	召回率	Cohen's Kappa	F1 分数
BiLSTM	81.74%	81.66%	81.73%	78.08%	81.45%
BiLSTM-Transformer	75.35%	75.83%	75.39%	70.42%	75.02%
CNN-BiLSTM	82.63%	82.94%	82.61%	79.15%	82.66%
BiLSTM-BGRU	90.83%	91.08%	90.80%	89.00%	90.84%
CNN-BiLSTM-Transformer	76.32%	76.59%	76.31%	71.57%	75.96%
CNN-BiLSTM-BGRU	95.59%	95.61%	95.59%	94.71%	95.60%

在单结构模型中，BiLSTM 分类模型的 F1 分数为 81.45%。准确度、精确度、召回率和 Cohen's Kappa 值分别为 81.74%、81.66%、81.73%、78.08%，分类性能一般，能捕捉序列数据的前后关系，但提取特征能力有限，在多数情况下难以取得最佳性能，因此可以作为基准模型，但通常需要结合其他结构以增强模型的分类性能。

为了增强模型的时序建模能力，本研究在 BiLSTM 的基础上尝试双结构融合模型，在 BiLSTM 模型的基础上增加 CNN、Transformer、BGRU 构架，以增强特征提取能力，优化分类效果。BiLSTM-BGRU 模型 F1 分数为 90.84%，准确度、精确度、召回率和 Cohen's Kappa 值为也分别为 90.83%、91.08%、90.80%、89.00%，双结构融合模型中表现最优。CNN-BiLSTM 模型的性能表现次之，F1 分数为 82.66%，准确度、精确度、召回率和 Cohen's Kappa 值为也分别为 82.63%、82.94%、82.61%、79.15%。BiLSTM-Transformer F1 分数为 75.02%，准确度、精确度、召回率和 Cohen's Kappa 值为也较低，分类效果明显弱于前述模型。

在双结构融合模型中，BiLSTM 与 BGRU 取得最优性能，这意味着双结构融合模型在不平衡数据上能充分发挥其对时间序列特征的挖掘能力，另外，利用 GRU 的门控机制，有效控制了冗余信息，提高了模型的分类准确度，具有更强的泛化性，使得信息的丢失更少。相较于 LSTM，BGRU 的结构更为简约，提高了计算效率，并在一定程度上缓解了梯度消失的问题，进而优化了整体性能。虽然 CNN 与 BiLSTM 的组合略有提升，显示了 CNN 在局部特征提取方面的贡献，但由于 CNN 主要侧重于捕捉局部模式，而 BiLSTM 则关注全局上下文信息，因此这两者的融合效应不及 BiLSTM 与 BGRU 的效果

明显。此外, BiLSTM 与 Transformer 的组合表现不佳, 甚至不如单独使用 BiLSTM, 这表明在此次任务中, Transformer 并未有效地增强 BiLSTM 的特征表示能力。

为了进一步提升, 探讨了三结构融合模型, 以实现更全面的特征提取。其中, CNN-BiLSTM-BGRU 模型的表现最为优异, 其 F1 分数高达 95.60%, 而准确度、精确度、召回率及 Cohen's Kappa 值分别为 95.59%、95.61%、95.59%和 94.71%。这些结果显示该模型在分类性能方面达到了最佳水准。相比之下, CNN-BiLSTM-Transformer 模型的性能明显不如前者, F1 分数仅为 75.96%, 其他指标同样偏低, 并没有取得较好的结果。

与其他模型相比, CNN-BiLSTM-BGRU 架构充分利用了 CNN 在局部特征提取方面的优势, 并结合了 LSTM 和 BGRU 的时序建模能力。这种组合使得模型能够捕获更丰富的特征信息, 并在较高的计算效率下实现卓越的分类性能。其中, CNN 负责迅速提取空间模式, LSTM 主要关注长期依赖关系, 而 BGRU 则有效降低了计算复杂性, 并进一步优化了时序建模, 从而使得模型在准确性和泛化能力上都达到了最佳状态。相对而言, CNN-BiLSTM-Transformer 模型的表现与 LSTM-Transformer 相似, 表明在当前任务背景下, Transformer 的引入并未显著提升性能, 这可能导致了模型复杂性的增加, 从而使训练变得更加困难, 降低了模型的有效性。因此, 总体来看, CNN-BiLSTM-BGRU 架构在所有模型中表现最为优越。

混淆矩阵可以直观地显示模型在各个类别上的分类情况, 能看出模型在哪些类别上表现较好, 哪些类别容易被误分类, 不同模型的混淆矩阵如图 3.7 所示。从实验结果可以看出, CNN-BiLSTM-BGRU 模型在各个类别上都表现出了较高的准确率, 只有极少数样本得到了误分类。可以看出该模型具有良好的泛化能力, 能够准确区分不同类别的数据。相比之下, BiLSTM 和 BiLSTM-Transformer 在大多数类别上的预测准确率都有提高, 但在类别 1 和类别 4 上的识别准确率有所下降, 这说明单一使用时序建模或者引入 Transformer 的方式可能无法捕捉到这些类别中某些特征较为相似的样本的区别。

从整体上看, CNN-BiLSTM-BGRU 能够提取更多的数据特征, 具有较强的分类能力, 在多类场景下具有更好的鲁棒性与稳定性。




图 3.7 不同模型混淆矩阵

不同神经网络结构的训练时间对比如表 3.6 所示。对于单一结构模型，BiLSTM 所需要的训练时间最少，由于其结构比较简单；而对于双结构融合模型，训练时间开销也增大，但 BiLSTM-BGRU 所需要的训练时间比较少，算力效率较高；而对于三结构融合模型，训练时间开销更大。其中，CNN-BiLSTM-BGRU 模型最为复杂，训练时间最长；CNN-BiLSTM-Transformer 模型需要的训练时间相对较短。总的来说，模型的复杂度越大，所需要的训练时间越长，但不同的结构融合也存在一定的差异。

表 3.6 不同模型运行时长

模型	运行时长
BiLSTM	1072.34 s
BiLSTM-BGRU	2831.82 s
BiLSTM-Transformer	4951.12 s
CNN-BiLSTM	5341.69 s
CNN-BiLSTM-BGRU	4330.44 s
CNN-BiLSTM-Transformer	2067.20 s

损失曲线可以帮助网络训练过程判断模型是否在训练中过于收敛，判断模型是否欠拟合或者过拟合，如图 3.8 所示。根据损失曲线的下降趋势可知，不同的模型训练过程的稳定性各不相同。CNN-BiLSTM-BGRU 具有较为稳定的损失曲线，当 epoch 不断增加时，损失值逐渐下降，直至停止下降，在一定的 epoch 之后，损失趋于稳定，表示网络在训练过程中能够有效的学习特征，没有产生严重的过拟合欠拟合现象。BiLSTM-Transformer 的损失曲线有较大的波动，BiLSTM 的损失下降趋势较为缓慢，表明 BiLSTM 在训练过程中学习特征过于缓慢，收敛较为缓慢。CNN-BiLSTM 的损失曲线下下降速度较快，在训练初期能够快速的学习特征，从而趋于收敛。对比之下，CNN-BiLSTM-Transformer 的损失曲线同样缺乏理想的下降趋势，验证损失曲线下下降趋势不如 CNN-BiLSTM-BGRU 稳定。

总体而言，不同模型的损失曲线特征反映了其训练动态和特征学习能力，CNN-BiLSTM-BGRU 由于其稳定的收敛趋势和较好的训练表现，在该任务中具备更优的学习效果。




图 3.8 不同模型的损失曲线

3.6 本章小结

本章探讨了 HRV 在飞行员认知负荷评估中的应用。通过对不同飞行阶段的飞行员

认知负荷进行主观评估和分析,研究发现,不同飞行阶段的认知负荷从高到低依次为:着陆、起飞、下降、爬升、转弯、巡航。此外,本章还详细介绍了数据的处理流程,构建了飞行员认知负荷识别的模型,并通过对比分析,对这些模型的识别效果进行了比较。其中,在飞行员认知负荷识别任务中,CNN-BiLSTM-BGRU 模型表现卓越,其 F1 分数高达 95.60%。此外,其他评估指标同样显示出较高水平,这些都为飞行员认知负荷的评估提供了可靠的数据支撑。

第 4 章 基于飞行数据的飞行员训练评价

4.1 飞行数据的获取

微软模拟飞行 2020 桌面式飞行训练器的飞行数据是可以通过数据提取插件 CAFUC Flight Sim Test 提取,作为飞行操控行为分析与飞行性能评估的研究基础。模拟飞行 2020 作为目前行业领先的飞行模拟软件,能够高度逼真地模拟真实飞行环境,包括空气动力学特性、气象条件以及飞机系统响应等。飞行数据的采集软件使用,该软件可用于配套的模拟飞行 2020 使用,在科目进行的过程中用 1Hz 的频率时采集飞行过程中的核心飞行参数的数据。数据记录涵盖飞行状态、操控输入等多维信息,主要包括飞行姿态(俯仰角、滚转角、偏航角)、空速、高度、航向角、发动机参数、气象条件、飞行轨迹及自动驾驶仪状态等。飞行参数具体含义如表 4.1 所示。数据采集从飞行开始时启动,并持续记录整个飞行过程中的关键参数,直至飞行结束后停止记录,并且可以在飞行结束后将飞行数据以 EXCEL 的表格格式输出,更利于后期的数据分析和处理实验过程中。

表 4.1 飞行参数描述

参数	单位	描述
time	s	时间戳
altitude	ft	修正海平面气压高度
course	°	航向角
pitch	°	俯仰角
roll_angle	°	滚转角
latitude	°	当前纬度坐标。
longitude	°	当前经度坐标。
flaps	/	襟翼位置
speed	knots	指示空速
sink_rate	ft/min	升降率
g_factor	G	加速度过载
engine_speed	RPM	发动机转速

表 4.1 飞行参数描述（续）

参数	单位	描述
onrunway	布尔值	是否处于跑道上
autopilot	开/关	自动驾驶仪状态
ZUGH	NM	与广汉台的距离
XTK	NM	横向偏航误差

4.2 飞行参数指标筛选

本实验共收集了 110 份模拟机的飞行数据，每份数据包含 15 个飞行参数，涵盖速度、航向、高度等关键飞行信息，其中很多数据的存在与否或是大小改变不会影响对飞行训练品质的评价。为确保研究的科学性、针对性及数据的有效性，首先对所有参数进行了系统性筛选。经分析，发现经纬度数据、襟翼状态、自驾状态、ZUGH 及 XTK 等多个参数在本研究框架下缺乏直接分析价值，无法为飞行性能评估及训练优化提供有效支持，故予以删除。

为了精确衡量学员在各个训练阶段的操作效能，本研究计划挑选能够直观呈现飞行状态及操作状况的指标，并排除那些影响较小的数据点。在本飞行科目中，我们将特别关注飞机的关键参数，如高度、航向、俯仰角以及速度等。

高度是表示飞行中垂直运动的重要参数，在起飞和爬升阶段，高度应不断升高；在平飞阶段，高度保持恒定；在下降和着陆阶段，高度应缓慢降落。航向是指飞行器在水平面上的运动方向。在转弯、进近和着陆阶段，航向的变化反映了飞行器的操纵状态。如果俯仰角异常，例如机头过度上仰可能导致失速，而下降过快可能导致着陆冲击过大。在起飞时，机头需要上仰以提供升力，而在下降过程中，俯仰角需要适当降低，以控制下降速率，因此俯仰角不可或缺。在飞行中，速度也是评价飞行品质的关键参数。在起飞阶段，速度必须要满足最低起飞速度要求，否则难以起飞；在下降和着陆阶段，速度过快和过慢，都会导致冲击着陆和不稳着陆。因此，速度是不可或缺的评估指标。

相比之下，升降率、g 因子和发动机转速等参数要么可以通过其他数据推导出来，要么对飞行品质评估贡献有限。升降率本质上是高度变化率，不需要单独记录。g 因子表示飞行器所承受的过载情况，虽然在剧烈机动时可能具有一定参考价值，但在正常飞

行中，它的变化不大，且不会直接影响飞行品质，因此并不是关键评估参数。发动机转速虽然影响推力和燃油效率，但它并不能直接决定飞行品质，飞行器的操控质量更多取决于飞行姿态速度，而发动机转速只是其中的影响因素之一，因此不作为独立评估指标。此外，是否在跑道上这一参数仅用于标识飞机是否处于起飞或着陆阶段，而这一信息可以通过高度和速度的数据推测得出，因此无需额外保留。实验所选用的为安装 Garmin1000 航电设备的塞斯纳 C-172 型飞机，全程 autopilot 模式不接通，因此这一参数也被剔除。

综合上述因素，最终筛选出 altitude、course、pitch、speed 四个核心飞行参数，作为本研究的核心分析对象。后续研究将围绕这些核心指标展开，重点探讨它们在不同飞行阶段中的变化规律。

4.3 飞行阶段划分

飞行阶段划分是一种依靠飞行科目中不同阶段的相关参数阈值识别飞机飞行状态。基于高度变化、速度调整、航向转变、爬升率、下降率等关键参数，将整个飞行过程精确划分为 24 个阶段，包括起飞、一边爬升、一转弯、二边、二转弯、爬升、平飞、小速度平飞、平飞、三转弯、下降、平飞、四转弯、平飞、五转弯、下降、平飞、六转弯、七转弯、平飞、八转弯、下降、九转弯、着陆阶段，每个阶段的开始与结束条件明确，为飞行监测和管理提供精准的数据支持。通过对每个飞行阶段的开始和结束位置进行特征识别，标记开始时间及结束时间，对完整的飞行阶段进行分段处理。结合各飞行阶段高度、速度、航向等特定飞行数据参数确定飞行过程的每个阶段，所有阶段划分中主要飞行参数具体如表 4.2 所示。

表 4.2 飞行计划相关飞行参数

序号	阶段	开始高度/ (ft)	结束高度/ (ft)	开始航向/ (°)	结束航向/ (°)	开始速度 (kts)	结束速度 (kts)
1	起飞	1530	1565	127	127	0	75
2	一边爬升	1565	1800	127	127	75	75
3	一转弯	1800	2000	127	127	75	75

表 4.2 飞行计划相关飞行参数 (续)

序号	阶段	开始高度/ (ft)	结束高度/ (ft)	开始航向/ (°)	结束航向/ (°)	开始速度 (kts)	结束速度 (kts)
4	二边	2000	3000	40	40	75	75
5	二转弯	3000	3000	40	330	75	75
6	爬升	3000	4000	330	330	75	75
7	平飞	4000	4000	330	330	75	65
8	小速度平飞	4000	4000	330	330	65	90
9	平飞	4000	4000	330	330	90	90
10	三转弯	4000	3000	330	150	90	90
11	下降	3000	3000	150	150	90	90
12	平飞	3000	3000	150	150	90	90
13	四转弯	3000	3000	150	180	90	90
14	平飞	3000	2500	180	180	90	90
15	五转弯	2500	2500	180	127	90	90
16	下降	2500	2500	127	127	90	90
17	平飞	2500	2500	127	127	90	90
18	六转弯	2500	2500	127	37	90	90
19	七转弯	2500	2500	37	307	90	90
20	平飞	2500	2500	307	307	90	90
21	八转弯	2500	2400	307	217	90	75
22	下降	2400	2200	217	217	75	65
23	九转弯	2200	2000	217	127	65	65
24	着陆	2000	1530	127	127	65	0

4.4 飞行数据预处理

在飞行学员的培训过程中,数据预处理是至关重要的一步,关系到模型后续准确度与可靠性的关键步骤。在本研究中,使用模拟机系统上的飞行参数作为研究对象,通过

数据预处理以确保数据的准确性和可靠性。数据预处理主要包括数据清洗、数据平滑处理和时间归一化处理等核心步骤。

4.4.1 数据清洗

在本研究的初始阶段，细致地进行了数据的预处理工作，是对数据集中的空缺值和非数值的检测和处理^[61]。常见的数据填充方法包括删除缺失值、均值填充、前向/后向填充、插值方法、回归填补、K 近邻填补等。

在飞行数据处理中，高度、航向、俯仰角和速度是关键飞行指标。当这些参数存在缺失值时，填补方法采用前向填充和后向填充。前向填充通过使用前一个有效数据点来填补当前缺失值，适用于变化平稳、波动较小的飞行参数，如飞行高度和速度。后向填充则是利用后一个有效数据点来填补缺失值，适用于需要保持时间序列完整性的场景，如航向或俯仰角数据的缺失。通过这两种方法，能够确保飞行数据的连续性和完整性，减少因数据缺失而引发的分析误差，进而提升后续分析及模型训练的准确度。

4.4.2 平滑处理

在飞行数据预处理中，平滑处理能够有效减少噪声、降低异常值对分析结果的影响，并保留数据的整体趋势。经典的平滑滤波算法包括移动平均、局部加权光滑描点技术算法、局部加权回归散点平滑算法和 Savitzky-Golay 算法。Savitzky-Golay 算法被广泛地运用于数据流平滑除噪，与传统算法相比，Savitzky-Golay 算法具有更稳定、误差更小的平滑去噪效果^[62]。因此，在飞行数据预处理中，本研究使用的是 Savitzky-Golay 滤波作为平滑处理的方法，减少异常数据对分析结果的影响，使后续的数据建模和分析更加准确可靠。该方法基于局部多项式拟合，能够在减少高频噪声的同时，较好地保持数据的趋势、峰值和曲率信息。Savitzky-Golay 滤波的核心思想是在滑动窗口内使用最小二乘法拟合低阶多项式，并利用拟合结果计算平滑后的数据点。其数学表达式如下：

$$y'_i = \sum_{j=-m}^m c_j y_{i+j} \quad (4.1)$$

其中： y'_i 是平滑后的数据， y_{i+j} 是原始数据， c_j 是滤波器的系数， m 是窗口大小的一半。

4.4.3 时间归一化处理

在处理不同数据集时，原始时间长度的差异可能会导致分析和比较时出现困难。为

了有效解决不同飞行员在同一阶段下时长不一致、以及不同阶段时长差异的问题,本研究采用了统一时间轴和插值的方法。创建一个标准的时间轴,该轴将所有数据统一映射到0到100的范围内。通过标准化时间轴,能够消除这种困扰,使每个飞行数据序列可以在相同的时间框架内被分析,从而解放限制于不同数据长度的问题。

其次,采用插值方法对不同长度的飞行数据进行重新采样,使得不同数据能够在统一的标准时间轴上进行对比和分析。具体而言,对于每个包含有效数据的列,首先构建其原始时间轴,然后使用函数进行线性插值处理。

4.5 参考曲线的获取

量化飞行学员训练品质,需要比较每位飞行学员的飞参数据曲线与参考航迹曲线之间的差别,由于飞行科目训练是一个动态的过程,没有标准的数据曲线用于量化学生成绩。所以为了得到参考曲线,对采集到的飞行数据进行处理和拟合,得到所需的参考航迹,后续通过飞行学员的训练数据与参考数据进行对比,用于训练评估。为了建立科学的飞行品质评估体系,本研究采用K-Means聚类分析以对飞行员进行分组。

RMSE 用于计算某个飞行员的数据与所有飞行员平均数据之间的偏差,数值越大,说明该飞行员的轨迹与其他飞行员差异越大。

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \bar{y}_i)^2} \quad (4.2)$$

其中: y_i 是第 i 个数据点, $\bar{y}_i$ 是所有飞行员在该时间点的平均值, n 是数据点的数量。

K-Means 是一种无监督学习算法,将数据点分为不同的类别。在异常值检测中,使用 RMSE 值作为聚类特征, RMSE 值特别高会将其归入异常类别。K-Means 目标是最小化类内平方误差 (SSE), K-Means 通过不断迭代更新中心点 μ_j 并重新分配数据点,最终达到收敛。

$$SSE = \sum_{j=1}^k \sum_{i \in C_j} \|x_i - \mu_j\|^2 \quad (4.3)$$

其中, k 是簇的个数, C_j 是第 j 个簇, x_i 是属于该簇的数据点, μ_j 是该簇的中心点。

K-Means 聚类分析通过对数据点进行分类,将正常数据与异常数据区分开来。当某些数据点远离主要数据簇时,可以将其判定为异常值。RMSE 则用于衡量数据与期望值之间的偏差。如果某个数据点的 RMSE 远超设定阈值,则说明其不属于优秀飞行员。

聚类的类别数设定为 2，即将飞行员分为“优秀”和“普通”两类，设定为类别 0 与类别 1。为了保证聚类结果的稳定性，设定随机种子为 42，并将初始化次数设置为 10，以提高结果的可靠性。在聚类分析后，可以通过选择 RMSE 最小的群体来筛选出“优秀飞行员”。

基于提取的数据的均值，生成参考曲线。通过计算每个飞行员在飞行过程中各个参数的平均值，使用 Matplotlib 绘制出每个参数随时间变化的曲线，得到参考曲线。飞行过程可以分为起飞、爬升、平飞、转弯、下降、着陆六个阶段，每个阶段的操作品质直接影响整体飞行的安全性和效率。因此，在训练品质评估中，需要重点关注飞行员在各阶段的操作表现，并与参考曲线进行对比分析。以下对各阶段的关键参数拟合曲线进行详细分析。起飞阶段是整个飞行任务的开始，飞行员需要精准控制俯仰角、速度和航向，确保飞机顺利离地并进入爬升状态。起飞时，飞行员通常会快速拉起机头，使俯仰角迅速上升，随后，俯仰角趋于稳定，以保持平稳爬升，速度逐渐加速，达到安全起飞速度后离地，并持续加速至爬升速度，航向角应保持稳定，避免侧风影响导致的偏航，参考曲线如图 4.1 所示。






图 4.1 起飞阶段飞行参数拟合曲线

爬升阶段是飞机从地面爬升至巡航高度的过程，参考曲线如图 4.2 所示。核心目标


是尽快达到巡航高度，飞行员需要保持俯仰角、航向和飞行速度，对准预定航路，确保飞行按照标准航线进行。



(a)俯仰角拟合曲线




(b)速度拟合曲线




(c)航向拟合曲线

图 4.2 爬升阶段飞行参数拟合曲线


平飞阶段是飞行最稳定的阶段，参考曲线如图 4.3 所示，飞机保持恒定的高度、速度和航向，主要任务是维持飞行稳定性，减少不必要的操作干预。



(a)高度拟合曲线




(b)速度拟合曲线




(c)航向拟合曲线

图 4.3 平飞阶段飞行参数拟合曲线


转弯阶段分为爬升转弯、下降转弯、平飞转弯，以爬升转弯为例，参考曲线如图 4.4 所示。飞行员需同时管理高度、航向和速度，应平稳过渡，避免航向变更过快或过慢影响飞行轨迹。



(a)高度拟合曲线



(b)速度拟合曲线



(c)航向拟合曲线

图 4.4 转弯阶段飞行参数拟合曲线

下降阶段是落地准备的重要过程，涉及航向、速度和飞行姿态的协同调整，参考曲线如图 4.5 所示。




图 4.5 下降阶段飞行参数拟合曲线

着陆阶段是整个飞行任务最复杂、风险最大的部分，要求飞行员高度集中，参考曲线如图 4.6 所示。




图 4.6 着陆阶段飞行参数拟合曲线

4.6 指标比重的确定

在航线飞行品质评估过程中,每个飞行阶段及其相关的飞行参数对整体评估的影响不同,因此合理确定权重对于准确评估飞行训练质量至关重要。不同阶段的操作复杂性、安全性要求、环境因素等都会导致其重要性不同。此外,即使在同一阶段,不同飞行参数的影响程度也各不相同。因此,科学合理地确定权重系数,是确保飞行品质评估结果准确性和客观性的关键。

目前,确定权重的方法主要分为主观赋权法、客观赋权法和主客观组合赋权法^[63]。主观赋权法:依赖于专家经验和判断,如德尔菲法、层次分析法、序关系分析法等。客观赋权法:熵权法、主成分分析法、独立性权重法等;主客观组合赋权法:结合主观和客观赋权方法的优点,提高权重确定的准确性和科学性^[64]。其中,序关系分析法(G1),是一种基于层次分析法的主观赋权法^[65],适用于飞行品质评估的主观赋权方法,能够有效反映专家对飞行阶段及飞行参数重要性的判断,并且计算过程直观、易操作。

首先,确定序关系,如果有 M 个评价指标 $y_1, y_2, y_3, \dots, y_n$, 若 N 个专家对其进行排序,按重要性先后原则,最重要的指标为 x_1 , 第二重要指标的记为 x_2 , 最后可得出这样一个序关系^[66]: $x_1 > x_2 > x_3 > \dots > x_n$

其次,专家对 x_{i-1} 和 x_i 的相对重要程度 R_{ki} 的判断为下列公式:

$$R_K = \frac{X_{K-1}}{X_K}, \quad k = n, n-1, \dots, 2 \quad (4.4)$$

其中, n 为评价指标总数, R_K 为专家确定的 X_{K-1} 对 X_K 的相对重要程度。

随后,计算指标权重。计算各个指标权重的公式为:

$$W_k = \left(1 + \sum_{k=2}^n \prod_{i=k}^n R_i \right)^{-1} \quad (4.5)$$

$$W_K = R_K W_K, \quad k = n, n-1, \dots, 2 \quad (4.6)$$

其中, W_K 为指标主权重。

最后,经过归一化处理,通过以上步骤计算得到一级指标、二级指标的权重。

$$W_i = \frac{w_i}{\sum w_j} \quad (4.7)$$

4.6.1 一级指标权重确定

一级指标为起飞、爬升、转弯、平飞、下降、着陆。根据专家打分结果,可以得出

各指标的重要性序关系：着陆>起飞>下降>爬升>平飞。利用序关系分析法中公式(4.4)计算相对重要性比值如表4.4所示，利用公式(4.5)计算得到一级指标权重系数，如表4.4所示。

表 4.3 一级指标相对重要性比值

飞行阶段	平均评分	相对重要性比值 R_i
起飞	5	1
爬升	3.67	0.73
平飞	3	0.6
下降	3.67	0.73
着陆	5	1
转弯	2.67	0.53

表 4.4 一级指标权重系数

飞行阶段	权重 (%)
起飞	0.2213
爬升	0.1555
平飞	0.126
下降	0.1555
着陆	0.2213
转弯	0.1204

4.6.2 二级指标权重确定

二级指标为高度、速度、航向、俯仰角、横滚角。根据专家打分结果，可以得出各指标的重要性序关系：

起飞阶段：俯仰角>航向>速度

爬升阶段：速度>航向>俯仰角

平飞阶段：速度>航向>速度

下降阶段：高度>航向>速度

着陆阶段：速度>航向>俯仰角

转弯阶段：高度>航向>俯仰角

利用公示（4.5）计算得到一级指标权重系数，如表 4.5 所示。

表 4.5 二级指标权重

飞行阶段	速度	航向	高度	俯仰角
起飞阶段	0.286	0.333	0	0.381
爬升阶段	0.429	0.333	0	0.238
平飞阶段	0.269	0.346	0.385	0
下降阶段	0.391	0.348	0.391	0
着陆阶段	0.375	0.333	0	0.292
转弯阶段	0	0.348	0.261	0.391

4.7 飞行训练品质评估

飞行技术的评价贯穿整个飞行过程，客观公正地评价对飞行员技术提高，对民航飞行安全意义重大。目前对飞行技术评价主观随意性强，评价方式不全面，难以适应新时代下飞行员技能全生命周期培养的需要。因此建立一个标准化的飞行技术评价体系以提高对飞行技术的准确评估至关重要。

飞行品质评分从轨迹匹配度、轨迹误差和飞行稳定性三个方面进行衡量，主要反映的是整个飞行的质量水平。一个好的飞行不仅是参考轨迹的匹配度，而且偏差稳定系数要小。因此，本评分标准综合考虑这三个维度，建立模型，进行计算得到飞行品质得分，为飞行员训练品质提供客观的评估。

4.7.1 轨迹匹配度

轨迹匹配度是飞行品质评分体系中核心的指标，用于衡量飞行数据与标准参考曲线之间的相似程度。采用皮尔逊相关系数进行计算。皮尔逊相关系数 r 用于测量两个变量之间的线性关系，其取值范围为 $[-1, 1]$ ，当 $r=1$ 时，说明飞行数据与标准曲线完全一致；当 $r=0$ 时，说明飞行数据与标准曲线无相关性；当 $r=-1$ 时，说明飞行数据与标准曲线

呈完全负相关,即飞行方向与参考曲线完全相反。标准参考曲线是基于飞行任务标准通过优秀飞行员的数据拟合出来的曲线,而实际飞行数据则来自所有飞行员的实际飞行数据。两者的匹配程度直接反映了飞行员操作的精准度。皮尔逊相关系数定义为:

$$r = \frac{\sum(X_i - \bar{X})(Y_i - \bar{Y})}{\sqrt{\sum(X_i - \bar{X})^2 \sum(Y_i - \bar{Y})^2}} \quad \#(4.8)$$

其中, X_i : 实际飞行数据点, Y : 标准参考曲线数据点, $\bar{X}$: 实际飞行数据的均值, $\bar{Y}$: 参考曲线数据的均值, r : 皮尔逊相关系数。

归一化处理

为了适应评分需求并突出匹配度的重要性,需要将 r 转换为一个非负值,并放大权重。最终的 S 值范围为 $[0,1]$,数值越大,说明轨迹匹配度越好,评分体系中,轨迹匹配度的权重占比 50%。

4.7.2 轨迹误差

飞行数据中,轨迹误差是指飞行员实际的飞行轨迹偏离标准参考轨迹的程度,误差越大,说明飞行员的操纵与标准曲线的偏差越大,对飞机稳定和安全都会造成影响,因此需要通过合适的误差计算方法对这种偏离程度进行量化。轨迹误差表示飞行数据偏离标准曲线的程度,使用均值绝对误差(MAE)计算,计算公式如下:

$$MAE = \frac{1}{n} \sum_i^n |X_i - Y_i| \quad \#(4.9)$$

通过 MAE 计算飞行数据的偏离程度,进行归一化处理,范围调整至 $[0,1]$ 。

$$E = \left(1 - \frac{1}{1 + MAE}\right) \quad \#(4.10)$$

结合评分机制,轨迹误差的权重占比 30%,可以为飞行质量进行量化评估。这不仅有助于筛选优秀飞行员,也能为飞行训练提供可靠的参考依据,从而提升整体飞行安全性和稳定性。

4.7.3 飞行稳定性

飞行稳定性是衡量飞行器在飞行过程中受气流、控制系统调整及其他外部因素影响时,保持飞行稳定状态的一个重要指标。为了量化飞行稳定性,需要分析飞行数据的高频抖动情况。高频噪声反映了飞行过程中数据的剧烈波动,通常由飞行器状态的不稳定、操作不平稳或者传感器数据的波动引起。过多的高频噪声可能表明飞行质量较差,飞行员的操作可能存在过度调整。因此,高频噪声可以作为评估飞行稳定性的评价指标。

对于飞行数据来说,其频率成分中的低频部分代表飞行器平稳的飞行状态,而高频部分则反映了飞行器在飞行过程中急速变化的状态,通过对高频成分的提取和分析,可以判断飞行数据中是否出现过多的剧烈变化。为了对高频噪声进行量化,常把飞行数据从时域变换到频域进行分析,利用傅里叶变换(FFT)对高频噪声进行计算。傅里叶变换利用一系列三角基函数将时域数据分解为不同幅值和相位的正余弦函数,得到能量随频率的变化规律。为了处理离散数据,对傅里叶变换进行改进后研究出了离散傅里叶变换(DFT)。DFT 处理的是离散且有限的数字,这适用于采集到的飞行数据的规律,通过 DFT,我们可以将复杂的时域信号分解为一系列简单的正弦波,从而更容易地分析和理解信号的特性。离散傅里叶变换的公式为:

$$X(k) = \sum_{n=0}^{N-1} x(n)e^{-j\frac{2\pi n}{N}k}, k = 0, 1, \dots, N-1 \quad (4.11)$$

其中, $X(k)$ 是第 k 频率分量, $e^{-j\frac{2\pi n}{N}k}$ 为基函数, N 是样本总数。

将飞行数据分离出频率分量,每一个分量有对应的振幅和相位。通常,为了关注高频部分的影响,将变换后的数据截取,去除低频,仅保留较高频率,以更好地考察飞行数据的剧烈程度,并量化这种剧烈程度对飞行品质的影响。

由于 FFT 变换后的结果是对称的,频谱的前半部分对应低频信号,后半部分对应高频信号。因此,可以通过截取频谱的后半部分来提取高频分量:

$$Y_{high} = \sum_{k=\frac{N}{2}}^{N-1} |X_k| \quad (4.12)$$

其中: Y_{high} 代表高频分量的能量, X_k 是 FFT 变换后的频谱分量, $N/2$ 到 $N-1$ 代表高频部分的索引范围。具体来说,计算高频部分的振幅总和,以衡量数据的高频噪声强度。在整个信号中提取那些快速变化的成分,并通过计算它们的总能量来反映飞行数据的抖动程度。

为了使得不同数据集的高频噪声值具有可比性,对结果进行归一化处理。

$$Y_{norm} = \frac{Y_{high}}{\sum_{k=0}^{N-1} |X_k|} \quad (4.13)$$

即将高频能量占总能量的比例作为标准化指标,评分体系中飞行稳定性的权重占比 20%。

4.7.4 飞行训练品质评估模型建立

在飞行器的性能评估中，综合得分是一个至关重要的衡量指标，它用于全面评估飞行器在执行任务时的整体表现。为了更准确地反映飞行器的多维度能力，该评分体系基于飞行数据的定量分析，并结合多个核心评分指标，以加权平均的方式计算最终得分。

在飞行器的综合性能评估体系中，轨迹匹配度评分（S）、轨迹误差评分（E）、飞行稳定性评分（N）是最重要的三个维度。通过合理的权重分配，使得综合得分能够更符合不同任务环境下的需求。综合得分通常由 S、E、N 这三项评分加权计算而成，以全面评估飞行器的性能。综合得分计算公式如下：

$$F = w_1 \times S + w_2 \times (1 - E) + w_3 \times N \quad (4.14)$$

其中， w_1 、 w_2 、 w_3 分别表示轨迹匹配度、轨迹误差和飞行稳定性的权重。

在飞行器性能评估中，综合得分是一个关键指标，它综合考虑了飞行器在多个飞行阶段的表现，如起飞、爬升、转弯、平飞、下降和着陆。该评分体系能够全面反映飞行器在各阶段的飞行品质，为飞行性能的客观评估提供科学依据。飞行员的得分如表 4.6 所示，因篇幅所限，仅选取部分数据进行展示。各个飞行阶段的满分分别为：起飞 0.2213、爬升 0.1555、转弯 0.1204、平飞 0.126、下降 0.1555、着陆 0.2213，总分满分为 1。这一评分体系能够用于飞行员训练与考核，全面反映飞行器在不同阶段的性能表现。

表 4.6 飞行训练品质评分表（10 个）

飞行员序号	起飞	爬升	转弯	平飞	下降	着陆	总分
1	0.114	0.0681	0.0833	0.0876	0.0918	0.1459	0.5907
2	0.1762	0.1047	0.0918	0.1069	0.1118	0.1892	0.7806
3	0.1104	0.0668	0.0726	0.0976	0.1081	0.1687	0.6241
4	0.111	0.0628	0.0804	0.0892	0.0968	0.1501	0.5903
5	0.1883	0.107	0.0884	0.1037	0.1095	0.14	0.7368
6	0.1076	0.0594	0.0879	0.0803	0.1001	0.1673	0.6026
7	0.1197	0.0673	0.0798	0.0832	0.1028	0.1142	0.567
8	0.1864	0.1055	0.0886	0.1027	0.1061	0.1715	0.7609
9	0.1111	0.0698	0.0817	0.0838	0.1067	0.1375	0.5906
10	0.1109	0.0811	0.0807	0.0776	0.1055	0.1829	0.6388

4.8 飞行训练品质评估模型的验证

4.8.1 现有飞行品质评分系统

目前, 模型训练课程中飞行数据的采集和评分软件使用 CAFUC FlightSim Test, 其评分细则通过明确的误差范围来对飞行员的操作进行量化评分。通过飞行计划中设定明确的标准, 得到误差参数, 对飞行员的操作表现进行量化评分, 该评分标准涵盖多个核心飞行参数, 包括坡度、高度、速度和航向, 以确保飞行员在训练过程中掌握核心飞行技巧。其中, 坡度误差控制在 $\pm 5^\circ$ 以内可获得满分 2 分, 高度误差不超过 $\pm 50\text{ft}$ 可获得满分 3 分, 速度误差维持在 $\pm 5\text{kt}$ 以内可获得满分 5 分, 而航向误差若控制在 $\pm 5^\circ$ 内, 则可获得满分 5 分, 本次研究的飞行科目中关注的评分细则如表 4.7 所示。

表 4.7 软件评分要点

序号	评分要点	分值	序号	评分要点	分值
1	第一边航向监测	5	13	距离广汉机场 5 海里时高度	5
2	第一边爬升速度维持	5	14	起落航线第二边高度	5
3	一转弯坡度监测	5	15	起落航线第三边 XTK 维持	3
4	一转弯爬升速度监测	3	16	起落航线第三边高度维持	5
5	切入径向线时高度	5	17	起落航线第三边速度维持	3
6	沿径向线爬升速度维持	5	18	起落航线三转弯坡度	5
7	沿径向线航向监测	5	19	起落航线第四边初始高度	3
8	沿径向线高度维持	5	20	第四边速度维持	3
9	小速度飞行维持	5	21	起落航线四转弯坡度	3
10	归航时坡度监测	3	22	起落航线第五边初始高度	3
11	大坡度盘旋时高度维持	5	23	进近速度	5
12	归航时速度监测	3	24	入口速度	3

4.8.2 回归模型构建与评价

飞行训练评估的核心在于建立飞行参数偏差与操作质量之间的量化映射关系。飞行质量的优劣本质上体现为实际飞行轨迹与标准飞行轨迹之间的偏离程度, 这些偏离可通

过核心飞行参数的偏差进行表征。本研究通过构建偏差参数与专家评分的回归模型，系统评估评分体系对飞行训练评估的表征效度。模型预测误差越小，表明评分方法对实际飞行偏差的预测越准确，从而验证其作为评估指标的有效性。

根据飞行计划中各阶段的标准，对飞行任务划分为 24 个飞行阶段，并针对速度、高度、航向和俯仰角等核心飞行参数，计算飞行误差。误差计算采用均方误差（MSE），并进一步提取误差的最大值、最小值和平均值等统计特征，构建成数据集，其中飞行误差特征作为自变量（ X ），同时引入两类评估指标作为因变量（ Y ）： Y_1 代表现有评估方法的得分， Y_2 代表基于新模型计算的质量评分。随后，通过回归分析方法，探究现有评估方法（ Y_1 ）和新模型（ Y_2 ）计算的飞行质量评分进行对比，探究新模型的优劣势。

数据预处理阶段，为了确定权重最大的特征，使用线性回归模型结合 SHAP 算法，计算出特征重要性，选出特征集合中影响最大的 30 个特征，采用四分位距离（IQR）方法对异常值进行处理，剔除特征值高于或低于正常值的样本，对目标变量取对数处理，降低偏态分布对模型的影响。数据集分为训练集合和测试集合，其中测试集合占 20%。分别划分 Y_1 、 Y_2 集合。在特征工程阶段，程序先通过主成分分析降维，保留 95% 的解释方差，以减少特征冗余。随后应用多项式扩展，生成二阶交互特征，增强模型表达能力，并通过标准化处理，确保模型训练的稳定性。在模型训练阶段，程序分别定义了两个线性回归模型，用于预测 Y_1 与 Y_2 。通过 5 折交叉验证，评估 Y_1 、 Y_2 的 MSE 与 RMSE。结果如表 4.8 所示，相比于 Y_1 ， Y_2 的 MSE 和 RMSE 均显著降低， Y_2 在误差指标上具有更优表现。

表 4.8 误差结果

	MSE	RMSE
Y_1	0.0049	0.0696
Y_2	0.001	0.0315

为了检验两个模型在误差表现上的显著性差异，使用成对 t 检验对 MSE 分布进行了统计分析，结果如表 4.9 所示。 Y_2 相较于 Y_1 的误差降低在统计上具有显著性（ $p < 0.05$ ），表明新模型在飞行评估任务中具有更优的预测能力。此外，为了验证线性回归模型的假设是否成立，我们对 Y_1 和 Y_2 的残差进行 Shapiro-Wilk 正态性检验，结果如表 4.10 所示。

由于 p -value 远大于 0.05, 可以认为 Y_1 和 Y_2 的残差均符合正态分布假设。这表明线性回归模型的统计推断是可靠的, 综合来看, 新模型在飞行质量评估任务中表现更优, 能够更准确地反映飞行误差特征, 具有更高的应用价值。

表 4.9 显著性结果

统计指标	值
t 统计量	3.2667
p 值	0.0309

表 4.10 正态性检验结果

	W 统计量	p-value
Y_1	0.9819	0.9683
Y_2	0.9598	0.8168

4.9 本章小结

本章对飞行数据进行了预处理, 包括数据清洗、平滑、时间归一化等步骤, 提升数据质量。然后对参考曲线的获取方式进行讨论, 确定一级指标和二级指标的权重, 对反映飞行训练品质的主要评价指标进行了分析, 建立了飞行训练品质评估模型, 包括轨迹匹配度、轨迹误差和飞行稳定性, 建立参考曲线训练评估模型, 并进行检验, 为飞行员训练质量的客观评价提供一定的理论基础, 为提高飞行训练效果提供参考。

第5章 融合生理数据与飞行数据的飞行训练品质评估

5.1 数据集建立

在本研究中,前述章节已基于心率数据和飞行数据分别探讨了认知负荷与飞行训练品质两个方面内容。然而,单独分析二者无法全面反映其在飞行训练过程中的相关性及对训练效果的影响。因此,本研究进一步引入数据融合方法,深入揭示飞行过程中的HRV与飞行参数对飞行训练品质的综合影响。

数据融合方法包括数据级融合、特征级融合、决策级融合^[67]。数据级融合是在数据采集阶段直接对原始数据进行融合。这种方法适用于具有相同时间戳或空间对齐的数据;特征级融合是指在数据预处理和特征提取阶段,将不同模态的数据转换为特征向量,并进行融合。相较于数据级融合,特征级融合更具鲁棒性,能够减少噪声对分析的影响;决策级融合是指对不同数据来源分别训练独立的模型,在决策阶段再融合它们的结果。这种方法适用于不同模态数据格式不兼容的情况^[68]。

本研究采用特征级融合方法构建数据集。数据来源方面,生理数据是基于PPI数据提取各飞行阶段的HRV,描述飞行员在不同负荷下的生理反应。飞行数据依托模拟飞行器中软件采集速度、高度、航向角等飞行参数。具体操作上,从飞行数据中提取关键参数,如速度、高度、航向角等,并在不同阶段下对飞行参数进行统计分析,计算其平均值、最大值、最小值等指标,从而刻画各阶段的飞行表现特征。与此同时,各阶段的HRV特征进行均值处理,并确保与飞行数据在时间轴上的对齐,以实现数据的融合。最终,将飞行员序号、飞行阶段、新模型的飞行得分、HRV特征和飞行参数等信息按照时间序列整合,构建新的数据集。数据集实现了生理信号与飞行数据的融合。在数据融合环节,通过时间戳校准,确保HRV数据与飞行参数在时间维度上进行对齐,并对数据进行归一化,提升了数据集的规范性。

5.2 数据处理

飞行训练品质得分为本章的目标变量,是在0-1范围内分数值,但由于此次实验的飞行员得分过于集中,回归预测不太理想,现对分数划分等级,根据不同的分数范围划分为不同的等级,将飞行得分转化为离散的类别,为后续的分类预测提供一个清晰的标签。飞行得分的划分规则为高分(≥ 0.8)、中分($0.6 \sim 0.8$)、低分(< 0.6)。通过这样的划

分,可以这些标签将帮助模型学习从飞行得分到表现类别的映射,从而使其进行准确的分类预测。

模型构建过程中,特征筛选是决定模型性能的关键步骤。数据集中特征中可能包含一些冗余、有噪声、与目标变量相关性不强的特征,如果不对其进行筛选,可能导致模型训练时间过长、泛化能力差、甚至出现过拟合等问题。因此,通过低方差筛选、相关性筛选、基于 F 值进行特征选择,能有效提升模型的性能。

低方差特征移除。这一步的目的是删除方差低于 0.01 的特征,因为方差过低意味着该特征几乎为恒定变量,对分类问题没有太大贡献。只有具有足够变化的特征才能保留下来,通过低方差筛选移除了 `cvsd`、`cvnni` 特征。

相关性筛选是通过计算每个特征与目标变量之间的皮尔逊相关系数来选择与目标变量相关性较强的特征。特征筛选时计算了所有特性与目标变量之间的相关性矩阵,按照相关性大小选取那些与目标变量关联性强的特性。特征相关性热力图如图 5.1 所示,深浅代表热力图强度的分布,一般用渐变色的颜色标示,其中深蓝色表示强负相关,白色表示无相关性,深红色表示强正相关。这样分析者很轻易就能够抓住特性之间的关系,便于对特性进行选择 and 后续处理。在热力图中,选择相关性大于 0.1 的特性,即这些特性对预测任务目标变量有一定的影响。经过相关性筛选后,保留的特征包括 `sdnn`、`range_nni`、`cvnni`、`min_hr`、`lf`、`hf`、`lfnu`、`hfnu`、`total_power`、`vlf`、`sd2`、速度最大值、横滚角均值。这样避免了对与飞行得分没用的特征和噪声特征的使用,使得模型只使用真正与得分相关的特征,进一步确保了模型的鲁棒性。




图 5.1 特征相关性

在进行特征相关性筛选后，基于 F 值的特征选择通过单因素方差分析（ANOVA）衡量每个特征与目标变量之间的统计显著性，选出最具判别力的特征，从而优化模型性能。筛选后的特征包括：sdnn、range_nni、cvnni、min_hr、lf、hf、lfnu、hfnu、total_power、vlf、sd2、速度最大值、横滚角均值。

在构建机器学习模型前，首先需要确定输入特征和目标变量，本研究中输入特征为筛选后的特征，目标变量为飞行训练得分等级。为了更准确地捕捉不同飞行阶段的特征差异，我们按照飞行阶段对数据进行分组，每个阶段单独训练模型，以提升模型的针对性和预测性能。在数据划分过程中，我们采用 80%训练集、20%测试集的划分比例，并通过分层抽样，确保不同得分等级类别在训练集和测试集中保持相对均衡的分布。针对类别不平衡问题，模型对训练集进行了过采样，若最小类别样本数 ≥ 6 ，使用 SMOTE 进行合成采样；若最小类别样本数 ≥ 3 ，使用 ADASYN 进行自适应采样；若样本过少，不进行过采样。所有特征数据在训练前都经过标准化，以保证模型训练效果。

5.3 模型构建

在基于数据融合进行飞行训练评价研究中，使用了随机森林算法(Random Forest, RF)、支持向量机（Support Vector Machine, SVM）、K 近邻(K-nearest Neighbor, KNN)、多层感知机(Multilayer Perceptron, MLP)、逻辑回归(Logistic Regression, LR)等模型。

RF 是通过构建决策树的集成学习方法,其核心思想是 Bagging,即:通过从训练数据集中有放回地抽取多个子集,每个子集用于训练一棵决策树。其次,每棵树在分裂时,会从所有特征中随机选择部分特征,这样能够减少特征之间的相关性,从而提高模型的泛化能力^[69]。最终的预测结果由所有决策树的投票决定;

随机森林的最终预测结果 $F(X)$ 由 T 棵决策树 $h_t(X)$ 的预测结果取平均:

$$F(X) = \frac{1}{T} \sum_{t=1}^T h_t(X) \quad \#(5.1)$$

其中, T 是决策树的数量, $h_t(X)$ 是第 t 棵决策树的预测结果。决策树使用信息增益来决定特征划分:

$$H(D) = - \sum_{i=1}^c p_i \log_2 p_i \quad \#(5.2)$$

$$IG(D, A) = H(D) - \sum_{v \in V} \frac{|D_v|}{|D|} H(D_v) \quad \#(5.3)$$

$$z = W \cdot x + b \quad \#(5.4)$$

$$\text{ReLU}(z) = \max(0, z) \quad \#(5.5)$$

$$\frac{\partial L}{\partial W} = \frac{1}{m} \sum_{i=1}^m \delta_i x_i^T \quad \#(5.6)$$

其中: $H(D)$ 是数据集 D 的熵, p_i 是类别 i 在数据集中的概率, A 是用于划分数据集的特征, D_v 是按特征 A 取不同值划分后的子数据集。

SVM 是一种最大化分类间隔的分类算法,其目标是找到一个最优超平面,使得数据点之间的间隔最大化。给定训练数据 (x_i, y_i) , SVM 需要优化如下目标函数,确保样本正确分类并使间隔最大^[70]。

$$\min_{w, b} \frac{1}{2} \|w\|^2 + C \sum \max(0, 1 - y_i(w \cdot x_i + b)) \quad \#(5.7)$$

当数据线性不可分时, SVM 使用核函数(Kernel Trick)将数据映射到高维空间:

$$K(x_i, y_i) = \phi(x_i) \cdot \phi(x_j) \quad \#(5.8)$$

其中 $\phi(x)$ 是特征映射函数,使低维数据在高维空间中可分。

KNN 是一种基于实例的非参数分类算法,是基于欧几里得距离计算测试样本与训练样本的相似性,并通过最近的 K 个样本投票决定类别^[71]。

$$d(x_i, x_j) = \sqrt{\sum_{m=1}^M (x_i^{(m)} - x_j^{(m)})^2} \quad \#(5.9)$$

$$\hat{y} = \operatorname{argmax}_{c \in C} \sum_{i=1}^k 1(y_i = c) \quad (5.10)$$

其中： x_i, x_j 分别是两个样本的特征向量， M 是特征的维度， $\hat{y}$ 是KNN预测的类别， C 是所有类别的集合， y_i 是 K 个最近邻样本的类别， $1(y_i = c)$ 是指示函数，若 y_i 属于类别 c ，则取值为1，否则为0。

LR在多分类任务中，逻辑回归为Softmax回归，也称为多项逻辑回归。计算每个类别的概率，并选择概率最高的类别作为预测结果。Softmax函数用于将多个线性变换后的结果转换为概率^[72]：

$$P(Y = j | X) = \frac{e^{W_j X + b_j}}{\sum_{k=1}^C e^{W_k X + b_k}} \quad (5.11)$$

其中： $P(Y = j | X)$ 表示样本 X 预测为类别 j 的概率， W_j 是类别 j 的权重向量， b_j 是偏置项， C 是类别总数。最终的预测类别是概率最大的类别：

$$\hat{y} = \operatorname{argmax}_j P(Y = j | X) \quad (5.12)$$

为了优化模型，逻辑回归在多分类问题中使用交叉熵损失函数。

$$L = -\frac{1}{N} \sum_{i=1}^N \sum_{j=1}^C y_{i,j} \log P(Y = j | X_i) \quad (5.13)$$

其中： N 是样本数， C 是类别数， $y_{i,j}$ 是样本 i 在类别 j 上的真实标签， $P(Y = j | X_i)$ 是模型预测的概率。如果真实类别的概率接近1，则损失接近0，说明模型预测正确。如果真实类别的概率很小（接近0），则损失较大，模型需要调整参数来提高正确分类的概率。

MLP是一种前馈式的人工神经网络，由输入层、隐藏层和输出层组成。每个节点神经元与前后层的节点通过权重连接^[72]。通过非线性激活函数和优化算法Adam训练网络，可以对输入的融合特征进行非线性映射，并生成各类的类别概率，

$$z = W \cdot x + b \quad (5.14)$$

为了引入非线性特征，在每个线性变换后会应用一个非线性激活函数

$$\operatorname{ReLU}(z) = \max(0, z) \quad (5.15)$$

输出层的作用是将隐藏层的结果映射到具体的分类任务中。线性变换表示与隐藏层相同，但为了得到各负荷类别的概率，应用Softmax激活函数将所有输出映射 $[0,1]$ 区间内，使它们的总和为1，即

$$\text{Softmax}(z_i) = \frac{e^{z_i}}{\sum_{j=1}^K e^{z_j}} \quad (5.16)$$

权重的梯度:

$$\frac{\partial L}{\partial W} = \frac{1}{m} \sum_{i=1}^m \delta_i x_i^T \quad (5.17)$$

其中, W 为权重矩阵, x 为输入向量, b 为偏置项, L 为损失函数, δ_i 为第 i 个样本的误差项。

对于构建分类预测,数据集被划分为 80%训练集和 20%测试集,保持各类别的比例不变。对于随机森林使用 100 棵决策树,同时限制最大深度为 6,使用基尼系数计算节点分裂。SVM 通过最大化数据间隔来进行分类,采用径向基核函数,启用概率预测,设置正则化参数 $C=1.0$,自动计算 γ 值,使模型能够更好地适应不同的数据集。KNN 选择 5 个最近邻样本进行分类,使用欧几里得距离计算样本之间的相似性。逻辑回归采用 L-BFGS 优化算法,最大迭代次数设定为 300。MLP 采用两层神经网络结构,第一层含 100 个神经元,第二层 50 个神经元,最大训练次数设定为 500,使用 Adam 优化器以加快训练速度。

模型评估中使用了包括准确率(Accuracy)、精确率(Precision)、Kappa 系数(Cohen's Kappa)、召回率(Recall)、F1 分数(F1 Score)、平衡准确率(Balanced Accuracy)、等多种指标。为了更直观地分析模型的分类能力,采用 AUC 曲线进行可视化,评估模型在不同阈值下的分类表现。

5.4 模型结果分析

研究通过多种分类算法的深入研究,挖掘数据的内部结构和特征,从而验证不同分类方法与飞行训练品质等级关系的一致性与可靠性。考虑到数据的不均衡性,Accuracy 可能会受到多数类样本的影响,从而无法全面反映模型的分类性能。因此,本研究主要基于 F1 Score、Balanced Accuracy 作为核心评估指标,以更全面地衡量模型在不同类别上的预测能力,而其他分类指标仅作为参考。

5.4.1 起飞阶段

在起飞阶段中,不同的分类模型在识别效果上表现出了明显差异,分类结果如表 5.1 所示。从各项指标来看,MLP 和 RF 在分类预测中的表现优于其他模型。MLP 分类模

型的 F1 分数为 0.9362，Balanced Accuracy 为 0.9369，且准确度、精确度和召回率等指标也为各项模型中的最高；RF 的性能表现紧随其后，其 F1 分数为 0.8704，Balanced Accuracy 为 0.8739，整体表现稳定。相比之下，SVM、KNN 和 LR 的 F1 分数分别为 0.7352、0.7737 和 0.6578，整体表现一般，分类效果明显弱于前述模型。

表 5.1 起飞阶段不同分类模型评价指标结果

模型	Accuracy	F1 Score	Kappa	Precision	Recall	Balanced Accuracy
RF	0.8739	0.8704	0.8108	0.8868	0.8739	0.8739
SVM	0.7387	0.7352	0.6081	0.7381	0.7387	0.7387
KNN	0.7838	0.7737	0.6757	0.7974	0.7838	0.7838
LR	0.6667	0.6578	0.6000	0.6565	0.6667	0.6667
MLP	0.9369	0.9362	0.9054	0.9386	0.9369	0.9369

起飞阶段的 ROC 曲线和 AUC 如图 5.2 所示。MLP、RF、KNN、SVM 和 LR 等分类模型得到的 AUC 分别为 0.8269、0.8598、0.7980、0.7754、0.7602。RF 的 AUC 高于 MLP，其分类表现相对较稳定。综合来看，MLP 是起飞阶段中表现最好的模型，适用于最终的分类任务。但如果追求在不同决策阈值下保持稳定的能力，RF 具有一定优势。




图 5.2 起飞阶段不同模型的 ROC 曲线和 AUC

5.4.2 爬升阶段

在爬升阶段中，不同的分类模型分类结果如表 5.2 所示。从各项指标来看，MLP 和 RF 在分类预测中的表现优于其他模型。MLP 分类模型的 F1 分数为 0.9756，Balanced Accuracy 为 0.9756，且准确度、精确度和召回率等指标也为各项模型中的最高；RF 的性能表现紧随其后，其 F1 分数为 0.9502，Balanced Accuracy 为 0.9502，整体表现稳定。相比之下，SVM、KNN 和 LR 的 F1 分数分别为 0.8167、0.7632 和 0.8036，分类效果明显逊色于 MLP 与 RF 模型。与起飞阶段相比，MLP 和 Balanced RandomForest 的 Accuracy 和 F1 Score 均有所提升，这表明模型在爬升阶段对数据的适应性更强，能够更精准地进行分类预测。

综合来看，MLP 和 RF 在爬升阶段的分类任务中表现优越，适合作为此阶段的分类模型，

表 5.2 爬升阶段不同分类模型评价指标结果

模型	Accuracy	F1 Score	Kappa	Precision	Recall	Balanced Accuracy
RF	0.9512	0.9502	0.9268	0.9545	0.9512	0.9512
SVM	0.8211	0.8167	0.7317	0.8606	0.8211	0.8211
KNN	0.7886	0.7632	0.6829	0.8384	0.7886	0.7886
LR	0.813	0.8036	0.7195	0.8124	0.813	0.813
MLP	0.9756	0.9756	0.9634	0.9773	0.9756	0.9756

爬升阶段的 ROC 曲线和 AUC 如图 5.3 所示。MLP、RF、KNN、SVM 和 LR 等分类模型得到的 AUC 分别为 0.9377、0.9222、0.8236、0.7975。MLP 的 AUC 最高，其分类表现相对较稳定。综合来看，MLP 是起飞阶段分类中表现最好的模型，适用于最终的分类任务。




图 5.3 爬升阶段不同模型的 ROC 曲线和 AUC

5.4.3 平飞阶段

在平飞阶段中，不同的分类模型分类结果如表 5.3 所示。从各项指标来看，MLP 和 RF 在分类预测中的表现优于其他模型。MLP 分类模型的 F1 分数为 0.9393，Balanced Accuracy 为 0.9394，且准确度、精确度和召回率等指标也为各项模型中的最高；RF 的性能表现紧随其后，其 F1 分数为 0.918，Balanced Accuracy 为 0.9192，整体表现稳定。相比之下，SVM、KNN 和 LR 的 F1 分数分别为 0.8581、0.814 和 0.8887，分类效果明显逊色于 MLP 与 RF 模型。

表 5.3 平飞阶段不同分类模型评价指标结果

模型	Accuracy	F1 Score	Kappa	Precision	Recall	Balanced Accuracy
RF	0.9192	0.918	0.8788	0.935	0.9192	0.9192
SVM	0.8586	0.8581	0.7879	0.8614	0.8586	0.8586
KNN	0.8182	0.814	0.7273	0.8235	0.8182	0.8182
LR	0.8889	0.8887	0.8333	0.8907	0.8889	0.8889
MLP	0.9394	0.9393	0.9091	0.9404	0.9394	0.9394

平飞阶段的 ROC 曲线和 AUC 如图 5.4 所示。MLP、RF、KNN、SVM 和 LR 等分

类模型得到的 AUC 分别为 0.8970、0.9042、0.8722、0.8900、0.8991。RF 的 AUC 最高，其分类表现相对较稳定。LR 与 MLP 的 AUC 略低于 RF，但仍然处于较高水平。综合来看，MLP 与 RF 是起飞阶段分类中表现好的模型，适用于最终的分类任务。但如果追求在不同决策阈值下保持稳定的分类能力，LR 具有一定优势。SVM 和 KNN 在综合表现上较差。




图 5.4 平飞阶段不同模型的 ROC 曲线和 AUC

5.4.4 转弯阶段

在转弯阶段中，不同的分类模型分类结果如表 5.4 所示。从各项指标来看，SVM 和 MLP 在分类预测中的表现优于其他模型。SVM 分类模型的 F1 分数为 0.961，Balanced Accuracy 为 0.9394，且准确度、精确度和召回率等指标也为各项模型中的最高；MLP 的性能表现紧随其后，其 F1 分数为 0.918，Balanced Accuracy 为 0.9192，整体表现优秀，说明其在转弯阶段能够较好地适应数据分布，做出精准预测。相比之下，RF、KNN 和 LR 的 F1 分数分别为 0.9425、0.9491 和 0.9415，分类效果也具有较好的分类能力，但弱于 SVM 与 MLP 模型。

综合来看，SVM 在转弯阶段的分类任务中表现最佳，适合作为该阶段的主要分类模型，而 MLP 也展现出较强的分类能力，可以作为备选方案。若考虑分类稳定性与泛化能力，RF、KNN 和 LR 亦可作为补充模型，以进一步提升整体分类效果。

表 5.4 转弯阶段不同分类模型评价指标结果

模型	Accuracy	F1 Score	Kappa	Precision	Recall	Balanced Accuracy
RF	0.9390	0.9425	0.8780	0.8913	0.9000	0.9390
SVM	0.9780	0.9785	0.9561	0.9579	0.9500	0.9780
KNN	0.9463	0.9491	0.8927	0.9031	0.9000	0.9463
LR	0.9390	0.9415	0.8780	0.9054	0.9805	0.939
MLP	0.9610	0.9621	0.9220	0.9355	0.9902	0.9610

转弯阶段的 ROC 曲线和 AUC 如图 5.5 所示。从结果来看，各模型均取得了较高的 AUC 值,MLP、RF、KNN、SVM 和 LR 等分类模型得到的 AUC 分别为 0.9456、0.9793、0.9741、0.9597、0.9452，表明其分类性能较为优异。其中，SVM、RF 的 AUC 最高，其分类表现相对较稳定，表明它们在不同决策阈值下均能维持较强的分类能力。此外，MLP、KNN、和 LR 等模型的 AUC 略低，但仍然处于较高水平，说明这些模型在转弯阶段的分类任务中仍具有较好的区分能力。

综合来看，SVM 在起飞阶段的分类任务中表现优异，在转弯阶段依然保持较强的分类能力，因此适用于最终的分类任务。然而，如果在不同决策阈值下保持稳定的分类能力是主要考虑因素，那么 RF 由于其更高的 AUC 值，更具优势。




图 5.5 转弯阶段不同模型的 ROC 曲线和 AUC

5.4.5 下降阶段

在下降阶段中，不同的分类模型分类结果如表 5.5 所示。从各项指标来看，MLP 在分类预测中的表现优于其他模型。MLP 分类模型的 F1 分数为 0.9079，Balanced Accuracy 为 0.9091，且准确度、精确度和召回率等指标也为各项模型中的最高，相比之下，SVM、KNN 的 F1 分数分别为 0.7565、0.7586，分类效果较差。

表 5.5 下降阶段不同分类模型评价指标结果

模型	Accuracy	F1 Score	Kappa	Precision	Recall	Balanced Accuracy
SVM	0.7652	0.7565	0.6477	0.7616	0.7652	0.7652
KNN	0.7652	0.7586	0.6477	0.7715	0.7652	0.7652
MLP	0.9091	0.9079	0.8636	0.9087	0.9091	0.9091

下降阶段的 ROC 曲线和 AUC 如图 5.6 所示。MLP、KNN、SVM 等分类模型得到的 AUC 分别为 0.89、0.73、0.75。MLP 的 AUC 最高，其分类表现相对较稳定。其他模型的 AUC 较低，综合来看，MLP 是起飞阶段分类中表现好的模型，适用于最终的分类任务。




图 5.6 下降阶段不同模型的 ROC 曲线和 AUC

5.4.6 着陆阶段

在着陆阶段中，不同的分类模型分类结果如表 5.6 所示。从各项指标来看，MLP 和

RF 在分类预测中的表现优于其他模型。MLP 分类模型的 F1 分数为 0.9790，Balanced Accuracy 为 0.9792，且准确度、精确度和召回率等指标也为各项模型中的最高；RF 的性能表现紧随其后，其 F1 分数为 0.9067，Balanced Accuracy 为 0.9062，整体表现稳定。相比之下，SVM、KNN 和 LR 的 F1 分数分别为 0.8151、0.7425 和 0.7150，分类效果明显逊色于 MLP 与 RF 模型。

表 5.6 着陆阶段不同分类模型评价指标结果

模型	Accuracy	F1 Score	Kappa	Precision	Recall	Balanced Accuracy
RF	0.9062	0.9067	0.8594	0.9080	0.9062	0.9062
SVM	0.8125	0.8151	0.7188	0.8224	0.8125	0.8125
KNN	0.7500	0.7425	0.6250	0.7466	0.7500	0.7500
LR	0.7188	0.7150	0.5781	0.7196	0.7188	0.7188
MLP	0.9792	0.9790	0.9688	0.9798	0.9792	0.9792

着陆阶段的 ROC 曲线和 AUC 如图 5.7 所示。MLP、RF、KNN、SVM 和 LR 等分类模型得到的 AUC 分别为 0.9167、0.8836、0.8683、0.8062、0.7378。MLP 的 AUC 最高，其分类表现相对较稳定。综合来看，MLP 是着陆阶段分类中表现好的模型，适用于最终的分类任务。




图 5.7 着陆阶段不同模型的 ROC 曲线和 AUC

模型性能差异源于多方面因素。MLP 作为基于神经网络的模型，具备强大的非线性拟合能力，能够自动学习数据中的复杂特征和模式。在飞行训练数据中，生理信号与飞行操作参数之间存在高度非线性关系，MLP 通过多层神经元的信息传递与变换，能够有效捕捉这些关系，从而在多数阶段表现优异。而 RF 通过构建多个决策树并投票决策，对数据中的噪声和异常值具有较好的鲁棒性，同时能处理高维数据，因此在多个阶段也展现出稳定性能。相比之下，SVM、KNN 和 LR 的模型结构相对简单，难以适应复杂的非线性数据分布，导致分类性能受限。

不同飞行阶段的数据分布存在差异，RF 通过随机采样和特征选择构建决策树，能够有效处理数据的多样性和复杂性，在数据分布变化较大的情况下仍能保持较好性能。而 KNN 依赖于样本间的距离度量，当数据分布不均匀或存在噪声时，容易出现误分类；LR 基于线性假设，难以处理非线性关系，在复杂数据场景下表现不佳。

综上所述，MLP 有其强大的非线性拟合能力和对复杂特征的学习能力，是飞行训练品质预测的最佳分类模型，适用于最终的分类任务；RF 作为次优选择，在转弯等阶段具有较好的稳定性。如果在不同决策阈值下需要保持稳定的分类能力，RF 也可以作为候选模型。SVM 和 LR 在部分阶段表现尚可，但整体不及 MLP 和 RF，而 KNN 和 LR 的分类性能相对较弱，不适用于最终任务。

5.5 不同飞行阶段的认知负荷与飞行表现分析

飞行员在不同认知负荷等级下的表现存在显著差异，为了更清晰地理解飞行员在不同飞行阶段的表现差异，根据第三章中认知负荷排序，从低到高依次划分为：平飞（1）、转弯（2）、爬升（3）、下降（4）、起飞（5）和着陆（6）。该箱线图展示了飞行员在不同认知负荷等级下的飞行得分分布，并区分了不同飞行得分等级，如图 5.8 所示。




图 5.8 不同认知负荷等级下飞行得分等级分布

从数据整体趋势上来分析, 在平飞和转弯等低负荷阶段, 飞行得分的中位数较高, 且数据分布相对集中。在这一阶段, 低分组较少, 高分组较多, 表明多数飞行员在这一阶段能保持较高的飞行质量, 较少飞行员在此阶段出现明显失误或操作不佳的情况; 在爬升和下降等中等负荷阶段, 中位数有轻微下降趋势, 表明整体表现开始受到一定影响, 得分分布开始变宽, 数据波动增加, 低分组数量有所增加, 表明部分飞行员在中等负荷下的表现有所下降; 在起飞与着陆等较高认知负荷阶段时, 飞行得分的中位数进一步降低, 且分布更为分散, 表明整体表现受到较大影响, 个体间的表现差异进一步拉大。低分组显著增多, 高分组减少, 尤其是在着陆阶段时, 部分飞行员的得分极低, 说明较高的认知负荷对飞行员表现有负面影响。

从离群点数量上看, 在平飞、转弯等低负荷阶段, 离群点数量较少, 表明此时大多数飞行员个体差异较小; 而在起飞、着陆等认知负荷较高的阶段, 离群点数较高, 说明少数飞行员表现出极端情况。在中分组中, 也可能存在个别飞行员表现较差, 在面临任务复杂项时, 不同个体之间的差异较大。高分组中离群点数量较少, 说明在较高负荷的任务中, 飞行员仍然表现出较强的稳定性, 对高负荷任务有较高的适应能力。

从研究结果可以看出, 在相对较低的认知负荷中, 飞行员操纵稳定性水平发挥较稳定, 飞行得分高且波动较小, 而在高度认知负荷中, 差异增大, 飞行员发挥水平整体下降; 同时, 随着认知负荷的增加, 低分组型飞行员出现次数增多, 且多出现在高负荷阶段, 高分组型飞行员出现次数增多, 且多出现在低负荷阶段, 即在相对负荷较低的飞行

阶段, 飞行员更易出现稳定水平发挥, 反之, 在高负荷的飞行阶段, 个体差异较大。因此, 可以根据训练情况, 着重对高负荷水平能力突出的飞行员进行训练, 对出现反常表现的飞行员重点分析操作行为及认知反应, 确定该类飞行员存在的问题, 制定个性化训练计划, 提升训练效益和飞行安全水平。

本研究采用单因素方差分析 (ANOVA) 来判断不同认知负荷水平下的飞行得分是否存在显著差异。ANOVA 结果显示 $p < 0.05$, 说明不同认知负荷等级之间的飞行得分确实存在显著差异^[73]。因此, 我们进一步采用 Tukey HSD 事后检验来识别具体哪些飞行阶段之间的差异达到统计学显著性, 结果详见表 5.7。

表 5.7 Tukey HSD 检验结果

组别 1	组别 2	均值差异	调整后 p 值	置信区间下限	置信区间上限	是否显著
1	2	0.0138	0.9679	-0.0357	0.0633	否
1	3	-0.1138	<0.01	-0.1633	-0.0643	是
1	4	-0.142	<0.01	-0.1915	-0.0925	是
1	5	-0.0413	0.1657	-0.091	0.0084	否
1	6	-0.1186	<0.01	-0.1695	-0.0677	是
2	3	-0.1276	<0.01	-0.1771	-0.0781	是
2	4	-0.1558	<0.01	-0.2053	-0.1062	是
2	5	-0.0551	0.02	-0.1048	-0.0054	是
2	6	-0.1324	<0.01	-0.1833	-0.0815	是
3	4	-0.0282	0.5789	-0.0777	0.0213	否
3	5	0.0725	0.0005	0.0228	0.1222	是
3	6	-0.0048	0.9998	-0.0557	0.0461	否
4	5	0.1007	<0.01	0.051	0.1504	是
4	6	0.0234	0.7767	-0.0275	0.0743	否
5	6	-0.0773	0.0003	-0.1284	-0.0262	是

认知负荷等级 1 与 3、4、6, 认知负荷等级 2 与 3、4、5、6, 认知负荷等级 3 与 5, 以及认知负荷等级 4 与 5 和 5 与 6 之间的飞行得分存在显著差异。这些显著性差异表明,

低负荷（1、2级）与高负荷（3级及以上）之间的飞行得分差异显著，而中高负荷之间的差异情况较为复杂，具体来看，认知负荷较低的等级（1、2级）与较高负荷的等级（3、4、5、6级）之间差异较为明显。1级负荷的飞行得分显著高于3、4、6级，说明较低的认知负荷可能有助于飞行表现的提高。同时，2级负荷与3、4、5、6级之间的差异也具有显著性，进一步表明轻度认知负荷下能够维持较高的飞行表现。然而，中等负荷（3、4级）与高负荷（5、6级）之间的差异并不总是显著。可能意味着这两个负荷等级对飞行得分的影响较为相似。从分析中可以看到，3级与5级、4级与5级之间存在显著差异，表明认知负荷达到5级时，飞行得分明显下降。此外，5级与6级之间的显著差异进一步表明，在较高负荷水平下，飞行得分可能会持续下降。

本研究揭示了不同飞行阶段的认知负荷变化对飞行员表现的显著影响。研究结果表明：处于低飞行负荷时，飞行员表现出更好的稳定性，飞行绩效得分更高，组间差异也更小。当处于高飞行负荷时，飞行员间的差异更大，飞行绩效总体下降趋势明显，且低分组中着陆阶段所占比例有所上升；高分组中，高负荷下仍能维持较好的稳定性，说明在高负荷任务中，个体适应能力起到重要作用；起飞、着陆等阶段飞行负荷较大时，飞行绩效下降比较明显，是飞行训练中值得重视的阶段。

5.6 本章小结

本章主要介绍了数据集建立、数据预处理、特征筛选、模型构建及模型结果分析等。HRV数据与飞行参数融合成新的数据集，对数据集进行了清洗、标准化及异常值处理，并通过相关统计分析方法进行特征选择，采用不同分类预测模型进行训练，并对模型性能进行了评估和比较。在不同飞行阶段，不同模型的分类性能存在差异，其中MLP在起飞、爬升、平飞、下降、着陆阶段均表现最佳，而RF在转弯阶段更稳定的分类能力，综合来看，MLP是飞行训练品质预测的最佳分类模型。

此外，箱线图直观展示了不同负荷下的得分分布情况，并采用ANOVA和Tukey HSD事后检验进一步验证不同认知负荷等级之间的显著性差异。结果表明：随着认知负荷的增加，飞行员的任务执行稳定性下降，尤其在起飞和着陆等高负荷阶段，对飞行表现的影响最为显著，为个性化训练提供了数据支持。

结论与展望

总结:

本论文以飞行员为研究对象,以提高飞行安全性为宗旨,以飞行员的训练质量和认知负荷为目标,进行定性分析,从而优化飞行训练效果,提高飞行安全性。

在飞行员认知负荷评估方面,本研究通过主观方式评估不同飞行阶段的认知负荷,经过特征筛选后结合多种深度学习模型进行分类预测,并对其性能进行了综合评估。研究表明, CNN-BiLSTM-BGRU 模型在认知负荷识别任务中表现最优,展示了该模型在飞行员认知负荷识别中的显著优势。

在飞行训练品质评估方面,本研究基于飞行数据构建了参考曲线与评估指标体系,提出了衡量飞行训练品质的关键指标,包括轨迹匹配度、轨迹误差与飞行稳定性,并据此建立了评估模型,并基于飞行数据误差进行回归分析,验证了模型的可靠。

在数据融合这一章中,本研究通过构建新的数据集、结合数据预处理、特征筛选等步骤,建立分类预测模型。实验结果表明, MLP 和 RF 模型在不同飞行阶段的分类性能表现最佳,尤其在起飞、爬升、平飞、下降、着陆阶段, MLP 模型表现突出,而在转弯阶段, RF 模型则展现了较为稳定的分类能力。进一步的可视化分析与统计检验表明,不同飞行阶段的认知负荷对飞行员表现具有显著影响,特别是在起飞和着陆阶段,飞行员的表现受到高认知负荷的影响最为明显。

综上所述,本论文通过 HRV 与飞行数据融合,构建了分类预测模型,并结合统计分析,为飞行员训练品质评估提供了理论依据。

主要创新点:

(1) 本研究所选取的飞行科目不再依赖常见的矩形起落航线,而是基于飞行员“初筛”阶段的真实训练任务进行设置。这一设计更贴近实际训练场景。

(2) 本研究采用了多模态数据融合,将 HRV 数据与飞行数据进行融合,搭建了一个多维度的飞行训练品质评估体系。相较于传统依赖单一数据源的评估方法,该融合框架显著提升了评估结果的客观性和全面性,为更科学地衡量飞行员训练表现提供了坚实的数据支持。

(3) 本研究将统计分析方法与机器学习算法相结合,通过 ANOVA 方差分析、Tukey HSD 事后检验以及箱线图分析,定量评估了不同飞行阶段的认知负荷对飞行员操作表现

的影响，从而明确了认知负荷水平与飞行表现之间存在的显著关联性。

展望：

尽管本研究在飞行员训练评估方面取得了一定成果，但仍存在一些不足之处。首先，模拟飞行实验采集的数据不是真实飞行数据，这可能会影响模型的泛化能力。因此，未来研究可以尝试真实飞行数据，以增强研究结果在实际应用中的可靠性。

其次，单一的 HRV 数据虽然能够有效反映飞行员的认知负荷水平，但飞行员的生理状态还受到脑电、眼动、皮电等多种生理信号的影响。单一的数据来源可能限制了对飞行员状态的全面评估，因此未来可以尝试融合多模态生理数据，以提升认知负荷识别的准确性和稳定性。

此外，个体差异是本研究尚未深入探讨的另一个方面。不同飞行员在飞行经验、心理状态和身体素质等方面存在显著差异，这些因素可能会影响其认知负荷水平和训练表现。未来的研究可以为不同类型的飞行员制定更加个性化的认知负荷评估标准，以提高评估结果的适应性和科学性。

综上所述，未来研究可以从多个方面进行改进，以进一步提升飞行员训练评估的科学性和实用性，从而为训练优化提供更加可靠的支持。

参考文献

- [1] 邓位. 基于 Cessna CJ1 模拟机的飞行员飞行训练品质评估系统研究[D]. 广汉: 中国民用航空飞行学院, 2018.
- [2] 李笠.ACPC 飞行训练工作负荷评估研究[D]. 广汉: 中国民用航空飞行学院, 2024.
- [3] MoghimiEsfandabadi M H, Djavareshkian M H, Abedi S. Significance of aviation safety, its evaluation, and ways to strengthen security[J]. International Journal of Reliability, Risk and Safety: Theory and Application, 2023, 6(2): 37-45.
- [4] 张之洋. 面向 SPO 模式的飞行员脑力负荷特征研究[D]. 天津: 中国民航大学, 2023.
- [5] 王超. 模拟飞行训练中人机结合的认知负荷研究[D]. 西安: 西安工业大学, 2024.
- [6] 李佳员, 孙宏, 李凡, 等. 基于 VENN 模型的民航飞行员胜任力评估标准优化[J]. 科学技术与工程, 2024, 24(17): 7422-7428.
- [7] 王越, 徐亚军, 张华忠. 飞行学员飞行品质评价模型的建立[J]. 中国科技信息, 2019, (09): 48-49.
- [8] 刘伟, 刘玉妍, 杨泳. 人工和数据相结合的飞行技术量化评价方法研究[J]. 航空工程进展, 2024, 1-13.
- [9] 孙宝嵩, 石治国, 潘新龙, 等. 基于灰色关联分析和 XGBoost 的飞机飞行品质评价[J]. 航空工程进展, 2024, 1-8.
- [10] 王帅, 陈勇刚, 曾超. 基于超限事件的飞行训练品质评估模型[J]. 科学技术与工程, 2022, 22(12): 5074-5080.
- [11] 祝祯祯, 钱宇, 王杰, 等. 基于时间序列相似度的飞行训练品质评价研究[J]. 飞行力学, 2021, 39(06): 75-81.
- [12] Sun H, Jiang D, Li F. Flight Operating Quality Evaluation for the Final Approach Segment Based on Flight Technical Error[C]//2021 IEEE 3rd International Conference on Civil Aviation Safety and Information Technology (ICCASIT). IEEE, 2021: 1260-1264.
- [13] 邓永恒. 矩形起落航线训练品质评估方法研究[D]. 广汉: 中国民用航空飞行学院, 2016.
- [14] 姜迪. 基于 SD 卡数据的进近阶段飞行训练操纵品质评估[D]. 广汉: 中国民用航空飞行学院, 2022.
- [15] 孙赫. 飞行参数驱动的飞行训练品质评价方法及适应性分析[D]. 广汉: 中国民用航空飞行学院, 2022.

- [16] 卢飞, 魏星宇, 陈昊南. 民航飞行员着陆操作品质综合评价体系研究[J]. 安全与环境学报, 2025, 25(02): 558-571.
- [17] Bian Q, Nener B, Wang X. Control parameter tuning for aircraft crosswind landing via multi-solution particle swarm optimization[J]. Engineering Optimization, 2018, 50(11): 1914-1925.
- [18] Wang L, Wu C, Sun R. An analysis of flight Quick Access Recorder (QAR) data and its applications in preventing landing incidents[J]. Reliability Engineering & System Safety, 2014, 127: 86-96.
- [19] 王亚文, 刘婷婷, 王长元, 等. 飞行员认知负荷评估综述[J]. 西安工业大学学报, 2025, 45(01): 53-69.
- [20] Wang C, Guo J. A data-driven framework for learners' cognitive load detection using ECG-PPG physiological feature fusion and XGBoost classification[J]. Procedia computer science, 2019, 147: 338-348.
- [21] 罗诗涵, 张晨阳, 朱文兵, 等. 基于非接触式感知的飞行学员认知负荷评估研究[J]. 中国安全生产科学技术, 2025, 21(02): 67-73.
- [22] 李葳宁, 韩宗昌, 邢晨光. 基于脑电信号的飞行员认知负荷实时监测评估系统[J]. 航空科学技术, 2024, 35(11): 95-103.
- [23] 李文斌, 康阳, 谢小萍, 等. 基于脑电微状态分析的模拟飞行多任务脑力负荷敏感性研究[J]. 载人航天, 2022, 28(01): 55-62.
- [24] 朱通, 祁杰, 贺强, 等. 直升机模拟机飞行训练中的眼动、认知负荷与情境意识[J]. 民航学报, 2024, 8(02): 148-152.
- [25] 周勇邦. 航空人为因素适航审定中生理参数检测技术的研究与实现[D]. 上海: 上海交通大学, 2013.
- [26] 王深深, 孙有朝. 基于多生理参数的飞行员任务负荷评估[J]. 人类工效学, 2023, 29(04): 62-69.
- [27] Mohanavelu K, Poonguzhali S, Janani A, et al. Machine learning-based approach for identifying mental workload of pilots[J]. Biomedical Signal Processing and Control, 2022, 75: 103623.
- [28] Arutyunova K R, Bakhchina A V, Konovalov D I, et al. Heart rate dynamics for cognitive load estimation in a driving simulation task[J]. Scientific Reports, 2024, 14(1): 31656.
- [29] Huynh P, Warner G, Lin H. Effects of EMD and Feature Extraction on EEG Analysis[J]. Journal of Advances in Information Technology, 2020, 11(1): 26-34.

- [30] Ghaderi M, Ben Abdesslem H, Antoine M, et al. Estimation of Piloting Attention Level Based on the Correlation of Pupil Dilation and EEG[C]//International Conference on Intelligent Tutoring Systems. Cham: Springer Nature Switzerland, 2023: 381-390.
- [31] Wang H, Jiang N, Pan T, et al. Cognitive load identification of pilots based on Physiological-Psychological characteristics in complex environments[J]. Journal of Advanced Transportation, 2020, 2020: 1-16.
- [32] 张龙. 基于模糊逻辑的飞行员飞行品质评价[D]. 广汉: 中国民用航空飞行学院, 2016.
- [33] 仇志凡. 大型飞机操纵品质等级评估方法研究[D]. 南京: 南京航空航天大学, 2019.
- [34] 孙瑞山, 肖亚兵. 基于 QAR 记录数据的民航飞行员操作特征指标结构研究[J]. 中国安全生产科学技术, 2012, 8(11): 49-54.
- [35] 柳忠起, 袁修干, 樊瑜波. 基于 BP 神经网络的飞行绩效评价模型[J]. 北京航空航天大学学报, 2010, 36(4): 403-406.
- [36] 孙敬周. 基于生理指标测量的飞行学员疲劳特性与飞行品质评估研究[D]. 广汉: 中国民用航空飞行学院, 2018.
- [37] 蒙果, 李鸣皋. 海军飞行学员教练机首次单飞心率和心率变异性变化的研究[J]. 海军医学杂志, 2019, 40(02): 118-119.
- [38] Cao X, MacNaughton P, Cadet L R, et al. Heart rate variability and performance of commercial airline pilots during flight simulations[J]. International journal of environmental research and public health, 2019, 16(2): 237.
- [39] Pham T, Lau Z J, Chen S H A, et al. Heart rate variability in psychology: A review of HRV indices and an analysis tutorial[J]. Sensors, 2021, 21(12): 3998.
- [40] Wang H, Jiang N, Pan T, et al. Cognitive Load Identification of Pilots Based on Physiological - Psychological Characteristics in Complex Environments[J]. Journal of Advanced Transportation, 2020, 2020(1): 5640784.
- [41] Wang P, Houghton R, Majumdar A. Detecting and predicting pilot mental workload using heart rate variability: A systematic review[J]. Sensors, 2024, 24(12): 3723.
- [42] 何金松. 基于多模生理电信号的飞行员认知负荷综合评估研究[D]. 南京: 南京航空航天大学, 2019.

- [43] 刘洋, 曹新生, 文治洪, 等. 心电技术在飞行生理参数监测与评估教学中的应用[J]. 心脏杂志, 2023, 35(06): 694-699.
- [44] 张宁宁, 陈飒. 基于心率变异性的飞行员脑力负荷特征[J]. 科学技术与工程, 2024, 24(13): 5634-5641.
- [45] 辛甜, 罗志燕, 蒋利添, 等. 飞机着陆阶段飞行员认知负荷分析[J]. 人类工效学, 2019, 25(02): 62-65.
- [46] 何雪丽, 王黎静, 湛希, 等. 飞行员工作负荷定量实时预测模型[J]. 北京航空航天大学学报, 2025, 1-11.
- [47] 朱文兵, 张晨阳, 袁家俊, 等. 基于便携式心电设备的模拟舰载机飞行员认知负荷识别[J]. 空军军医大学学报, 2025, 46(01): 63-71.
- [48] Chen Q, Meng Z, Liu X, et al. Decision variants for the automatic determination of optimal feature subset in RF-RFE[J]. Genes, 2018, 9(6): 301.
- [49] Chen Y, Xu W C, Zhu W, et al. Beat-to-beat heart rate detection based on seismocardiogram using BiLSTM network[C]//2021 IEEE 20th International Conference on Trust, Security and Privacy in Computing and Communications (TrustCom). IEEE, 2021: 1503-1507.
- [50] Li R, Zhang X, Dai H, et al. Interpretability analysis of heartbeat classification based on heartbeat activity's global sequence features and BiLSTM-attention neural network[J]. IEEE Access, 2019, 7: 109870-109883.
- [51] Su X, Wang X, Ge H. Exercise ECG Classification Based on Novel R-Peak Detection Using BiLSTM-CNN and Multi-Feature Fusion Method[J]. Electronics, 2025, 14(2): 281.
- [52] Islam M S, Islam M N, Hashim N, et al. New hybrid deep learning approach using BiGRU-BiLSTM and multilayered dilated CNN to detect arrhythmia[J]. IEEE Access, 2022, 10: 58081-58096.
- [53] Al-Ali E M, Hajji Y, Said Y, et al. Solar energy production forecasting based on a hybrid CNN-LSTM-transformer model[J]. Mathematics, 2023, 11(3): 676.
- [54] Lalwani P, Ramasamy G. Human activity recognition using a multi-branched CNN-BiLSTM-BiGRU model[J]. Applied Soft Computing, 2024, 154: 111344.
- [55] 蒋闯, 艾红, 陈雯柏. 基于时域特征与 LSTM-Attention 的 IGBT 退化预测方法[J]. 中国测试, 2023, 49(8): 8-14.

- [56] 叶然 道肯. 基于 BiLSTM 深度学习模型的径流预测方法[J]. 水利科技与经济, 2025, 31(03): 93-99.
- [57] Zhang H, Zhang Q, Shao S, et al. Attention-based LSTM network for rotatory machine remaining useful life prediction[J]. Ieee Access, 2020, 8: 132188-132199.
- [58] 孙震, 徐昊, 朱洪志, 等. 基于分解重构与特征筛选的短期电力负荷预测[J]. 电气自动化, 2025, 47(01): 61-63.
- [59] 郝磊. 基于 CNN 和 BiLSTM 的电缆故障自动化定位技术[J]. 自动化与仪表, 2025, 40(03): 118-121.
- [60] Li X, Ma X, Xiao F, et al. Time-series production forecasting method based on the integration of Bidirectional Gated Recurrent Unit network and Sparrow Search Algorithm[J]. Journal of Petroleum Science and Engineering, 2022, 208: 109309.
- [61] 沈搏林. 基于大数据的飞行训练质量评估方法研究[D]. 广汉: 中国民用航空飞行学院, 2024.
- [62] 雷林平. 基于 Savitzky-Golay 算法的曲线平滑去噪[J]. 电脑与信息技术, 2014, 22(05): 30-31.
- [63] 王越. 飞行学员飞行品质评价模型研究[D]. 广汉:中国民用航空飞行学院, 2019.
- [64] 侯晓雪. 起落航线飞行训练品质评估研究[D]. 广汉:中国民用航空飞行学院, 2024.
- [65] 崔志坤, 王清亮, 刘景青, 等. 基于模糊集理论和序关系分析法的电力市场指标体系研究[J]. 电测与仪表, 2024, 61(05): 31-37.
- [66] 慈铁军, 赵占占, 任行健, 等. 基于 G1 序关系分析法的光伏瓦片发电系统综合效益评价[J]. 电力科学与工程, 2023, 39(06): 48-54.
- [67] Wei Y, Wu D, Terpenney J. Decision-level data fusion in quality control and predictive maintenance[J]. IEEE Transactions on Automation Science and Engineering, 2020, 18(1): 184-194.
- [68] Kashinath S A, Mostafa S A, Mustapha A, et al. Review of data fusion methods for real-time and multi-sensor traffic flow analysis[J]. IEEE Access, 2021, 9: 51258-51276.
- [69] Salman H A, Kalakech A, Steiti A. Random forest algorithm overview[J]. Babylonian Journal of Machine Learning, 2024, 2024: 69-79.
- [70] Ke L, Zhang G, He J, et al. Pilot selection in the era of virtual reality: algorithms for accurate and interpretable machine learning models[J]. Aerospace, 2023, 10(5): 394.
- [71] Zhang Z. Introduction to machine learning: k-nearest neighbors[J]. Annals of translational medicine, 2016, 4(11): 218.

- Tang Y. Airline flight delay prediction using machine learning models[C]//Proceedings of the 2021 5th International Conference on E-Business and Internet. 2021: 151-154.
- [72] Alla H, Moumoun L, Balouki Y. A multilayer perceptron neural network with selective-data training for flight arrival delay prediction[J]. Scientific Programming, 2021, 2021(1): 5558918.
- [73] Hebbar P A, Bhattacharya K, Prabhakar G, et al. Correlation between physiological and performance-based metrics to estimate pilots' cognitive workload[J]. Frontiers in psychology, 2021, 12: 555446.