

学校代码 10702

密级 公开

中图分类号 TP391.4

学号 2006211068T



西安工业大学
Xi'an Technological University

硕士学位论文

多模态数据融合的操作员脑力
负荷检测研究

学位申请人：薛金娜

指导教师：王长元 教授

学科名称：软件工程

学位门类：工学

2024年5月



西安工业大学
Xi'an Technological University

硕士学位论文

题目：多模态数据融合的操作员
脑力负荷检测研究

作者 薛金娜

指导教师 王长元 专业技术职务 教授
学科 软件工程

西安工业大学

2024 年 5 月 中国·西安

**Multimodal Data Fusion for Operator Mental Workload
Detection Study**

by

Jinna Xue

Thesis Submitted to the faculty of the Xi'an Technological University in

Partial Fulfillment of

the Requirements for the Degree of

MASTER

in

Software Engineering

Supervisor: Prof.ChangYuan Wang

Xi'an Technological University

May 2024

Xi'an, Shaanxi, P.R.China

摘 要

人机交互是现代智能化发展的主流趋势，更是对“人”的工作状态提出了更高的要求，使得人的脑力负荷一定程度上被提升，而持续的高负荷脑力状态极易引发安全事故。脑力负荷是指操作者在有限的时间内执行工作任务所付出的认知资源。因此，本文提出了多模态数据融合的操作员脑力负荷决策研究方案，在保证操作者安全的同时能够有效提升其工作效率。本文进行模拟飞行环境下的人机交互操作任务，采集操作员的多生理信号，并对其特征提取及分析，使用多模态数据融合决策方法进行实验及理论研究。具体的研究内容如下：

1) 结合脑力负荷认知要求、模拟飞行实验设计和数据融合策略，形成了操作员脑力负荷数据采集方案。根据操作员的状态监测要求，进行模拟飞行实验设计；结合脑电采集仪、无线心电传感器和无线肌电传感器，通过同步测量采集系统实时记录模拟飞行作业任务下操作员的脑电、心电及肌电数据。

2) 进行基于生理信号的脑力负荷分类方法设计与分析，对操作员脑力负荷进行分析，并使用五折交叉验证及 AUC 进行指标评价。通过分析各生理电信号的决策效果，发现脑电信号对于脑力负荷决策的影响相对肌电及心电较高，且心电及肌电对脑力负荷决策有一定的影响，为基于深度学习的多模态数据融合研究提供了思路。

3) 将脑电信号作为研究的主要数据，分别搭建 ELSNet 与 ST-CNet 深度神经网络模型，对比融合心电及肌电前后的脑力负荷决策性能。对比研究结果，发现两种决策模型下的多模态数据融合决策分类研究准确率比基于脑电的分类决策分别提高了 7.11% 和 6.98%；对比模型中各模块的性能，发现脑力负荷决策的效果与模型的完整度成正比。与前人的研究方法进行对比，发现 ELSNet 与 ST-CNet 模型对脑力负荷的决策效果均有所提高，分别提高了 3.63% 和 7.54%。

综合以上研究方法，本文结合航天飞行的环境因素，构建模拟飞行环境下操作员状态监测实验平台。并从各生理信号及多模态数据融合的角度出发，设计实验并采集多生理电信号数据，以此来进行基于生理信号的脑力负荷分类设计分析和多模态数据融合脑力负荷决策分析。研究结果表明，各生理信号及多模态数据融合的脑力负荷状态分析方法，能够有效地反映操作员的脑力负荷决策效果，且多模态数据融合的脑力负荷决策效果更佳。

关键词：脑力负荷；生理电信号；机器学习；神经网络；多模态数据融合

本研究得到国家自然科学基金（编号：52072293）和陕西省重点研发计划项目（编号：2024GX-YBXM-126）资助。

Abstract

Human-computer interaction is the mainstream trend of modern intelligent development, which puts higher requirements on the working state of "human", it making the human mental workload elevated to a certain extent, and the continuous high load of mental state is very likely to cause safety accidents. Mental workload is the cognitive resources devoted by the operator to perform a work task in a limited time frame. Therefore, this paper proposes a multi-modal data fusion research program for operator mental workload decision-making, which can effectively improve the operating efficiency of operators while ensuring their safety. In this paper, we carry out a simulated human-computer interaction operation task in a flight environment, collect the operator's multi-physiological signals, extract and analyze their features, and carry out experimental and theoretical research using a multi-modal data fusion decision-making method. The specifics of the study are as follows:

1) An operator mental workload data acquisition program was developed by combining the cognitive requirements of mental workload, flight simulation experimental design, and data fusion strategies. According to the operator's state detection requirements, combined with the EEG collector, wireless ECG sensor, and wireless EMG sensor, the EEG, ECG, and EMG data of the operator under the simulated flight operation task are recorded in real-time by the synchronized measurement and acquisition system.

2) The design and analysis of the physiological signal-based mental workload classification method to analyze the operator's mental workload and the metrics are valued using five-fold cross-validation and AUC. By analyzing the decision-making effect of each physiological electrical signal, it is found that the influence of EEG signals on mental workload decision-making is relatively high compared to EMG and ECG and that ECG and EMG have an effect on mental workload decision-making, which provides an idea for the research of multimodal data fusion based on deep learning.

3) Taking EEG signals as the primary data of the study, ELSNet and ST-CNet deep neural network models were structured to compare the performance of mental workload decision-making before and after fusion of ECG and EMG. Compared to the research results, it was found that the classification study accuracy of the multimodal data fusion decision-making under both decision-making models was improved by 7.11% and 6.98% over the EEG-based classification decision, respectively. Compared to the performance of each module in the model, it is found that the effect of mental workload decision-making is directly proportional to the completeness of the model. Compared to the previous research methods, it is found that the decision-making effect of ELSNet and ST-CNet models on mental workload are both improved,

Increased by 3.63% and 7.54%, respectively.

Combining the above research methods, this paper combines the environmental factors of space flight to construct an experimental platform for operator state detection under a simulated flight environment. From the perspective of physiological signals and multimodal data fusion, we design experiments and collect multiphysiological electrical signal data, to carry out the brain load classification design analysis based on physiological signals and multimodal data fusion mental workload decision analysis. The results show that the mental workload state analysis method of each physiological signal and multimodal data fusion can effectively reflect the operator's mental workload decision-making effect, and the multimodal data fusion mental workload decision-making effect is better.

Key Words: Mental Workload; Physiological Signal; Machine Learning; Multi-modality Data Fusion

The present work is supported by the fund of National Nature Science Foundation of China (Project No: 52072293) and the Key Research and Development Project of Shaanxi Province (No. 2024GX-YBXM-126).

目 录

1 绪论.....	1
1.1 研究背景及意义.....	1
1.1.1 研究背景.....	1
1.1.2 研究意义.....	2
1.2 脑力负荷概述.....	2
1.2.1 脑力负荷的定义.....	2
1.2.2 脑力负荷的理论研究.....	3
1.3 国内外研究现状.....	5
1.3.1 生理信号处理的研究现状.....	5
1.3.2 数据融合相关研究进展.....	6
1.3.3 脑力负荷分类的研究现状.....	7
1.4 本文研究方案.....	9
1.4.1 主要研究内容.....	9
1.4.2 论文组织结构.....	10
2 生理信号与数据融合理论基础	11
2.1 脑电信号基础知识.....	11
2.1.1 脑电信号的产生机制.....	11
2.1.2 脑电信号的特点.....	12
2.1.3 脑电信号的分析方法.....	12
2.2 心电信号基础知识.....	15
2.2.1 心电信号的产生机制.....	15
2.2.2 心电信号的特点.....	15
2.2.3 心电信号的分析方法.....	15
2.3 肌电信号基础知识.....	18
2.3.1 肌电信号的产生机制.....	18
2.3.2 肌电信号的特点.....	18
2.3.3 肌电信号的分析方法.....	19
2.4 数据融合方法.....	19
2.4.1 数据层融合方法.....	20
2.4.2 特征层融合方法.....	21
2.4.3 决策层融合方法.....	21
2.5 本章小结.....	22
3 操作员脑力负荷实验及数据采集	23
3.1 操作员脑力负荷状态分析	23

3.2 数据采集设备.....	24
3.3 实验过程.....	27
3.3.1 实验对象.....	27
3.3.2 实验平台.....	28
3.3.3 实验设计.....	28
3.4 本章小结.....	32
4 基于生理信号的脑力负荷分类研究.....	33
4.1 脑力负荷分类模型组件设计.....	33
4.1.1 支持向量机分类方法组件设计.....	33
4.1.2 朴素贝叶斯分类方法组件设计.....	34
4.1.3 K-近邻分类方法组件设计.....	34
4.2 基于脑电信号的脑力负荷分析.....	35
4.2.1 脑电通道选取.....	36
4.2.2 脑电信号预处理.....	36
4.2.3 脑电信号特征提取.....	38
4.2.4 脑电特征脑力负荷分类结果分析.....	39
4.3 基于心电信号的脑力负荷分析.....	41
4.3.1 心电信号预处理.....	41
4.3.2 心电信号特征提取.....	42
4.3.3 心电特征脑力负荷分类结果分析.....	43
4.4 基于肌电信号的脑力负荷分析.....	44
4.4.1 肌电信号预处理.....	45
4.4.2 肌电信号特征提取.....	45
4.4.3 肌电特征脑力负荷分类结果分析.....	46
4.5 结果对比与性能分析.....	48
4.5.1 结果对比.....	48
4.5.2 性能分析.....	48
4.6 本章小结.....	49
5 多模态数据融合的脑力负荷决策研究.....	50
5.1 ELSNet 决策模型.....	50
5.1.1 模型架构.....	50
5.1.2 类 EEGNet 模块.....	51
5.1.3 LSTM 模块.....	51
5.1.4 模型损失函数.....	52
5.2 ST-CNet 决策模型.....	52
5.2.1 模型架构.....	52
5.2.2 类 Transformer 模块.....	53
5.2.3 卷积模块.....	55

5.2.4 模型损失函数.....	57
5.3 评价指标.....	57
5.4 结果分析与讨论.....	57
5.4.1 ELSNet 模型决策结果分析.....	57
5.4.2 ST-CNet 模型决策结果分析.....	58
5.4.3 实验结果对比分析.....	60
5.5 本章小结.....	61
6 结论与展望.....	62
6.1 研究总结.....	62
6.2 未来展望.....	63
参考文献.....	64

1 绪 论

本章节中，主要从研究背景、研究意义、脑力负荷概述及国内外研究现状等多个方面出发，对脑力负荷状态检测的意义及其常用的主要方法进行相关概述。在本章的最后一节将对本篇毕业论文的主要研究内容和整体的组织结构进行简要的梳理与介绍。

1.1 研究背景及意义

1.1.1 研究背景

在人类社会的发展过程中，人机交互中“人-机-环境”间的相互制约与发展促进了工业进程的进展。随着科学技术的迅速发展，现在的作业任务对信息的依赖程度较强，并且伴随着多任务的特点等。操作员在进行相关的工作当中需要获取到较多的仪表数据信息，并与所在工作环境相结合进行综合分析，从而快速且准确做出相应的决策。在相关的操作过程中需要高度集中注意力，可能会产生较大的脑力劳动^[1]，不仅会影响工作效率，更有甚者将会造成严重事故。由此可见，在人机交互中，脑力劳动逐步占据了优势。脑力劳动的强度可以用脑力负荷进行衡量，脑力负荷主要产生于操作员使用有限的脑力资源进行任务处理的工程中。适当的脑力负荷有助于操作员对良好任务绩效的保持，而过高或过低的脑力负荷则将会对操作中的绩效造成不利影响。

在快速发展的科技水平背景下，现如今人们的日常工作多依赖于脑力活动，易使人们的精神状态长时间处于紧绷的环境中。长期的高脑力负荷状态及在现代电子产品的诱惑而缺乏锻炼使得人体极易处于亚健康状态，对于外部环境的感知能力下降、思考和执行力也相应降低，进而影响到作业质量及操作设备安全。例如，据航空事故研究报告可知，有60%~90%的飞行事故发生于飞行员脑力负荷强度过高，应激任务水平大的飞行中^[2]，在飞行任务中需要处理的信息变得越来越大且更加复杂，包含了导航信息、气象情况、飞行器状况以及目标识别等多个方面，使得飞行员需要同时处理多方面的数据，增加了飞行员在工作任务中的脑力强度。在防空导弹、医疗抢救以及高效驾驶等复杂的人机交互操作中，伴随着高负荷的人机交互任务。如在导弹武器行动中，需要实现精确而快捷的对战斗目标航向、速度等空间情报的分析，同时快速实现对战斗目标威胁的评估用以实施目标追踪和攻击等相关复杂动作。由于该过程具有较大强度的人机交互作业任务，高强度的作业极易导致脑力操作者陷入超负荷状态，因而降低作业过程中的安全性和可靠性，极易引发安全事故。因此，脑力负荷的研究对于人机交互中的安全性及可靠性显得尤为重要。

脑力负荷的概念最早于20世纪80年代提出，学者们主要就脑力负荷的影响原因、内在机理以及测量方法等方面进行了深入的研究及探讨。近年来，研究人员持续关注有关操作人员的脑力负荷问题^{[3][4]}。

1.1.2 研究意义

根据上述研究背景可知,飞行员脑力负荷状态的检测研究对于解决飞行员状态安全和选拔训练中的人因问题具有关键意义,在军民航空领域中应用需求迫切,在操作飞行驾驶中对提高飞行的安全性、飞行员训练及操作流程的优化,以及飞行环境的改善都具有较大的影响。本文基于《国家自然科学基金》的支持,将综合运用理论和实验方法,研究操作员脑力负荷的影响因素及变化规律,建立操作员脑力负荷状态检测决策模型。本次研究中,操作员是指在“人-机-环境”中进行操控任务的作业人员。操作员在作业任务中通过处理大量的信息来进行相关决策,并需时刻保持较高的警觉性,进行脑力负荷的研究对操作员的作业任务具有以下重要意义:

1) 脑力负荷是基于飞行任务的复杂性以及其较高的要求的关键因素。脑力负荷的研究能够确保操作员在不同的飞行阶段及任务中做出有效的信息处理及决策,由此可以减少操作员作业任务中认知过载所存在的风险。

2) 研究操作员的脑力负荷可以改善飞行员的培训计划。通过对操作员在训练过程中的脑力负荷状态进行检测和分析,可以根据检测和分析结果来调整操作员的培训强度和训练内容,以确保操作员在不同情况下能够更好地适应飞行作业任务和应对作业中的要求。

3) 脑力负荷的研究有助于改进操作员的工作环境。通过优化驾驶舱的人机交互方式可以降低操作员的脑力负荷,使其能够关注关键任务,由此提高飞行的安全性和效率。

4) 高程度的脑力负荷极易导致操作员的认知疲劳及情绪负担,进而对其工作表现及心理健康造成影响。通过研究脑力负荷可以帮助检测其心理健康风险,从而采取恰当的方式来进行预防措施。

综上,脑力负荷的研究在飞行驾驶人机交互的研究具有重要意义。为了保证操作员在作业任务中的自身安全,本研究在进行操作员脑力负荷的研究中,运用了非侵入式生理传感器进行数据采集,通过对所得数据进行特征的提取和选择,使用多模态数据融合的方法,建立操作员脑力负荷决策模型,根据操作员的生理参数信息来判别其脑力负荷程度,确保其在作业任务中的主观警觉度,进而到达预防事故发生的目的。

1.2 脑力负荷概述

伴随科学技术的快速发展,大部分人类活动已由体力劳动向脑力劳动转变。在航天驾驶、医疗手术及重大机械操作等复杂的作业环境,人类大脑均需投入较大的认知资源。研究表明,脑力负荷的程度对操作员的作业效率具有较大的影响。人体大脑结构复杂且操作员易受外部环境等因素的干扰,因此对操作员的脑力负荷检测研究极为重要。

1.2.1 脑力负荷的定义

脑力负荷(mental workload, MWL)又被称作心理负荷、精神负荷,最早应用于人类工效学领域,主要是用以评价估计任务需求和人类能力需求间存在的差异^[5]。脑力负荷的内

涵较为复杂且抽象,学术界对脑力负荷定义没有较为一致的说法。目前比较具有说服力的有以下几种:

19 世纪 80 年代北大西洋公约组织在脑力负荷学术专题讨论会议上将脑力负荷总结为:脑力负荷是一个多维概念,它涉及到工作要求(task demand),时间压力(time pressure),操作者的能力(operator' capacity)和努力程度(effect),行为表现(performance)和其他许多因素^[6];卫宗敏等人^[7]从工作要求的角度出发,将其定义为:操作员在工作时对某项作业任务的处理速度,即操作中的判定结论速度及其对应的处理难度;Buchner 等人^[8]从资源占用的角度出发,将其定义为:操作员在作业任务过程中所占用自身注意力资源的程度大小,即作业任务中,操作员脑力负荷的占用程度大小与操作员所剩的作业操作表现为负相关。

Melnicuk 等人^[9]从工作时间占有率和信息处理情况两方面对脑负荷力作出了界定:时间占有率越低,表示操作过程中所耗费的脑负荷力程度越低,反之则越高;信息处理强度则表示在单个作业任务时间内工作人员所需要进行信息处理的总量或操作过程中信息的繁忙程度,即执行脑力工作实际有多忙。信息处理强度越高,操作员脑力负荷程度越强,反之则越低。

1.2.2 脑力负荷的理论研究

脑力负荷的多维性特征,使得其影响因素具有多面性。工作内容对于脑力负荷具有最直接的影响。在同等条件下,工作内容越多、完成所需时间越长、任务精确度要求越高、完成过程越复杂,操作员作业过程中脑力负荷程度越高^[10]。根据脑力负荷影响因素间的关系主要有以下几种典型研究:

1) 耶基斯-多德森定律(Yerkes - Dodson Law)

心理学家 Yerkes 和 Dodson 对作业动机程度和工作绩效的关系进行了相关研究,得出了耶基斯-多德森定律^[11]。该定律表明,动机的最佳水平并非固定不变的,而是会依据任务的性质发生改变,在不同难度工作任务中,随着操作者对任务的动机水平变化,工作的效率水平也会随着发生变化。动机强度、任务类型与工作效率的关系如图 1.1 所示。




图 1.1 耶基斯-多德森定律

在简单任务中，随着动机强度的增高，效率可以随着工作动机强度的增加而达到最佳状态；在中等程度的任务中，中等程度的动机工作效率最高；在复杂或苦难任务中，较低的工作动机使得工作效率最佳。

2) “三阶段”模式

Graça 等人^[12]通过对影响脑力负荷因素的工作绩效进行研究，得到了其关系的“三阶段”模式，如图 1.2 所示。




图 1.2 脑力负荷“三阶段”模型

该模式将脑力需求曲线分为三个区域：A 区域指低负荷需求的操作员在工作中具有较高的工作绩效，且工作绩效并非随着需求的增加而增高；B 区域指明了随着工作需求的增加和脑力负荷程度的增高，工作绩效在逐步下降；C 区域得出在脑力需求负荷过高的情况下操作员的工作绩效下降到了最低水平，随着作业需求的升高，工作绩效基本不发生变化且稳定在最低水平。由此可以得出：只有在 B 区域时，工作绩效对作业需求及脑力负荷需求变化较为敏感，工作绩效会随着作业需求的变化而发生改变。在 A 区域和 C 区域的变化对工作绩效的影响不大。

3) “倒 U 型”模型

“倒 U 型”模型是 Chen 等人^[13]在“三阶段”模式的研究基础上得到的，能够更加有效地反映脑力负荷与工作绩效之间的关系。该模型是在“三阶段”模型的基础上增加了 D 区域，同时将低作业需求下的 A 区域划分为了 3 个部分，分别为 A1、A2、A3，如图 1.3 所示。

“倒 U 型”模式中 D 区域表示脑力负荷尚处于未激活状态，体现了作业任务需求过低情况，在该区域中，随着作业需求的增高，操作员的脑力负荷处于下降状态且工作绩效逐渐上升。在 A 区域中，虽然工作绩效并未随着工作需求的增加而改变，但操作员的脑力负荷会随之发生改变。在被划分为 A1、A2、A3 三部分的 A 区域中，可以看出：在 A2

部分,工作需求的增加不会对操作员的脑力负荷及工作努力程度提出更高的要求,只需保持在前一水平即可保持工作绩效的最优状态,且脑力负荷维持在最低水平。在 A3 区域中,随着飞行操作任务需求的增加需要操作员付出更多的努力来完成增加的需求任务,进而使得脑力负荷水平不断升高来保持工作绩效的最优状态。




图 1.3 脑力负荷“倒 U”型模式

1.3 国内外研究现状

脑力负荷作为认知心理学的一个重要概念,在国内外受到了极大的关注。其研究对于不同领域的实践应用都具有较大的意义。本小节将从生理信号处理、数据融合及脑力负荷分类进行国内外研究现状介绍。

1.3.1 生理信号处理的研究现状

生理信号处理主要是对人体产生的生理信息进行采集、分析的相关过程。通过这些信息对于人类的认知负荷、情绪状况以及身体状态等^{[14][15]}进行分析,可应用于人机协同、精神心理学、医疗等领域^{[16][17]}。

在生理信号处理的各种研究中,常用的信号处理技术主要包括时频分析、频谱分析以及非线性动力学分析。这些方法常用于脑电峰值特征检测及疾病诊断等,如 Mahmoodian 等人^[18]将其用于检测脑电信号中的峰值特征,对 200 多个脑电图样本进行模拟实验,证明它能够抑制高斯噪声并产生反映更多信息的光谱结构。Rahman 等人^[19]将时频分析用于在时域和频域中映射脑电图信号,通过将信号数据划分为窗口并对其进行评分,可以在时频域中识别癫痫信号。Hosseini 等人^[20]使用 HOS 来分析神经营销领域的脑电信号,研究结果得到使用 SVM 和高斯核的模型在所有被试者中实现了 73.24% 的平均准确率。Luo 等人^[21]将 HOS 特征用于访问处于典型情绪状态但未表现出任何运动运动的受试者,使用 CNN 优化 Wigner-Ville 分布作为无参数输入,显示出其优于其他方法的明显优势。如 García

等人^[22]使用 Lyapunov 指数、复杂性度量和分形维数来分析脑电图信号。Attia 等人^[23]通过 Hurst 指数、Lyapunov 指数、样本熵、小波熵等指标有效提取脑电信号的特征。Subasi 等人^[24]通过研究分析排列熵和样本熵的算法过程,提出了一种名为等符号熵的新算法,并通过仿真验证了该算法在精度和效率方面的有效性。

心电信号的测量本质是对心脏进行电信号活动追踪。随着科学技术的发展,如今使用特征数量特别大的数据集变得较为普遍,这使得在数据处理过程中尤其是特征提取及信号分析过程变得更为复杂。El-Gindy 等人^[25]通过统计均值、中位数、峰度、偏度以及离散度中的标准差、范围等统计对被试者生物特征进行识别。Lin 等人^[26]使用主成分分析技术从 ECG 信号中进行特征提取,跟踪心房颤动期间心肌缺血或信号分离引起的时间变化,由此得到残差信号特征用于心率失常检测应用。Singh 等人^[27]通过使用离散化信号的当前值和过去值来建立自回归模型计算未来值,该方法可用于数据压缩和降低信号噪声。Pandey 等人^[28]使用离散余弦变换和自相关从 ECG 中提取特征,用以测试这些个体是否可以被系统识别。Tepe 等人^[29]使用本征时间尺度分解法进行心电信号去噪,有助于数据压缩,在该方法中使用小波去噪来保留 QRS 波群。

肌电信号的研究分析前需要进行预处理,主要是通过缩小尺寸,窗口化来提高分类精度。Accolti 等人^[30]通过重叠窗口和滑动窗口进行分割来提高分类器的准确率,尤其是获取新数据时,最大重叠窗口长度限制为 300 ms。Chen 等人^[31]使用的手势分类方法在半重叠大小的时间长度下实现了最高的预测精度。Ng 等人^[32]提出了一种高效的移动数据平均技术,通过抑制肌电信号噪声来提高信号质量。Prabhavathy 等人^[33]提出了一种基于变分模态分解(VMD)的表面肌电信号(sEMG)和肌肉肌电图信号(iEMG)的去噪技术,对去噪信号进行重构。肌电图电极记录的是通过模数转换器(ADC)产生的数字信号,最常用的去噪方法则是滤波处理,如 Li 等人^[34]使用工作频率为 50Hz 的滤波器来滤除干扰性电源频率。Torres-Castillo 等人^[35]将卡尔曼滤波器用于破译听觉信号,并使用经验模态分解法通过使用较少的参数设置来进行去噪处理。

综上各生理信号的处理方法可知,传统的线性方法难以准确评估生理信号的动态特征,因此难以揭示生理活动的本质特征。而利用非线性动力学方法提取和分析生理信号能够进一步研究人脑活动的过程和特征,并为操作员的大脑负荷研究中生理信号的处理提供了更为有效地方法。

1.3.2 数据融合相关研究进展

多信息融合(Multi-sensor Information Fusion, MSIF)在信息技术快速发展的互联网时代具有极大的参考价值,引起了较多学者的关注。MSIF 将多个信息源与空间、时间或互补信息约束相结合,从而具有充分利用各种信息源的能力。与原始传感器数据相比,多模态数据融合决策具有更一致、更丰富和更准确的决策效果。

MSIF 从信号处理及人工智能等各个领域出发,以基于统计推断和估计理论的传统融

合方法为理论基础,来进行多信息融合决策研究分析。近年来,基于人工智能和信息论等新方法的出现,使 MSIF 相关技术取得了较大进展。在本节中,对 MSIF 的体系结构、融合系统的模型以及信息融合的理论和方法的进展进行介绍^{[36][37]}。根据信息数据的处理级别,将 MSIF 分为了数据级、特征级以及决策级。数据级融合是低级的融合方法,用于其原始数据,可以获得高精度、可靠性和低噪声的数据输出,通常用于需要保留更多原始信息的信息融合场景。因此,数据级融合通常用于信号融合、图像融合及类似的应用。特征级融合的输入信息是已进行特征提取的数据,较数据层融合方法更加详细全面,能够展示数据的各种特征。决策级融合是进一步整合生成的信息来进行综合全面的决策,需要从全局出发,以获取更全面准确的结果。

信念函数理论将信念和合理性分配给可能测量假设的概念以及融合它们所需的组合规则,它处理涉及不确定性和不精确性的数据,可以被认为是贝叶斯理论的扩展,用于处理概率质量函数。旨在理解和完善 Fisher 的概率推理方法,主要包含了证据推理 (Dempster-Shafer, DST) 和 Dezert-Smarandache 理论 (DSmT)。DST 在 MSIF 领域中融合高度冲突的证据时,该规则可能会产生反直觉的结果。针对这一问题,Xiao 等人^[38]提出了广义证据 Jensen-Shannon 分歧法来衡量多个证据来源之间的冲突和差异。Nishad 等人^[39]提出了 DSmT 方法,将来自各种信息来源的证据融合到一组使用 D 函数表示的基本信念分配中,旨在解决 DST 在处理非排他元素时遇到的缺陷。Xiao 等人^[40]为了提高专家系统的不确定性推理,设计了一种基于 CECC 的加权多源信息融合算法 CECC-WDMSIF,用以增强 CET 专家系统的性能;通过对否定过程的研究,揭示了否定迭代的趋势,为知识表示、不确定性度量和量子信息融合提供了有希望的解决方案。

1.3.3 脑力负荷分类的研究现状

1) 基于生理特征的脑力负荷研究

对于操作员的脑力负荷研究,随着眼动追踪技术近年来的逐步完善,眼动特征成为了进行评价脑力负荷的重要指标。在进行有关的研究中可以通过眨眼次数、扫视路径长度等眼动特征和性能特征对认知负荷进行相关研究。基于眼动特征的脑力负荷研究方法总结如表 1.1 所示。

表 1.1 基于眼动特征的脑力负荷研究方法总结

作者	眼动特征	测评方法	评价指标	结果
Ahmad	瞳孔直径	朴素贝叶斯	分类准确率	85.83%
Wu	瞳孔直径、眼跳率	ANN、MWL	均值假设检验	P 值>0.05
Tolvanen	注视熵	朴素贝叶斯	分类准确率	84.7%
Orlandi	眼睛注视分布 AOI	NASA-TLX	准确率	80%

Ahmad 等人^[41]通过测量操作员在光照条件下的瞳孔直径(pupil dilation)进行脑力负荷评价工作,结果证明在通过瞳孔直径评价脑力负荷时还受到光照条件的影响。Wu 等人^[42]通过追踪瞳孔直径及眼跳率等眼动指标对于主观心理负荷的敏感性,结果证明了基于

ANN 的脑力负荷(MWL)的预测模型具备有效性。Tolvanen 等人^[43]通过研究测量操作者模拟机器人手术任务中的眼动注视熵特征来预测任务难度对脑力负荷引起的注视熵程度,结果证明注视熵随着任务难度的增加而增加。Orlandi 等人^[44]通过模拟船舶航行任务负荷操纵,来测量眼球注视分布随任务负荷的相关变化,得到在高注意力控制的个体工作负荷较低。

脑电图信号与特定的认知任务和精神状态具有较高的相关程度,可以用其来进行有关脑力负荷的评估研究,其方法如表 1.2 所示。

表 1.2 基于脑电信号的脑力负荷研究方法

作者	滤波范围/Hz	使用特征	主要方法	准确率/%
So	0.5-45	PLI	SVM、RBP	65%-75%
Liu	1-30	PSD	KNN	87.57%
Liu	1-40	ERD/ERS	CNN、SVM	89%、82%
Dimitrakopoulos	4-32	$\delta, \theta, \alpha, \beta$	ICA、PLI	75%
Gogna	0-30	PSD	SVM、RFE	91.3%
Ma	0.1-45	PSD	PCA、PCANet	95%

So 等人^[45]采用无限单通道研究有关短时额叶脑电信号对于脑力负荷的动态变化,研究表明 θ 波是 EEG 的常用特征,通过 SVM 模型进行脑力负荷分类研究,表明额叶 EEG 对脑力负荷的动态评估研究具备可信度。Liu 等人^[46]使用 NASA 任务负荷指数评分(NASA-TLX)评估和标记脑力负荷状态:通过快速傅里叶变换来提取生理特征信息,并比较 Kruskal-Wallis(K-W)检验进行特征选择,分析了来自不同大脑区域的脑电图特征的影响以及不同 MWL 水平的 PSD 变化,使用多类 K-最近邻分类器对不同 MWL 水平进行分类,获得了 87.57%的最优准确率。Liu 等人^[47]使用进行 n-back 任务的 fNIRS 脑电图进行脑力负荷分类检测研究,结果表明 CNN 较传统方法相比取得了较大的改进。Dimitrakopoulos 等人^[48]设计了两个不同的心理任务(心算任务、n-back 任务),使用 ICA 进行特征提取,并对四个频段(delta、theta、alpha、beta)的锁相指数(PLI)进行估计,在工作负载级别判别取得了 75%的分类准确率。Gogna 等人^[49]使用递归特征消除(RFE)技术消除所有贡献最小的特征,研究结果还显著显示了所选特征在三个工作量水平下的平均值变化 ($p<0.05$)。Ma 等人^[50]提出了整合主成分分析和主成分分析网络的深度学习模型进行脑电图特征提取。主成分分析被用来预处理 EEG 数据以减少其维度,以克服 PCANet 造成的维度爆炸的限制。

2) 数据融合的脑力负荷研究

脑力负荷的研究大多是对较为单一的特征进行分析,使得研究结果准确率相对较低,而对于多生理信号融合的脑力负荷研究则更具研究意义。

国外学者 Han 等人^[51]使用线性判别分析对于模拟操作工作中操作员的脑电信号、心电信号以及皮电等多生理信号进行了相关的脑力负荷研究分析,使用 LSTM 网络将提取

到的脑电信号外围特征与 CCN 提取到的特征融合输出, 最后实现分类。Wu 等人^[52]通过眼睛闭合度对操作者脑力负荷程度进行了分类, 同时使用额头电图与脑电图特征信息间的互补, 进行多模态信息融合, 结果表明, 特征融合拟合的方法使得性能明显提升。Lee 等人^[53]提出了使用短期(<30s)生理信号的非线性表示检测操作压力, 使用多模态卷积神经网络自动提取脚皮肤电化学反应、手皮肤电化学反应和心率信号的典型特征, 用于区分操作者的脑力负荷状态。

国内郑玲等人^[54]通过对操作员的生理信息和作业任务操作状况, 提出来多维信息融合的脑力负荷研究方法, 结果表明, 多维特征信息融合的脑力负荷研究方法明显优于较为单一的特征信息。李瑞等人^[55]结合迁移学习对生理信息的多维特征进行相关研究分析, 从时域和频域上对多生理信息特征进行融合, 其结果相较于传统方法取得了较大的进步, 为进一步研究多生理信号融合的脑力负荷研究提供了较大的价值。

综上所述, 目前脑力负荷的研究方法多以单生理信息或眼动特征为主。但眼动信息的测量对采集设备要求较高, 极易受到光线等环境因素的影响, 且均为间接测量, 获取的数据缺乏较高的准确性, 使得脑力负荷的分类决策准确率难以提升较大。而单生理信息的脑力负荷决策研究缺少全局性, 不能从多方面进行脑力负荷分类研究。由于脑电、心电以及肌电等生理电信号能够直接测量生理信息电活动, 因此可以从多生理电信号研究出发, 研究分析脑电、心电及肌电信号对于脑力负荷分类决策的有效性, 然后使用多模态数据融合方法对多生理电信号进行研究分析, 进行多模态数据融合的操作员脑力负荷检测研究, 使得脑力负荷状态检测研究更加全面。

1.4 本文研究方案

1.4.1 主要研究内容

本课题基于脑电、心电及肌电多生理信号建立多模态数据融合的脑力负荷决策模型。以往的研究中主要针对某一生理信息的一个或多个特征进行研究分析, 获取到的数据较为单一, 容易限制脑力负荷的状态评估。本课题主要基于模拟飞行操作任务设计操作员脑力负荷实验, 采集操作员的多生理电信号并进行多模态数据融合来建立脑力负荷决策模型。主要进行了以下内容的研究:

1) 数据采集实验

以实验室的研究环境为实验背景, 搭建模拟飞行实验环境, 设计并展开了操控类脑力负荷实验任务, 招募了 12 名志愿者进行数据采集工作, 并实时记录好模拟飞行实验数据及被试者的脑电、心电以及肌电数据。

2) 多生理数据预处理及特征提取

通过模拟飞行实验, 采集到了大量的生理数据。首先, 分别对脑电、心电以及肌电数据使用巴特沃斯低通滤波、高斯滤波等进行干扰伪迹去除的预处理。然后对脑电信号进行相关性分析并提取脑电信号的节律特征, 提取心电信号的心率变异率, 对肌电信号进行时

域及频域特征提取。

3) 基于生理信号的脑力负荷分类设计与分析

建立不同的脑力负荷分类方法,分别基于脑电、心电及肌电信号进行脑力负荷分类决策研究。通过输入不同的生理数据来分析脑力负荷状态,分别使用五折交叉验证及 AUC 对脑力负荷决策进行指标评价。同时,对比分析各生理信号对于脑力负荷状态监测的有效性。

4) 多模态数据融合的脑力负荷决策建模

在多模态数据融合中使用了特征层的数据融合方法,设计搭建了 ELSNet 和 ST-CNet 深度神经网络模型。分别对脑电、肌电、心电多模态数据融合,两两组合的生理数据融合及各生理数据进行脑力负荷决策研究,并对比各数据下的脑力负荷效果;同时,对比分析模型中各模块与整体模型的效果。

1.4.2 论文组织结构

论文总共包含六个章节,各章节主要内容如下:

第一章,绪论。首先介绍了操作员脑力负荷状态分析的研究背景及意义;然后对脑力负荷的定义、理论研究及测量方法进行了概述;其次总结了相关的国内外研究现状;最后对本文的研究内容及组织结构进行介绍。

第二章,生理信号与数据融合理论基础。对多生理电信号的产生机制、特点及分析方法和数据融合方法进行介绍,为后续多模态数据融合研究分析奠定理论基础。

第三章,操作员脑力负荷实验及数据采集。通过设计模拟飞行实验,使用同步测量采集系统对脑电、肌电及心电信号进行数据采集工作,并记录飞行实验过程中的飞行数据。

第四章,基于生理信号的脑力负荷分类研究。该章节根据各生理信号特点结合机器学习的相关算法设计脑力负荷分类方法,对脑电、心电以及肌电信号分别进行脑力负荷分析,并对分类结果进行对比分析。

第五章,多模态数据融合的脑力负荷决策研究。该章节分别搭建了以类 EEGNet 和长短期记忆神经网络为基础的 ELSNet 脑力负荷决策分类模型,和以类 Transformer 与卷积神经网络为基础的 ST-CNet 脑力负荷决策分类模型;对比分析了两类深度神经网络决策模型的研究结果,并分析各模型的不同模块的贡献程度。

第六章,结论与展望。总结分析主要研究内容 and 创新点,并对下一步的研究工作进行了展望。

2 生理信号与数据融合理论基础

随着生物传感技术的快速发展,基于生物传感器测量的脑电、心率、皮电等生理信息从人机交互、医学心理健康等领域被广泛研究。在多模态数据融合的操作员脑力负荷研究中主要基于多生理电信号融合进行操作员脑力负荷决策研究,在此研究基础上需要对生理电信号的相关理论基础进行一定的了解,本章节将从脑电信号、心电信号以及肌电信号的产生机制、特点和分析方法及数据融合方法进行介绍。

2.1 脑电信号基础知识

2.1.1 脑电信号的产生机制

根据医学研究可知,中枢神经中最重要的器官是大脑的组织结构,复杂的大脑对人类生命活动极为重要。脑电信号是大脑中神经元活动的产物,其产生机制涉及到神经元的电位变化及各个神经元之间的相互作用^[56]。神经元结构图如图 2.1 所示。




图 2.1 神经元结构图

神经元由细胞体和突起两部分组成。细胞体能够实现细胞内的信息整合并进行输出;突起包含轴突与树突,轴突能够进行兴奋冲动的传递,树突进行信息的接收。各个神经元之间通过突触连接,通过突触前神经元释放神经递质进行信号传递,进而影响突触后神经元的电活动。脑电信号则是由大量神经元活动的电位变化叠加而组成,而神经网络中的同步和异步活动都将会影响到脑电信号的幅度与频率。不同脑区间的神经元活动会产生不

同频率、时空特征的脑电信号,如果出现了脑区特异性,可根据脑电信号进行不同认知功能的研究。

2.1.2 脑电信号的特点

脑电信号的研究虽然已经成为了生物医学界研究人脑的主要渠道,但在研究过程仍然存在较多的阻碍。大脑可以影响到人类的情绪与认知活动,但其多变性及其自身较为微弱的特点使得测量研究分析较为困难。除此之外,大脑自身的复杂结构也会影响脑电信息分析。根据脑电信号的频率分布的范围状况则会为研究者们提供较大的研究便利与研究依据。

脑电信号具有较高时程分辨率,能够捕捉到毫秒级的神经元电信号活动,介于这一特点,其可用于相关电位的事件、反应时间以及神经元传递速度等,对于生理电信号的脑力负荷研究具有重要的研究基础。脑电信号具有较强的节律性特征^[57],能够在不同的频率范围下表现出不同的特性,主要包含了 δ 、 θ 、 α 、 β 和 γ 五个频带。其中 δ 的频率范围为0.5-4Hz,主要出现在深睡眠状态; θ 的频率范围为4-8Hz,主要出现在注意力分散、浅睡眠以及认知过程中; α 的频率范围为8-13Hz,主要常见于放松状态、闭眼养神时; β 的频率范围为13-30Hz,主要出现于认知任务及警觉状态中,有高低之分; γ 的频率范围为30-100Hz,主要出现于神经网络调节、人类的认知与感知处理中。根据不同频率脑电波与生理状态和注意力、情绪及睡眠等认知间的关系,脑电信号可被广泛应用于脑机接口、神经心理学、认知过程以及大脑与外部环境的交互等研究领域。

2.1.3 脑电信号的分析方法

脑电图是一种用于测量人体大脑各个区域的神经元活动的神经生理学技术。大脑是由大量神经元组成的,脑电活动产生于大脑不同的头皮电位,在不同的警觉状态、对外部刺激的反应以及个体因素下产生信号。在脑电信号的采集过程中需要使用适当的脑电采集设备,其采集方式有侵入式和非侵入式两种^[58]。侵入式的采集设备主要是将电极插入大脑皮层或大脑的其他区域用于采集信号;而非侵入式则是使用头皮表面的脑电信号采集传感器,不需要植入电极。目前大多数的脑电信号采集方法都是采用非侵入式的,以减少对人体的伤害。

根据非侵入式脑电采集设备的采集方式,可得知外部的干扰会对采集的数据产生各种干扰伪迹,进而会影响到采集到的数据质量。已知脑电信号中存在不自主的眼球运动、眨眼等生理伪迹,可能会产生负面影响^[59]。为了确保脑电信号中特征提取的可靠性,必须去除相关的伪迹。目前的降噪技术主要有回归分析法、盲源分离法、典型相关分析、小波变换法以及经验模态分解。

1) 回归分析法

回归分析法是去除脑电信号中的眼电伪迹的传统方法。该方法是在记录脑电图信号的同时记录眼电图,通过使用回归分析获得各种噪声源的系数,如闪烁伪迹(VEOG)、眼动

伪迹(HEOG)和其他噪声源。根据这些系数来估计特定的脑电通道中伪迹的比率。Noorbasha 等人^[60]提出了一个一般滞后回归模型表示去除伪迹过程,如公式(2.1)所示。

$$egg(t) = EEG(t) - \sum_{g=0}^T \beta_g eog(t-g) \quad (2.1)$$

其中 $EEG(t)$ 和 $eog(t-g)$ 是记录的 EEG 和 EOG 在时间 t 和 $t-g$ 的信息, $EEG(t)$ 表示未去除伪迹的, $eog(t)$ 是在回归系数 β_g 的测量效果。但是回归方法主要是针对于双向伪迹处理。例如, EOG 记录中可能包含眼电位和神经电位。因此, 从脑电信号中去除眼电活动则需要从每次的记录信息中删除一部分的脑电信息。此外, 在回归分析法中缺乏明确的电极参考通道, 则对其他伪迹的处理可能效果不佳, 如 EMG 伪迹。

2) 盲源分离法

盲源分离法表示在事先不了解原始信号的情况下将源信号和混合信号分离的技术。首先是将脑电图分解成其来源, 识别并去除噪声源的同时保留大脑活动源, 其通常用于脑电信号的去噪, 主要有独立成分分析和主成分分析。

a、独立成分分析

不同研究中所提出的各类型独立成分分析(Independent Component Analysis, ICA)算法使得其成为了生理电信号处理的关键盲源分离技术之一。独立成分分析能够从生理信号中提取出统计学上的独立信号源。使用 ICA 去除伪迹如公式(2.2)所示。

$$X = AS \quad (2.2)$$

其中, 给定了 X 、 A 、 S 三个涉及方程的矩阵。矩阵 X 为 EEG 数据, 矩阵 A 表示各种源(如 EEG 和伪迹源)的线性混合, 独立组件共同组成了矩阵 S , 例如大脑和伪迹。通过独立组件来检查识别伪迹, 如眨眼等活动, EEG 信号可以通过去除这些伪迹组件来降噪。

由于脑电信号和肌电伪迹信号在时间与空间域中存在显著重叠, 传统的 ICA 算法通常难以去除所有肌电图伪迹并生成一组独立的分量。为了解决这个问题, Li 等人^[61]提出了在 ICA 模型的基础上增加 EMG 源进行改进的 EMG 去除模型。该模型是将来自头部和颈部肌肉的肌电图参考伪迹作为 ICA 的输入, 来增加了一些独立组件中肌电图伪迹的功率, 从而实现更准确的伪迹去除。在与传统的 ICA 算法研究结果对比验证中, ERASE 算法从 EEG 信号中去除的 EMG 伪迹平均高出 26%。Maddirala 等人^[62]设计了一种将 ICA 与连续小波变换进行合并的去噪框架, 连续小波变化和 K-means 算法用于映射检测到的眨眼伪迹。然后, 通过 ICA 进行去噪时保留脑电图信息。

b、主成分分析

主成分分析(Principal Component Analysis, PCA)是一种易于使用的数据缩减技术, 它利用正交性原理来消除伪迹。利用 PCA 降维, 可以消除数据中由小特征值表示的噪声。通常, 给定脑电图数据 X , PCA 的主要目标是求解方程(2.3)。

$$XX^T w_i = \lambda_i w_i \quad (2.3)$$

其中, λ 表示特征值, ω 表示特征向量。首先通过分解矩阵的特征值来实现数据降维, 然后对得到的特征值进行排序, 并选取顶部的 d 值作为投影矩阵, 投影矩阵主要是将 D 表示的 EEG 数据转换为 $D^*=W^TD$, 可以较大限度的降低噪音。

3) 典型相关分析

在脑电图信号被肌电伪迹影响的情况下, 典型相关分析(canonical correlation analysis, CCA)通常比 ICA 更有效。由于与大脑活动相比, 肌电伪迹自相关相对较低, 因此采用经典相关分析作为区分肌电活动和大脑活动的手段是可行的, 用于脑电信号去噪的公式如公式(2.4)所示。

$$\max_u \frac{u^T R_{xy} v}{\sqrt{u^T R_{xx} u} \sqrt{v^T R_{yy} v}} \quad (2.4)$$

其中, u 和 v 表示规范向量, 是脑电通道的线性组合。脑电数据和伪迹数据具有协方差矩阵, 分别用 R_{xx} 和 R_{yy} 表示。脑电数据和伪迹数据间的交叉方差矩阵用 R_{xy} 表示。获取典型变量后通过减法消除用于伪迹去除。

4) 小波变换法

小波变换主要分为离散小波变换和连续小波变换^[63]。根据脑电信号的连续性特性, 在其处理中主要使用离散小波变换, 可表示为公式(2.5)。

$$DWT(m, n) = \int_{-\infty}^{+\infty} x(t) \psi_{m,n}(t) dt \quad (2.5)$$

其中 m, n 分别表示缩放因子和平移因子。离散小波分析的过程是将 $x(t)$ 分解为各种规模, 如公式(2.6)所示。

$$x(t) = \sum_{j=1}^K \sum_{k=-\infty}^{\infty} d_j(k) \psi_{j,k}(t) + \sum_{k=-\infty}^{\infty} a_k(k) \phi_{K,k}(t) \quad (2.6)$$

该方程涉及以 $\psi_{j,k}(t)$ 表示的离散分析小波和以 $\phi_{K,t}$ 表示的离散缩放函数。 $d_j(k)$ 表示小波系数。

5) 经验模态分解法

经验模态分解是一种用于分析非平稳和非线性信号的技术。它利用信号极值点将信号分解为一组本征模态函数(Intrinsic Mode Function, IMF)和一个单调残差, 如公式(2.7)所示。

$$x(t) = \sum_{i=1}^n C_i(t) + r_N(t) \quad (2.7)$$

其中, C_i 代表 IMF, r_N 代表单调残差。IMF 能够捕获不同频率的基本振荡分量, 这有助于区分伪迹与预期的 EEG 信号。要获得信号的高频信息的具体信息, 可以从输入信号中减去包络线。包络代表通过信号局部最大值和最小值的平滑曲线。这种技术可以在保留原始脑电信号的同时, 消除不需要的伪迹信息, 将清除后的分量相加即可得到重建信号。

2.2 心电信号基础知识

2.2.1 心电信号的产生机制

心电信号(Electrocardiogram, ECG)是一种记录心脏电活动的生理信号,主要反映了心脏在心跳活动过程中的电位变化情况。心电信号是心肌细胞兴奋-传导-收缩的过程中产生的微小电位变化,其波形图如图 2.2 所示。




图 2.2 心电信号波形图

心电图中包括了 P 波、QRS 波群及 T 波。心脏中的传导系统将电信号从心脏的起始点(即窦房结)传递到心脏的其他各个地方。兴奋首先从窦房结传递到心房,进而引起心房收缩,产生 P 波;然后通过房室传递进入到心室的各个部位,由此产生 QRS 波群;最后心室复极产生 T 波。

2.2.2 心电信号的特点

心脏的节律性活动由心电信号的周期性变化来反映,从一个心搏开始到下一个心搏开始的心跳活动过程代表了心电信号的周期性变化。心电信号是由一系列的波形变化而组成的,心电图的波形代表着心脏电信号活动的不同阶段^[64]。

在心电波形图中, P 波用来表示心房的兴奋和收缩过程; QRS 波群用来表示心室的兴奋及收缩过程; T 波用来表示心室的复极过程; PR 间期、QT 间期和 ST 间期是心电信号在不同波形之间的时间间隔提供的心脏信息。异常的心电波形和间期能够提示心动过速、心房颤动以及心动过缓等心律失常情况。对于心电信号的波形、时间间隔及节律特性的分析研究可应用于有关于心脏健康及诊断的医学研究等方面。

2.2.3 心电信号的分析方法

对于心电信号的分析方法主要是从心电信号中提取出心律失常、心脏健康及其他相关

信息。在易受到基线漂移与各种噪声影响的心电信号预处理方法中主要使用滤波和去除噪声来提高信号质量；对于心率分析则是通过测量 R 波和 R 波间隔来进行心率计算；心动过速、过缓及心房颤动等心律失常可以使用自动化算法进行异常心电波形的检测；心肌缺血及心肌梗死可能使 ST 段异常变化，因此可通过 ST 段的偏移分析进行检测；心室复极的时间 QT 间期能够进行心电图评估心脏是否存在潜在的问题^[65]。这些方法能够单独使用或者组合使用来进行认知负荷及医学领域的研究。

预处理阶段中，可以使用一种 q 滞后无偏有限脉冲响应平滑技术，优化选择 N 个 ECG 数据点和最小化均方误差，以此来去除伪迹并进行各种特征识别，在 P 波、Q 波、S 波和 T 波的起始点以及 R 波和 T 波的峰值特征提取，进行心律失常与正常的分析^[66]。结合时域信息能够进行最佳的时间分辨率但缺少频率信息，而频域分析则能够提供最佳的频率分析分辨率但缺少时间信息。可通过时频分析技术结合两者的优势进行心电信号分析研究，主要有短期傅里叶变换、连续小波变换、离散小波变换、Winger-Ville 分布法以及 Hilbert Huang 变换法。

1) 短时傅里叶变化

在短时傅里叶变化方法(Short-Time Fourier Transform, STFT)中，首先将原始信号分解为较小段的“L”长度，然后计算每段的傅里叶变化(FT)。对于连续的时间信号 $x(t)$ ，可以用公式(2.8)表示 STFT 系数。

$$X(\tau, \omega) = \int_{-\infty}^{\infty} x(t)w(t-\tau)e^{-j\omega t} dt \quad (2.8)$$

其中， $X(\tau, \omega)$ 是 FT， w 为窗口函数， t 和 τ 分别表示时间和频率轴。原始信号 $x(t)$ 可以使用逆 STFT 得到，其表达式如式 (2.9) 所示。

$$x(t) = \frac{1}{2} \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} X(\tau, \omega) e^{-j\omega t} d\tau d\omega \quad (2.9)$$

为计算离散时间信号的 STFT，可以使用离散傅里叶变换(Discrete Fourier Transform, DFT)代替 FT，如公式(2.10)所示。

$$X[m; k] = \sum_{n=0}^{L-1} x[m+n] e^{-j\omega n k} \quad (2.10)$$

其中， m 表示局部 DFT 的起点， k 表示 DFT 指数， L 表示窗口或段的长度， $X[m, k]$ 取决于时间(n)和频率(ω)的傅里叶系数。

2) 连续小波变换

小波变换方法主要是通过在时间及频率上提供适合的分辨率解决与 FT 相关的问题，连续小波变换则将给定的信号分解为不同系数，如公式(2.11)所示。

$$CWT_{\tau, s, \psi}(x) = \frac{1}{\sqrt{s}} \int_{-\infty}^{\infty} x(t) \psi_{\tau, s}^*(t) dt \quad (2.11)$$

其中 $1/\sqrt{s}$ 用于归一化 ψ 。采用连续小波变换产生的变换信号取决于缩放因子 s 和平

移因子 τ 。较低的 s 值会导致小波的快速变化,能够用于检测信号的较高频率,而较高的 s 值有助于检测低频成分。原始信号的重建可通过公式(2.12)进行。

$$x(t) = \frac{1}{2\pi\psi} \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} \frac{1}{2} CWT_{\tau,s,\psi}(x) e^{-j(t-\tau/s)} d\tau ds \quad (2.12)$$

频谱图是连续小波变换的绝对值与时间和频率的函数关系,频谱图由于其不同尺度的信号特征能够提供更多信息。

3) 离散小波变换

离散小波变换是对于时间序列信号进行缩放函数和小波函数的正向小波变换,其公式分别如公式(2.13)和(2.14)所示。

$$W_{\varphi}(j_0, k) = \frac{1}{\sqrt{m}} \sum_n x(n) \varphi_{j_0, k}(n) \quad (2.13)$$

$$W_{\psi}(j, k) = \frac{1}{\sqrt{m}} \sum_n x(n) \psi_{j, k}(n) \quad (2.14)$$

其中 $x(n)$ 为时间序列信号,其样本数为 m 。则 $x(n)$ 可使用缩放函数和小波函数表示为公式(2.15)所示,可称其为逆离散小波变换。

$$x(n) = \frac{1}{\sqrt{m}} \sum_k W_{\varphi}(j_0, k) \varphi_{j_0, k}(n) + \sum_{j=j_0}^{\infty} \sum_k W_{\psi}(j, k) \psi_{j, k}(n) \quad (2.15)$$

4) Winger-Ville 分布

Winger-Ville 分布(WVD)能够在时频域中对信号能量进行定量表示,通过使用自相关函数来进行功率谱计算。自相关函数(ACF)将信号 $x(t)$ 与时移(τ)进行比较,表示为公式(2.16)。

$$ACFx = \int x(t)x(t+\tau)dt \quad (2.16)$$

自相关函数中将信号进行内积分,使它成为一个仅依赖于 τ 的函数。而 WVD 使用瞬时自相关函数(IACF)的 ACF 变体来设置时间参数,如公式(2.17)所示。

$$IACF = x(t + \frac{\tau}{2})x^*(t - \frac{\tau}{2}) \quad (2.17)$$

WVD 将不同时间和频率的信号与当前的进行对比,可看做是 IACF 上的 FT,可表示为公式(2.18)。

$$WVD_x(t, \omega) = \frac{1}{2\pi} \int_{-\infty}^{\infty} x(t + \frac{\tau}{2})x^*(t - \frac{\tau}{2})e^{-j\omega\tau} d\tau \quad (2.18)$$

与 STFT 相比, WVD 具有更好的光谱分辨率。但当信号具有多个频率分量时,输入信号中存在多个部分,就会发生交叉项,其时间和频率节拍相似。通过在时频平面上使用

滑动平均窗口来调制 WVD 函数，可以最小化交叉项。

5) Hilbert Huang 变换

Hilbert Huang 变换 (HHT) 是对 EMD 进行扩展。从原始信号中获取到 IMF 后,对 IMF_i 进行 HT, 可表示为公式(2.19)。

$$z_i(t) = IMF_i + jd_i(t) = A_i e^{j\theta} \quad (2.19)$$

其中 $z_i(t)$ 是通过 IMF 进行希尔伯特变换获得的解析信号。

2.3 肌电信号基础知识

2.3.1 肌电信号的产生机制

肌电信号 (Electromyogram, EMG) 是一种用于记录肌肉电活动的生理信号,其产生于动作电位在肌肉表面引起的微小电流变化,这些微小电流扩散于肌肉纤维及表面,进而形成了肌电信号,主要包括神经冲动、动作电位、细胞膜变化以及肌肉收缩,其电位变化如图 2.3 所示。




图 2.3 肌电信号电位变化图

2.3.2 肌电信号的特点

根据肌电信号的波形、振幅以及频率等各种特点,能够通过对其进行分析可以获取有关肌肉功能、运动控制以及相关疾病的相关信息^[67]。通过肌肉收缩及放松的电位变化产生的一系列波形变化,能够反映出肌肉的静息状态、放松以及收缩等阶段的电位变化,而在收缩过程中的时间持续变化时间较短,相比之下放松的时间较长,由此体现出肌电信号的时程特性;肌肉的振幅变化能够根据肌肉的收缩强度进行反映,当肌肉的收缩程度越强产生的肌电信号电活动振幅则越大;肌电信号的频率范围取决于肌肉的类型以及活动,通

常在 20-150Hz 之间, 类型不同的肌肉及运动方式则会产生不同频率特征的肌电信号; 而在各种不同的肌肉协调模式活动中, 能够反映出肌肉间的协调及活动机制。

2.3.3 肌电信号的分析方法

肌电信号在各种疾病诊断、康复、认知意图识别中必不可少, 对其进行研究分析时, 需要先进行预处理, 用于确保 EMG 数据后期分析的效果^[68]。预处理方法主要包括降噪、基线校正、滤波和归一化^[69]。而对其时域特征、频域特征等特征的提取对于实现肌肉活动的全面表征研究较为重要, 对其进行分类的方法多为机器学习和深度学习^[70]。下面将从这些方面对肌电信号的分析处理方法进行介绍。

运动神经元的两个细胞内动作电位导致神经肌肉接头相互相反放电时, 就会产生电位差, 它们通过使每根肌肉纤维去极化和复极化来传递。运动单元中所有肌纤维的细胞内联合动作电位称为运动单元动作电位(MUAP)。由此, 多列 MUAP 的线性平均值构成了 EMG。当骨骼肌进行收缩时, 会存在静态和动态肌肉收缩两种不同的类型。在动态收缩期间, 关节运动和肌肉纤维长度不同。由于动态收缩期间关节运动和肌肉纤维的长度不同, 可以使用随机过程对 EMG 信号进行建模, 根据均值和协方差可能随时间几乎保持不变, 可考虑使用静态收缩模型(MMSC), 如公式(2.20)所示。

$$EMG(t) = \sum_{i=1}^N s_i(t) * m_i(t) \quad (2.20)$$

其中 N 代表由肌肉纤维和运动神经元组成的运动单元(MU)的总和, $s_i(t)$ 表示运动单元活动时刻的脉冲链, $m_i(t)$ 是每个运动单元的 MUAP, 可用于进行卷积。当身体受到温度或者疲惫的影响时, 则可能出现非平稳过程, 此时使用动态收缩模型(MMDC), 如公式(2.21)所示。

$$EMG(t) = a(t)w(t) + n(t) \quad (2.21)$$

其中 $a(t)$ 表示肌电信号强度函数, $w(t)$ 为一个单位方差的高斯过程, 用于表示肌电信号的随机分量, $n(t)$ 代表传感器噪声及生物信号伪迹。

进行肌电信号分类分析中的机器学习模型中主要分为监督式和无监督式。未处理的输入与处理的输出数据之间以监督方法为基础进行数学模型的建立; 而无监督方法则是试图在不知道输出的情况下识别原始输入数据的模式。而深度学习的方法则是包括了从输入到输出整个过程的全面方法, 该过程从初始输入数据开始, 通过多层网络自主执行特征提取和模型学习, 能够使用较少的参数来拟合复杂的函数。在深度学习模型进行肌电分类方法中, 主要有卷积神经网络(CNN)、循环神经网络(RNN)等。

2.4 数据融合方法

数据信息融合是对多种数据进行综合分析使得能够获取到更加丰富且准确的信息。按照数据融合的层次结构特点可分为数据层、特征层以及决策层融合三个层次级别^[71]。

在脑力负荷决策分析整体架构中，各构件通过连接件进行数据间的信息传递及交互。数据层融合能够将各数据源的有效信息最大限度应用分析；特征层融合可以将各数据源提取的有效特征进行融合分析，缩减数据量的同时获取高效的决策效果；决策层融合能够在较高的容错率下实现多源数据的综合评估分析。因此，将数据融合方法与系统架构中的组件和构件联系起来，可以构建一个端到端的数据融合和决策支持系统。在进行多生理信号的数据融合中，主要使用集中式的体系结构，其框架如图 2.4 所示。




图 2.4 集中式融合的体系结构图

在进行实际的数据融合应用时，可根据数据采集的传感器设备来选取其中的融合方法，也可将这三种融合方法结合使用。本小节将对多模态生理电信号融合在这三个层次的融合方法进行介绍，在后续的多模态数据融合脑力负荷决策模型中可选取其中的一种或多种综合应用。

2.4.1 数据层融合方法

数据层融合是在原始数据上的融合方法，核心是对原始数据进行修正校准、跟踪以及关联分析等方法消除冗余的同时尽可能多的保留原始数据，并对其进行局部信息的融合，使得能够获取到更精确的决策效果，如图 2.5 所示。




图 2.5 数据层融合

数据层融合的优势在于能够保留较多的原始数据,相比于其他层级的融合能够提供细微信息。在进行数据层融合时,需要进行大量的数据处理以至于消耗时间较长,且对原始数据的精度、完整性以及稳定性具有较高的要求。

2.4.2 特征层融合方法

特征层融合是指对数据的不同特征进行整理融合,是在特征层的联合判别。在特征层融合中能获得更多的目标状态特征,可以扩大特征维度,从而获取到较多有价值的特征信息,融合过程如图 2.6 所示。




图 2.6 特征层融合

在进行特征融合前需完成对原始数据的预处理工作,同时应将多维度数据的格式进行统一化表示,即进行数据配准工作。常用的特征层融合方法有聚类分析法、加权平均法、神经网络以及特征拼接等。相较于数据层融合,在进行特征融合时会对原始数据进行压缩处理,虽然能够提高数据时效性,但也会丢失部分数据信息。

2.4.3 决策层融合方法

决策层融合主要是针对不同类型的数据,每种类型的数据各自分别经过一系数的数据操作后进行子决策,然后再进行决策级的融合判别获得最终的决策结果,融合过程如图 2.7 所示。




图 2.7 决策层融合

相较于数据及特征层融合方法,该方法可以对异步性的数据信息进行融合分析。在进行决策级融合时,具有较高的容错率,对生理电信号的传输要求相对较低,所需的数量较小,但在前期的数据处理方面则相对麻烦。

2.5 本章小结

在多模态数据融合的操作员脑力负荷研究中,以多生理电信号为基础,使用数据融合的方法对操作员的脑力负荷状态进行监测评估。为了更好地对脑力负荷进行研究分析,本章通过对脑电信号、心电信号及肌电信号的产生机制、特点以及分析方法和数据融合方法进行理论基础介绍,为后期基于生理信号的操作员脑力负荷分类研究奠定一定的生理信号研究理论基础。

3 操作员脑力负荷实验及数据采集

本章节中,对数据采集进行了实验设计,实时记录了被试者飞行操作过程中的飞行数据信息,并使用与生理信号采集设备对应的同步测量系统实时记录脑电、心电、肌电数据。结合脑力负荷决策方案,根据模拟飞行过程中的飞行精度制定了实验中的标签数据,以此构建脑力负荷决策数据集。为后续基于生理信号的脑力负荷分类研究和多模态数据融合的脑力负荷决策研究提供了数据支持。

3.1 操作员脑力负荷状态分析

在模拟飞行的操作员脑力负荷状态监测评估中,主要涉及了从实验设计、模拟飞行平台搭建、数据采集、数据传输及整理到最终的状态分析各个过程。在此主要划分为数据采集层、网络层、数据服务层以及应用层四个方面,其整体结构分析如图 3.1 所示。




图 3.1 操作员脑力负荷状态分析图

数据采集层主要包含进行操作员生理信号数据采集的各生理信号采集传感器,以及进行模拟飞行操作过程的飞行仿真和飞行操作输入设备。生理信号采集传感器负责采集被试者在模拟飞行过程中脑电信息、心电信息和肌电信息,并将这些信息转化为数字信息以便于进行操作员的脑力负荷状态检测分析;飞行仿真用于指导操作员进行模拟飞行实验,而飞行操作设备用于辅助模拟飞行过程中的操作输入。

网络层包含了进行无线数据传输的物理设备和用于数据传输的逻辑通信。物理设备根据实验场景进行脑力负荷实验数据的实时采集,通过无线数据传输的方式进行原始数据的传递;而数据逻辑通信中,可以采用 TCP、UDP 以及串口等数据通信协议,实现脑力负荷实验数据的高效准确传输。

数据服务层负责将采集到的原始数据进行一系列的数据管理及数据运算,以便于进行脑力负荷状态分析。数据管理能够确保采集到数据的安全性和完整性;数据运算可以对原始数据进行处理和分析,以此来提取有效信息。

应用层则包含了应用软件、数据融合和脑力负荷状态分析。应用软件分为记录生理信号数据的同步测量采集软件,以及进行模拟飞行及实时飞行数据记录的模拟飞行软件;数据融合可以实现多生理信号融合的操作员脑力负荷状态分析。

3.2 数据采集设备

在本次多模态数据融合脑力负荷研究中,主要使用了多生理电信号进行分析研究飞行员脑力负荷状态,其总体架构如图 3.2 所示。



图 3.2 脑力负荷状态分析整体架构图

进行操作员脑力负荷状态分析时，首先是进行实验数据采集，通过无线传输进行实验数据记录，然后进行脑力负荷状态分析。数据采集，包含各生理信号数据采集传感设备，本节分别对其进行介绍。

生理电信号的采集设备分别为脑电、心电以及肌电信号，各采集设备传感器参数如表 3.1 所示。

表 3.1 实验采集设备参数

采集设备	数据类别	测量范围 (uV)	采样率
32 导脑电采集仪器	脑电数据	-3000~+3000	256Hz
无线心电采集仪器	心电数据	-1500~+1500	1024Hz
无线肌电采集仪器	肌电数据	-1500~+1500	512Hz

在进行多生理数据采集时，使用了同一厂家提供的同步测量采集系统，以闭眼时的脑电信号为例展示系统脑电同步测量如图 3.3 所示。




图 3.3 系统脑电同步测量图

根据同步测量系统中被试者闭眼时，脑电信号出现了较为明显的的跳跃性变化，由此可以得出生理信号同步测量系统能够有效地进行脑电信号的实时监测采集。

1) 脑电采集设备

在脑电数据采集中，使用了脑电帽采集设备，如图 3.4 所示。可用其对应的平台采集系统进行脑电数据的实时记录。



图 3.4 脑电信号采集设备

该脑电帽为 32 导水电极，以湿海绵作为传导介质，配备 10-10 标准脑电导联系统，其电极如图 3.5 所示。脑电电极端口分别包含了额区的 FP1、FP2、AP3、AF4、Fz、F3、F4、F7、F8、FC1、FC2，顶区的 Cz、C3、C4、CP1、CP2、P3、P4、Pz，颞区的 T7、T8、FC5、FC6、CP5、CP6、P7、P8，以及枕区的 PO3、PO4、O1、O2、Oz。




图 3.5 脑电电极端口分布图

2) 心电采集设备

在心电数据采集，使用了同步测量采集系统所对应的配套无线心电采集设备，该采集设备能够用于记录心脏从感受到刺激至趋于平静的电活动变化过程。进行数据采集的过程中对实验人员具有较小的影响，且具备较大的抗干扰能力。心电数据采集设备包含三个电极，进行采集时每个电极需根据对应的位置进行导电电极贴片穿戴操作，采集设备及对应连接如图 3.6 所示。




图 3.6 心电采集设备及连接图

其中，图 3.6(a)为进行心电信号采集的无线心电采集仪器，3.6(b)为心电采集仪器所对应的连接示意图。

3) 肌电采集设备

在进行肌电信号的采集中，本研究所选用的采集设备是 ErgoLAB 同步测量采集系统配备的 EMG 无线肌电采集仪器。肌电数据采集设备包含三个电极，进行采集时每个电极需根据对应的位置进行导电电极贴片穿戴操作，采集设备及对应连接如图 3.7 所示。其中，图 3.7(a)为无线肌电采集仪器，3.7(b)为肌电采集仪器对应的连接方式。




图 3.7 无线肌电传感器及连接示意图

3.3 实验过程

3.3.1 实验对象

本次人机环境下的模拟飞行实验中，招募选取 12 名志愿者作为研究对象，年龄为 20

到 30 周岁之间，身高为 165cm 到 180cm 之间，并要求志愿者各方面的身体状况良好且不存在精神方面的疾病。在试验期间不能服用各种药物，实验环境不会对被试者造成伤害。试验前，需对被试者进行专业培训，以便于他们能够对实验环境有良好的适应。受试人员在实验前应进行适应性模拟飞行实验练习，熟悉飞行任务要求。参与此次试验的志愿者应提前签署知情同意书，以保证后续实验的合法性。

3.3.2 实验平台

在进行数据采集前，需要进行实验设计并搭建好模拟飞行实验平台。该平台由硬件及软件两部分组成，如图 3.8 所示。其中，3.8(a)为实验环境的硬件平台，主要包括了用于模拟飞行体感的六轴全动平台底座、进行模拟环境展示的三联显示器、进行飞行操作的飞行摇杆、飞行脚踩以及油门控制器、数据采集仪器和主机等。



(a)实验硬件平台搭建

(b)模拟飞行实验场景

图 3.8 模拟飞行实验平台

飞行环境仿真部分将 Steam 中的 DCS world 作为飞行仿真平台，以模拟飞行驾驶座舱为实验环境，其对应的硬件操作平台为一平三下的人机交互环境，用以进行模拟飞行实验，模拟飞行实验场景如图 3.8(b)所示。在进行飞行过程中，被试者能够对仿真画面进行实时切换及操作，能够随时对飞机座舱内和舱外切换，便于及时观察飞行过程中的各种情况。

3.3.3 实验设计

在模拟飞行实验过程中，主要以五边飞行为基本飞行任务。在基础飞行任务的基础上，设计并添加一定的刺激测试事件，以及视觉注视类飞行事件检测；通过进行该模拟飞行实

验, 获取得到实验数据, 实验设计图如图 3.9 所示。针对脑力负荷检测的模拟飞行实验任务使用了五边飞行巡航训练项目, 在进行操控训练项目的各个工作阶段中均设置了飞行航向、速度以及高度的要求。实验数据的采集过程中, 要求被试者应当在完成实验作业任务的同时, 以自身的最大限度尽力接近实验所设置的飞行精度要求。




图 3.9 实验设计图

1) 设计思路

脑力负荷可以用于表示操作员在进行模拟飞行任务过程中为最大程度完成任务所承受的认知决策压力, 能够反映出其在该作业任务阶段的信息处理能力及认知资源专注程度。操作类作业任务的脑力负荷状态监测主要是根据操作员在进行飞行实验过程中各生理信息变化情况进行脑力负荷状态监测评估。

在本次脑力负荷决策实验设计中, 主要是采集作为样本数据的生理电信号和作为标签数据的飞行数据。其中生理电信号主要包括 EEG、ECG、EMG, 而飞行数据则包含了飞行航向、飞行速度以及飞行的高度。信息的处理强度指的是操作者在进行操作作业任务中要完成的作业量或作业程序的难度, 它与脑力负荷的程度成正比。由于不同被试者的信息处理能力存在一定差距, 为了保证数据的真实可靠性, 则可用飞行精度来对各被试飞行任务下的生理数据进行标签设置。进行飞行实验设计中, 在设定巡航飞行的线路时, 可以根据飞行任务设定整个巡航工作过程中的飞行参数, 以飞行设定的参数与实际飞行中的数据进行对比, 获取实验过程中的飞行精度。以此为依据, 对同步采集到的生理信号数据进行脑力负荷程度标签设置。为模拟被试者在处理较高强度的操作任务, 实验中可以添加随机触发的视觉注视类事件检测工作, 要求被试者在进行正常的飞行操作类工作任务下处理随机产生的其他作业任务, 以此来获取到高脑力负荷状态下的实验数据。

2) 实验任务

本实验设计主要以起飞、降落以及巡航等飞行作业任务为主要的模拟飞行实验操作训

练,旨在评估飞行员的操作类任务处理能力。起飞降落等飞行训练项目作为本次实验的主要作业任务,能够根据不同被试者的飞行操作水平,针对飞行过程中各阶段的飞行精度及被试者的生理信息来获取到操作者在各飞行任务阶段中的状态变化。在进行飞行训练中,飞行操作者由起始点开始起飞后,环绕飞行一周之后进行降落返回到起始点,整个飞行过程中包含了五个飞行航向边,则可被称作五边飞行。

一次完整的模拟飞行操作任务主要包含了 9 个阶段,分别是第一边的起飞阶段、第五边的降落阶段、从第 2 边到第 4 边的 3 个航行、各个航行边的 4 个转向,其航行线路如图 3.10 所示。




图 3.10 飞行实验航行线路图

在整个模拟飞行过程中设计了 4 个关键的航向点,操作员在距离航向点 1.6 海里的位置处开始执行转弯操作,要求在进行转弯操作时将其半径保持在 1.6 海里左右。进行一次完整的实验任务需要消耗大概 30 分钟,被试者在完成一场完整的飞行操作作业任务返回降落到起点后,对所驾驶的飞机不进行完全的减速操作,随后加速进行起飞的操作任务,接着进行新一轮的模拟飞行操作任务。每次的模拟飞行实验可以操作完成多次的五边飞行航向任务。

在进行模拟飞行操作类任务时,对飞行操作任务过程中的各个阶段均制定了航向、速度以及高度等参数信息,作为被试者在进行数据采集过程中的飞行操作标准。飞行实验任务中各参数信息如表 3.2 所示。

根据实验的飞行操作参数信息,可以发现,整个实验过程中,主要包括进行直线的航行阶段和进行转弯操作的转向阶段。在被试者所操作的航行高度到达所设定的直线航行高

度时认定为被试者开始执行空中航行任务。因为直线航行部分占用了整个飞行实验过程中的极大部分,则该过程是进行被试者状态监测观察的主要阶段,飞行的参数信息依据了飞行的质量标准对直线航行过程的特点进行了相关设定。在进行实验操作任务时,要求被试者进行持续两次的起降实验过程。

表 3.2 飞行任务参数信息要求

航行阶段	航行线路	飞行任务参数信息要求
起飞过程	第一边	从地面开始加速起飞到高度位 650m, 航行方向为 95°, 航行速度为 250 节(463km/h)。
直线航行过程	第二边	保持航行高度为 650m, 航行方向为 05° 的直线航行, 航行速度为 250 节(463km/h)。
	第三边	保持航行高度为 650m, 航行方向为 275° 的直线航行, 航行速度为 250 节(463km/h)。
	第四边	保持航行高度为 650m, 航行方向为 185° 的直线航行, 航行速度为 250 节(463km/h)。
转弯过程	第 1~2 的转弯	
	第 2~3 的转弯	保持航行高度为 650m, 航行速度为 250 节(463km/h), 将转弯半径
	第 3~4 的转弯	保持在 1.6 海里(2963m)左右。
	第 4~5 的转弯	
降落过程	第五边	转完后到达跑道的航行方向 95°, 进行降落操作。

3) 飞行精度

从飞行任务要求来看,航空飞行实验过程中要求被试者对各个飞行操作阶段中的高度、速度以及航向进行一定的感知,在整个任务过程中添加有随机的事件检测类任务。脑力负荷的认知实验则是对被试者在飞行操作类任务中的飞行表现作为飞行绩效,也就是飞行精度。用它来进行评估模拟飞行实验中不同的时间范围下被试者的脑力负荷状态,将其作为同步测量采集系统采集到的生理数据的标签数据,由此来进行各生理信号的状态评估,形成数据集。具体的数据采集过程如图 3.11 所示。




图 3.11 数据采集过程

为了确保被试人员因其他外界因素或误操作引起飞行偏差。实验要求被试人员在中午

1 点至 3 点及晚上 9 点至 11 点进行实验采集工作。实验开始时, 首先对模拟飞行游戏软件及生理信号采集设备进行调整调准; 然后被试者需进行一个场次的飞行适应训练, 在此过程中不进行数据采集工作; 正式的数据采集过程中, 需要连续进行 2 次起降飞行操作实验; 数据采集过程中, 模拟飞行软件记录实际的飞行参数数据, 各生理采集设备同步记录各生理信号数据。

本次实验将飞行精度作为标签数据, 以 3 秒为一个数据条宽度进行样本截取, 获取到有效样本 71600 条, 包括了高负荷样本和低负荷样本, 分别为 31800 条和 39800 条, 将该数据作为脑力负荷决策数据集。

3.4 本章小结

本章节主要进行了模拟飞行实验设计, 实验以模拟飞行平台及生理电信号采集设备为硬件基础, 以生理电信号同步测量采集系统及 DCS world 飞行驾驶为软件基础, 搭建了飞行仿真交互平台, 能够对实验内容及人员进行动态调整, 以保证采集到的实验数据较为丰富且确保数据的有效性。为后续研究操作员脑力负荷状态检测研究提供了数据支撑, 便于下一步的研究分析。

4 基于生理信号的脑力负荷分类研究

前一章节进行数据采集实验，已经采集获取到了大量的脑电、心电、肌电数据。本章节将基于机器学习的方法对各生理信号的脑力负荷分类进行研究与分析。首先是进行分类方法的设计；然后对各生理信号进行预处理及特征提取，将处理后的各生理数据在不同分类方法下进行脑力负荷分类研究分析；最后对不同分类模型的结果进行对比分析，并对各生理信号的脑力负荷分类结果进行分析，对比各生理信号对脑力负荷分类的有效性。

4.1 脑力负荷分类模型组件设计

4.1.1 支持向量机分类方法组件设计

根据数据的特征向量分布可使用支持向量机对其进行脑力负荷分类研究，其目的是找出可以将标签类别分割开的超平面，其实现过程如表 4.1 所示。假定数据集 x 具有 n 维特征，则其对应的目标超平面 D 表示为公式(4.1)所示。

$$w^T x + b = 0 \quad (4.1)$$

表 4.1 支持向量机实现过程

Algorithm SVM

Input: 训练数据集 Dx

Output: 预测结果

步骤 1.随机初始化参数，参数 b 初始为 0

步骤 2.误差计算 $E=F(x_i)-y_i$

步骤 3.对各参数的向量梯度进行计算

步骤 4.权重更新

end

其中， w 为超平面的方向。此时，当训练数据样本符合公式(4.2)时，该 n 维特征向量与所找到的超平面的距离如公式(4.3)所示。

$$\begin{cases} w^T x_i + b \geq 1, y_i = 1 \\ w^T x_i + b \leq -1, y_i = -1 \end{cases} \quad (4.2)$$

$$d = \frac{|w^T x + b|}{\|w\|} \quad (4.3)$$

在非线性问题中，使用高斯径向基作为核函数，如公式(4.4)所示。

$$K(X_i, X_j) = \exp\left(-\frac{\|X_i - X_j\|^2}{2\sigma^2}\right) = \exp(-\gamma\|X_i - X_j\|^2) \quad (4.4)$$

其中, K 为 n 维特征空间内积, γ 为该核函数的核参数。

4.1.2 朴素贝叶斯分类方法组件设计

朴素贝叶斯分类中首先假定给出了类别, 且进行分类计算的特征都是条件独立的, 因此, 某一特征出现的概率与其他的各类特征均无关系。根据其算法原理, 如果需要确定数据样本 x 的类别 b 的后验概率, 则首先需要获取类别 b 的先验概率、证据因子以及条件概率。根据大数定律可知构成模型训练样本的数据集出现的频率与证据因子接近。将其条件概率表示为 $P(b|x)$, 则其计算方式如公式(4.5)所示。

$$P(b|x) = \frac{P(b)P(x|b)}{P(x)} \quad (4.5)$$

其中, b 为样本, x 代表其属性, $P(b)$ 为先验概率, $P(x|b)$ 为该类条件概率, 代表了 b 包含属性类别的可能性。其实现过程如表 4.2 所示。

表 4.2 朴素贝叶斯分类实现过程

Algorithm NBC

Input: 训练数据集 Dx

Output: 预测结果

步骤 1. 计算每个类别的先验概率, 如 $P(b)$

步骤 2. 计算每个类别的条件概率, 如 $P(b|x)$

步骤 3. 对新样本 x_{new} 进行分类:

3.1 计算各类别的后验概率

3.2 将具有最大后验概率的类别作为预测结果。

end

4.1.3 K-近邻分类方法组件设计

K 近邻的基本思想是通过对未标记的新样本与训练数据集已标记过的样本距离进行比较, 其距离代表着样本的相似程度, 来选择距离最近的 K 个样本, 由此进行训练预测。假设其特征空间 χ 是由 n 维的特征向量构成的向量空间 R^n , 则可将其距离 L_p 表示如公式(4.6)所示。根据距离不同的度量, 可以确定不同的最临近点。

$$L_p(x_i, x_j) = \left(\sum_{l=1}^n |x_i^{(l)} - x_j^{(l)}|^p \right)^{\frac{1}{p}}, \quad p \geq 1 \quad (4.6)$$

此处, 在 $p=2$ 时, 可称之为欧氏距离, 如公式(4.7)所示。

$$L_2(x_i, x_j) = \left(\sum_{l=1}^n |x_i^{(l)} - x_j^{(l)}|^2 \right)^{\frac{1}{2}} \quad (4.7)$$

在 $p=1$ 时, 将其称为曼哈顿距离, 如公式(4.8)所示。

$$L_1(x_i, x_j) = \sum_{l=1}^n |x_i^{(l)} - x_j^{(l)}| \quad (4.8)$$

在 p 为 ∞ 时, 则表示为坐标距离的最大值, 如公式(4.9)所示。

$$L_\infty(x_i, x_j) = \max_l |x_i^{(l)} - x_j^{(l)}| \quad (4.9)$$

在 K 近邻分类决策中, K 值的选择会直接影响到预测结果。如果所选择的 K 值过小, 则会使得决策判别结果对样本十分敏感, 对模型整体的预测结果影响较大; 如果选择的值过大, 则会使得与当前样本差距较大的邻域数据被用于预测, 从而增加了预测的近似误差。所以, 在进行实际训练预测中, 通常会预先根据数据样本对不同 K 值下的 K 近邻性能进行遍历探索测试来选取最佳值, 在此过程中, 如果有 n 个特征, 则其计算过程中的时间复杂度为 $O(n*k)$, 其实现过程如表 4.3 所示。

表 4.3 K -近邻实现过程

Algorithm K-近邻

Input: 特征向量 x

Output: K 值

for k to $K_{\max}$

 步骤 1. 随机选取 k 个质心

 步骤 2. 计算各样本距质心的距离, 将小于阈值的划分为一类

 步骤 3. 根据上一步得到的分类重新计算质心

end

4.2 基于脑电信号的脑力负荷分析

脑电信号是进行脑力负荷分析的主要数据, 其进行脑力负荷分类分析的流程如图 4.1 所示。




图 4.1 EEG 的脑力负荷分析流程

在进行基于脑电信号的脑力负荷分析时，主要包括脑电通道选取、数据预处理、脑电节律信息提取，并分别进行 KNN 分类方法、NBC 分类方法以及 SVM 分类方法的脑力负荷分类决策研究。

4.2.1 脑电通道选取

在进行脑电的脑力负荷分类研究中，由于采集到的 32 通道的脑电数据量太大，在进行脑力负荷分类训练中耗时较长，为了降低训练过程中的难度，则需要减少一定的脑电通道数。为了保证减少数据量的同时能够保留较多的有效信息，通过阅读相关的参考文献及脑电信号中脑力负荷相关的脑部区域，最终选择了 14 个通道的脑电极数据^[72]。其中 A1 和 A2 是零势能参考电位，因此不参与模型的训练，进行具体的实验时，仅选择其中一个便可。选用的其他脑电通道分别是前额叶的 Fp1、Fp2 电极；额叶的 F4、F8 电极；中央脑区的 C3、Cz、C4 电极；顶叶的 Pz、P4 电极；枕叶的 O1、Oz、O2 电极，各电极的分布位置如图 4.2 所示。




图 4.2 选择的电极分布位置

4.2.2 脑电信号预处理

在本次基于脑电信号的脑力负荷分类研究中，主要关注进行飞行操作实验中被试者的脑电相关事件。脑电信号采集设备主要是通过各个电极来采集获取大脑神经元活动产生的细微电位差信号，能够采集到的电压信号变化范围在 $-1500\mu\text{V}$ 到 $+1500\mu\text{V}$ 之间，在实际的采集使用过程中容易被其他干扰信号所影响，这些干扰信息常被称作伪迹信息。常见的干扰伪迹信息被分为生理信号伪迹干扰信息和非生理伪迹干扰信息。生理伪迹干扰信息是进行脑电信号采集过程中，被试者的其他身体部位神经元活动引发的电位差混进脑电信号采集里；而非生理伪迹干扰信息则是进行实验过程中，环境及其他设备产生的电磁伪迹信息混入其中。

在进行伪迹去除时,假设实验过程中采集到的数据为 $Bs(t)$, 将实际的脑神经元活动产生的 EEG 设为 $Es(t)$, 将干扰信息设为 $Hs(t)$, 由此可以得到 $Es(t)$ 的计算公式如(4.10)所示。

$$Es(t) = Bs(t) - Hs(t) \quad (4.10)$$

根据国内外脑电信号相关处理研究可知,部分伪迹干扰信息在某些频率范围存在较为显著的信息,例如生理干扰伪迹之中的心跳干扰在 0.01~1.4Hz 中较为显著。实验环境及设备伪迹干扰信息中主要是城市用电过程中的交流电磁干扰,其频率主要在 50Hz。由此,可以根据伪迹干扰的频率范围进行伪迹滤波处理,其计算公式如(4.11)所示。

$$E_{signal}(t) = B_{signal}(t) - NF_{physiology}(t) - NF_{ElectricSupply}(t) \quad (4.11)$$

其中, $NF_{physiology}$ 为滤波处理器, B_{signal} 为脑电采集设备获取到的脑电信号信息, E_{signal} 为大脑神经元活动的电位活动差信息。

对获取到的脑电数据分别进行频谱和时频分析,对比分析滤波处理前后的脑电信号频谱图,能够发现频率范围在 50Hz~80Hz 之间,有一个较为稳定的伪迹干扰信息,为城市交流电干扰,对比如图 4.3(a)、(b)所示。滤波处理前后的时频对比如图 4.3(c)、(d)所示。




图 4.3 EEG 预处理前后对比分析图

4.2.3 脑电信号特征提取


根据目前的生物医学、心理认知学以及神经学等有关研究可以得到,脑电信号具有较强的节律特征。与脑力负荷相关的脑电节律特征主要包含了 δ 、 θ 、 α 和 β 这四个频段的信息,这些频段的特征与大脑神经元活动具有极为密切的联系,各个频段的节律特征见表 4.4 所示。

表 4.4 脑电信号基本节律

基本频段节律名称	对应频率范围(Hz)	振幅 (μV)	人体生理对应状态
δ	1~4	20~200	深度休息, 无梦的睡眠
θ	4~8	20~150	深度放松的
α	8~13	20~100	平静
β	13~30	5~20	意识专注, 记忆, 解决问题


根据相关性分析, EEG 信号的 δ , θ , α , β 指标在 0.05 的显著性水平下, EEG 指标在高负荷状态和低负荷状态均存在显著性差异, 且 P 值处于同一量级范围, 为此, 本次研究对 EEG 指标做进一步统计性分析, 相比于低负荷状态, 高负荷状态时上述四个指标的均差值都有增加, 其中 Pz、Cz 和 Oz 的 δ , θ , α , β 值变化最为显著, 部分结果如图 4.4 所示。

Mann-Whitnet U 检验主要用于检测两组样本是否来自于同一主体, 等价于判断两组样本均值是否具有显著性差异, 其利用数据的大小顺序来判断两组样本差异, 计算公式如式(4.12)-(4.17)所示, 本文利用 Python3.6 中的科学计算 `scipy.stats.mannwhitneyu` 进行处理。



(a)不同样本下 $(\alpha+\theta)/\beta$ 的结果

图 4.4 部分样本的 Pz、Cz 和 Oz 的 δ , θ , α , β 结果

(b)不同样本下 α/β 的结果图 4.4 (续图) 部分样本的 Pz、Cz 和 Oz 的 δ , θ , α , β 结果

$$U_1 = n_1 n_2 + \frac{n_1(n_1-1)}{2} - T_1 \quad (4.12)$$

$$U_2 = n_1 n_2 + \frac{n_2(n_2-1)}{2} - T_2 \quad (4.13)$$

$$U = \min(U_1, U_2) \quad (4.14)$$

$$\mu_U = \frac{n_1 n_2}{2} \quad (4.15)$$

$$\sigma^2 = \frac{n_1 n_2 (n_1 + n_2 + 1)}{12} \quad (4.16)$$

$$Z_U = \frac{U - \mu_U}{\sigma_U} \quad (4.17)$$

其中 n_i ——第 i 组样本容量, T_i ——第 i 组样本序列和($i=\{1,2\}$)。

4.2.4 脑电特征脑力负荷分类结果分析

在基于脑电信号的脑力负荷分类决策建模过程中,进行支持向量机的分类决策时,使用了本章第一小节设计的高斯径向基作为SVM的核函数,将脑电信号的各频段节律特征映射到对应的特征空间向量中。在进行K-近邻分类研究时,将其K值的范围预先设定在[1,30]之间,进行对比参数设置范围内的所有K值所对应的分类决策模型失误率,如图4.5所示。通过对比发现,最佳的K值选取应为2。在进行脑力负荷分类效果评判时,使用五折交叉验证法和AUC进行评价分析。




图 4.5 不同 K 值下 KNN 脑电脑力负荷决策模型失误变化图

在进行五折交叉验证下，得到各分类方法的准确率如表 4.5 所示。对比分析可以得到在基于脑电信号的脑力负荷分类决策中，支持向量机的分类效果最佳，准确率能够达到 77.18%；其次是 K-近邻分类方法，准确率能够达到 67.54%；准确率效果最差的是朴素贝叶斯分类算法，准确率为 59.37%。使用 AUC 对不同分类方法结果进行对比分析，其对应的 ROC 曲线结果如图 4.6 所示。

表 4.5 基于脑电信号的三种分类决策方法准确率对比表

模型	KNN	NBC	SVM
准确度	67.54%	59.37%	77.18%




图 4.6 三种决策模型 ROC 曲线对比图

根据结果图可以得知 K-近邻分类方法的 AUC 值最高, 最终结果为 0.754; 其次是支持向量机分类方法, 达到了 0.725; 而朴素贝叶斯的值最低, 为 0.412。与五折交叉验证下的结果相比, AUC 能够避免由于正负样本存在不均衡的问题对实验结果评判的干扰。

4.3 基于心电信号的脑力负荷分析

基于心电信号的脑力负荷分析时, 主要包括数据预处理、心电信号的时域及频域特征提取, 并使用各分类方法进行决策分析, 其分析流程如图 4.7 所示。




图 4.7 ECG 的脑力负荷分类流程

4.3.1 心电信号预处理

心电信号的采集中易受到随机噪声、工频以及基线漂移等干扰的影响, 则对于心电信号预处理工作中的主要任务是进行降噪去除伪迹干扰。因为工频干扰的活动范围常为 50Hz, 而心电信号的频率活动主要位于低频率的范围内, 由此在本次心电信号的预处理中可以使用低通滤波器去除伪迹干扰信号。

使用巴特沃斯低通滤波器(Butterworth filter)对心电信号进行预处理, 巴特沃斯低通滤波器可表示为公式(4.18)所示, 滤波前后对比如图 4.8 所示。




图 4.8 滤波前后心电波形对比图

$$|H(\omega)|^2 = \frac{1}{1 + \left(\frac{\omega}{\omega_c}\right)^{2n}} \quad (4.18)$$

其中, n 为滤波器的阶数, ω_c 为截断频率。

4.3.2 心电信号特征提取

一次心跳的过程主要包含了 P 波、PR 间期、QRS 波群、ST 段和 T 段这五个波段。其中 P 波表示心脏的兴奋情况下的状态; PR 间期表示兴奋从细胞体传递到心脏房室的阶段。兴奋首先从窦房结传递到心房, 进而引起心房收缩, 产生 P 波; 然后通过房室传递进入到心室的各个部位, 由此产生 QRS 波群; 最后心室复极产生 T 波。

在进行 ECG 的 HRV 提取前, 应当对心跳过程中的 RR 间期进行确定。则应当对 QRS 波群中的极值点 R 进行确定, 其效果如图 4.9 所示。




图 4.9 ECG 的 R 点提取效果图

R 点主要是使用阈值进行确定, 将心电电位信号差超过阈值的两个临近极值点确定为 QRS 的极值点。确定的如公式(4.19)所示, R 是波群的极值点, V 是所设定的阈值, 通过实验对比将其设置为 0.3。

$$|R_i - R_j| \geq V, \forall i < j \in R \quad (4.19)$$

根据相关研究分析可以得知, 人体生理信息在不同的脑力负荷时, HRV 会出现显著的状态变化。由此, HRV 可以作为心电脑力负荷分析的重要特征信息。其计算过程如下:

1) RR 均值 (NN.mean) 计算如公式(4.20)所示。

$$NN.mean = \frac{\sum_{i=1}^N NN_i}{N} \quad (4.20)$$

公式中, NN_i 是指心电信号中的第 i 个 RR;

2) RR 均方根(rMSSD)计算如公式(4.21)所示。

$$rMSSD = \sqrt{E((NN_{i+1} - NN_i)^2)} \quad (4.21)$$

公式中 $E(\cdot)$ 是指进行均值计算;

3) PNN50 是指时间序列中 RR 间隔大于 50ms 时的所占比例, 计算公式如(4.22)所示。

$$PNN50 = \frac{\text{count}(|NN_{i+1} - NN_i| > 50)}{N - 1} \quad (4.22)$$

公式中 $\text{count}(\cdot)$ 是指间隔大于 50ms 的次数。

4.3.3 心电特征脑力负荷分类结果分析

在基于心电信号的脑力负荷分类决策建模时, 将心电信号的时域及频域特征映射到对应的特征空间向量中。在进行 K-近邻分类研究时, 将其 K 值的范围预先设定在 [1,30] 之间, 进行对比参数设置范围内的所有 K 值所对应的分类决策模型失误差, 如图 4.10 所示。通过对比发现, 最佳的 K 值选取应为 27。




图 4.10 不同 K 值下 KNN 心电脑力负荷分类误差变化图

在进行脑力负荷分类效果评判时, 使用五折交叉验证法和 AUC 进行评价分析。五折交叉验证下, 得到各分类方法的准确率如表 4.6 所示。

表 4.6 三种心电脑力负荷决策模型分类准确度对比表

模型	KNN	NBC	SVM
准确度	64.38%	58.76%	57.64%

对比分析可以得到在基于脑电信号的脑力负荷分类决策中，K-近邻分类方法效果最佳，准确率达到了 64.38%；其次是朴素贝叶斯分类方法，准确率为 58.76%；效果最差的为支持向量机分类方法，准确率为 57.64%。

使用 AUC 对不同分类方法结果进行对比分析，其对应的 ROC 曲线结果如图 4.11 所示。根据结果图可以得知 K-近邻分类方法的 AUC 值最高，最终结果为 0.673；其次是朴素贝叶斯分类方法，达到了 0.647；而支持向量机的值最低，为 0.598。




图 4.11 三种心电脑力负荷决策模型 ROC 曲线对比图

4.4 基于肌电信号的脑力负荷分析

基于肌电信号的脑力负荷分析时，主要包括数据预处理、肌电信号的时域及频域特征提取，对肌电信号的时域和频域特征分别使用 KNN 分类方法、NBC 分类方法以及 SVM 分类方法进行特征融合的脑力负荷分类决策分析，具体的脑力负荷分类决策分析流程如图 4.12 所示。




图 4.12 EMG 的脑力负荷分类流程

4.4.1 肌电信号预处理

在肌电信号的预处理工作中,使用了高斯滤波进行处理。在这里将高斯分布算法作为数据预处理的滤波函数,其计算如公式(4.23)所示。

$$G(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{x^2}{2\sigma^2}} \quad (4.23)$$

根据高斯分布滤波算法进行了肌电信号预处理流程规划,如表 4.7 所示。

表 4.7 高斯分布算法流程

Gauss Filtering
输 入: 肌电信号 $x(n)$
输 出: 处理后的数据 $y(n)$
步骤 1: 读入肌电信号数据;
步骤 2: 设定高斯滤波器的标准差 sigma;
步骤 3: 使用高斯滤波进行肌电信号平滑处理。
end

4.4.2 肌电信号特征提取

肌电信号产生于肌肉表面动作电位的微小变化,在进行相关研究分析时,主要分析其时域及频域特征。在时域分析方面,积分肌电值(iEMG)和均方根值(RMS)能够对肌肉收缩过程的强度进行评估,RMS 会随着肌肉的负荷强度增高而降低,相反则会升高。对肌电信号进行时域的 iEMG 和 RMS 计算分别如公式(4.24)、(4.25)所示。

$$iEMG = \int_t^{t+T} |EMG(t)| dt \quad (4.24)$$

$$RMS = \sqrt{\frac{1}{N} \sum_{i=1}^N x_i^2} \quad (4.25)$$

其中, N 为肌电信号的数据量, x_i 是指该肌电数据序列中的第 i 个数据,在这里表示进行肌电数据采集中的数据平均功率。经过积分肌电值和均方根值处理后与 EMG 的结果对比如图 4.13 所示。

在肌电数据的频域特征提取中,分别使用了平均功率频率(MPF)和中位频率(MF)方法进行处理,两种特征提取方法的计算公式分别如(4.26)、(4.27)所示。

$$MPF = \frac{\int_0^{\infty} fP(f)df}{\int_0^{\infty} P(f)df} \quad (4.26)$$




图 4.13 EMG、iEMG、RMS 对比图

$$\int_0^{MF} P(f)df = \frac{1}{2} \int_0^{\infty} P(f)df \quad (4.27)$$

其中 $P(f)$ 表示肌电的功率谱。经过平均功率谱及中位频率后与 EEG 的结果对比如图 4.14 所示。




图 4.14 EMG、MPF、MF 对比图

4.4.3 肌电特征脑力负荷分类结果分析

在基于肌电信号的脑力负荷分类决策建模时,将肌电信号的时域及频域特征映射到对应的特征空间向量中。在进行 K-近邻分类研究时,将其 K 值的范围预先设定在[1,30]之间,进行对比参数设置范围内的所有 K 值所对应的分类决策模型失误率,如图 4.15 所示。通过对比发现,最佳的 K 值选取应为 2。




图 4.15 不同 K 值下 KNN 肌电脑力负荷决策模型失误变化图

在进行脑力负荷分类效果评判时，使用五折交叉验证法和 AUC 进行评价分析。五折交叉验证下，得到各分类方法的准确率如表 4.8 所示。对比分析可以得到在基于脑电信号的脑力负荷分类决策中，K-近邻分类方法效果最佳，准确率达到了 60.5%；其次是朴素贝叶斯分类方法，准确率为 60.4%；效果最差的为支持向量机分类方法，准确率为 59.2%。使用 AUC 对不同分类方法结果进行对比分析，其对应的 ROC 曲线结果如图 4.16 所示。

表 4.8 三种肌电脑力负荷决策模型分类准确度对比表

模型	KNN	NBC	SVM
准确度	60.5%	60.4%	59.2%




图 4.16 三种肌电脑力负荷决策模型 ROC 曲线对比图

根据结果图可以得知 K-近邻分类方法的 AUC 值最高，最终结果为 0.619；其次是朴素贝叶斯分类方法，达到了 0.581；而支持向量机的值最低，为 0.517。

4.5 结果对比与性能分析

4.5.1 结果对比

脑电信号、心电信号及肌电信号下分别使用支持向量机分类方法、K-近邻分类方法以及朴素贝叶斯分类方法的脑力负荷分类决策结果对比如图 4.17 所示。




图 4.17 各生理信号下不同脑力负荷分类方法的分类结果对比图

通过对比不同的分类方法，发现朴素贝叶斯分类方法在各生理数据的效果差距较小，而支持向量机的方法在脑电数据下的分类中具有较为明显的优势。对比不同的生理数据下的分类效果发现，脑电信号对于脑力负荷的分类决策整体效果较好，而心电与肌电的效果相对较差。因此，在后续的多模态数据融合研究脑力负荷状态中，可以以脑电信号为主，对比分析其他生理数据进行融合前后的脑力负荷分类决策效果。

4.5.2 性能分析

上述三种不同的脑力负荷分类方法结果表明，机器学习的脑力负荷分类方法在生理信号决策分析中，具备一定的有效性，但总体的分类结果均在 80% 以下，效果较差。为了分析主要原因，对分类效果较好的脑电信号选取了其偏度和峭度进行样本分析。选取了低负荷和高负荷各一个样本数据，分别进行不同峭度值及偏度值的分析，如图 4.18 所示。




图 4.18 相近偏度和峭度特征的脑电信号样本

在图 4.18(a)低负荷样本中的峭度值可以发现, 其值相近(2.5139 和 2.5314)的情况下, 发现 A 区域中的波形存在较大的变化; 而峭度值差距大(2.5314 和 4.4718)的低负荷样本中, 对应的波形变化较为相近。图 4.18(b)高负荷样本中的不同偏度值的波形变化也出现了同样的情况。上述问题的出现可能是本次各生理信号下脑力负荷分类决策效果较差的主要原因。

4.6 本章小结

本章分别建立了关于支持向量机、朴素贝叶斯和 K-近邻的脑力负荷分类方法, 对各生理数据下的脑力负荷分类进行了分析, 使用五折交叉验证及 AUC 作为指标评价, 对比了各生理信号对于脑力负荷研究的有效性。根据研究结果, 对比各生理信号的决策效果可知, 脑电信号对于脑力负荷决策的有效性相对于肌电及心电信号较高, 为后续多模态数据融合的脑力负荷决策研究提供了思路。

5 多模态数据融合的脑力负荷决策研究

根据上一章基于生理信号的脑力负荷分类研究结果,本章节将以脑电信号为主,在其基础上融合心电及肌电信号,综合分析操作员的脑力负荷状态。设计搭建了两种类型的深度神经网络决策研究模型,分别是以类 EEGNet 和长短期记忆神经网络为基础的 ELSNet 脑力负荷决策分类模型和以类 Transformer 与卷积神经网络为基础的 ST-CNet 脑力负荷决策分类模型。首先对 ELSNet 和 ST-CNet 脑力负荷分类决策模型分别进行介绍,然后对两种深度神经网络模型的研究结果及各模型的不同模块的贡献程度进行分析。

5.1 ELSNet 决策模型

卷积神经网络能够较快的获取生理电信号的信息,而 EEGNet 则是在卷积神经网络的技术上搭建而成的且具有深度卷积可分离的特点,能够较大程度的保留原有数据的信息特征的同时对大量生理信号进行降维操作,从而降低了后续模型训练的难度。而在生理信号的提取中,LSTM 则能够获取到连续长时的生理特征,能够提高脑力负荷决策的全局性。最后对提取的多生理特征进行特征层融合,得到脑力负荷分类结果。

5.1.1 模型架构

本节脑力负荷决策模型借鉴了 EEGNet 网络模型的思路,在此基础上加入了 LSTM 进行特征提取,最后进行决策分析,搭建了以类 EEGNet 与长短期记忆神经网络为基础的 ELSNet 模型,如图 5.1 所示。




图 5.1 ELSNet 模型图

5.1.2 类 EEGNet 模块

EEGNet 是一种将深度卷积网络与可分离的卷积神经网络进行综合，进而能够实现两种功能的卷积神经网络，其网络结构主要包含了三个卷积层以及一个全连接层。在本模型中，类似于对生理电信号的多维特征提取前的滤波处理，将其改为两个卷积层，然后进行拉平操作，最后进行最大池化，实现多模态生理电信号的降维，为下一步的数据融合前的特征提取做准备，类 EEGNet 网络结构模块如图 5.2 所示。




图 5.2 类 EEGNet 模块

在该模块中，分别对处理过的脑电、心电以及肌电信号进行类 EEGNet 操作，具体的操作步骤为：第一层卷积分别对处理过的 256×1 各生理信号进行 kernel size 为 5，步长为 2 的一维卷积操作，输出为 128×64 ；第二层卷积将上一步输出作为输入，进行 kernels size 为 3，步长为 2 的卷积操作，输出为 64×128 ；然后各生理数据进行 flatten 拉平操作，将二维数据转变为 8192 的一维数据；最后对其进行最大池化操作。在这个过程中，实现了数据降维以减少后续数据量庞大的同时，较大限度的保留了生物电信号原有的连续性含义。

5.1.3 LSTM 模块

长短期记忆网络是循环神经网络的一种，它由输入门、遗忘门和输出门三部分组成，其结构如图 5.3 所示。




图 5.3 LSTM 结构图

存储单元用于进行状态信息的收集，当触发输入门时，可进行新信息的收集；触发遗忘门时，则会消除以往的信息；sigmoid 函数可以决定信息是存于存储单元还是输入遗忘

门，反馈回路通过 **sigmoid** 激活函数输出(0,1)之间的数值。

遗忘门被触发时，能够消除以往的存储信息，其作用是能够控制信息传递过程中的丢失率，其计算如式(5.1)所示。

$$f_t = \sigma(W_f^T \times s_{t-1} + U_f^T \times x_t + b_f) \quad (5.1)$$

其中 σ 表示激活函数，通常设为 **sigmoid** 函数， W_f^T 表示遗忘门权重矩阵， U_f^T 是遗忘门输入层与隐含层间的权重矩阵， b_f 表示遗忘门的偏置 s_{t-1} 为前一时刻输出值， x_t 为当前时刻的输入值。遗忘门输出值越接近 1，表示保留的信息越多；越接近 0，表示保留的信息越少。

输入门能够决定输入信息占送入记忆信息流的比例，其计算如式(5.2)所示。

$$i_t = \sigma(W_i^T \times s_{t-1} + U_o^T \times x_t + b_o) \quad (5.2)$$

输出门用于控制更新下一层网络的信息量，计算方式如公式(5.3)所示。

$$O_t = \sigma(W_o^T \times s_{t-1} + U_o^T \times x_t + b_o) \quad (5.3)$$

σ 为 **sigmoid** 函数，它可以扩大当前信息的效果，能够输出与公式(5.4)相结合的记忆信息，由此获得当前时刻的输出值。

$$s_t = O_t \times \tanh(C_t) \quad (5.4)$$

5.1.4 模型损失函数

在基于长短期记忆网络的分类研究中，使用的损失函数(Loss)设置如公式(5.5)所示。

$$Loss = \sum_{i=1}^n F(x_i) - y_i \quad (5.5)$$

其中， $F(x)$ 为外显函数，即模型的表现， x_i 为数据样本， y_i 为其对应的标签。

5.2 ST-CNet 决策模型

基于注意力机制的 Transformer 结构，能够反映不同生理电信号的特征之间的关联性并判断其重要程度，由此进行各特征的权重调节，而集中的注意力机制部分，则能够使得各信息的位置距离缩小为一个常量，进而使得获取到的信息更具全局性。在本次的脑力负荷决策模型中，CNN 模块被赋予原始时间序列数据的子序列，而注意机制模块被赋予子序列的中点值。注意机制模块的输入序列比 CNN 模块的输入序列长，并且它覆盖分支中的 CNN 模块输入。

5.2.1 模型架构

多生理电信号融合的飞行员脑力负荷分类研究中，主要是通过改进 Transformer 中的多头注意力机制，同时结合卷积神经网络进行脑力负荷分类研究，提出以类 Transformer

和卷积神经网络为基础的 ST-CNet 脑力负荷决策模型，模型如图 5.4 所示。神经网络部分搭建了改进的 Transformer 结构，主要以一维卷积和全连接层为核心。




图 5.4 ST-CNet 模型图

5.2.2 类 Transformer 模块

Transformer 是以注意力机制为基础的深度神经网络结构，在自然语言处理等研究领域具有明显优势。它的主要理念是通过对某句话中的各个词语进行分析，获取其相互间存在的联系，以此来进行各部分联系性分析和重要性判断。根据分析判断结果来进行语句中各个词语所占权重的分配，由此获得更具全面性的语句表达。将该方法运用到生理信号的脑力负荷决策研究中，能够获取到各生理数据中更全面的数据信息。

本节脑力负荷决策建模中，类 Transformer 部分主要以注意力机制为基础，通过将输入数据中不同时间点的数据之间存在的距离放缩变换为一个常量，进而使得注意力机制层可以获取到全局信息之间的关联。与循环神经网络相对比，不需要通过各个步骤的递推计算便能获取到有效信息，使其具备较大的优势。

在 ST-CNet 决策模型的建立中，针对类 Transformer 模块部分，主要使用了注意力机制里进行输入数据位置确定的位置编码(Positional Encoding)、进行输入数据注意力计算的多头注意力(Multi-Head Attention)和用于对输入数据的特征提取部分的编码器。

1) 位置编码

与以往的卷积神经网络和递归网络的区别是 Transformer 在进行编码时针对位置进行

了新的方法来获取输入的生理数据的序列位置信息。对数输入的数据信息中不同频率的正弦及余弦序列与归一化序列相结合，实现其数据信息的编码。其实现公式分别如式(5.6)、(5.7)所示。

$$PE(pos, 2j) = \sin\left(\frac{pos}{10000 \frac{2j}{d}}\right) \quad (5.6)$$

$$PE(pos, 2j+1) = \cos\left(\frac{pos}{10000 \frac{2j}{d}}\right) \quad (5.7)$$

公式中 pos 指的是输入数据信息所在的位置， j 指的是生理数据特征向量的第 j 维。编码器中的信息输入是各维度数据累计和，计算方式如公式(5.8)所示。其中每个数据样本点所对应的编码位置是不变的，同时它的长度信息能够进行随意的放缩操作，以确保进行决策训练数据的有效性。

$$X_{e-in} = x' + PE \quad (5.8)$$

2) 多头注意力

注意力的评分能够对进行脑力负荷程度的预测所对应的数据序列信息进行确定，在这里使用点积计算方法对其评分分数进行计算，公式如(5.9)所示。

$$Attention(Q, K, V) = \text{soft max}\left(\frac{QK^T}{\sqrt{d_k}}\right)V \quad (5.9)$$

公式中 Q 表示了数据序列， K 表示计算中的键值， V 表示计算过程中的权重值。这里采用多头注意力机制，对输入数据信息中的数据序列、计算键值和对应的权重作线性计算，从而实现特征向量的空间映射，对应的计算公式如(5.10)所示。

$$head_i = Attention(QW_i^Q, KW_i^K, VW_i^V) \quad (5.10)$$

公式中 W_i^V 表示计算中的权重矩阵。

3) 编码器

编码器部分主要包含了 6 个相同模块栈堆，各个模块中存在两个子层次结构，该模块把将查询到数据的输入信息与前一个模块的输出信息进行连接。其次，对各个模块中的网络层进行归一化处理。每个模块的输出公式如(5.11)所示。

$$Output = LayerNorm(y + Sublayer(y)) \quad (5.11)$$

公式中 y 为子模块，可以进行 y 功能的实现，为确保残差网络的有效连接，对该模型中的子模块均进行子维度的输出操作。

对于注意力机制的网络模型改进，主要是将原有模型中的激活函数、Embedding 部分、Linear 部分以及输出去掉。对模型中进行特征放大和提取功能做了保留操作，使得可以对

输入的生理信息进行操作，本次的类 Transformer 结构如图 5.5 所示。




图 5.5 类 Transformer 结构图

5.2.3 卷积模块

1) 一维卷积计算

卷积神经网络最早用于视觉图像方面的分析，后来也被应用于信号方面，本次卷积模块主要使用一维卷积，其卷积过程如图 5.6 所示，其计算方式如公式(5.12)所示。

$$y(t) = \sum_{i=1}^k x_i w_i \quad (5.12)$$




图 5.6 一维卷积过程

2) 卷积结构调整

理论上的神经网络模型中的结构层可以无限扩展，相当于模型可以不断增加神经元或功能结构层来进行全局的数据覆盖，使其性能上一定程度能够超过机器学习。但无限的增加其结构也会造成模型训练过程中的过拟合，提高了模型计算过程中的代价成本。为了防止上述现象，提高模型性能，对卷积神经网络进行了模块调整操作，其实现流程如图 5.7(a) 所示，结构调整结果如图 5.7(b) 所示。




图 5.7 卷积调整图

由于在常见的神经网络分类训练中，其训练的下限在 85%；在历年的 ImageNet 竞赛中，效果较好的参赛模型准确率通常在 80%左右，而竞赛中的难度往往较高，且本次模型使用自采数据集，因此可以提高模型准确率的阈值。根据卷积结构调整优化结果可知，其拐点处卷积块数量为 5，则在建模时，搭建 5 个卷积功能块。

3) 结构优化后的卷积模块

CNN 模块的输出特征与注意机制模块的输出特征逐元素相乘，能够根据其相对于其他特征的值来反映每个特征的重要性。卷积模块使用了连续的最大池化、Dropout、一维卷积和激活层。从输入端到输出端池化层的核大小均为 2，一维卷积核数量分别为 $2n(n=7,6,5,4,3)$ ，卷积操作的步长均为 1。全连接部分使用了连续的全连接层，各层的全连接神经元个数分别为 $2n(n=4,3,2,1)$ ，卷积模块结构如图 5.8 所示。




图 5.8 卷积模块结构图

5.2.4 模型损失函数

本决策模型中,模型的损失函数(Loss)设置选用交叉熵函数,如公式(5.13)所示。

$$Loss = \log(1 + \sum_{i \in \Omega_{neg}} e^{s_i}) + \log(1 + \sum_{j \in \Omega_{pos}} e^{-s_j}) \quad (5.13)$$

其中 Ω_{neg} 和 Ω_{pos} 分别表示模型分类中错误与正确的组成集合, s_i 为模型中正样本的数据结果, s_j 为模型中负样本输出的结果。

5.3 评价指标

在本章节多模态数据融合的脑力负荷分类中,主要针对二分类进行研究。因此,在进行模型准确率指标评价时,主要使用模型的识别率(Acc)和模型损失(Loss)在十折交叉验证下来进行结果评价。

5.4 结果分析与讨论

5.4.1 ELSNet 模型决策结果分析

在 ELSNet 模型的决策研究中,实验中首先使用了十折交叉验证对深度神经网络模型进行了性能影响分析。使用 300 个 epoch 作为模型的训练批次,训练结果如图 5.9 所示。在训练到 124 个 epoch 后模型的准确率能够稳定在 91.18%,之后便没有较大的变化。




图 5.9 实验结果对比图

实验过程中使用了十折交叉验证对模型进行了性能对比分析。对比实验结果 5.9(a)发现,使用十折交叉验证后,当模型训练到 119 个批次时,能够取得 92.63%的最高准确率,十次训练的平均效果能够达到 89.73%。

通过 Loss 结果对比图 5.9(b)发现,在不使用十折交叉验证时,在训练到 130 个批次

时, 损失稳定到了 0.1 以下; 在使用了十折交叉验证的情况下, 损失在训练到 58 批次后基本稳定到了 0.09 以下。

实验添加了对照组, 对选择的各脑电通道分类效果进行了对比分析, 结果如图 5.10(a) 所示。通过对比发现, 在结合心电及肌电的 12 个脑电通道数据融合结果中, 分类结果能够达到 92.63%, 不使用心电及肌电信号时也能达到 85.17%。在 ELSNet 模型中, 单一的脑电通道在结合心电和肌电信号前后的准确率均相差 11% 左右。

图 5.10(b) 对比了 ELSNet 模型及该模型中不同模块结合心电及肌电信号前后的分类效果。对比发现, 结合了心电及肌电信号后的分类准确率相差 7% 左右; 而分类结果的准确率与模型的完整度成正比, LSTM 模块的效果要高于类 EEGNet 模块。




图 5.10 实验对照结果准确率

5.4.2 ST-CNet 模型决策结果分析

在 ST-CNet 决策研究分析中, 对模型进行了 300 批次的训练, 最终的实验结果准确率为 96.54%, 训练的 Accuracy 和 Loss 结果如图 5.11 所示。

使用十折交叉验证前后的实验结果 Accuracy 对比如图 5.11(a) 所示, 在未进行十折交叉验证的情况下, 训练的准确率在 106 时准确率基本达到 92% 左右, 并逐渐趋于稳定缓慢上升, 最终的准确率达到 95.78%; 使用了十折交叉验证后模型的准确率在训练第 54 批次时准确率基本到达 95% 左右, 并存在一定的幅度变化, 但总体均在 90% 以上。

通过结果 Loss 对比图 5.11(b) 所示, 根据结果发现在未使用十折交叉验证的情况下, 在训练到 214 各批次后, 模型的损失下降到了 0.1 以下, 并保持稳定; 在使用了十折交叉验证的情况下, 模型在第 50 个批次的训练中快速下降到了 0.1 以下, 后续的 Loss 逐步趋于稳定并缓慢下降, 直到 171 批次, Loss 下降到了 0.02 左右, 并保持稳定。




图 5.11 实验结果对比图

本次添加对比实验,对各脑电通道的数据及总的脑电数据进行实验对比分析,结果如图 5.12(a)所示。通过对比发现,在结合心电及肌电的 12 个脑电通道数据融合结果中,分类结果能够达到 96.54%,不使用心电及肌电信号时也能达到 87.79%。在 ST-CNet 模型中,单一的脑电通道在结合心电和肌电信号前后的准确率均相差 9%左右。图 5.12(b)对比 ST-CNet 模型及该模型中不同模块结合心电及肌电信号前后的分类效果。对比发现,结合了心电及肌电信号后整体模型的分类型准确率相差 7%左右,而类 Transformer 模块及卷积模块则分别相差 13%和 16%左右;模型的分类型准确率与模型的完整度成正比,类 Transformer 模块的准确率要高于卷积模块。




图 5.12 实验对照结果准确率

5.4.3 实验结果对比分析

根据脑电波的节律特征,对提取到不同频段的脑电波段信号进行两类脑力负荷决策分析。将提取到的不同频段脑电波信号结合心电及肌电前后对比分析,实验对比结果如表 5.1 所示。

表 5.1 不同频段脑电信号在模型上的分类表现

信号频段	判别准确率 (%)			
	ELSNet 模型		ST-CNet 模型	
	使用 ECG、EMG	不使用 ECG、EMG	使用 ECG、EMG	不使用 ECG、EMG
δ (1~4Hz)	71.23	66.12	73.15	67.93
θ (4~8Hz)	70.62	66.45	72.57	68.67
α (8~14Hz)	75.03	63.29	76.15	64.87
β (14~30Hz)	76.89	67.96	79.68	70.79

在 ELSNet 模型的研究结果中,发现不使用心电及肌电信号的单个脑电波段节律特征下的分类结果在 63%-68%之间,融合心电及肌电后的脑力负荷决策结果均提升到了 70% 以上;而在 ST-CNet 模型结果中,未使用心电和肌电信号的分类结果为 64%-71%之间,融合了心电及肌电信号的分类结果为 72.57%-79.68%之间,由此表明了肌电及心电信号能够有效提升脑力负荷分类结果。同时,通过对比发现, β 波段下的脑电节律特征具有较高的分类准确率,与脑电节律特征下该波段表现出的意识专注、记忆、解决问题等心理行为状态相吻合,反映了研究结果的可靠性。

实验对比分析了两类深度学习模型在 EEG+ECG+EMG、EEG+ECG、EEG+EMG、ECG+EMG、EEG、ECG 以及 EMG 数据下的脑力负荷分类结果,如图 5.13 所示。




图 5.13 结果对比分析

对比发现在进行三种信号的多模态数据融合研究中, 脑力负荷分类效果最佳, ELSNet、ST-CNet 模型的准确率分别能够达到 92.63%和 96.54%, 相对于两两生理信号融合的准确率平均增长了 5%以上; 而单生理信号的脑力负荷分类准确率效果要低于两类融合的效果, 其中基于肌电信号的脑力负荷分类效果最差, 两种方法分别为 74.63%和 77.28%。

本次实验对比了前人的方法与本章多模态数据融合的操作员脑力负荷决策方法的结果, 如表 5.2 所示。通过对比发现, 本次的研究方法在脑力负荷的分类决策效果中具有一定的优势。

表 5.2 与其他方法判别准确率对比

研究团队	信号类型	核心分类方法	准确率 (%)
Winnie	EEG	SVM、RBP	65-75
Qu	EEG	ICs、LDA、BP、KNN、SVM	79.8
Saadati	ECG, EMG	CNN、SVM	89、82
Chakladar	ECG	BLSTM、LSTM	86.33、82.57
Deng	EMG	DCSAEN	81.5
本文	EEG,ECG,EMG	ELSNet、ST-CNet 模型	92.63、96.54

5.5 本章小结

本章节通过建立 ELSNet 与 ST-CNet 深度神经网络模型, 对操作员脑力负荷状态进行了相关研究分析。前两小节对两种网络模型的设计及结构组成进行了介绍, 最后一节对两种模型的研究结果进行了介绍及分析。在结果分析中, 不仅对比了模型中各个组成模块的贡献率, 同时对比分析了所选取的脑电各通道以及融合心电及肌电的分类效果。结果表明, ELSNet 与 ST-CNet 对于脑力负荷的决策研究相较于以往的研究准确率均有所提高, ST-CNet 的效果更为明显; 通过是否融合心电及肌电的分类结果对比发现, 心电和肌电对于脑力负荷决策的分类研究中具有一定的贡献, 为后续的多生理数据融合研究分析操作员脑力负荷状态监测研究提供了新的思路。

6 结论与展望

6.1 研究总结

在进行脑力负荷研究中,对于装配作业、道路运输等操作类任务已经普遍使用脑电信号进行研究分析,并且在较多领域如计算机科学和心理学进行了广泛的应用。但对于多生理信息的融合研究分析,目前相对较少。对于如何从多面出发,利用全局性的信息进行脑力负荷决策研究,以提高操作员脑力负荷决策精度是研究的重点问题。本文从利用全局性数据的角度出发,基于实验室的硬件平台及数据采集设备搭建了模拟飞行实验平台,并进行了模拟飞行实验设计。通过同步测量系统采集到了模拟飞行环境下的操作员多生理电信号数据,对采集到的数据进行了多特征融合的机器学习脑力负荷决策研究;通过分析各生理电信号对脑力负荷决策的有效性,进一步提出了深度学习下多模态数据融合的操作员脑力负荷决策研究模型,实现更高精度的脑力负荷决策分类。

1) 主要研究内容

a、多生理电信号的数据预处理及特征提取。在多生理电信号预处理中,对脑电信号进行了生理伪迹滤波及工频滤波处理;使用巴特沃斯低通滤波去除心电信号伪迹干扰;使用高斯滤波进行肌电信号的预处理。对于处理后的脑电信号进行了相关性分析,并提取了脑电信号不同波段的节律特征;分析了心电信号各波段变化内容,使用均值及均方根提取心电信号的时域特征;使用积分肌电值和均方根值提取肌电信号的时域特征,并使用平均功率频率和中位频率提取肌电信号的频域特征。

b、基于生理信号的脑力负荷分类研究。建立了支持向量机、朴素贝叶斯及 K-近邻脑力负荷分类模型,分别对脑电、肌电及心电信号进行脑力负荷分类研究,使用五折交叉验证及 AUC 进行指标评价。通过分析各生理电信号的决策效果,发现脑电信号对于脑力负荷决策的影响相对肌电及心电较大,且心电及肌电对脑力负荷决策有一定的影响,对下一步基于深度学习的多模态数据融合研究提供了思路。

c、多模态数据融合的脑力负荷决策研究。根据各生理信号的脑力负荷分类研究结果,在多模态数据融合的脑力负荷决策研究中,主要以脑电信号进行研究,同时融合肌电及心电信号进行多模态数据融合决策,分别建立了 ELSNet 和 ST-CNet 深度神经网络模型。对比分析了各模型中各个模块的贡献程度,发现在 ELSNet 模型中 LSTM 模块的贡献度高于类 EEGNet 模块;在 ST-CNet 模型中,类 Transformer 模块的贡献度高于卷积神经网络模块。在 ELSNet 模型中,将肌电及心电融合到脑电的分类准确率为 92.63%,相比于纯脑电的分类准确率提高了 7.11%;在 ST-CNet 模型中,将肌电及心电融合到脑电的分类准确率为 96.54%,相比于纯脑电的分类准确率提高了 6.98%,由此可以得到心电和肌电信号对脑力负荷的决策研究不可忽略。

2) 主要创新点

a、针对飞行操作者复杂环境下脑力负荷状态研究中单一角度数据检测的局限性，从操作者的实操飞行数据和各生理数据出发，提出多模态数据采集监测机制。数据采集根据操作者的认知决策及生理参数，进行飞行操作数据、脑电、心电及肌电同步数据采集工作，实现多模态数据监测。该监测机制能够从更全面的角度对操作员的脑力负荷状态进行检测，可以将不同数据的优势相结合，使它们之间形成数据互补，能够有效提升操作员脑力负荷状态监测数据的可靠性。

b、为实现飞行操作数据、脑电等生理数据特征的充分提取分析，提出了 ELSNet 和 ST-CNet 深度神经网络进行多模态数据融合的操作员脑力负荷决策研究。ELSNet 以类 EEGNet 和长短期记忆神经网络为基础，ST-CNet 以类 Transformer 与卷积神经网络为基础分别实现多模态数据融合脑力负荷决策分析，充分发挥了各数据的优势。通过设置多组对照实验，并与前人的研究方法进行对比分析，发现该方法下的多模态数据融合脑力负荷决策效果较好。

6.2 未来展望

根据前人关于脑力负荷的决策研究，本文认为现有的基于脑电特征的脑力负荷决策研究具有较大的研究效果，但单生理信息的研究，往往具有较大的局限性，不能从全局出发对人的多方面生理进行综合分析评估研究。因此，本文采用了多模态数据融合决策方法，将心电和肌电信号融合脑电来提高脑力负荷的决策性能。虽然本文取得了一定的进展，但在后续的研究工作中仍有以下需要改进的方面：

1) 数据多样性问题

关于操作员的脑力负荷研究中，数据问题具有较多的争议。本文的主要针对基于五边飞行的模拟环境下的操控类任务进行信息处理能力方面的脑力负荷数据采集工作。而在飞行环境中人具有较多的不可控因素，为了采集更加接近于飞行环境下的数据，后续工作中，将针对不同的天气环境条件，增加飞行对战模式，来提升飞行操作难度，以获取多样性数据进行脑力负荷研究分析。

2) 决策方法优化问题

本文所采用的数据融合方法位于特征层，该层相较于决策层而言包含了较多的数据信息，具有较高的分类准确性，但所需的数据量相对较多，计算将对复杂，抗干扰的能力相对较弱。因此，在后续的研究工作中，将结合决策层的数据融合研究方法，利用其他的融合研究算法，在减少数据计算的同时保留较多数据特征信息，来提高决策模型抗干扰能力，更好地实现脑力负荷决策研究。

参考文献

- [1] Kakkos I, Dimitrakopoulos G N, Sun Y, et al. EEG Fingerprints of Task-Independent Mental Workload Discrimination[J]. IEEE Journal of Biomedical and Health Informatics, 2021, 25(10): 3824-3833.
- [2] Mansikka H, Virtanen K, Harris D. Comparison of NASA-TLX scale, modified Cooper-Harper scale and mean inter-beat interval as measures of pilot mental workload during simulated flight tasks[J]. Ergonomics, 2019, 62(2): 246-254.
- [3] Loft S, Bhaskara A, Lock B A, et al. The Impact of Transparency and Decision Risk on Human-Automation Teaming Outcomes[J]. Human Factors, 2023, 65(5): 846-861.
- [4] Rainieri G, Fraboni F, Russo G, et al. Visual Scanning Techniques and Mental Workload of Helicopter Pilots During Simulated Flight[J]. Aerospace Medicine and Human Performance, 2021, 92(1): 11-19.
- [5] Pagnotta M, Jacobs D M, de Frutos P L, et al. Task difficulty and physiological measures of mental workload in air traffic control: a scoping review[J]. Ergonomics, 2022, 65(8): 1095-1118.
- [6] Particle Data Group, Zyla P A, Barnett R M, et al. Review of Particle Physics[J]. Progress of theoretical and experimental physics, 2020, 2020(8): 083C01.
- [7] 卫宗敏. 面向复杂飞行任务的脑力负荷多维综合评估模型[J]. 北京航空航天大学学报, 2020, 46(7): 1287-1295.
- [8] Buchner J, Buntins K, Kerres M. The impact of augmented reality on cognitive load and performance: A systematic review[J]. Journal of Computer Assisted Learning, 2022, 38(1): 285-303.
- [9] Melnicuk V, Thompson S, Jennings P, et al. Effect of cognitive load on drivers' State and task performance during automated driving: Introducing a novel method for determining stabilisation time following take-over of control[J]. Accident Analysis & Prevention, 2021, 151(1): 105967.
- [10] Bläsing D, Bornewasser M. Influence of Increasing Task Complexity and Use of Informational Assistance Systems on Mental Workload[J]. Brain Sciences, 2021, 11(1): 102.
- [11] Darvishi-Bayazi M J, Law A, Romero S M, et al. Beyond performance: the role of task demand, effort, and individual differences in ab initio pilots[J]. Scientific Reports, 2023, 13(1): 14035.
- [12] Graça M, Pais L, Mónico L, et al. Decent Work and Work Engagement: A Profile Study with Academic Personnel[J]. Applied Research in Quality of Life, 2021, 16(3): 917-939.
- [13] Chen W, Sawaragi T, Horiguchi Y. Measurement of Driver's Mental Workload in Partial Autonomous Driving[J]. IFAC-PapersOnLine, 2019, 52(19): 347-352.
- [14] De Paolis L T, Gatto C, Corchia L, et al. Usability, user experience and mental workload in a mobile Augmented Reality application for digital storytelling in cultural heritage[J]. Virtual Reality, 2023, 27(2): 1117-1143.
- [15] Singh G, Chanel C P C, Roy R N. Mental Workload Estimation Based on Physiological Features for

- Pilot-UAV Teaming Applications[J]. *Frontiers in Human Neuroscience*, 2021, 15(1): 692878.
- [16] Wang P, Fang W, Guo B. Mental workload evaluation and its application in train driving multitasking scheduling: a Timed Petri Net-based model[J]. *Cognition, Technology & Work*, 2021, 23(1): 299-313.
- [17] Longo L, Orrú G. Evaluating instructional designs with mental workload assessments in university classrooms[J]. *Behaviour & Information Technology*, 2022, 41(6): 1199-1229.
- [18] Mahmoodian N, Haddadnia J, Illanes A, et al. Seizure prediction with cross-higher-order spectral analysis of EEG signals[J]. *Signal, Image and Video Processing*, 2020, 14(1): 821-828.
- [19] Rahman M M, Sarkar A K, Hossain M A, et al. Recognition of human emotions using EEG signals: A review[J]. *Computers in biology and medicine*, 2021, 136(1): 104696.
- [20] Hosseini S A, Houshmand M. Analysis of the EEG Signal Using Higher-Order Spectra (HOS) in the Neuro-marketing Application[J]. *New Marketing Research Journal*, 2022, 12(1): 25-42.
- [21] Luo C, Li F, Li P, et al. A survey of brain network analysis by electroencephalographic signals[J]. *Cognitive Neurodynamics*, 2022, 16(1): 17-41.
- [22] García-Martínez B, Fernández-Caballero A, Zunino L, et al. Recognition of Emotional States from EEG Signals with Nonlinear Regularity-and Predictability-Based Entropy Metrics[J]. *Cognitive Computation*, 2021, 13(1): 403-417.
- [23] Attia Z I, Harmon D M, Behr E R, et al. Application of artificial intelligence to the electrocardiogram[J]. *European heart journal*, 2021, 42(46): 4717-4730.
- [24] Subasi A, Mian Qaisar S. The Ensemble Machine Learning-Based Classification of Motor Imagery Tasks in Brain-Computer Interface[J]. *Journal of Healthcare Engineering*, 2021, 207(1): 1426.
- [25] El-Gindy S A E, Ibrahim F E, Alabasy M, et al. Detection of Abnormal Activities from Various Signals Based on Statistical Analysis[J]. *Wireless Personal Communications*, 2022, 125(2): 1013-1046.
- [26] Liu X, Wang H, Li Z, et al. Deep learning in ECG diagnosis: A review[J]. *Knowledge-Based Systems*, 2021, 227(1): 107187.
- [27] Singh A K, Krishnan S. ECG signal feature extraction trends in methods and applications[J]. *BioMedical Engineering OnLine*, 2023, 22(1): 22.
- [28] Pandey A. ECG data compression using the formation of QRS-complex segment bank and integer DCT-based plateau region processing[J]. *Biomedical Signal Processing and Control*, 2023, 85(1): 104823.
- [29] Tepe C, Demir M C. Real-Time Classification of EMG Myo Armband Data Using Support Vector Machine[J]. *IRBM*, 2022, 43(4): 300-308.
- [30] D'Accolti D, Clemente F, Mannini A, et al. Online Classification of Transient EMG Patterns for the Control of the Wrist and Hand in a Transradial Prosthesis[J]. *IEEE Robotics and Automation Letters*, 2023, 8(2): 1045-1052.
- [31] Chen J, Bi S, Zhang G, et al. High-Density Surface EMG-Based Gesture Recognition Using a 3D

- Convolutional Neural Network[J]. *Sensors*, 2020, 20(4): 1201.
- [32] Ng C L, Reaz M B I, Crespo M L, et al. A Flexible Capacitive Electromyography Biomedical Sensor for Wearable Healthcare Applications[J]. *IEEE Transactions on Instrumentation and Measurement*, 2023, 72(1): 1430.
- [33] Prabhavathy T, Elumalai V K, Balaji E. Hand gesture classification framework leveraging the entropy features from sEMG signals and VMD augmented multi-class SVM[J]. *Expert Systems with Applications*, 2024, 238(1): 121972.
- [34] Li C, Li G, Jiang G, et al. Surface EMG data aggregation processing for intelligent prosthetic action recognition[J]. *Neural Computing and Applications*, 2020, 32(1): 16795-16806.
- [35] Torres-Castillo J R, Lopez-Lopez C O, Padilla-Castaneda M A. Neuromuscular disorders detection through time-frequency analysis and classification of multi-muscular EMG signals using Hilbert-Huang transform[J]. *Biomedical Signal Processing and Control*, 2022, 71(1): 103037.
- [36] Chen R C, Dewi C, Huang S W, et al. Selecting critical features for data classification based on machine learning methods[J]. *Journal of Big Data*, 2020, 7(1): 52.
- [37] Yang F, Zhang P. MSIF: Multi-source information fusion based on information sets[J]. *Journal of Intelligent & Fuzzy Systems*, 2023, 44(3): 4103-4112.
- [38] Xiao F. Multi-sensor data fusion based on the belief divergence measure of evidences and the belief entropy[J]. *Information Fusion*, 2019, 46(1): 23-32.
- [39] Nishad A K, Aggarwal G. Hesitant fuzzy time series forecasting model of higher order based on one and two-factor aggregate logical relationship[J]. *Engineering Applications of Artificial Intelligence*, 2023, 126(1): 106897.
- [40] Xiao F, Pedrycz W. Negation of the Quantum Mass Function for Multisource Quantum Information Fusion With its Application to Pattern Classification[J]. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 2022, 45(2): 2054-2070.
- [41] Ahmad M I, Keller I, Robb D A, et al. A framework to estimate cognitive load using physiological data[J]. *Personal and Ubiquitous Computing*, 2023, 27(1): 2027-2041.
- [42] Wu Y, Liu Z, Jia M, et al. Using Artificial Neural Networks for Predicting Mental Workload in Nuclear Power Plants Based on Eye Tracking[J]. *Nuclear Technology*, 2020, 206(1): 94-106.
- [43] Tolvanen O, Elomaa A P, Itkonen M, et al. Eye-Tracking Indicators of Workload in Surgery: A Systematic Review[J]. *Journal of Investigative Surgery*, 2022, 35(6): 1340-1349.
- [44] Orlandi L, Brooks B. Measuring mental workload and physiological reactions in marine pilots: Building bridges towards redlines of performance[J]. *Applied ergonomics*, 2018, 69(1): 74-92.
- [45] So W K Y, Wong S W H, Mak J N, et al. An evaluation of mental workload with frontal EEG[J]. *PloS one*, 2017, 12(4): e0174949.
- [46] Liu C, Zhang C, Sun L, et al. Detection of Pilot's Mental Workload Using a Wireless EEG Headset in

- Airfield Traffic Pattern Tasks[J]. *Entropy*, 2023, 25(7): 1035.
- [47] Liu Z, Shore J, Wang M, et al. A systematic review on hybrid EEG/fNIRS in brain-computer interface[J]. *Biomedical Signal Processing and Control*, 2021, 68(1): 102595.
- [48] Dimitrakopoulos G N, Kakkos I, Anastasiou A, et al. Cognitive Reorganization Due to Mental Workload: A Functional Connectivity Analysis Based on Working Memory Paradigms[J]. *Applied Sciences*, 2023, 13(4): 2129.
- [49] Gogna Y, Tiwari S, Singla R. Towards a versatile mental workload modeling using neurometric indices[J]. *Biomedical Engineering/Biomedizinische Technik*, 2023, 68(3): 297-316.
- [50] Ma Y, Chen B, Li R, et al. Driving Fatigue Detection from EEG Using a Modified PCANet Method[J]. *Computational intelligence and neuroscience*, 2019, 38(1): 22507.
- [51] Han S Y, Kwak N S, Oh T, et al. Classification of pilots' mental states using a multimodal deep learning network[J]. *Biocybernetics and Biomedical Engineering*, 2020, 40(1): 324-336.
- [52] Wu W, Sun W, Wu Q M J, et al. Multimodal Vigilance Estimation Using Deep Learning[J]. *IEEE Transactions on Cybernetics*, 2020, 52(5): 3097-3110.
- [53] Lee J, Lee H, Shin M. Driving Stress Detection Using Multimodal Convolutional Neural Networks with Nonlinear Representation of Short-Term Physiological Signals[J]. *Sensors*, 2021, 21(7): 2381.
- [54] 郑玲, 乔旭强, 倪涛, 等. 基于多维信息特征分析的驾驶人认知负荷研究[J]. *中国公路学报*, 2021, 34(4): 240.
- [55] 李瑞, 柳长安, 王彦平, 等. 基于多生理信息迁移学习的脑力负荷分类[J]. *科学技术与工程*, 2022, 22(14): 5555-5561.
- [56] Ma T, Li Y, Huggins J E, et al. Bayesian Inferences on Neural Activity in EEG-Based Brain-Computer Interface[J]. *Journal of the American Statistical Association*, 2022, 117(539): 1122-1133.
- [57] Demir F, Sobahi N, Siuly S, et al. Exploring Deep Learning Features for Automatic Classification of Human Emotion Using EEG Rhythms[J]. *IEEE Sensors Journal*, 2021, 21(13): 14923-14930.
- [58] Choi H, Park J, Yang Y M. A Novel Quick-Response Eigenface Analysis Scheme for Brain-Computer Interfaces[J]. *Sensors*, 2022, 22(15): 5860.
- [59] Jiang X, Bian G, Tian Z. Removal of Artifacts from EEG Signals: A Review[J]. *Sensors*, 2019, 19(5): 987.
- [60] Noorbasha S K, Sudha G F. Removal of EOG artifacts and separation of different cerebral activity components from single channel EEG — an efficient approach combining SSA - ICA with wavelet thresholding for BCI applications[J]. *Biomedical Signal Processing and Control*, 2021, 63(1): 102168.
- [61] Li Y, Wang P T, Vaidya M P, et al. Electromyogram (EMG) Removal by Adding Sources of EMG (ERASE)—A Novel ICA-Based Algorithm for Removing Myoelectric Artifacts From EEG[J]. *Frontiers in Neuroscience*, 2021, 14(1): 597941.
- [62] Maddirala A K, Veluvolu K C. ICA with CWT and k-means for Eye-blink Artifact Removal from Fewer

- Channel EEG[J]. IEEE Transactions on Neural Systems and Rehabilitation Engineering, 2022, 30(1): 1361-1373.
- [63] Hu Q, Li M, Li Y. Single-channel EEG signal extraction based on DWT, CEEMDAN, and ICA method[J]. Frontiers in Human Neuroscience, 2022, 16(1): 1010760.
- [64] Weimann K, Conrad T O F. Transfer learning for ECG classification[J]. Scientific reports, 2021, 11(1): 5251.
- [65] Hammad M, Kandala R N, Abdelatey A, et al. Automated detection of shockable ECG signals: A review[J]. Information Sciences, 2021, 571(1): 580-604.
- [66] Gullett N, Zajkowska Z, Walsh A, et al. Heart rate variability (HRV) as a way to understand associations between the autonomic nervous system (ANS) and affective states: A critical review of the literature[J]. International Journal of Psychophysiology, 2023, 193(1): 35-42.
- [67] Xi X, Sun Z, Hua X, et al. Construction and analysis of cortical-muscular functional network based on EEG-EMG coherence using wavelet coherence[J]. Neurocomputing, 2021, 438(1): 248-258.
- [68] Dai Y, Wu J, Fan Y, et al. MSEva: A Musculoskeletal Rehabilitation Evaluation System Based on EMG Signals[J]. ACM Transactions on Sensor Networks, 2022, 19(1): 1-23.
- [69] Boyer M, Bouyer L, Roy J S, et al. Reducing Noise, Artifacts and Interference in Single-Channel EMG Signals: A Review[J]. Sensors, 2023, 23(6): 2927.
- [70] Buongiorno D, Cascarano G D, De Feudis I, et al. Deep learning for processing electromyographic signals: A taxonomy-based survey[J]. Neurocomputing, 2021, 452(1): 549-565.
- [71] Azcarate S M, Ríos-Reina R, Amigo J M, et al. Data handling in data fusion: Methodologies and applications[J]. TrAC Trends in Analytical Chemistry, 2021, 143(1): 116355.
- [72] Wickramasinghe I, Kalutarage H. Naive Bayes: applications, variations and vulnerabilities: a review of literature with code snippets for implementation[J]. Soft Computing, 2021, 25(3): 2277-2293.