



西安工业大学
Xi'an Technological University

专业硕士学位论文

(学 位 研 究 生)

题目：多维数据融合的飞行员
操作意图推断方法研究

作者 乌骏

校内导师 王长元 专业技术职务 教授
企业导师 高宗科 专业技术职务 主任医师
专业领域 机械

西安工业大学

2025 年 5 月 中国.西安

**Pilot Operation Intention Inference Method using
Multidimensional Data Fusion**

by
Wu Jun

Thesis Submitted to the faculty of the Xi'an Technological University in

Partial Fulfillment of

the Requirements for the Degree of

MASTER

in

Mechanical Engineering

Supervisor: Professor Wang Changyuan

Supervisor: Chief physician Gao Zongke

Xi'an Technological University

May 2025

Xi'an, Shaanxi, P.R.China

摘 要

根据上世纪中叶至今的统计数据可知,有半数以上的致命性飞行事故是由于人为操作失误导致的,因此减少人为失误是提升飞行安全性最有效的途径。随着智能化设备的发展以及人机交互技术的成熟,关于人类意图的研究逐渐被拓展并应用在各个领域之中。而对于飞行过程中的飞行员操作意图,现有研究存在建模数据单一、真实飞行中采集数据困难等可实现性问题。对此,本文提出一种基于非侵入式设备采集眼动数据,并与实时飞行参数融合的飞行员操作意图推断方法。旨在通过无感的方式快速、精确地推断意图,使系统能在关键时刻辅助飞行员进行决策,提升飞行安全性。本文的主要工作有以下几个方面:

(1)深入分析视觉系统机理和眼动特征,选取适用于表示注意力变化的扫视特征作为区分意图眼动的特征数据。使用 QT 开发实验 GUI 界面,设计实验流程并用非侵入式眼动仪采集眼动数据。对原始数据进行线性插值法补全眨眼导致的缺失、EMA 算法消除数据抖动。再使用 SVM 进行建模,对比其他模型证明其在小样本数据下的优秀分类能力。

(2)按照单一与组合的操作方式,将飞行操作将飞行操作分为 9 种类型,并根据其过程中的参数变化情况选取建模使用的飞行参数。使用俄制 Su-25T 作为实验飞行器,在六自由度飞行平台上进行五边形飞行实验。通过卡尔曼滤波计算飞机姿态角,并与垂直速度、转弯率、眼动数据一同构成表征意图数据集。

(3)将数据集分为训练集与测试集两个部分,并使用机器学习与深度学习两种方法进行建模。在使用隐马尔可夫模型的方法中,通过引入高斯混合模型增强对连续数据的描述能力。对于每个操作意图训练对应的 GMM-HMM 模型,并得到高斯成分为 6 时模型性能最佳。再通过消融实验验证了多维数据融合方式,以及使用意图眼动分类对于模型性能提升的有效性。而在使用 LSTM 的方法中,引入 CNN 网络对原训练集进行处理,将两种数据分别提取局部特征后,在特征层融合后传入 LSTM 层进行学习。在测试集上的评估结果表明该方法可有效决策出正确的操作意图。

综上所述,本研究提出了一套完整的数据采集与处理流程,并最终在同样的训练与测试数据上,通过两种方法实现飞行员操作意图推断任务。隐马尔可夫模型可以在极小的训练成本下得到相对准确的决策结果。而 LSTM 得益于其复杂的模型结构和更高的训练成本,结果往往更加准确。本研究不仅能对航空领域提高飞行安全性的问题提供解决方案,还能对其他领域内的相似问题提供参考。

关键词: 人机交互; 意图推断; 数据融合; 眼动特征; 机器学习

本研究得到国家自然科学基金项目(编号: 52072293)资助

Abstract

Based on the statistical data from the middle of the last century to the present, it is known that more than half of the fatal flight accidents are caused by human operational errors. Therefore, reducing human errors is the most effective way to improve flight safety. With the development of intelligent devices and the maturity of human - computer interaction technology, research on human intentions has gradually been expanded and applied in various fields. However, for the research on pilots' operation intentions during flight, existing studies have practical problems such as single - source modeling data and difficulties in collecting data during actual flights. In response to this, this paper proposes a method for inferring pilots' operation intentions. This method collects eye - movement data through non-intrusive devices and fuses it with real-time flight parameters, aiming to infer intentions quickly and accurately in a non-intrusive manner, enabling the system to assist pilots in decision-making at critical moments and enhancing flight safety. The main work of this paper is as follows:

(1) Thoroughly analyzing the mechanism of the visual system and eye-movement characteristics, and selecting saccade features suitable for representing changes in attention as the characteristic data for distinguishing intention-related eye movements. And QT is used to develop the experimental GUI interface, design the experimental process, and collect eye-movement data with a non-intrusive eye tracker. For the original data, using the linear interpolation method to complete the data missing caused by blinking and the EMA algorithm to eliminate data jitter. Then, SVM is used for modeling, and compare it with other models to prove its excellent classification ability with small-sample data.

(2) According to the single and combined operation modes, it should be divided flight operations into 9 types, and selects the flight parameters used for modeling based on the parameter changes during the operation process. Using the Russian-made Su-25T as the experimental aircraft, and conducting a pentagonal flight experiment on a six-degree-of-freedom flight platform. Then, Calculating the aircraft attitude angles through the Kalman filter, and combining them with the vertical speed, turn rate, and eye-movement data to form an intention-representing dataset.

(3) Dividing the dataset into a training set and a test set, and using the methods of machine learning and deep learning for modeling. For using the Hidden Markov Model, introducing the Gaussian Mixture Model to enhance the ability to describe continuous data. For training corresponding GMM - HMM models for each operation intention, it is obtained that the best performs of model when the number is 6 of Gaussian components. Then, verifying the effectiveness of the multi-dimensional data fusion method and the use of

intention-related eye-movement classification in improving the model performance through ablation experiments. In the method for using LSTM, introducing a CNN network to process the original training set. Extracting the local features of the two types of data respectively, and inputting them into the LSTM layer for learning after fusing the features at the feature level. The evaluation results on the test set show that this method can effectively determine the correct operation intention.

In conclusion, this study proposes a complete data collection and processing process. Based on the same training and test data, the task of inferring pilots' operation intentions is achieved through two methods in the end. The Hidden Markov Model can obtain relatively accurate decision-making results with minimal training costs. While benefiting from complex model structure and higher training costs, LSTM would often provide more accurate results. This research can not only provide solutions to the problem of improving flight safety in the aviation field, but also offer references for similar problems in other fields.

Key Words: human-computer interaction; intention inference; data fusion; eye movement feature; machine learning

The present work is supported by the fund of The National Natural Science Foundation of China (No.52072293)

目 录

1 绪论.....	1
1.1 研究背景与意义.....	1
1.1.1 研究背景.....	1
1.1.2 意图推断概念及应用.....	2
1.1.3 研究意义.....	2
1.2 意图推断国内外研究现状	3
1.2.1 不同类型输入源数据研究综述.....	3
1.2.2 航空领域内的意图研究现状.....	5
1.3 现有研究总结和问题分析	7
1.4 论文结构与主要研究内容	7
2 眼动数据分析与意图眼动分类	10
2.1 视觉系统分析及眼动特征提取	10
2.1.1 意图视线注意力转移分析.....	10
2.1.2 眼动特征分类与选取.....	11
2.2 基于支持向量机(SVM)的意图眼动分类方法	11
2.2.1 支持向量机算法实现过程.....	11
2.2.2 实验平台软硬件配置.....	13
2.2.3 眼动数据采集与特征提取.....	14
2.2.4 意图眼动分类模型搭建.....	17
2.2.5 模型分类性能评估.....	19
2.3 本章小结.....	21
3 飞行操作类型定义及飞行参数选取	23
3.1 飞行器分析与操作.....	23
3.1.1 实验用飞行器选取.....	23
3.1.2 表征操作意图飞行参数分析.....	24
3.1.3 飞行员操控动作类型规范化.....	25
3.2 模拟飞行实验数据采集与处理	26
3.2.1 六自由度飞行平台配置介绍.....	26
3.2.2 五边形飞行任务设计及实验流程.....	27
3.2.3 基于卡尔曼滤波的姿态角解算.....	30
3.3 本章小结.....	34
4 飞行员操作意图推断模型搭建	35
4.1 基于隐马尔可夫模型(HMM)的方法.....	35
4.1.1 隐马尔可夫模型原理.....	35

4.1.2 高斯混合函数离散输入实现.....	39
4.1.3 GMM-HMM 操作意图模型搭建	40
4.1.4 机器学习方法模型性能分析.....	41
4.2 基于长短期记忆网络(LSTM)的方法	45
4.2.1 RNN 与 LSTM 神经网络结构介绍	45
4.2.2 基于卷积神经网络的特征层融合方法	48
4.2.3 CNN-LSTM 操作意图模型搭建	51
4.2.4 深度学习方法模型性能分析.....	52
4.3 本章小结.....	55
5 结论与展望.....	56
5.1 结论.....	56
5.2 展望.....	57
参考文献.....	58

1 绪 论

1.1 研究背景与意义

1.1.1 研究背景

自飞机成为主要交通、运输和作战工具以来，飞行安全就成为航空领域永恒的主题，尽管已经有较为完善的事故监测与预防体系，但是全球范围内的空中事故还是层出不穷，其一旦发生也会严重威胁到飞机所乘人员生命安全。更有严重的情况，还会造成持续的社会负面影响^[1]。21 世纪以后，计算机、电气等技术的成熟和新材料的应用，使得飞机自身的运行环境和设备可靠性都得到了大幅度的提升，由于飞机自身设备故障所引起的飞行事故也越来越少。表 1-1 为空难事故网站 (<https://planecrashinfo.com>) 所统计的 1950 年至 2019 年所发生的所有致命性民航事故原因分类。从整体上看，有高达半数左右的事故都是由飞行员自身失误所导致的。

表 1.1 每十年致命事故原因分类

		十年周期							
		1950	1960	1970	1980	1990	2000	2010	总计
事故原因	飞行员失误	50%	53%	49%	42%	49%	50%	57%	49%
	机械故障	26%	27%	19%	22%	22%	23%	21%	23%
	天气	15%	7%	10%	14%	7%	8%	10%	10%
	蓄意破坏	4%	4%	9%	12%	8%	9%	8%	8%
	其他	5%	9%	13%	10%	14%	10%	4%	10%

因此，人为操作失误是目前造成飞行事故的最主要原因，也是飞行安全的决定因素^[2]，所以减少人为失误即是提高飞行安全水平最有效的方法。随着航空培训体系不断完善，通过提升飞行员自身综合素质的方法得到了极大的拓展。许多航空公司和军事航空机构广泛采用模拟飞行器（Flight Simulator）进行高强度训练，使飞行员在各种极端环境中进行应对练习，增强对复杂气象、设备故障等突发情况的反应能力。航空心理学研究也在优化飞行员选拔和心理调适，以减少疲劳、压力等因素对操作的影响。这些方法在一定程度可以降低飞行事故的发生。而随着智能化设备的普及，外部系统的辅助作用也逐渐凸显出来。其中，人机交互（Human-Computer Interaction）技术被广泛地应用在各类半自主化系统当中。

人机交互技术旨在研究系统与用户之间交互过程，它可以将大量的信息、提示和请求等以特定方式传递，在系统处理完信息后，会将其结果再以特定方式呈现给用户，从而实现一次完整的交互体验^{[3][4]}。人与机器之间的信息传递能够使系统分析并产生契合于当前环

境的操作指令，以此控制各类半智能化设备做出合理的安全举措，从而有效地避免不可预料状况的发生。因此，智能系统如何根据输入数据快速而精确的推断用户的想法并给予回馈，成为了人机交互技术中的重要问题，即意图推断问题。

1.1.2 意图推断概念及应用

从广义上讲，意图推断又称为意图识别，是指通过各种应用场景下的传感器，收集到目标本身以及周边环境的信息进行综合分析，利用建模和相关推理方法进行不确定性推理，从而判断、预测或者解释目标的设想、打算、计划以及过程^[5]。早期的意图识别高度依赖人类自身的思维判断和知识经验，由于人本身的感官能力与知识水平的限制，只能在复杂度较低的场景下做简单推理。近年来，随着统计学理论的发展、各类人工智能算法的出现以及硬件性能的大幅提升，意图识别的方法也更加多样和精准，应用领域也拓展至交通运输、网络安全、电子游戏等方面。

目前意图识别技术在交通领域内的应用大多集中在民用车辆的辅助驾驶系统上。例如宋晓琳^[6]等人对于驾驶员换道意图的研究，通过获取驾驶员对自身车辆操控信息以及外部邻域车辆的距离方位信息，推断驾驶员的实时换道意图并给予辅助提示，从而有效降低因驾驶员属于观察导致的交通事故发生。

而对于驾驶环境更为复杂的航空领域，意图推断任务需要有针对性地根据飞行环境与任务目标来制定实现方法。现有研究多以空中作战敌方目标的战术意图推断为研究方向，如张晨浩^[7]等人将目标作战意图分为威胁意图和非威胁意图，再细分为独立作战意图和群体作战意图进行推断，根据战术意图推断结果制定我方战术计划。而对于我方飞行员的操作意图推断的研究尚处于早期探索，大多为模拟飞行实验环境下基于单一数据的建模方式，且数据采集对目标以及外部环境状态均有较高的要求。因此在复杂的实际飞行环境中，此类方法的稳定性尚有优化空间。

综上所述，本文拟实现一种基于多维数据融合的意图推断方法。通过非侵入式设备传感器采集所需数据，消除数据采集对飞行员的直接影响以提升数据可用性。该方法旨在提升飞行过程种人机交互的效率，确保系统在关键时刻能协助飞行员做出正确的决策，减少人为失误的发生。

1.1.3 研究意义

在航空领域内，快速、精确地意图推断方法：1) 可以提高飞行安全，通过实时监测飞行员的意图和状态，预防和预警可能的飞行事故。2) 可以优化飞行控制，通过实现人机共享自主权，根据飞行员的意图和环境信息，自动调整飞机的控制参数和模式。3) 可以增强飞行体验，通过提供个性化的飞行辅助和反馈，增加飞行员的舒适度和信心。4) 可以促进飞行员的培训和评估，通过分析飞行员的意图和行为，提供有效的教学和反馈，提高飞行员的技能和水平。除此之外，该意图推断方法可作为其他领域任务提升人机交互体验、辅助用户达成目的参考。

1.2 意图推断国内外研究现状

1.2.1 不同类型输入源数据研究综述

1) 基于自然语言输入

以自然语言为输入数据的意图识别主要分为文本分析和语音识别两类。其中文本分析是对用户直接输入的文本内容进行分析和理解,包括识别词性、划分语句、语法和语义分析等^[8]。对于传统算法难以捕捉短文本语料特征的问题,王超^[9]等人结合 TextCNN 和 BiGRU-att 的优点提出双通道短文本意图识别模型。在两种网络提取局部特征后进行融合,最终在测试数据集得到的 96.68% 的准确率和 96.67% 的 F1 值。郭云雪^[10]发现了在人机对话系统中,以往的意图识模型不能很好的应对文本噪声多、特征稀疏、一词多义、前后对话信息不独立等问题。并针对于此,分别提出了基于 BERT 和 word2vec 的联合模型,以及使用了 CNN、LSTM 和 BLSTM 模型来应多用户使用短句或省略词的情况。

自然语言作为人类生活中最常用的沟通工具,通常由自主发出且带有实际交互意义,有着易获取、高信息密度的特点。因此被广泛应用于搜索引擎、智能 AI 等场景中。

而语音识别技术建立在文本技术之上,先通过训练好的声学模型对采集到的音频进行处理,转化为文本之后再进行意图识别^[11]。Zhang^[12]等人鉴于 RNN 模型对口语理解任务的局限性,提出了基于 Graph-LSTM 的识别方法。其使用卷积层与自注意力单元来学习语音数据的长距离依赖关系,通过上下文门控机制理解历史信息中的上下位关系。并在测试集上得到了 87.57% 的意图识别准确率。周新宇^[13]提出了一种条件序列生成对抗网络来解决标记训练数据不足的问题。同构基于转换器的双向变换编码与基于深度网络的语义模的快速意图识别匹配算法,用来解决复杂系统上的识别时延问题。

语音输入的形式降低了输入数据的时间和操作成本,但由于外界干扰和用户自身特征差距较大带来的影响,导致其对比其他数据的识别精度普遍略低。因此,目前语音识别技术在较短的输入数据量和指定有限的意图框架下效果尚可,如语音助手、智能控制、医疗保健等场景中都有着较为广泛的应用。

2) 基于行为信息与环境信息输入

行为指用户在一定时间内所做连续动作的总和,用户的行为或多或少会决定环境信息的变化与否,例如在大多数载具当中,驾驶员对油门的行为会直接影响载具的速度变化。针对于连续的行为信息,Stefan^[14]等人提出一种基于隐马尔可夫模型(HMM)的方法,利用在 GECO 飞行模拟器中记录的专业飞行员的飞行操作数据,参考可以触发特定事件的上下文操作,结合领域内的专家共识,来总结出飞行员舱内交互行为与飞行任务的逻辑关系,从而对 HMM 的参数进行训练和验证。Strohal^[15]和他的团队使用了一个基于知识的驾驶舱助理系统(CAMA),该系统由数个不同功能的模块组成,服务于军用运输机的情景感知和冲突解决。其中飞行员意图和错误的识别(PIER)模块使用了模糊逻辑和自组织映射

(SOM)来学习飞行员的行为模式,并通过神经网络和聚类分析来优化模型。周旺旺^[16]将每10个连续雷达取样点的目标状态进行封装,结合最后时刻飞行速度、高度与角速度等飞行器参数制作出12维特征数据与8种常见作战意图的Data数据集。最后对比了多个常用神经网络模型来验证其有效性,最终确定Adam优化器+ReLU激活函数的模型准确率最高,达到了98.16%。

行为信息和环境信息的记录方式都是以时间为序列进行记录,具有真实的数学规律。与被人脑加工过的主观的文本和语音数据相比,这种数据是客观且更具说服力的。

3) 基于生理信号输入

由于生理机能正常的人在处于活动状态下会产生多种生物电信号,并且根据不同的活动呈现出某种规律,因此生理信号具有较强的可学习性。生理信息数据一般通过专业仪器采集到原始信号后,进行较为复杂的放大、滤波、转换等预处理,再通过机器学习或者神经网络等方法构建分类器,再根据特征参数来识别不同的意图。

李玉祥^[19]针对于现有使用脑电数据实现意图识别方法的缺点,分别提出了三种解决方案:采用相似性聚类的双分类器对抗域适应跨个体意图识别算法,解决了个体数据分布差异性大导致意图识别模型精度下降的问题;基于域不变特征的无源域适应意图识别算法,解决了已有用户数据无法访问导致跨个体识别困难的问题;基于加权对抗的域适应跨时期意图识别算法,解决了脑电数据分布非平稳波动导致用户定制模型精度下降的问题。

Kim^[17]和Zhang^[18]设立了多种不同场景的模拟驾驶实验。Kim通过采集数名被试者的脑电信号,提取了三种类型的特征来区分不同的种类的刹车情况:事件相关电位,准备电位和事件相关去同步。他们使用了正则化的线性判别分析来对这些特征进行分类,最后使用AUC值来评估分类性能。而Zhang的团队使用了熵和复杂度的指标来分析被试者的脑电信号,发现这些指标能够反映驾驶员的疲劳程度,并且与主观评分和驾驶行为有一致的趋势。最后使用了支持向量机来对驾驶员的疲劳状态进行分类,达到了较高的准确率和召回率。

4) 基于视觉信息输入

眼睛是人类获取环境信息的重要工具,其根据不同的目标以及追踪方式都会产生不同的眼动行为。在此过程中,通过专业仪器捕捉到视线运动的动态轨迹数据,可以从一定程度上反应被试者注意力的变化过程,进而用来推测其行为或心理状态。随着近几年机器学习和计算机视觉技术的快速发展,视线信息越来越多的被用于人机交互、智能辅助、生物反馈等领域。

王一男^[20]等人建立了一种GMM-HMM模型用于判断车辆驾驶员的换道意图。该实验收集了头眼运动、方向盘转角熵、车辆状态和环境状态等数据,提取出能够表征驾驶意图的特征变量。GMM可以处理连续数据的特性很好的弥补了传统HMM只能处理离散数据的缺陷,所以当输入数据时间密度更大时,其模型的识别精度也会提高。将所有数据组合训练时模型识别效果最好,其准确率达到了91.2%。

聂玉洁^[21]针对于老人机能下降,日常行动不便的情况,提出了一种基于眼动信息的老年人日常生活意图识别框架。作者首先模拟出室内视觉平面图像,在 Tobi 眼动仪捕获的原始眼动数据中,利用 SVM 筛选出有意图眼动信息,并结合特定场景交互上下文行为构建出训练数据集,最后使用朴素贝叶斯和隐马尔可夫模型进行训练,分别得到了 4 个意图的 83.7%准确率和 8 个意图的 71.1%准确率。

综合上述信息可知,意图识别技术有着较为广泛的实现方式。以不同类型的数据作为输入源则各有优劣,本文对其特点进行了总结,如表 1.2 所示:

表 1.2 不同输入源优缺点总结

输入源	优点	缺点
自然语言信息	易于获取,技术已经有大规模的商业应用,其开发较为成熟。可以提供人的声音特征,用于身份识别、情感分析、行为识别和异常检测等任务。存储和检索较为方便且不占空间,便于后续的分析 and 应用。	文本存在歧义和多义性,需要进行上下文分析和消歧。由于文本的规范性不强,所以容易存在噪声和错误,需要进行清洗和预处理。可能存在口音和方言差异,影响识别率,需要进行模型适应和训练。
行为环境信息	采集到的数据多为数值型数据,较为直观且利于统计与处理。可以实际的体现出由意图产生的某种行为与该行为导致的周围环境信息变化,一般由多种数据组成。	数据量庞大且种类繁多,对于不同传感器采集到的不同类型的数据要进行统一维度的处理。筛选困难,泛化性弱,相同的数据在不同的识别场景中有可能造成识别率降低。
生理信号	生理信号可以提供如脑电波、心电图、肌电和眼动等丰富的信息,从生理学和医学的角度来分析人的行为意图。生理信号一般超前于人所产生的实际运动,理论上可以用于运动预判	生理信号采集设备成本较高,需要专业设备和技术支持。且采集过程中可能会对人體造成一定的不适或危害,需要进行安全保护和伦理审查。
视觉信息	视觉信息可以提供人的视觉行为特征,如注视点位置、注视时间等,多种信息来源可以实现多模式交叉应用。可直接表达人的注意力方向,以此来推测意图。	视觉信息较为复杂采集过程中受到环境光照、传感器性能等因素,采集到的噪声类型较多且难以处理,需要大量运算,对整体设备性能有一定的要求。

1.2.2 航空领域内的意图研究现状

由于航空飞行的特殊性与高风险性,其他领域内的方法通常无法直接移植。现有航空领域的意图识别基于通用意图识别技术,结合特定飞行任务的特点进一步改良。下文将其按照建模方法的不同进行区分介绍。

传统机器学习方法历经长时间的发展与积累而趋于成熟,其依靠迭代算法不断推导最优拟合函数,以实现意图的分类决策。江佳运^[22]等人提出了一种基于 GASVM-HMM(遗传算法、支持向量机、隐马尔可夫)双层模型的飞行员操控意图识别方法。在模拟飞行平台采集被试者与显示器和控制装置的交互动作数据,建立对应的操作意图数据集,并将其输入至 GASVM 层进行初步的意图识别,然后将输出转化为概率输入到 HMM 层进行进一步的意图识别,该双层模型的准确率可达 92.92%。

Ernest^[23]等人介绍了基于遗传模糊树算法的人工智能系统 ALPHA。ALPHA 的结构包括用于处理不同的决策层次的多个分支，如高级战术，开火，规避，态势感知和防御性等，被用于实现特定任务中对无人作战设备群体的行为控制。在此文中，作者团队模拟了空中作战任务，使用 ALPHA 控制无人机群来对抗人类驾驶员，使用收集到的作战数据训练出最优 GFT 作为控制器。

杨雨田^[24]等人针对复杂战场环境中敌目标战术意图的动态性和序列性，构建了动态序列贝叶斯网络模型，分析了多实体贝叶斯网络在表达规则知识概率迁移关系和序列关系的局限性，提出了基于 EMEBN 的 DSBN 构建方法，在实验当中设置连续的多批次敌方空中目标协同作战并预测其意图，验证其有效性和可行性。Chen^[25]的团队提出了一种多时间尺度分层意图识别方法，设置海军作战任务为实验场景，将海军编队的意图分为三个层次：编队层、群层和平台层，对于不同层次的意图分别使用情境特定贝叶斯网络和动态贝叶斯网络的层次贝叶斯网络，来处理快时标的低层意图识别和慢时标的高层意图识别，这种方法可以更好的处理不确定性和动态性的问题。

近年来，随着深度学习的理论发展和硬件计算能力的提升，搭建神经网络模型的方法也逐渐被用于意图识别领域中。贾苏元^[26]等人将自适应神经网络模糊系统（ANFIS）用于目标的意图识别，该模型是一种基于 Takagi-Sugeno 型的神经网络结构，其推理将去模糊化结合到模糊推理系统中。采用误差反向传播算法，在前向后向学习当中分别调节前提参数和结论参数，使得误差代价函数最小化，从而提升模型的识别准确度。

滕飞^[27]等人针对于目标状态呈现动态、时序变化的特点，在长短期记忆网络(LSTM)的基础上引入双向(Bidirectional)传播机制和注意力(Attention)机制，提出基于 BiLSTM-Attention 的目标战术意图识别模型，该模型在准确率和损失值两方面都表现得更加优异，较传统机器学习方法 SVM 和 MLP 准确率可提高约 30%，较传统神经网络方法准确率可提高约 20%，较基础 LSTM 模型准确率提高 2.8%。

彭俊榕^[28]等人为了实现基于人工智能的单人制机组，在 Cessna-172S 驾驶舱内，采用 YOLOv5s 模型对采集到的飞行员手部操作图像进行训练，可以有效地检测出左、右手的操作杆握持状态。并使用 Hough 变换以及 AlexNet 网络对飞机倾斜和抚养指示进行检测，得到了平均 1.5 秒内的检出时间与 95%的检出率。使用朴素贝叶斯对 Media Pipe 框架提取手部运动特征数据进行分类操作，实现了座舱面板的操作检测。最终综合全部数据判断飞行员的操作类型。

可以看出，机器学习方法经过长期发展已较为成熟，其能够在样本量相对较少且数据不复杂的情况下，快速训练出有效的分类模型。而深度学习方法通常需要大量的输入数据和较高的计算资源，模型复杂度较高。但其在处理高维数据和复杂任务时展现出显著优势，往往能获得更好的性能表现。

1.3 现有研究总结和问题分析

通过查阅文献可以发现,关于人类意图的研究进展主要体现在不同类型的输入源数据及建模方法上。这些方法的框架大多为将采集到的各类人体、外部环境和设备信息进行有监督学习,从而能够正确对各项意图进行分类。在现有的航空领域意图研究中,受限于复杂的飞行任务环境,多数研究采用单一数据作为输入来实现少量类型的分类任务,这使得此类方法的泛化能力往往较弱。而对于可学习性极高的生理信息类型,在数据量充足的情况下往往能得到较为精准的分类结果。然而生理信号的采集大多采用侵入式设备完成,不同个体之间的变化差异较大,同时数据采集的过程中对外部环境变化较为敏感。因此,在航空任务复杂外部飞行环境下难以保证数据有效性,而为了将数据采集对飞行员的影响降至最低,也应当避免侵入式设备的使用。

综上所述,为了实现快速、精确的飞行员操作意图推断方法,本文在同时考虑保证飞行员驾驶体验与采集数据有效性的前提下,使用非侵入式设备以达到飞行过程中无感知的数据采集。而对于现有意图研究大多局限于分析单一类型数据源的情况,从人机数据融合的方式出发,将眼动数据与多种飞机飞行参数来构成表征飞行员操作意图的多维数据集,最终以两种模型结构来实现操作意图的正确决策。

1.4 论文结构与主要研究内容

综合上文所提及的研究现状分析可知,在意图推断领域的任务中,选取合理的意图表征变量数据以及意图推断模型的构建方法对决策结果有较强的影响。本文以推测飞行员在飞行过程中产生的基本操控意图为任务目标,基于在模拟飞行实验过程中收集到的飞行员视觉信息以及飞行设备的各项状态信息构建能够表征飞行员操作意图的数据集,最终使用机器学习与深度学习方法对不同操作意图进行建模并计算分类准确率。

文章的主要研究内容包括:

(1) 使用支持向量机对采集到飞行员飞行过程中的眼动数据进行分析,根据视线特征区分出意图眼动数据,提升数据集质量 (2) 通过卡尔曼滤波对飞行设备状态信息进行飞行姿态解算,将得到的飞行设备姿态角数据与飞行员眼动数据结合构建意图表征数据集 (3) 基于隐马尔可夫模型对意图推断任务进行建模,引入高斯模型使其拥有对数值连续的多维序列的处理能力。基于长短期记忆神经网络对意图推断任务进行建模,分别计算不同方法下的模型准确率,分析不同条件下的模型优劣情况。

文章的整体框架如图 1.1 所示:




图 1.1 文章整体框架图

本文共包含了五个章节，每个章节的具体内容安排如下：

第一章为绪论部分。首先介绍了本文的研究背景、研究意义，以及意图推断领域的国内外研究现状，并总结了不同类型输入源的优缺点。针对于现阶段飞行员操作意图的研究多以侵入式设备采集数据，且缺少多维数据融合方式的研究现状。本文拟设计一个以飞行参数以及眼动数据为输入的飞行员操作意图推断方法。最后简要介绍了论文主要研究内容与章节安排。

第二章为视线数据分析。首先从人类视觉机理出发，分析在产生某意图时的视线对于注意力的表示关系。并在两类常见眼动特征中，确定可用于判断意图眼动的眼动特征数据。之后详细介绍了采集眼动数据所使用的设备环境和采集实验方法，设计人机交互界面并按照拟定流程采集出带有标签的眼动数据，在经过预处理后使用支持向量机算法对其进行分类，实现意图眼动数据的检测。

第三章为飞行器数据分析。通过分析飞行时的参数变化模式，选取横滚角、俯仰角、垂直速度以及转弯率作为飞行参数数据。将飞机操作类型按照飞行时不同的运动状态分为九种类型用于后续评估。之后在六自由度模拟飞行平台上，设计五边形飞行实验采集所需数据，并使用卡尔曼滤波方法融合加速度角速度数据姿态解算，求出飞行器欧拉角。最后与眼动数据融合构建意图表征数据集，用于下一步的模型训练与验证。

第四章为意图推断模型的搭建。此章节采用机器学习与深度学习两种方式进行建模。第一部基于隐马尔可夫模型实现，首先介绍了隐马尔可夫模型的构成、训练与评估方法，并在普通隐马尔可夫模型的基础上引入高斯模型，使其拥有处理任务中连续多维时序数据

的能力。之后对于不同的操作意图分别进行建模，构成操作意图模型库。最后测试集数据对不同方法的模型性能进行对比评估。第二部分基于长短期记忆网络实现，首先介绍了循环神经网络的结构、优势，以及其在处理长时间步数据时的缺陷。针对这种情况，长短期记忆网络引入门控机制有效解决历史数据的遗忘问题。在此之上，选用卷积神经网络对输入数据进行局部特征提取。最终由第一部分相同的数据对模型进行训练与评估。

第五章对整体的工作进行了总结，并针对研究的不足之处拟定了未来可能采取的优化方式。

2 眼动数据分析与意图眼动分类

人类视觉系统（Human Visual System, HVS）不仅是获取外部世界信息的主要途径，也是认知处理和行为决策的核心组成部分^[29]。人类活动过程中的视觉信息并不是随机变化的，在意图由产生转为执行的这一过程中，个体的视觉行为也会完成由自然行为到主动行为的转变。当某个区域或对应物体处于意图行为过程中的关键节点时，其对应的视觉行为也会表现出不一样的特征变化，其中最主要的就是眼动信息（Eye-Tracking）的变化。而眼球在连续工作时，由于其特殊的眼肌结构和神经机制，会导致经常出现无意义或与目标背道而驰的视线运动行为，这种现象一般被称为“米达斯接触”现象^[30]。因此，在采集分析眼动数据时，应当对无意义的眼动行为作出区分判断，减小其对实验结果的影响。

2.1 视觉系统分析及眼动特征提取

2.1.1 意图视线注意力转移分析

常说“眼睛是心灵的窗户”，视觉信息处理的过程中，眼动数据则是反映个体注意力分配和行为意图的重要生理信号。研究表明，视觉注意力的分配通常伴随着注视点的运动轨迹、注视时间以及眼动模式的变化^{[31][32]}。意图作为目标驱动的认知状态，能够引导个体的眼动行为做出相应变化，因此眼动信息与人的意图也密切相关。

图 2.1 为某个意图视线转移示例图。假设个体的视野范围内有咖啡、水杯和热水壶三个相关物体。当个体产生想要喝咖啡的意图时，视线会在视野范围内的咖啡、水杯和热水壶之间进行快速移动寻找目标物品，视线在目标物体上做一定停留后按照意图中的执行动作序列寻找下一目标物体。



图 2.1 意图视线转移示例

在这一过程中，大脑的神经信号主要通过视觉皮层、顶叶和前额叶区域的互动进行传递^[33]。顶叶负责处理物体的位置、空间关系以及目标的筛选，而前额叶则调控这些信息的整合和动作计划。大脑通过前额叶皮层向视觉皮层发送指令，将注意力转向周围的相关物体，完成咖啡-水杯-烧水壶的视线移动序列。同时运动皮层会被激活，协调手部的执行相应的动作，最终完成倒咖啡-冲咖啡-喝咖啡的动作序列。

可以看出,通过分析视觉信息和注意力的互动关系,能够隐性的描述出人类在感知过程中的眼脑联动机制,为人机交互、认知障碍诊断等领域提供了重要的理论依据和实践指导。而随着科学技术的发展,对于视觉信息的分析已经成为认知心理学、神经科学、人工智能等领域的一个重要研究方向。同理,飞行员在驾驶飞行器的过程中,个体的视线会根据操作意图的产生集中在最为关键的区域^[34],从而为其决策提供必要的信息。因此,眼动信息的变化可以为推测个体的操作意图提供有力的证据^[35]。

2.1.2 眼动特征分类与选取

在眼动研究中,眼动特征是分析个体视觉行为和注意力分布的重要指标,通常分为注视特征(Fixation)和扫视特征(Saccade)两大类。这两类特征分别代表了人类视觉信息加工的两种不同机制。

注视是指眼睛在视觉场景中的某一区域稳定停留的过程,一般注视时间持续在200-300ms时即可读取该区域的信息^[36]。在注视期间,视觉信息主要通过中央凹(Fovea)传入大脑进行精细加工,其特征可以反映个体对某一区域的集中关注程度和兴趣程度。常见的注视特征包括注视持续时间、注视次数以及注视位置的分布模式等^[37],往往表示个体对特定视觉区域的静态关注行为和视觉停留的局部特点,而对个体的动作规划和注意力变化的描述能力有限。

扫视是指眼睛快速从一个注视点转移到另一个注视点的过程。由于扫视过程中视网膜的感知能力较弱,因此扫视特征更多反映了个体对于整个视觉场景中的探索过程。常见的扫视特征包括扫视幅度、扫视速度、扫视方向等^[37],往往表示个体对目标的探索路径和优先级选择。因此,扫视特征能够精准的体现个体在视觉场景中动态转移注意力情况,更适合用于判断个体的动作规划和意图变化。

在扫视特征中,视线位置的扫视速度和相对位移是两种能够有效表征扫视行为动态变化的关键特征。扫视速度指视线在连续移动过程中的速度变化,而相对位移则是视线在两个扫视点之间欧式距离。扫视速度和相对位移的变化通常能够反映个体视线在视觉场景中的运动情况与注视点之间的转移特性。在有意图眼动中,个体的视线会围绕目标区域进行有规律的、方向性强的短距离位移,无意图眼动则缺乏规律性,表现为较大的随机性或无明显目标导向。因此,这两种特征在描述是否为有意图眼动时具有较强的区分能力。

基于上述分析,本文决定将扫视特征中的扫视速度和相对位移作为输入特征,使用机器学习的支持向量机算法进行有监督训练。通过这种方法能够更精确地对个体的有意图眼动行为进行分类,减少“米达斯接触”问题对于意图推测任务结果的影响。

2.2 基于支持向量机(SVM)的意图眼动分类方法

2.2.1 支持向量机算法实现过程

支持向量机(Support Vector Machine,SVM)是一种经典的有监督机器学习算法,由

Vladimir Vapnik 等人在 20 世纪 90 年代提出^[38]。SVM 以其良好的理论基础和出色的泛化能力被广泛应用于分类和回归任务，其核心思想是通过寻找一个最佳超平面将不同类别的样本分开，使得被分类样本的边界样本与最优超平面产生最大间距，来实现精确、高效的分类^[39]。

SVM 的理论遵循统计学习理论中的“结构风险最小化”的原则，通过最大化分类边界的间隔来平衡模型复杂度和训练误差，从而提高模型的泛化能力。相比于神经网络所需要的大量训练样本，SVM 在样本非线性、维度高和数量少的条件下也能保持良好的分类性能。图 2.2 为二分类任务中，解得最优超平面分类原理示意图。其中绿色的“•”表示正例，而红色的“×”表示负例。SVM 通过训练得到唯一的最优超平面，以此为界限实现不同数据的分类。可以看到，在二维平面内数据线性可分时，最优超平面可表示为一条直线。而当数据在二维平面内线性不可分时，SVM 通过引入非线性核函数将数据从低维空间映射到高维空间，在高维空间中寻找最优的分类超平面。




图 2.2 最优超平面分类原理示意图

以 SVM 基本的二分类任务为例，给定分类样本的训练数据集 D ：

$$D = \{(x_i, y_i) | x_i \in R^n, y_i \in \{-1, +1\}, i = 1, 2, \dots, n\} \quad (2.1)$$

其中 x_i 表示第 i 个样本的特征向量， y_i 表示第 i 个样本对应的类别标签，+1 和 -1 分别代表正例与负例。

一般来说，分类最优超平面的几何形式可表示为下式其中 ω^T 为决定超平面方向的法向量， b 为决定超平面与原点距离的偏置项。

$$\omega^T \cdot x + b = 0 \quad (2.2)$$

数据集中任意一点 x_i 到超平面的距离是 x_i 到超平面在法向量方向上的垂直投影。点 x_i 到超平面满足 $|\omega^T \cdot x_i + b|$ ，法向量 ω^T 的单位向量为：

$$\frac{\omega^T}{\omega} \quad (2.3)$$

可得到任意一点 x_i 到超平面的距离为:

$$d = \frac{|\omega^T \cdot x_i + b|}{\omega} \quad (2.4)$$

模型目标需要求得边界样本与超平面有最大化间隔, 则需要最小化 ω^2 :

$$\min_{\omega, b} \frac{1}{2} \omega^2 \quad (2.5)$$

对于正确分类的样本点, 约束条件为:

$$\begin{cases} (\omega^T \cdot x_i + b) \leq -1, y_i = -1 \\ (\omega^T \cdot x_i + b) \geq +1, y_i = +1 \end{cases} \quad (2.6)$$

引入拉格朗日乘子 $\alpha_i \geq 0$ 构造拉格朗日函数, 再分别对 ω 与 b 求偏导并令其为 0:

$$L(\omega, b, \alpha) = \frac{1}{2} \omega^2 - \sum_i \alpha_i [y_i (\omega^T \cdot x_i + b) - 1] \quad (2.7)$$

$$\frac{\partial L}{\partial \omega} = 0 \rightarrow \omega - \sum_{i=1}^n \alpha_i y_i x_i = 0$$

$$\frac{\partial L}{\partial b} = 0 \rightarrow \sum_{i=1}^n \alpha_i y_i = 0$$

通过带入原式将凸二次规划问题转为如下式的拉格朗日对偶问题:

$$\max_{\alpha} \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j (x_i^T x_j) \quad (2.8)$$

$$s.t. \quad \sum_{i=1}^n \alpha_i y_i = 0, \alpha_i \geq 0, \forall i$$

解得 α_i 后, 通过支持向量 $\alpha_i \geq 0$ 的样本构建分类决策函数即可通过输出判断样本分类:

$$f(x) = \text{sign} \left(\sum_{i=1}^n \alpha_i y_i (x_i^T \cdot x) + b \right) \quad (2.9)$$

2.2.2 实验平台软硬件配置

眼动数据的采集是电脑软件与眼动仪器协同记录制作。在采集过程中, 需要实现的目标意图由电脑软件中人为给出, 同时眼动仪器将采集实时的眼动数据并保存。为了快速、精准的采集有效眼动数据并给予正确的训练标签, 本文使用了 Python3.9 和 PyQt5 框架开发了具有 GUI 界面的人机交互眼动数据采集软件, 具体的效果如图 2.3 所示, 界面分为左侧的场景目标显示区域和右侧的功能选择区域。




图 2.3 眼动数据采集 GUI 界面

为了模拟人眼对于目标意图物体的捕获行为，场景目标显示区域内设置有外形各不相同且均具有一定间距的数个目标物体。软件预先设置了 6 种意图用于随机测试，每种意图都有固定的目标物体的观测顺序，所有的目标物体都会出现在相应意图的观测流程之中。为了简化分析，将左侧的场景目标显示区域使用感兴趣区域(Area of Interest AOI)分析法^{[40][41]}以一定间隔划分为多个不同的区域。右侧的功能选择区域依次为开始随机排序、当前给定意图、中止任务和保存数据。

眼动仪器采用 Tobii 公司生产的 Tobii Eye Tracker 眼动仪，最高可在每秒 60Hz 的高刷新率下采集眼动数据，采集数据时将其置于 27 英寸显示器正下方。如图 2.4 所示，Tobii Eye Tracker 眼动仪通过使用三段红外摄像头在角膜上的反射实现检测眼球运动，当视线在交互界面左侧场景目标显示区域，右侧功能选择区域会实时显示用户视线落点的坐标位置，交互程序记录眼动数据并等待决定是否保存。当视线离开左侧场景目标显示区域时，眼动数据被视为无效且不做记录。




图 2.4 Tobii Eye Tracker 眼动仪

2.2.3 眼动数据采集与特征提取

实验共招募了 8 名年龄在 24-28 岁之间的被试者参与此次数据收集，所有被试者均未佩戴眼镜、未患有过眼部疾病且视力水平保持在 4.7 到 5.1 之间。如图 2.5 所示，眼动数据的采集在有固定光源的室内实验室环境中进行。安排被试者坐在装有眼动仪器的电脑屏幕前，为了契合下文模拟飞行试验种飞行器主要仪表区域的位置，被试者的双目与屏幕中心

应有水平方向上，向下 30° 左右的偏移角度。此时被试者双目与屏幕的直线距离应保持在 60cm 左右。开始实验前，所有被试者需提前熟悉实验设置的所有目标物体，在符合上述距离条件的前提下保持自然舒适的坐姿。在实验过程中，应尽可能减少头部移动对实验数据产生的影响。



图 2.5 意图眼动数据采集

实验开始时，左侧界面未显示任何物体，当点击生成按钮后，程序将随即指定一种意图显示在下方文本框内告知被试者，此时被试者需要进行二次确认后方可开始采集眼动数据。此时会有 8 个目标物体被随机分配在场景内的展示位，被试者需要保持自然观察姿态，按照给定意图对应的正确动作系列去寻找意图物体。实验将会在达到最长采集时间 10s 后自动中止，也可以在找到意图目标后手动中止。终止后可以通过右侧按钮选择是否保存此次实验数据。图形界面上的操作流程如图 2.6 所示：



图 2.6 数据采集实验操作流程

根据研究表明，成年人在自然状态下的一次完整眨眼时长普遍在 100ms 到 300ms 内^[42]。在眨眼过程中，大脑皮层、前庭系统与眼肌系统之间的信号传输能够产生精确的前馈控制，使得眼睛能够迅速恢复到先前的注视位置附近。所以在视线落点偏移量较小的情况下，对于眨眼所产生的数据异常，可以根据前后有效数据的线性关系计算并填充，此处使用线性

插值法（Linear Interpolation）来处理缺失数据。

设 $(gaze_x^t, gaze_y^t)$ 为 t 时刻缺失的视线数据，在二维平面中以像素值为单位进行表示。 t_1 和 t_2 分别表示 t 时刻前后拥有有效数据的最近时刻，对应 $(gaze_x^{t_1}, gaze_y^{t_1})$ 和 $(gaze_x^{t_2}, gaze_y^{t_2})$ 。由此可以得到式(2.10)：

$$gaze^t = gaze^{t_1} + \frac{(t - t_1) \cdot (gaze^{t_2} - gaze^{t_1})}{(t_2 - t_1)} \quad (2.10)$$

其中， $gaze^t$ 为 x, y 方向上眼动数据的通用表示。除此以外，对于采集过程中因眼动仪器异常所导致的短时间内数据缺失的情况，该方法同样适用。

在眼动数据采集的过程中，人的注意力需要维持在高度集中的状态。从生理层面分析，长时间的眼部运动会增加眼肌疲劳状态的累积，通常会导致眼球运动速度减慢、凝视异常以及产生不规则的眼跳行为^{[43][44]}。并且，由于环境光线的细微变化和采集设备的精度限制，原始的眼动数据往往不能直接使用。本文通过指数移动平均（Exponential Moving Average, EMA）减少数据噪声。

$$EMA^t = \alpha \cdot data^t + (1 - \alpha) \cdot EMA^{t-1} \quad (2.11)$$

在式(2.11)中， $data^t$ 是 t 时刻原始眼动数据，平滑因子 α 用于决定 t 时刻数据与历史 EMA 之间的权重关系，其取值的变化会影响数据的平滑程度。 EMA^t 代表 t 时刻平滑后的数据，通过递归对历史 EMA 进行加权，最终实现数据平滑。

图 2.7 展示了由 200 个帧节点构成的一组眼动数据在平滑前后的对比。相比于简单的移动平均， EMA 能有效地减少短期数据波动并保留整体的运动趋势，这种特性使其在眼动实验中具有更好的表现。




图 2.7 EMA 平滑数据对比

处理完之后的眼动数据集由 $D = \{time, gaze_x, gaze_y\}$ 表示，需要转换为 SVM 所需要的特征向量，即扫视速度和相对位移。

$$Sac_V(t_0, t_1) = \frac{\Delta d}{\Delta t} = \frac{\sqrt{(gaze_x^{t_1} - gaze_x^{t_0})^2 + (gaze_y^{t_1} - gaze_y^{t_0})^2}}{t_1 - t_0} \quad (2.12)$$

在式(2.10)中, $Sac_V(t_0, t_1)$ 表示 t_0 和 t_1 两个连续的時刻内的扫视速度, $(gaze_x, gaze_y)$ 为视线落点坐标。那么, 对于 n 个连续時刻, 计算 $n-1$ 个 Sac_V 的均值即可得到连续時刻的扫视速度:

$$Sac_V(t_0, t_n) = \frac{\sum_{i=0}^{n-1} Sac_V(t_i, t_{i+1})}{n-1} \quad (2.13)$$

而相对位移由 t_0 与 t_n 時刻视线落点的欧氏距离来表示:

$$Sac_D(t_0, t_n) = \sqrt{(gaze_x^{t_n} - gaze_x^{t_0})^2 + (gaze_y^{t_n} - gaze_y^{t_0})^2} \quad (2.14)$$

实验中所使用的眼动设备刷新率为 60Hz, 则两个连续時刻的间隔为 16.6ms。取 0.1s 内的连续数据提取眼动特征, 故将 n 设为 6。

2.2.4 意图眼动分类模型搭建

收集的数据集包括了来自 8 名被试者的 6204 个原始眼动数据, 使用线性插值法 *EMA* 算法和进行数据填充与数据平滑, 制作出数据集由文本组成, 表示为 $D = \{(Sac_V_i, Sac_D_i), y_i | \forall i\}$, Sac_V_i 表示扫视速度, Sac_D_i 表示相对位移, y_i 表示眼动标签。当眼动仪采集到的眼动特征数据对应的当前目标物体与意图物体一致时, 表示有意意图眼动数据, 标签 y_i 为+1; 眼动仪采集到的眼动特征对应的当前目标物体与意图物体不一致时, 表示无意意图眼动数据, 标签 y_i 为-1。为了消除实验开始与结束之时的视线偏移影响, 除去实验开始与结束 500ms 的数据后, 最终得到共 934 组眼动特征数据集。

图 2.8 为原始眼动数据与处理之后的数据:

gaze_point_x	gaze_point_y	Tag	gaze_point_x	gaze_point_y	Speed	Relative Displacement	Tag
1062.37	1021.46	0	1173.245	538.98075	2331.521	191.391864	-1
1057.79	1041.53	0	1032.948	849.7495833	2767.93	274.048634	-1
1042.93	1069.27	0	1321.24417	819.9025833	2786.145	260.5871606	-1
1029.78	1081.13	0	1611.3125	642.72575	4326.991	326.1580047	-1
-1	-1	-1	1859.1175	470.67875	1847.154	183.9746358	-1
1019.42	1097.92	0	1922.9575	368.6776667	804.524	54.56930113	-1
1021.77	1089.08	0	1699.375	346.05175	3740.152	373.9407241	-1
-1	-1	-1	1136.91883	351.3298333	5369.76	536.9260829	-1
992.551	1091.08	1	718.695167	364.3329167	1471.611	146.3530495	-1
1000.85	1085.14	0	682.127	386.12675	598.9132	59.74719608	-1
-1	-1	-1	778.4715	439.8093333	1671.193	159.2168902	-1
979.096	1079.28	1	903.549333	658.991	2508.779	246.9588581	-1
994.883	1075.38	1	945.613167	937.9164167	1358.622	113.1958392	-1
954.063	1087.53	1	968.222583	1085.5725	799.117	38.6185787	1
973.919	1083.63	1	933.16225	1087.861667	636.7574	34.29512768	1

图 2.8 眼动数据集处理结果

将数据集以 8: 2 的比例分为 747 组训练集与 187 组测试集。通过原始眼动数据处理之后提取到的眼动特征的扫视速度与相对位移作为 SVM 输入数据, 构建意图眼动分类模型。具体的分类流程图如图 2.9 所示:




图 2.9 意图眼动分类流程图

对于训练集 $D = \{(Sac_V_i, Sac_D_i), y_i | \forall i\}$ ，超平面可表示为式(2.15)，其中 (ω_1, ω_2) 表示权重向量， b 表示偏置项。

$$\omega_1 \cdot Sac_V + \omega_2 \cdot Sac_D + b = 0 \quad (2.15)$$

求解最优超平面问题将转为式(2.16)的约束最优化问题：

$$\min_{\omega, b} \frac{1}{2} \|\omega\|^2 = \frac{1}{2} (\omega_1^2 + \omega_2^2) \quad (2.16)$$

$$s.t \quad y_i (\omega_1 \cdot Sac_V_i + \omega_2 \cdot Sac_D_i + b) \geq 1$$

使用拉格朗日乘子法构造函数 $L(\omega, b, \alpha)$ ，分别对 ω 和 b 求偏导并令导函数为 0，带入原函数 $L(\omega, b, \alpha)$ 后引入线性核函数 $K(x_i, x_j) = Sac_V_i \cdot Sac_V_j + Sac_D_i \cdot Sac_D_j$ ，即可得到对偶问题的优化形式：

$$\max_{\alpha} \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j K(x_i, x_j) \quad (2.17)$$

$$s.t \quad \sum_{i=1}^n \alpha_i y_i = 0, \alpha_i \geq 0$$

求解后可得到最优拉格朗日乘子 α_i^* ，最优权重向量 ω^* 可表示为：

$$\omega^* = \sum_{i=1}^n \alpha_i^* y_i (Sac_V_i, Sac_D_i) \quad (2.18)$$

对于任意一个支持向量 x_k ，偏置项 b^* 可表示为：

$$b^* = y_k - \sum_{i=1}^n \alpha_i y_i K(x_i, x_k) \quad (2.19)$$

由此可得到最优超平面的决策函数为：

$$f(Sac_V, Sac_D) = \text{sign}(\omega_1^* \cdot Sac_V + \omega_2^* \cdot Sac_D + b^*) \quad (2.20)$$

对于有意图眼动数据的筛选可以有效提高操作意图推断数据质量。决策函数通过输入扫视速度和相对位移来产生意图眼动的识别结果，当决策函数输出为-1时表示无意图眼动

数据，输出为+1时表示有意图眼动数据。

2.2.5 模型分类性能评估

实验的代码部分基于 Windows 操作系统中 Python3.9 的环境下进行实现。处理后的 934 组眼动数据中，有其中正例 352 组和负例 582 组。上文中以 8:2 的比例将其分为训练集与测试集，训练部分使用加入线性核的 SVM 进行在 747 组训练数据上进行训练，测试部分将使用训练完成的模型在 187 组测试数据上进行测试。训练后的模型分类结果如图 2.10 所示：




图 2.10 意图眼动分类结果

实验使用准确率 (Accuracy)、精确度 (Precision) 和召回率 (Recall) 对模型性能进行分析评估，具体计算方法如公式(2.21)所示。其中，TP 表示 SVM 模型识别为意图眼动，实际样本也为意图眼动的数量；TN 表示 SVM 模型识别为非意图眼动，实际样本也为非意图眼动的数量；FP 表示 SVM 模型识别为意图眼动，实际样本为非意图眼动的数量；FN 表示 SVM 模型识别为非意图眼动，实际样本为意图眼动的数量。

$$Accuracy = \frac{TP + TN}{TP + FP + FN + TN} \quad (2.21)$$

$$Precision = \frac{TP}{TP + FP} \quad (2.22)$$

$$Recall = \frac{TP}{TP + FN} \quad (2.23)$$

则可以得出意图眼动识别模型在测试集上的实验结果由表 2.1 的混淆矩阵所示：

表 2.1 SVM 测试集混淆矩阵

	预测无意图 (F)	预测有意图 (T)
实际无意图 (F)	109	10
实际有意图 (T)	7	61

在总共 187 条测试集数据中，有 119 条为无意图眼动数据，其中 111 条被准确分类，

另外 8 条被判断为有意图眼动；其余的 68 条为有意图眼动数据，其中 62 条被准确分类，另外 6 条被判断为无意图眼动。混淆矩阵百分比热图如图 2.11 所示，可以看出该模型对于有意图眼动和无意图眼动的平均分类准确率超过 90%，表示其有着良好的分类性能。




图 2.11 混淆矩阵识别率热图

为了进一步验证 SVM 模型在小样本数据下训练的意图眼动识别性能优势，本文还使用了机器学习中的决策树（Decision Tree, DT）^[45]和基于逻辑回归的浅层全连接网络（Full Connect Neural Network, FCNN）以同样的数据集条件训练分类模型，并使用相同的测试集评估各自的准确度、精确度和召回率。评估结果如表 2.2 所示：

表 2.2 SVM、DT、FCNN 性能对比

Method	Accuracy	Precision	Recall
SVM	90.91%	85.92%	89.71%
DT	87.17%	84.42%	84.42%
FCNN	87.70%	87.50%	81.82%

对于三种算法的实验结果，可以看出 SVM 具有最高的分类准确度，为 92.51%。DT 的分类准确度最低，为 87.17%。FCNN 的分类效果稍好于 DT，但是低于 SVM，其分类准确度为。由此可见对于小样本数据下的意图眼动识别问题，SVM 训练得到的模型较于其他算法有更好的识别性能。

此外，为了分析 SVM 在小样本数据的非线性分类性能，还使用径向基核函数（RBF）进行非线性分类。RBF 的形式如下式所示，其中 γ 为控制非线性分类边界复杂度的超参数，在此取 $\gamma = 0.5$ 以控制核函数的作用范围。

$$K(x_i, x_j) = e^{-\gamma \|x_i - x_j\|^2} \quad (2.24)$$

为了简化非线性分类计算的复杂度以及减少不同量纲取值范围差异对训练的影响，在训练前对数据进行零均值标准化（Z-Score），其计算公式如下式所示：

$$\mu = \frac{1}{n} \sum_{i=1}^n x_i \quad (2.25)$$

$$\sigma = \sqrt{\frac{1}{n} \sum_{i=1}^n (x_i - \mu)^2} \quad (2.26)$$

$$z = \frac{x - \mu}{\sigma} \quad (2.27)$$

其中 x 为训练集中任意数据点, μ 、 σ 分别为所有数据点均值与标准差。Z-Score 标准化使原数据转换为均值为 0、标准差为 1 的标准正态分布数据。之后将处理完的数据使用 RBF 的 SVM 模型进行训练, 非线性超平面在二维空间中的分类结果图如下图所示。




图 2.12 RBF 核函数分类结果

训练完成的模型在相同测试集上的准确度、精确度和召回率评估结果如下表所示:

表 2.3 RBF 模型性能评估

Method	Accuracy	Precision	Recall
SVM	92.51%	88.57%	91.18%

可以看出, 使用 RBF 的模型相比于使用线性核的模型, 在准确度、精确度和召回率方面均有微弱的提升。由于非线性超平面含有指数函数的运算, 这使得 RBF 的计算复杂度提升较大, 二维特征下的分类效果与线性分类无法拉开较大差距, 因此在本实验数据集中使用线性核函数进行分类同样满足任务需求。

2.3 本章小结

本章从人类视觉系统的运动机理出发, 分析了注视特征和扫视特征与人类意图规划与行为过程的表述关系, 确定了使用扫视特征的扫视速度与相对位移构建输入向量。其次, 基于 PyQt5 框架制作了数据采集交互程序进行数据采集, 使用线性插值法和 EMA 算法对

原始眼动数据进行预处理，构建出模型训练所需要的眼动特征数据集。最后，详细的介绍了使用 SVM 实现意图眼动识别任务的推理过程，训练模型后与其他二分类模型以及使用 RBF 的 SVM 模型进行性能对比，验证了整体方法的有效性。

3 飞行操作类型定义及飞行参数选取

当个体在产生意图并执行的过程中，通常都会引起自身信息和外部信息的变化。本文的上一章从视觉机理的角度分析了个体的视觉信息与注意力转移的关系，而在实际执行的过程中，操作引起的一系列变化不仅体现在个体的视觉信息上，还会通过行为对环境产生直接作用，进而反映在相应的外部信息上。对于飞行任务来说，这种外部信息的变化主要表现为飞机的飞行参数的变化。飞行参数由飞行员的操作输入驱动，能够客观描述飞行器姿态和运动状态的变化，可以与反应注意力转移的视觉信息形成互补关系，共同作为操作意图的表征变量。

3.1 飞行器分析与操作

3.1.1 实验用飞行器选取

飞行器又名航空器，是能够自主产生升力实现飞行的工具。在飞行器研究初期，研究者通过滑翔实验积累实践经验，并围绕飞行过程的空气动力学原理展开理论探索，为飞行器的发展奠定两方面的基础。而飞机作为最常见的飞行器设备，自发明以来就在航空领域占据主要地位。如图 3.1 所示，莱特兄弟于 1903 年发明首架滑翔飞机并成功试飞。在经过 20 世纪的两次世界大战后，飞机快速的演化成最为高效安全的飞行器^[46]。



3.1 莱特兄弟试飞实验

将飞机按照动力类型作为区分，可以分为螺旋桨式飞机和喷气式飞机两大类^[47]。以喷气翼式飞机为例，其依靠固定翼提供的升力配合发动机产生的推力共同构成了复杂飞行力学系统，有长时间保持高速平稳飞行的优秀性能，因此，翼式飞机从发明至今都被广泛的用于民航运输和军事行动中。图 3.2 为螺旋桨式与喷气式飞机例图：



(a) 螺旋桨式飞机

(b) 喷气式飞机

图 3.2 飞机动力类型区分例图

Su-25T 是苏联在冷战时期研发的一种双发喷气翼式攻击机，被设计用于近距离支援地面部队，具有强大的战场生存能力和多用途作战能力。该机于 20 世纪 80 年代问世，配备了先进的火控系统、电子战设备以及精确制导武器系统，能够执行复杂的对地攻击任务^[48]。Su-25T 采用了坚固的装甲结构，能够抵御轻武器火力和地面导弹的威胁，同时其卓越的操控性能使其在低空、低速环境下表现出色，因此非常适合用于模拟复杂飞行操作。图 3.3 为 Su-25T 展示图：



图 3.3 Su-25T 攻击机

本文选择 Su-25T 战机作为模拟飞行实验的飞行器，其标准的喷气翼式飞机飞行特性和简易的操控系统为分析飞行员操作意图提供了良好的实验基础。通过采集该战机在不同飞行状态下的关键飞行参数，可以分析得出飞行员操作意图与其之间的变化关系。

3.1.2 表征操作意图飞行参数分析

在飞行过程中，飞机的飞行状态取决于气动力、重力、推力和阻力的平衡关系，三维空间中的运动姿态则是通过操控系统中的驾驶杆、脚蹬、油门以及特定功能开关来控制，而飞行员的每一次操作都会引起飞机飞行参数的变化^[49]。以爬升与转向为例，当飞行员意图爬升时，驾驶杆后拉的动作会直接导致俯仰角的增加，同时垂直加速度呈现正值，此时飞机在垂直方向上获得了额外的升力，飞机完成爬升动作。而当飞行员执行转向操作时，驾驶杆的横向移动会引起横滚角的变化，配合脚蹬操作调整尾翼状态来改变偏航角，这两者的协同作用使得转弯率增大，飞机完成转向动作。




图 3.4 爬升、转向操作飞行参数变化曲线

综合可实现性考虑, 本文选取横滚角、俯仰角、垂直速度和转弯率这四种飞行参数, 与眼动数据的融合构建操作意图表征向量。图 3.4 为某次爬升与转向操作时的上述飞行参数变化曲线图。可以看出, 在飞机运动姿态产生变化时, 与之关联的飞行参数也会产生规律的动态变化, 能够直观的量化表示飞行员的操作意图和操控动作的性质与幅度。其中姿态角参数需要计算得出, 另外两个参数可由内置传感器直接获得。

3.1.3 飞行员操控动作类型规范化

飞行员通过完成如速度控制、姿态调整、高度控制和航向控制等基本的单一操作种类实现, 不同单一操作的组合方式可以实现更复杂的飞机运动状态调整。如图 3.5 所示, 本文将飞机平直飞行作为基准状态, 以飞行角度偏转作为参考划分出 9 种飞机飞行时的运动状态, 用于表示飞行员对于飞机姿态调整的操作意图类型。




图 3.5 运动状态操作分类

为了使输出能够准确体现飞机在不同飞行状态下的参数变化特性, 在执行飞行参数采集实验中所涉及的各类飞行状态时, 对驾驶杆、脚蹬和油门等关键部件的操作将进行统一

规范。不同类型操作的参考规范如表 3.1 所示。飞行过程中，被试者应当严格按照参考规范执行操作，以减少因人为操作差异所带来的不确定性。

表 3.1 飞行操作参考规范

类型	部件	参考操作
平直飞行	驾驶杆	驾驶杆中立或微向后拉，以维持飞机的俯仰角稳定、机翼水平。
	脚蹬	保持脚蹬中立。如遇偏航，可轻踩左脚蹬或右脚蹬进行微调。
	油门	调整油门杆提供推力平衡飞机的阻力，保持飞行速度恒定。
爬升	驾驶杆	向后拉动驾驶杆，增大飞机的俯仰角，使机头上仰，实现爬升。
	脚蹬	保持脚蹬中立，如遇偏航，可轻踩左脚蹬或右脚蹬进行微调。
	油门	适当增加推力以确保飞机获得足够的速度，克服爬升阻力。
下降	驾驶杆	向前推动驾驶杆，减小飞机的俯仰角，使机头下俯，实现下降。
	脚蹬	保持脚蹬中立，如遇偏航，可轻踩左脚蹬或右脚蹬进行微调。
	油门	可适当减小推力降低速度，并保持最低安全飞行速度避免失速。
左舵水平转向	驾驶杆	向左推驾驶杆，增大左机翼的下压力，使飞机左倾横滚角变化。
	脚蹬	轻踩左脚蹬调整偏航角，确保飞机沿正确的左转弧线飞行。
	油门	保持稳定推力，维持水平飞行速度。
右舵水平转向	驾驶杆	向右推驾驶杆，增大右机翼的下压力，使飞机右倾横滚角变化。
	脚蹬	轻踩右脚蹬调整偏航角，确保飞机沿正确的右转弧线飞行。
	油门	维持恒定推力，确保水平飞行速度。
左舵转向爬升	驾驶杆	后拉并同时左推驾驶杆，增加俯仰角让飞机左倾爬升。
	脚蹬	轻踩左脚蹬，配合驾驶杆动作，确保偏航角与左转方向一致。
	油门	增加推力以提供额外升力，同时维持飞行速度。
右舵转向爬升	驾驶杆	后拉并同时右推驾驶杆，增加俯仰角让飞机右倾爬升。
	脚蹬	轻踩右脚蹬，配合驾驶杆动作，调整偏航角与右转方向一致。
	油门	增加推力以提供额外升力，同时维持飞行速度。
左舵转向下降	驾驶杆	前推并同时左推驾驶杆，减小俯仰角让飞机左倾下降。
	脚蹬	轻踩左脚蹬，配合驾驶杆动作，调整偏航角与左转方向一致。
	油门	可适当减小推力降低速度，并保持最低安全飞行速度避免失速。
右舵转向下降	驾驶杆	前推并同时右推驾驶杆，减小俯仰角让飞机右倾下降。
	脚蹬	轻踩右脚蹬，配合驾驶杆动作，调整偏航角与右转方向一致。
	油门	可适当减小推力降低速度，并保持最低安全飞行速度避免失速。

3.2 模拟飞行实验数据采集与处理

3.2.1 六自由度飞行平台配置介绍

飞行参数采集实验在三屏六自由度模拟舱飞行平台上进行，所使用的飞行器为上文介绍的 Su-25T 战机。如图 3.6 所示，飞行平台的基本结构包括平台基座、六自由度运动机构、计算机控制系统和视景仿真系统。设备通过电动缸驱动实现三种平移线性运动和三种旋转角运动的精准模拟，并配备驾驶杆、脚蹬、油门等操作装置以及仪表和视景系统，可以提供专业的沉浸式飞行操作、体验。计算机控制系统作为平台的核心，实时接收使用者的输入指令来控制平台的运动，同时与视景仿真系统联动，通过高逼真的视觉反馈模拟真实的飞行场景。



图 3.6 三屏六自由度飞行平台

软件部分则在 Windows11 环境下使用 DCS World 和 TacView 进行实验。如下图所示，DCS World 是由俄罗斯开发商 Eagle Dynamics 推出专业飞行模拟器，以其精确的物理建模、真实的飞行器操作和高还原度的自定义战场环境而著称，是市场上最先进的飞行模拟器之一。配合挂载 TacView 数据可视化分析软件的方案，能够记录飞行过程中基本参数，并以三维可视化的方式展现飞行轨迹、机动动作、交战细节和环境信息，目前被广泛运用于飞行员训练以及航空研究中。




图 3.7 DCS World 模拟飞行软件

3.2.2 五边形飞行任务设计及实验流程

飞行实验招募与第二章相同的了 8 名年龄在 24-28 岁之间的被试者采集数据，在拟定的区域内基于五边形飞行框架进行模拟飞行任务。任务地点设置在黑海正东方向的塞纳基·科尔奇机场。所有被试者在实验开始前以做过长时间飞行培训，熟悉飞行员驾驶模式技术、模拟平台飞行操作、飞行器设备的各个组件功能与操作方法，达到了独立完成模拟飞行任务的标准。飞行路线图如图 3.8 所示：




图 3.8 五边形飞行路线

为了保持与眼动数据采集条件的一致性,实验时需保持室内固定光源,调整座椅间隔使得被试者双目与前方屏幕直线距离保持在 60cm 左右,垂直方向偏下 30° 。实验过程中被试者须保持自然放松姿态,按照既定流程以此完成起飞→转向→巡航(二边)→转向→巡航(三边)→转向→巡航(四边)→转向→巡航(五边)→降落任务,总任务用时须保持在 25min 以内。飞行期间, Su-25T 的速度参考巡航飞行任务常见标准的 216-270kn (400-500km/h),为了便于降落以及在飞行时能将地面环境作为参考, Su-25T 的高度设置在比低空飞行任务标准略高一些的 1640-3280ft (500-1000m)。




图 3.9 飞行操作执行示意图

在每一个巡航边上飞行时,飞行员需按照指示执行上文分析的运动状态所对应的操作。其中爬升与下降角度在 10° - 45° 范围内,左右横滚角度在 20° - 50° 范围内,每次操作保持在 10s 内完成。将除了平直飞行以外的操作分以两个为一组执行。例如,执行完成左舵转向爬升后接着执行右舵转向下降。这样既能确保训练数据数量配比的均匀度,同时也能维持航向与高度在规定区间内进行实验。图 3.9 为一组操作执行示意图,其中虚线为原定平直

飞行路线，实线为执行一组操作的实际飞行路线。

实验过程中需保持开启 TacView 记录完整的飞行参数。为了在时间维度上对齐视线数据与飞行参数，同步开启第二章所使用的 Tobii Eye Tracker 眼动仪记录眼动数据，并将 TacView 的输出调整为与眼动仪刷新率一致的 60Hz。当飞行员执行运动状态操作时，视线会根据意图类型的不同在驾驶舱内视觉范围内产生不同的运动轨迹。Su-25T 的驾驶舱内主要观测区域划分与其对应部位信息如图 3.10 与表 3.2 所示。通过融合此过程中的视线数据和飞行参数可得到用于表征操作意图的特征向量。



图 3.10 Su-25T 舱内观测区域

表 3.2 观测区域对应部位信息

编号	仪表面板
1	迎角（AOA）指示器与加速度表（“G 表”）
2	指示空速表（IAS）
3	无线电高度表
4	气压高度表
5	姿态指引指示器（ADI）
6	水平状态指示器（HSI）
7	垂直速度表（VVI）
8	襟翼、减速板和起落架配置指示器
9	起落架状态控制杆
10	主视窗 HUD 显示器
11-12	左、右后视镜

以上述流程为标准完成五边形飞行任务 67 轮，为保持飞行员的疲劳程度，两次飞行之间的间隔应当不少于 15 分钟。最终采集到九种操作类型数据共 1800 组，在过滤出存在大面积丢失或跳跃的异常数据后，得到 143 组平直飞行、150 组爬升、142 组下降、219 组左舵水平转向、212 组右舵水平转向、166 组左舵转向爬升、194 组右舵转向爬升、189 组左舵转向下降、173 组右舵转向下降，合计 1588 组带有分类标签的有效数据集。

3.2.3 基于卡尔曼滤波的姿态角解算

在三维空间中，姿态角是描述刚体在空间中方向和姿态的重要参数，通常以横滚角、Roll、俯仰角 Pitch、和偏航角 Yaw 三个角度来表示。对于翼式飞机而言，姿态角基于飞机的三维坐标系，其中横滚角描述飞机绕纵轴（机身轴线）的旋转状态，用于判断机翼的倾斜；俯仰角描述飞机绕横轴（机翼轴线）的旋转状态，用于反映飞机机头的上下倾斜；偏航角描述飞机绕垂直轴（垂直于地面的轴线）的旋转状态，用于表示飞机航向的变化。由于姿态角无法直接输出，本文基于卡尔曼滤波的方法融合角速度和加速度参数进行姿态解算^{[50][51][52]}。图 3.11 为姿态角在三维空间的解释图：




图 3.11 三维空间飞机姿态角

卡尔曼滤波是一种用于动态系统状态估计的算法，通过融合多源传感器数据，能够以最优方式估计出系统的状态。其核心思想是基于系统的运动模型和传感器观测数据，利用预测和校正两个步骤，递归地计算出当前时刻的状态估计值^[53]。在飞行姿态角的解算中，分别使用角速度和加速度参数进行单独结算，容易出现漂移与动态噪声干扰的情况。通过卡尔曼滤波融合角速度和加速度参数，可以综合两者的优点实现对姿态角的精准解算。




图 3.12 飞机坐标系旋转过程

(1) 使用加速度参数进行姿态解算

如图 3.12 所示，定义飞机水平姿态作为初始坐标状态。初始坐标状态仅有 Z 轴承受重力加速度 g ，加速度在三个坐标轴的分量可表示为 a_x, a_y, a_z ，依次绕飞机坐标系 Z, Y, X 轴旋转 y, p, r 度之后，可由旋转矩阵 M ^[54]与初始加速度向量乘积得出：

$$\begin{bmatrix} a_x \\ a_y \\ a_z \end{bmatrix} = M_x \cdot M_y \cdot M_z \begin{bmatrix} 0 \\ 0 \\ g \end{bmatrix} = \begin{bmatrix} -\sin p \\ \cos p \cdot \sin r \\ \cos p \cdot \cos r \end{bmatrix} g \quad (3.1)$$

$$\begin{cases} a_x = -\sin p \cdot g \\ a_y = \cos p \cdot \sin r \cdot g \\ a_z = \cos p \cdot \cos r \cdot g \end{cases} \quad (3.2)$$

联立分量 a_x, a_y, a_z 输出可以得到由加速度参数解算的横滚角与俯仰角:

$$a_roll = \arctan\left(\frac{a_y}{a_z}\right) \quad a_pitch = \arctan\left(\frac{a_x}{\sqrt{a_y^2 + a_z^2}}\right) \quad (3.3)$$

(2) 使用角速度参数进行姿态解算。

在飞机坐标系旋转时, 对 Z, Y, X 轴所产生的角速度分量积分可得到角度值, 则采样时间周期内的 k 时刻的姿态根据 $k-1$ 时刻的姿态值与角度变化量更新而来:

$$\begin{cases} g_roll_k = g_roll_{k-1} + V_{roll} \cdot \Delta t \\ g_pitch_k = g_pitch_{k-1} + V_{pitch} \cdot \Delta t \\ g_yaw_k = g_yaw_{k-1} + V_{yaw} \cdot \Delta t \end{cases} \quad (3.4)$$

其中 $V_{roll}, V_{pitch}, V_{yaw}$ 与旋转矩阵 M 的线性组合得到三轴角速度 g_x, g_y, g_z :

$$\begin{aligned} \begin{bmatrix} g_x \\ g_y \\ g_z \end{bmatrix} &= M_x \cdot M_y \begin{bmatrix} 0 \\ 0 \\ V_{yaw} \end{bmatrix} + M_x \begin{bmatrix} 0 \\ V_{pitch} \\ 0 \end{bmatrix} + \begin{bmatrix} V_{roll} \\ 0 \\ 0 \end{bmatrix} \\ &= \begin{bmatrix} 1 & 0 & -\sin p \\ 0 & \cos r & \cos p \cdot \sin r \\ 0 & -\sin r & \cos p \cdot \cos r \end{bmatrix} \begin{bmatrix} V_{roll} \\ V_{pitch} \\ V_{yaw} \end{bmatrix} \end{aligned} \quad (3.5)$$

可通过逆矩阵形式反解出姿态更新的角速度:

$$\begin{bmatrix} V_{roll} \\ V_{pitch} \\ V_{yaw} \end{bmatrix} = \begin{bmatrix} 1 & \frac{\sin p \cdot \sin r}{\cos p} & \frac{\cos r \cdot \sin p}{\cos p} \\ 0 & \cos r & -\sin r \\ 0 & \frac{\sin r}{\cos p} & \frac{\cos r}{\cos p} \end{bmatrix} \begin{bmatrix} g_x \\ g_y \\ g_z \end{bmatrix} \quad (3.6)$$

(3) 使用卡尔曼滤波融合姿态解算

首先定义卡尔曼滤波状态方程:

$$\hat{x}_k^- = A x_{k-1} + B u_{k-1} \quad (3.7)$$

由于状态方程不包含过程噪声, 故 $\hat{x}_k^-$ 为先验估计的状态变量, A 和 B 分别为状态转移矩阵与控制输入矩阵, x_{k-1} 为上一时刻卡尔曼滤波输出结果, u_{k-1} 是角速度输出的转换结果。

将方程化为矩阵形式可得：

$$\begin{bmatrix} g_roll \\ g_pitch \end{bmatrix} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} k_roll \\ k_pitch \end{bmatrix} + \begin{bmatrix} \Delta t & 0 \\ 0 & \Delta t \end{bmatrix} \begin{bmatrix} V_{roll} \\ V_{pitch} \end{bmatrix} \quad (3.8)$$

$$\begin{cases} g_roll = k_roll + \Delta t \cdot V_{roll} \\ g_pitch = k_pitch + \Delta t \cdot V_{pitch} \end{cases} \quad (3.9)$$

其中， g_roll 与 g_pitch 为式 3.4 中角速度参数得出的横滚角与俯仰角， V_{roll}, V_{pitch} 为上式中得出的 $k-1$ 时刻的姿态更新角速度， x 的初值 $x_0 = 0$ 。

定义卡尔曼滤波观测方程：

$$z_k = H\hat{x}_k^{mea} \quad (3.9)$$

令观测样本 z_k 等于式 3.3 中加速度参数得出的观测变量 $\hat{x}_k^{mea}$ ，此时观测矩阵 H 表示为单位矩阵。

通过过程噪声协方差矩阵 Q 和 $k-1$ 时刻的误差协方差矩阵 P_{k-1} ，更新 k 时刻误差协方差矩阵 P_k^- 。 Q 的主对角线超参数在本文中设定为 0.003。由于样本 $roll$ 与 $pitch$ 线性不相关， P 的初值 P_0 副对角线取 0，得到 P_0 为单位阵。

$$P_k^- = AP_{k-1}A^T + Q = P_{k-1} + Q \quad (3.10)$$

下式计算卡尔曼增益 k_k ，观测噪声协方差矩阵 R 的主对角线超参数同设定为 0.003。

$$k_k = \frac{P_k^- H^T}{HP_k^- H^T + R} = \frac{P_k^-}{P_k^- + R} \quad (3.11)$$

加速度与角速度数据融合更新最优估计值 x_k ，即观测样本与估计值之差的线性组合，展开为矩阵形式可得：

$$x_k = \hat{x}_k^- + k_k (z_k - H\hat{x}_k^-) \quad (3.12)$$

$$\begin{bmatrix} k_roll \\ k_pitch \end{bmatrix} = \begin{bmatrix} g_roll \\ g_pitch \end{bmatrix} + \begin{bmatrix} k_{11} & 0 \\ 0 & k_{22} \end{bmatrix} \left(\begin{bmatrix} a_roll \\ a_pitch \end{bmatrix} - \begin{bmatrix} g_roll \\ g_pitch \end{bmatrix} \right) \quad (3.13)$$

其中， k_roll 与 k_pitch 为卡尔曼滤波数据融合之后的 k 时刻横滚角与俯仰角。最后，更新误差协方差矩阵 P_k ，用于求下一时刻最优估计值，其中 I 代表单位矩阵。

$$P_k = (I - k_k H)P_k^- \quad (3.14)$$

为了验证基于卡尔曼滤波数据融合姿态解算方法的可行性，在此使用了一组公开的飞机飞行参数进行姿态解算，将数据集内飞机系统输出的姿态角作为真实值进行参考，对比姿态解算结果与真实值之间的差异情况。如图 3.12 所示，此段飞行数据包含了飞机从起飞开始，直到 30min 内的飞行姿态角数据的变化情况，飞行期间内飞机进行数次高度调节与航向调节。




图 3.12 卡尔曼滤波与实际姿态变化对比

可以看出，基于卡尔曼滤波数据融合姿态解算方法对于横滚角数据的解算较为准确，结果并无出现较大的异常数据。而算法对于俯仰角的解算误差略大一些，尤其是在飞行开始前段与飞行中段的时间范围内，出现两次较大的数据波动，推测为该飞机在飞行的过程中遇到强烈气流导致飞机颠簸而影响结算结果。由于下文进行的模拟飞行实验处于恒定风速的条件下进行，故该影响可在此忽略。




图 3.13 姿态解算误差分布直方图

之后，对卡尔曼滤波结算结果进行误差分布统计，结果如图 3.13 所示。误差绝对值的

分布区间分别为 $|\varepsilon| \in [0,1]$ 、 $|\varepsilon| \in (1,3]$ 以及 $|\varepsilon| > 3$ 三种。可以看出,对于横滚角的解算值误差有 73.1%的误差绝对值可以保持在 $[0,1]$ 区间内,说明大部分数据解算值与实际姿态较为吻合。而俯仰角则有 63.2%的误差绝对值保持在 $[0,1]$ 区间内,其余 $(1,3]$ 与 >3 区间的数据占比达到了 22.9%和 13.9%,其结果也较为精准。

此外,本文还将均方根误差值(Root Mean Square Error, RMSE)以及决定系数(Coefficient of Determination, R^2)作为评估指标,用于表示解算值与真实值之间的拟合程度。二者的计算公式由式(3.15)和式(3.16)表示:

$$RMSE = \sqrt{\frac{\sum_{i=1}^n (x_i - \hat{x}_i)^2}{n}} \quad (3.15)$$

$$R^2 = 1 - \frac{\sum_{i=1}^n (x_i - \hat{x}_i)^2}{\sum_{i=1}^n (x_i - \bar{x}_i)^2} \quad (3.16)$$

其中 RMSE 表示平均误差幅度,值越小则代表解算精度越高。 R^2 的取值范围在 $[0,1]$ 区间内,值越接近 1 则代表解算值拟合程度越高。评估结果如表 3.3 所示,可以看出使用卡尔曼滤波的方法在横滚角和俯仰角上分别得到了 2.205 和 2.815 的误差幅度值,以及 0.814 和 0.779 的决定系数值,证明了该算法可以较好的通过数据融合解算出飞机姿态角。

表 3.3 卡尔曼滤波姿态解算评估

	Roll	Pitch
RMSE	2.205	2.815
R^2	0.814	0.779

3.3 本章小结

本章首先简要介绍了飞机的发展与基本分类,选择了俄制 Su-25T 攻击机作为实验飞行器,在三屏六自由度模拟舱飞行平台上使用 Dcs World+TacView 的方案进行模拟飞行试验。其次,制定了完整的实验数据采集流程,按照飞机运动状态将操作类型划分为 9 种,确定以飞机飞行时的横滚角、俯仰角、垂直速度和转弯率作为飞行参数与视线数据结合,采集到包含 9 种类型共 1588 组有效数据。最后,使用卡尔曼滤波数据融合算法进行飞机姿态解算,在测试数据集上进行误差分布统计分析,证明了算法的有效性。

4 飞行员操作意图推断模型搭建

为实现对操作意图的有效分类，本章采用高斯混合-隐马尔可夫模型（GMM-HMM）和长短期记忆网络（LSTM）两种方法，对上一章中所采集的包含 9 种意图操作的 1588 条样本数据集进行建模分析。隐马尔可夫模型具有较强的时序特征捕捉能力，适用于描述飞行员视线变化与操作意图之间的隐性关联，而长短期网络因其能够长期记忆时间序列数据中的关键信息，适用于处理飞行操作中多维度动态特征的非线性映射。本章将使用两种方法进行建模，并对样本量与模型参数进行控制变量，分析在不同训练数据与参数下的模型在相同测试集下的分类性能。

4.1 基于隐马尔可夫模型（HMM）的方法

4.1.1 隐马尔可夫模型原理

隐马尔可夫模型（Hidden Markov Model, HMM）是最早由 Leonard E. Baum 团队在 20 世纪 60 年代提出的一种基于贝叶斯推理的统计模型^[55]。图 4.1 为隐马尔可夫模型结构图，其核心部分包括隐藏状态与观测序列两大随机过程。对于飞行员操作意图推断任务，观测序列是由上文中的舱内区域视线数据、飞机姿态角、垂直速度以及转弯率所构成的时序数据集，而隐藏状态是无法直接通过观测得到的。HMM 通过状态转移概率矩阵和观测概率分布，将观测样本的转移映射到隐藏状态转移的序列当中，最终利用贝叶斯理论计算最可能的状态路径，实现对于不同操作意图的分类。




图 4.1 隐马尔可夫模型结构图

对于一个随机事件中的一条观测样本序列 $O = \{o_1, o_2, o_3, \dots, o_T\}$ ，每个时刻观测样本只对应 $S = \{s_1, s_2, s_3, \dots, s_T\}$ 中的一个隐藏状态，在此条件下，马尔可夫模型有三种假设：

（1）不动性假设：不同观测样本对应的状态转移与具体时间无关，任意时刻履行相同状态转移规则；

(2) 马尔可夫性假设: t 时刻的状态只与 $t-1$ 时刻的状态有关;

(3) 输出独立性假设: t 时刻的观测样本只能由 t 时刻的状态生成。

以上述三种假设为依据, 定义有限观测样本集合 $M = \{k\ldots\}$ 和有限状态值集合 $N = \{i, j, \ldots\}$, 则隐马尔可夫模型结构的一般形式可由式(4.1)三要素表示:

$$\lambda = \{\pi, A, B\} \quad (4.1)$$

其中 $\pi = \{\pi_i\}$ 为初始概率分布矩阵, 包含了 0 时刻所有隐藏状态 i 发生的概率, π 的参数一般在模型构建开始时作为初始条件确定, 训练中途无法修改。 A 代表状态转移矩阵 $A = \{a_{ij}\}$, 根据马尔可夫性假设可知 $a_{ij} = P(s_t = j | s_{t-1} = i)$, 即 t 时刻状态 i 转为 $t+1$ 时刻状态 j 的概率。 B 为发射概率矩阵 $B = \{b_i^k\}$, 表示状态 i 可能生成观测样本 k 的概率, 即观测样本 k 属于状态 i 的概率 $b_i^k = P(o_t = k | s_t = i)$ 。

隐马尔可夫模型的建模过程围绕评估、解码和优化三类问题的求解而实现, 这三类问题分别对应模型的观测序列概率计算、最优隐藏状态序列推理和参数学习过程, 下文将逐个展开分析:

(1) 评估问题

假设一组已知观测序列数据 $O = \{o_1, o_2, o_3, \ldots, o_T\}$ 和训练得到参数已知的 HMM 模型 $\lambda = \{\pi, A, B\}$, 求解观测序列 O 由模型 λ 生成的概率 $P(O | \lambda)$, 该问题的目的为通过输出值量化评估该观测序列与模型的拟合程度。

在 HMM 发展初期, 评估问题通常由下式枚举计算, 每一种可能的状态 S 并计算概率共有 N^T 种组合, 则遍历所需的计算复杂度为 $T \cdot N^T$ 。

$$P(O | \lambda) = \sum P(O, S | \lambda) = \sum_{s_1, s_2, \ldots, s_T} \pi_{s_1} \prod_{t=2}^T a_{s_{t-1}s_t} \prod_{t=1}^T b_{s_t}^{o_t} \quad (4.2)$$

可以看出, 直接算法的计算量随着状态数和序列长度的增加呈指数增长, 因此直接算法只局限于规模较小的模型使用。对于表征飞行员操作意图的多维数据集, 应使用前向-后向算法 (Forward-Backward Algorithm) 递推计算生成概率, 以减少计算复杂度。

以前向算法为例, 首先定义前向概率变量 $\alpha_t(i) = P(o_1, o_2, \ldots, o_t, s_t = i | \lambda)$, 表示前 t 时刻的所有观测样本已知时, t 时刻观测样本属于状态 i 的概率。由于任意时刻的状态只与上一时刻有关, 状态转移矩阵 A 与 t 时刻所有状态概率 α_t 构成的线性表达式可以描述 $t+1$ 时刻的状态概率, 其推导过程如图 4.2 所示, 对于每一个状态 i , 需要考虑由观测样本提供的发射概率。




图 4.2 前向算法推导过程

计算过程可由式(4.3)表示:

$$\begin{aligned}\alpha_{t+1}(i) &= \left(\sum_{j=1}^N P(o_1, o_2, \dots, o_t, s_t = j | \lambda) a_{ji} \right) b_i^{o_{t+1}} \\ &= \left(\sum_{j=1}^N \alpha_t(j) a_{ji} \right) b_i^{o_{t+1}}\end{aligned}\quad (4.3)$$

初始化前向概率变量由初始概率分布矩阵 $\pi = \{\pi_i\}$ 决定, $t = 2, 3, \dots, T$ 的任意时刻前向概率都可由上式递推解得。 $\alpha_1(i)$ 计算公式如下:

$$\alpha_1(i) = \pi_i b_i^{o_1} \quad (4.4)$$

则评估问题 $P(O | \lambda)$ 由式(4.5)得到, 即观测序列的生成概率为 $t = T$ 前向概率的总和:

$$P(O | \lambda) = \sum_{i=1}^N \alpha_T(i) \quad (4.5)$$

同理。定义后向概率变量 $\beta_t(i) = P(o_{t+1}, o_{t+2}, \dots, o_T | s_t = i, \lambda)$, 表示 t 时刻状态为 i 时, 生成后继样本序列的概率。对于 $t-1$ 时刻状态为 i 的后向概率由式(4.6)表示:

$$\beta_{t-1}(i) = \sum_{j=1}^N \beta_t(j) b_j^{o_t} a_{ij} \quad (4.6)$$

初始化 T 时刻后向变量 $\beta_T(i) = 1$, 评估问题 $P(O | \lambda)$ 为 $t = 1$ 时刻后向概率的总和:

$$P(O | \lambda) = \sum_{i=1}^N \pi_i \beta_1(i) b_i^{o_1} \quad (4.7)$$

与前向算法类似, 后向算法同样使用了动态规划思想, 从观测序列 $t = T$ 时刻开始向前递推至初始时刻并累加后向概率总和, 其最终输出结果与前向算法相同, 二者同时用于飞行员操作意图模型的优化任务计算。

(2) 解码问题

此问题的前提与评估问题一致, 同有一组已知观测序列数据 $O = \{o_1, o_2, o_3, \dots, o_T\}$ 和训练得到参数已知的 HMM 模型 $\lambda = \{\pi, A, B\}$, 求解隐藏状态序列 $S' = \{s_1, s_2, s_3, \dots, s_T\}$, 使得该序列为 λ 最大概率生成序列, 即后验概率 $P(S' | O, \lambda)$ 最大化。

解码问题通常使用维特比算法（Viterbi Algorithm）解决，通过记录 t 时刻状态转移最优路径概率 $\delta_t(i)$ 与前驱状态 $\varphi_t(i)$ 递推得出最优概率路径。

首先初始化 $t=1$ 时的所有状态概率：

$$\begin{cases} \delta_1(i) = \pi_i b_i^{o_1} \\ \varphi_1(i) = 0 \end{cases} \quad (4.8)$$

对于 $t=2, 3, \dots, T$ 任意时刻最优路径概率与前驱状态根据式(4.9~4.10)递推得出：

$$\delta_t(i) = \max_{1 \leq j \leq N} [\delta_{t-1}(j) a_{ji}] b_i^{o_t} \quad (4.9)$$

$$\varphi_t(i) = \arg \max_{1 \leq j \leq N} [\delta_{t-1}(j) a_{ji}] \quad (4.10)$$

在 $t=T$ 时刻得到最大 $\delta_T(i)$ ，此时最优状态为 $s_T = \arg \max \delta_T(i)$ 。最终从 $t=T-1$ 时刻回溯至初始时刻，其中任意时刻可根据记录的前驱状态 $\varphi_t(i)$ 回溯出隐藏状态序列 S' 。

（3）优化问题

已知一组观测序列数据 $O = \{o_1, o_2, o_3, \dots, o_T\}$ ，需求解一个隐马尔可夫模型 $\lambda = \{\pi, A, B\}$ 能够以最大概率生成观测序列数据 O ，其本质为使用给定的观测序列作为样本对模型三要素进行迭代更新，直至模型对于观测序列数据 O 的输出概率 $P(O|\lambda)$ 达到指定条件或不再变化。优化问题为 HMM 任务的核心问题，通常使用鲍姆-韦尔奇算法（Baum-Welch）与前向后向算法迭代期望最大化步骤^[56]，评估每一组模型三要素对 O 的输出概率 $P(O|\lambda)$ 变化，以此实现模型的更新。

首先给定观测序列 O ，根据初始参数计算每个观测样本属于状态 i 的概率 $\gamma_t(i) = P(s_t = i | O, \lambda)$ 以及 t 时刻至下一时刻的状态转移情况 $\xi_t(ij) = P(s_t = i, s_{t+1} = j | O, \lambda)$ ，计算公式如式(4.11~4.12)。其中， $\alpha_t(i)$ 与 $\beta_t(i)$ 为上文中得出的 t 时刻观测样本状态为 i 前向概率与后向概率。

$$\gamma_t(i) = \frac{\alpha_t(i) \beta_t(i)}{\sum_{i=1}^N \alpha_t(i) \beta_t(i)} \quad (4.11)$$

$$\xi_t(ij) = \frac{\alpha_t(i) a_{ij} \beta_{t+1}(j) b_j^{o_{t+1}}}{\sum_{i=1}^N \sum_{j=1}^N \alpha_t(i) a_{ij} \beta_{t+1}(j) b_j^{o_{t+1}}} \quad (4.12)$$

设共有 D 组用于训练的观测序列数据，隐马尔可夫模型三要素参数更新方法如下：初始概率分布矩阵 π 通过式(4.13)更新，由每条数据 d 的初始状态概率求均值得到。

$$\pi_i = \frac{\sum_{d=1}^D \gamma_1^d(i)}{D} \quad (4.13)$$

状态转移矩阵 A 通过式(4.14)更新，由每组观测序列数据的任意时刻的状态转移结果与

上一时刻的状态比值得到:

$$a_{ij} = \frac{\sum_{d=1}^D \sum_{t=1}^{T-1} \xi_t^d(ij)}{\sum_{d=1}^D \sum_{t=1}^{T-1} \gamma_t^d(i)} \quad (4.14)$$

发射概率矩阵 B 通过式(4.15)更新, 由全部属于状态 i 且观测样本为 k 的总数与全部属于状态 i 的观测样本总数的比值得到:

$$b_i^k = \frac{\sum_{d=1}^D \sum_{t=1}^T \gamma_t^d(i)}{\sum_{d=1}^D \sum_{t=1}^T \gamma_t^d(i)} \quad (4.15)$$

三要素 $\lambda = \{\pi, A, B\}$ 通过反复迭代训练直至满足给定收敛条件为止, 此时获得最佳隐马尔可夫模型模型参数可使该模型以最大概率生成观测序列 O 。

4.1.2 高斯混合函数离散输入实现

由于标准隐马尔可夫模型仅适用于离散观测序列数据, 对于本文的多维连续时序数据, 在矢量化的过程中会导致其丢失大量浮点特征。因此需要引入高斯混合模型来增强 HMM 对多维连续时序观测数据分布的刻画能力^[57], 提升最终模型的性能。

高斯混合模型(Gaussian Mixture Mode, GMM)是一种描述数据的连续分布的聚类方法, 由多个高斯成分通过线性叠加的方式组合实现。如式(4.16)所表示, 每个高斯成分都服从正态分布特性, 其中 μ 和 Σ 表示为均值向量和协方差矩阵, D 表示输入数据 x 的维度。

$$G(x; \mu; \Sigma) = \frac{1}{\sqrt{(2\pi)^D |\Sigma|}} e^{-\frac{1}{2}(x-\mu)\Sigma^{-1}(x-\mu)^T} \quad (4.16)$$

那么对于含有 K 个高斯成分的高斯混合模型, 其概率密度函数由式(4.17)表示:

$$GMM(x; \lambda) = \sum_{k=1}^K w_k G(x; \mu_k; \Sigma_k) \quad (4.17)$$

且对于每个高斯成分 k 的权重系数需满足式(4.18):

$$\sum_{k=1}^K w_k = 1 \quad (4.18)$$

引入高斯混合模型后, 标准隐马尔可夫模型中的发射概率矩阵 B 将由含有多个 GMM 的模型集合替换原有的离散数值。在训练模型时, 原有的定义 $\gamma_{im}(i)$ 为 t 时刻观测样本属于状态 i 的第 m 个高斯成分的概率:

$$\gamma_{im}(i) = P(s_t = i | O, \lambda) \cdot \frac{w_m G(o_t; \mu_m; \Sigma)}{\sum_{k=1}^K w_k G(o_t; \mu_k; \Sigma)} \quad (4.19)$$

其中，每个属于状态 i 的高斯成分 k 中的均值向量、协方差矩阵和权重系数由下式同步更新：

$$\mu_k(i) = \frac{\sum_{t=1}^T \gamma_{tk}(i) o_t}{\sum_{t=1}^T \gamma_{tk}(i)} \quad (4.20)$$

$$\Sigma_k(i) = \frac{\sum_{t=1}^T \gamma_{tk}(i) \cdot (o_t - \mu_k(i))(o_t - \mu_k(i))^T}{\sum_{t=1}^T \gamma_{tk}(i)} \quad (4.21)$$

$$w_k(i) = \frac{\sum_{t=1}^T \gamma_{tk}(i)}{T} \quad (4.22)$$

则确定 HMM 模型所需的三要素 $\lambda = \{\pi, A, B\}$ 拓展为五要素 $\lambda = \{\pi, A, w, \mu, \Sigma\}$ ，可以看出高斯混合模型的引入在给予原始模型处理多维连续时序数据的能力的同时，在一定程度上增大了每次迭代的计算复杂度，下文将展开分析 GMM-HMM 模型库的测试结果。

4.1.3 GMM-HMM 操作意图模型搭建

模型训练所使用的观测序列数据集为上一章中所采集的视线数据与飞行参数，包含 9 种操作类型共 1588 组有效数据，并将数据集以 8: 2 的比例分为 1270 组训练数据集和 318 组测试数据集，其中测试数据集仅用于后续评估模型性能，不参与模型训练。为了确保各类数据比例均匀度，使用 `test_split` 方法将全部 9 种类型的数据以均分的方法分配至训练数据集与测试数据集。模型的整体训练过程如图 4.3 所示：




图 4.3 模型训练过程

在飞行员操作意图推断任务中，首先利用标注好的观测序列数据对每种 HMM 模型进行训练，不同操作意图观测序列数据迭代产生最优三要素 $\lambda = \{\pi, A, B\}$ ，即确定一种意图模型。所有 9 种操作意图对应的独立 HMM 模型构成整体操作意图模型库。在评估阶段，输入一组未标注的观测序列数据至模型库中，分别计算在每个 HMM 模型下的生成概率 $P(O|\lambda)$ ，结果最大的 HMM 模型为最优评估模型，其所对应的操作意图类别则判断为飞

行员所执行的操作。任务流程图如下图所示：




图 4.4 操作意图推断流程图

结果评判方法如下式所示：

$$y' = \underset{y}{\text{Max}} P(O | \lambda_y), y \in \{1, 2, 3, \dots, 9\} \quad (4.23)$$

4.1.4 机器学习方法模型性能分析

由于 GMM-HMM 模型中对于高斯成分数量 K 值设定暂无有效地理论依据，不同的高斯成分的数量直接影响模型对数据分布的拟合能力。较大的 K 值能够更精确地捕捉数据的复杂分布，但也可能导致过拟合问题；而 K 值过小则无法充分描述数据特征，使模型的泛化能力受限。因此，本文首先分析不同数量的高斯成分下，训练得到的 GMM-HMM 模型准确率，以找到在当前数据集上，使模型准确率和泛化能力达到良平衡的最优 K 值。

训练时将 K 值分别设置为 2、4、6 和 8 进行训练，从训练轮次 30 轮直至训练 150 轮为止，每 10 轮训练完成后记录当前模型在测试集上的准确率。其测试结果如图 4.5 所示。可以看出，所有模型的预测准确度均随着 Epoch 数的增加而呈上升趋势。当 Epoch 的值超过 90 后再进行训练，此时所有模型的准确度的增加不再明显。对于取不同高斯成分的数量模型对比得出，当 K 值取 2、4 时的模型准确度整体低于 K 值取 6、8 时的模型准确度，这是因为过少的高斯混合成分数量使模型无法充分学习训练数据的特征变化所导致。而 K 值取 8 的模型准确度在 Epoch 高于 90 后，对比 K 值取 6 无明显优势，又因式可知斯混合成分数量的加会指数级增加模型的计算复杂度。因此当 $K = 6$ 时，模型在当前数据集上得到平衡状态。




图 4.5 差异化 K 值准确率测试

训练模型收敛条件设定为 0.001 或达到最大 150 轮训练终止，完成后将自动保存模型用于测试集评估。图 4.6 为 $K=6$ 时，部分操作模型的前向-后向概率变化图。其值越小，代表当前模型更拟合于训练数据集。




图 4.6 部分模型前向-后向概率变化图

使用不同类型的测试数据进行评估时，将其分别代入至各个操作意图所对应的 GMM-HMM 模型当中，使用上文解释的评估问题求得各个模型对于该测试数据的前向-后向概率值，对比得到产生最大值的意图模型可判定为当前测试数据对应的操作意图。由于此数值在累乘的过程中会变得趋近于 0，一般通过对数似然形式表示，为了便于评估，在此使用零均值标准化（Z-Score）对其进行处理。表 4.1 为测试集中抽取出的三条数据在 9 种操作意图模型下的前向-后向概率值标准化后的结果。其中数据 1、2、3 分别为平直飞行、左舵水平转向以及右舵转向爬升数据，模型的排序参考表 3.1 可以看出三条数据分别在 HMM1、HMM4 和 HMM6 的前向-后向概率值最大，此时根据式 4.23 即可判断操作意图类型。

表 4.1 抽样数据输出标准化值

	HMM1	HMM2	HMM3	HMM4	HMM5	HMM6	HMM7	HMM8	HMM9
数据 1	2.11	0.92	0.42	-0.09	-0.39	-0.20	-1.04	-1.45	-0.28
数据 2	-0.21	-2.61	-0.48	0.69	0.57	0.52	0.47	0.54	0.50
数据 3	-0.005	-2.51	-0.78	0.60	0.28	0.86	0.33	0.45	0.75

将完整的测试集作为输入数据输入操作意图模型库进行评估，9 种意图数据的分类结果由表 4.2 的混淆矩阵表示：

表 4.2 GMM-HMM 测试集评估混淆矩阵

		推断意图								
		意图 1	意图 2	意图 3	意图 4	意图 5	意图 6	意图 7	意图 8	意图 9
实 际 意 图	意图 1	26	0	0	2	0	0	0	0	1
	意图 2	0	34	1	0	0	2	0	0	0
	意图 3	1	0	21	0	0	0	0	6	0
	意图 4	2	0	0	33	0	0	0	0	1
	意图 5	1	0	1	0	29	0	0	0	1
	意图 6	0	1	0	0	0	38	0	0	0
	意图 7	0	6	0	0	0	1	36	0	0
	意图 8	0	0	1	0	0	0	0	41	0
	意图 9	0	1	0	0	0	0	0	0	31

由表可知，操作意图模型库对于完整测试集数据的评估效果较为优秀，大多数操作意图能够被正确分类。该混淆矩阵主对角线元素代表各个类别操作意图正确分类的数量，其余元素对应被错误分类为其他意图的数量。可以看出，共 28 下降操作中有 6 个被错误判定为左舵转向下降操作；共 36 个右舵转向上升操作中有 6 个被错误判定为上升操作。推测其原因在于在两种操作执行时，飞机飞行参数的时序特征可能从一定程度呈现相似的变化规律，这是由于组合操作与其构成单一操作对于飞机关键部件的控制相似性所导致的。图 4.7 为百分比形式的混淆矩阵热图：




图 4.7 百分比混淆矩阵热图

为了验证眼动数据与飞行参数结合方式对于模型下性能的提升，以及基于 SVM 的意图眼动识别对数据集的优化能力，在此分别对只使用飞行参数、飞行参数+眼动数据、飞机参数+SVM 意图眼动数据所训练得到模型在测试集进行消融实验的评估，对比不同模型的准确率、精确度以及召回率。上述三种取值在多分类任务中的计算方式有所不同，在此

处统一使用宏平均（Macro-Average）方法进行计算，具体表述为下式所示：

$$Accuracy = \frac{\sum_{i=1}^n C_{ii}}{\sum_{i=1}^n \sum_{j=1}^n C_{ij}} \quad (4.24)$$

$$Precision = \frac{1}{n} \sum_{j=1}^n \frac{C_{jj}}{\sum_{i=1}^n C_{ij}} \quad (4.25)$$

$$Recall = \frac{1}{n} \sum_{i=1}^n \frac{C_{ii}}{\sum_{j=1}^n C_{ij}} \quad (4.26)$$

其中 C_{nn} 代表混淆矩阵中的元素， n 为矩阵的行列数，对应九种不同操作意图。宏平均方法先统计每种操作意图模型的精确度以及召回率值，之后进行算术平均求终值。三种数据的组合方法得到的模型评估结果如下表所示：

表 4.3 不同数据组合评估结果

	Accuracy	Precision	Recall
飞行参数	78.61%	80.60%	79.49%
飞行参数+眼动数据	87.05%	88.12%	89.26%
飞机参数+SVM 意图眼动数据	90.88%	91.17%	90.50%

为了更直观的对比三种数据组合方法模型的实验结果，下文给出图 4.8 为准确率、精确度和召回率的柱状图对比形式。




图 4.8 消融实验评估柱状图

由图可得，消融实验中三种不同方法对模型的评估结果具有显著的影响。使用独立的飞行数据作为表征向量进行学习，得到的模型准确率、精确度和召回率降低至 78.61%、

80.60%和 79.49%。而加入了操作时眼动数据所训练得到的模型准确率、精确度和召回率分别达到了 87.05%、88.12%和 89.26%。可以看出多维数据集的构建对模型性能有着较为明显的提升。进一步使用上文中基于 SVM 的意图眼动识别方法优化眼动数据，最终模型的准确率提升了 3.83%、精确度提升了 3.58%、召回率提升了 1.24%，得到了上文中的结果。这也验证了数据集质量提升方法对增强操作意图推断结果的有效性。

4.2 基于长短期记忆网络（LSTM）的方法

4.2.1 RNN 与 LSTM 神经网络结构介绍

循环神经网络（Recurrent Neural Network, RNN）是一种针对连续序列数据处理的特化神经网络模型。其特殊的记忆机制允许相邻神经元中的信息循环流动，使模型能够利用先前时刻数据来对当前时刻数据进行预测或决策^[58]。这种特性使得 RNN 对时间序列数据有高效建模能力，并被广泛应用在语音识别、状态预测和自然语言处理等领域中。

如图 4.9 所示，RNN 的基本网络结构由输入层、隐藏层与输出层组成。神经元 A 在当前时刻输入数据的基础上结合上一时刻的状态数据进行处理，通过遍历完整时间序列来形成对历史数据的记忆能力。右半部分为 RNN 神经元的展开表达形式。




图 4.9 循环神经网络展开形式

其中， x 代表任意时刻的输入数据， h 代表任意时刻的状态数据。由展开形式可知，在 t 时刻下的输入数据 x_t 与上一时刻的状态数据 h_{t-1} 的线性组合方式，经由非线性激活函数 $\tanh$ 后输出得到 t 时刻的状态数据 h_t 。 w_x 和 w_h 分别为输入数据 x 和状态数据 h 的权重矩阵， b 为偏置向量。 h_t 可由下式表示：

$$h_t = \tanh(w_x \cdot x_t + w_h \cdot h_{t-1} + b)$$

则 t 时刻下输出数据 y_t 可由 h_t 经过 sigmoid 激活函数处理得到。具体由式(4.27)所表示，其中 w_y 为输出数据 y 的权重矩阵。

$$y_t = \text{sigmoid}(w_y \cdot h_t) \quad (4.27)$$

其中， Tanh 为双曲正切激活函数，可将输出值映射到 $(-1,1)$ 区间内； Sigmoid 激活函数

可将输出值映射到(0,1)区间内。他们的表达式与图像由式(4.28)与图 4.10 所示。

$$\tanh(x) = \frac{1 - e^{-2x}}{1 + e^{-2x}} \quad \text{sigmoid}(x) = \frac{1}{1 + e^{-x}} \quad (4.28)$$




图 4.10 激活函数图像

可以看出，当 RNN 遍历完整的时间序列数据后，最终输出数据可以包含任意历史时刻的输入数据特征。因此，RNN 在处理时序数据任务上的模型性能一般优于其他神经网络。

与全连接网络相同，RNN 的权重矩阵迭代遵循反向传播算法推导，循环的网络结构在时间维度上的展开特性使其无法应用于过长的时序数据上。由于反向传播中含有大量的链式偏导数计算过程，在梯度传递的过程中，较长的时间序列会使其呈指数级的增长或下降。当有小于 1 的值累乘时，梯度值以指数速度趋近于 0；当有大于 1 的值累乘时，梯度值以指数速度趋近于无穷。这就造成了普通 RNN 中常见的梯度消失与梯度爆炸问题，即权重矩阵值超出表示范围导致模型无法正确输出的情况。因此，为了保持模型对时序数据信息的记忆能力的同时，避免梯度消失与梯度爆炸问题的发生。本文将引入长短期记忆神经网络进行建模。




图 4.11 长短期记忆网络展开形式

长短期记忆神经网络（Long Short-Term Memory, LSTM）是为了解决梯度消失与梯度爆炸问题所提出的一种 RNN 结构的神经网络，由 Hochreiter 和 Schmidhuber 于 1997 年提出。LSTM 通过引入记忆单元和门控机制来解决 RNN 对长时序数据的处理能力缺陷的问题^{[59][60]}。图 4.11 为一组 LSTM 记忆单元的展开表达形式。可以看出，区别于普通 RNN 的隐藏层结构，LSTM 在更改算法的同时增加了一条贯穿整个时间序列的“传送带”，用于传输该时刻的记忆状态 C ，以此来实现对历史数据信息的精细化控制。




图 4.12 LSTM 记忆单元结构

如图 4.12 所示, 单一 LSTM 的记忆单元由遗忘门 (Forget Gate)、输入门 (Input Gate) 和输出门 (Output Gate) 三个部分共同组成。每个门控单元都由一个 sigmoid 激活函数和一个 Hadamard 乘积操作组成。sigmoid 函数的输出范围在 0 到 1 之间, 表示信息的保留程度。Hadamard 乘积操作为两矩阵对应元素相乘, 表示数据在同一维度上的融合。下文将依次对三个门控单元的展开详细的推导。

LSTM 记忆单元的第一部分为遗忘门, 其决定上一时刻记忆状态 C 中的信息是否需要舍弃。 t 时刻的遗忘门输出 f_t 由式(4.29)表示, 其中 w_f 为遗忘门的权重矩阵, b_f 为偏置项。 $[h_{t-1}, x_t]$ 表示将 $t-1$ 时刻状态数据 h_{t-1} 与 t 时刻输入数据 x_t 进行维度拼接。其输出结果再由 sigmoid 函数转换为遗忘系数, 通过与 C_{t-1} 进行 Hadamard 乘积操作来决定对应元素的保留程度。

$$f_t = \text{sigmoid}(w_f[h_{t-1}, x_t] + b_f) \quad (4.29)$$

第二部分为输入门, 其决定当前时刻的输入信息有多少需要保留到记忆单元中, 即输入 x 对于记忆状态 C 的更新比重。输入门由两个计算步骤组成, 首先使用 tanh 和 sigmoid 函数对 $[h_{t-1}, x_t]$ 的线性变化进行激活, 得到输入数据记忆状态的候选向量 $\tilde{C}_t$ 与输入系数 i_t 。之后将 $\tilde{C}_t$ 与 i_t 进行 Hadamard 乘积操作即可得到 t 时刻输入数据对于记忆状态的更新向量。 $\tilde{C}_t$ 与 i_t 的计算方式具体如式(4.30~4.31)所示, 其中 w_c 、 w_i 和 b_c 、 b_i 表示对应的权重矩阵与偏置项。

$$\tilde{C}_t = \tanh(w_c[h_{t-1}, x_t] + b_c) \quad (4.30)$$

$$i_t = \text{sigmoid}(w_i[h_{t-1}, x_t] + b_i) \quad (4.31)$$

则 t 时刻的记忆状态 C_t 由遗忘门的输出与输入门的输出共同更新得到:

$$C_t = f_t \cdot C_{t-1} + \tilde{C}_t \cdot i_t \quad (4.32)$$

第三部分为输出门, 其决定记忆单元中当前时刻输出的状态数据 h 。如式(4.33)所示, 其中 o_t 表示输出门在 t 时刻的输出, 由 sigmoid 函数对 $[h_{t-1}, x_t]$ 的线性变化进行激活得到, w_o

和 b_o 表示输出门的权重矩阵与偏置项。

$$o_t = \text{sigmoid}(w_o[h_{t-1}, x_t] + b_o) \quad (4.33)$$

t 时刻的状态数据 h_t 由记忆状态 C_t 与输出门的输出共同更新得到，计算公式为式 (4.34)。其值可用于下一时刻的记忆单元更新过程，也可作为当前时刻的模型输出进一步处理。

$$h_t = o_t \cdot \tanh(C_t) \quad (4.34)$$

在飞行员操作意图推断任务中，LSTM 记忆单元可以有效的捕捉数据中的长期依赖信息，并根据历史时刻的飞行参数与眼动数据输入值来决定模型的权重矩阵更新比重，从而得到包含全部时刻数据特征的输出结果。由此可知，LSTM 在继承了 RNN 对于时间序列数据处理能力的同时，重点强化了其对于时序周期较长数据的记忆能力，有效地解决了梯度消失与梯度爆炸的问题。

虽然传统的 LSTM 网络在处理序列数据的长期依赖关系方面表现出色，但其对于数据中的局部特征提取能力相对有限。因此，本文在输入训练数据至 LSTM 之前，使用数据融合的方式来增强模型对于两类数据的特征学习能力，同时减轻大规模数据导致的模型训练负担。

4.2.2 基于卷积神经网络的特征层融合方法

数据融合过程是指对以多源数据为输入进行整合，充分利用多源数据的优势，生成比单一数据源更具表达力的综合信息，在任务中实现超越原有单一数据所得结果的过程^[58]。

以具体的实现过程进行区分，数据融合可以分为数据层融合、特征层融合和决策层融合三种融合方式。在上文使用隐马尔可夫模型构建操作意图库的模块中，原始数据在经过预处理后以向量拼接的方式构成多维训练数据集，此过程为数据层融合。得益于隐马尔可夫模型轻量化的计算复杂度，在不舍弃任何时刻输入数据的前提下，使用数据层融合能够最大限度地保留原始数据信息的细节特征，其融合过程如图 4.13 所示：




图 4.13 数据层融合过程

而对于矩阵运算量较多的深度学习神经网络而言，较常使用特征层融合的数据处理方式，即对各个数据源的数据分别进行特征提取后，将提取得到的特征进一步融合的过程。相较于多源数据的直接拼接，特征层融合在最大程度保留数据有效特征的前提下，通过减

少了输入数据量的方式降低模型学习时的计算复杂度，其融合过程如图 4.14 所示：




图 4.14 特征层融合过程

而决策层融合是在各个数据源分别进行独立学习和决策后，将决策结果通过算法进行融合以产生新结果的过程，通常使用 D-S 证据理论（Dempster-Shafer Evidence Theory）和熵权法（Entropy Weight Method）等算法。由于本文未涉及决策层融合相关算法，故不在此处展开描述。

通过上文的研究中可知，飞行过程中的飞行参数与飞行员的眼动数据都具有各自独特的时空特征。飞行参数随时间的变化反映了飞机的运动状态和飞行员的操作趋势，而眼动数据则体现了飞行员在飞行过程中的注意力分布和视线落点的动态变化。因此，本文将使用双路卷积神经网络分别对飞行参数与眼动数据进行特征提取，之后再由 LSTM 对特征层融合数据进行训练。

卷积神经网络（Convolutional Neural Network, CNN）是一种基于神经认知机的深度学习网络结构，因其对于多维数据特征的学习能力而被广泛地用于图像识别、目标检测、语音识别等领域^[62]。CNN 的基本框架形由 Yann LeCun 等人在 1998 年提出，并在最早的 LeNet-5 网络上成功实现了手写数字识别任务。

与传统的全连接网络不同，标准的卷积神经网络一般由卷积层（Convolutional Layer）、池化层（Pooling Layer）和全连接层（Fully Connected Layer）组成。卷积层为 CNN 的核心部分。当输入数据进入网络时，首先会经由卷积层进行卷积处理来提取局部特征。卷积核的内部由指定大小与数量的卷积核构成，每个卷积核在对应输入数据上进行滑动运算来实现特征提取。以图 4.15 的二维卷积层运算为例，卷积核以输入数据矩阵第一个元素进行对齐，分别与 3×3 范围内的全部元素进行内积运算并作求和，再由非线性激活函数处理后得到特征矩阵的首个元素值。当步长为 1 时，卷积核将以每 1 个元素为一次滑动距离，循环往复直至遍历所有输入数据，此时得到完整的特征矩阵。




图 4.15 卷积层运算过程

其中，卷积核的数量代表从输入数据中提取出的特征矩阵数量，而步长控制特征矩阵的大小，设定不同卷积核数量与步长的组合方式使得 RNN 能在多个维度提取不同的局部特征信息。当输入数据较为复杂时，将提取出的特征矩阵反复输入至高层级的卷积层进行特征提取，即可在保留重要信息的同时大幅度减少数据规模。而为了避免早期的卷积运算过程中的过拟合问题，在每个卷积层之后通常衔接池化层来对特征矩阵进行快速降维处理。

池化层由指定的池化操作构成。通过对卷积层输出的特征矩阵进行下采样处理，能够在保留数据特征的前提下有效减少特征矩阵的尺寸，避免模型出现过拟合。常用的池化操作有最大池化（Max Pooling）和平均池化（Average Pooling）。以图 4.16 的二维特征矩阵池化操作为例。对于大小为 3×3 、步长为 1 的池化操作，通过类似卷积层的对齐方式依次滑动遍历整个特征矩阵。最大池化操作输出每个 3×3 范围的元素最大值，而平均池化则对每个 3×3 范围所有元素计算均值。




图 4.16 池化层运算过程

最后，卷积池化后的数据特征将通过全连接层的 Flatten 操作展开成为一维向量形式。此处的处理与全连接神经网络一致，当任务需要 CNN 直接输出结果时，模型通过 Softmax 等激活函数将全连接层输出映射到特定范围中。本实验中 CNN 仅作为操作意图的特征提取模块，其输出的特征矩阵无需经过全连接层映射，直接将其作为时序数据直接传入 LSTM 网络进行训练。

4.2.3 CNN-LSTM 操作意图模型搭建

基于上文所介绍的卷积神经网络与长短期记忆神经网络，本方法将采集到的飞行参数和眼动数据分别使用独立的 CNN 模块进行特征提取，在保留原数据时间顺序的情况下融合两种数据的特征参数，并将其输入至 LSTM 模块内进行训练。LSTM 通过由历史数据所不断更新的记忆状态来反复学习提取到的数据特征数据。其结果最后输入值全连接层展开，再通过 Softmax 激活函数输出为全部 9 种操作意图的编码格式。CNN-LSTM 网络结构如图 4.17 所示：




图 4.17 CNN-LSTM 网络结构

输入数据在模型中的完整传递过程如下：

(1) 在 CNN-LSTM 网络的起始部分，输入数据被分为飞行参数与眼动数据两个部分。其中，飞行参数部分的形状为(batch_size,600,4)，batch_size 表示数据输入模型时的训练批次大小，600 为每条数据的时间步数，4 表示横滚角、俯仰角、垂直速度和转弯率四种飞行参数，同理可知眼动数据部分的形状为(batch_size,600,2)。

数据传递至卷积层后，由 16 个大小为 3 的一维卷积沿时序方向进行滑动卷积操作。此处的步长 $S=1$ ，即每次跳跃一个数据进行卷积。且为了将输出特征向量长度维持在 600，将填充 P 设置为 1，即左右数据两侧各填充 1 格数据。在所有的 16 个卷积核运算完成后，输出的飞行参数与眼动数据的特征向量形状都为(batch_size,600,16)。

接着将数据传递至池化层内进行降维处理。飞行参数作为评估飞机状态的最直观的指标，更应保留其变化过程中的峰值信息作为特征条件。而眼动数据体现视线落点的移动趋势，应降低特征在时间序列上的数值波动。综上所述，考虑到飞行参数与眼动数据的不同特性，在此分别使用最大池化与平均池化操作。池化操作大小为 6，则得到输出的特征数据的形状为(batch_size,100,16)。

(2) 在经由 CNN 特征提取后，将飞行参数与眼动数据在时序维度上进行特征层融合，得到形状为(batch_size,100,32)的 LSTM 网络输入数据，LSTM 的记忆单元数量设定为 64。

输入数据通过三种门控机制不断更新状态数据和记忆状态，并在遍历完成后输出含有全部时刻信息的 h 值，得到输出的形状为(batch_size,64)。

为了增强模型的泛化能力，在 LSTM 层后对输出值采用随机的 Dropout 操作。Dropout 是一种防止神经网络过拟合的正则化技术，通过在训练过程中舍弃部分神经元来减少模型对相似样本的依赖性^[63]。被舍弃的样本以置 0 的方式覆盖于原先位置，以此保证数据形状不受影响。

(3) 第一层全连接网络包括 64 个神经元，与 LSTM 输出的所有特征数据进行加权求和计算，再通过 Relu 激活函数进行非线性变化后传递至输出层。输出层的神经元数量为 9 个，代表全部 9 种分类的飞行员操作意图，最后通过 Softmax 激活函数进行归一化处理后转换为概率分布，最终输出结果形状为(batch_size,9)。Softmax 输出值通过式(4.35)计算得出，其中 x_i 代表第 i 个神经元的直接输出值。若输入测试数据进行评估，则选取输出值最大的神经元所对应的操作意图为决策结果。

$$\text{Softmax}(x_i) = \frac{e^{x_i}}{\sum_{j=1}^N e^{x_j}} \quad (4.35)$$

下文将使用以上所介绍的 CNN-LSTM 网络进行飞行员操作意图模型搭建。为了保证数据一致性，此模型将在与 GMM-HMM 模型库相同的 1270 组训练数据集和 318 组测试数据集上进行训练与评估。

4.2.4 深度学习方法模型性能分析

深度学习模型基于 Python3.9 环境下进行训练，CNN 与 LSTM 网络层均使用 Tensorflow 框架中的 Keras 库实现。为了减少训练用时，调用 Nvidia RTX 4070 的 Cuda 核心进行硬件加速。

训练轮次设定为 150 轮，全部 1270 组训练数据分为 10 批次送入模型，每批次大小为 128 组。优化器部分使用 Adam 算法，初始学习率设定为 0.001。相较于传统的随机梯度下降算法，Adam 为每个参数计算自适应的学习率，通过计算梯度均值和未中心化的方差来调整每个参数的更新步长。通过历史梯度信息动态地调整学习率，使得模型在训练过程中可以更快速地收敛。

损失函数为分类任务中常用的交叉熵函数(Cross-Entropy)。由于本任务为多分类结果，以 Keras 库中的 categorical_crossentropy 函数将结果以独热编码(One-Hot Encoding)的格式输出，即决策类别概率为 1，其余为 0 的格式。函数公式如式(4.36)所示， B 代表批次大小， N 代表类别数量， y_{ij} 与 $\hat{y}_{ij}$ 分别为数据 i 真实标签的独热编码以及模型的预测概率分布。

$$\text{Loss} = \frac{1}{B} \sum_{i=1}^B - \sum_{j=1}^N y_{ij} \log(\hat{y}_{ij}) \quad (4.36)$$

模型的主要参数如下表所示：

表 4.4 模型主要参数

模型参数	设定值
训练轮次 (epoch)	150
批次大小 (batch_size)	128
初始学习率 (learning rate)	0.001
优化器 (optimizer)	Adam
损失函数 (loss Function)	categorical_crossentropy
输入形状	600×6
输出形状	1×9

为了记录模型在训练过程中的性能与泛化能力的变化过程，每经过一轮训练后分别使用训练数据集与测试数据集对当前模型的准确率进行评估，同时记录各自的损失函数输出值，其结果如图 4.18 所示。可以看到，训练集和测试集的损失值在训练初期都呈现快速下降的趋势，模型的准确率与损失值的变化相对应，呈现上升趋势。这表明 Adam 优化器通过调整了模型参数使得预测结果与真实标签之间的差异逐渐减小。随着训练轮数增加至 50 轮后，损失值下降的速度逐渐变缓，最终 100 轮后趋于平稳，说明模型逐渐接近收敛状态。




图 4.18 模型损失值与准确率变化

选取最终完成 150 轮次训练的模型进行测试集评估，对全部 9 中操作意图的分类结果如表 4.5 所示，其中意图 1 到 9 所对应的操作意图与 GMM-HMM 部分一致。

表 4.5 CNN-LSTM 测试集评估混淆矩阵

		推断意图								
		意图 1	意图 2	意图 3	意图 4	意图 5	意图 6	意图 7	意图 8	意图 9
实际意图	意图 1	28	0	0	0	0	0	0	0	1
	意图 2	0	29	1	0	0	6	1	0	0
	意图 3	1	0	25	0	0	0	0	2	0
	意图 4	0	0	0	35	0	0	0	0	1
	意图 5	0	0	0	0	31	0	0	0	1
	意图 6	0	0	0	0	0	39	0	0	0
	意图 7	0	1	0	0	0	0	42	0	0
	意图 8	1	0	0	0	0	0	0	41	0
	意图 9	0	0	0	0	0	1	0	0	31

可以看出，CNN-LSTM 模型同样具有优秀的分类能力，其中 39 个左舵转向上升操作

全部得到正确的判断。对于单一操作，仍有部分数据被错误判断为的包含其在内的组合操作，其中 37 个上升操作有 6 个被错误的判断为左舵转向上升。而剩余的 7 种操作仅有个别被错误判断为其他类型。百分比形式的混淆矩阵热图如图 4.19 所示：




图 4.19 百分比混淆矩阵热图

由此可知，在相同的训练数据集与训练轮次下，此节所搭建的长短期记忆网络模型性能要强于上文的隐马尔可夫模型。这是由于深度学习模型结构的复杂性能够学习到数据深层的时序特征，通过增加训练时的运算复杂度所得到的优势。而在数据集更加充足的前提下，这种优势会被进一步放大。

此外，为了验证本节设计的 CNN-LSTM 网络对于长时序数据的学习能力，将在相同的环境下使用 RNN 与 LSTM 网络进行建模，模型主要参数与上表保持一致，并使用同一数据集与测试集进行模型的训练与评估。三种模型最终的准确率、精确度和召回率如表 4.6 所示。

表 4.6 不同模型测试集评估结果

	Accuracy	Precision	Recall
RNN	91.19%	89.03%	89.70%
LSTM	93.39%	92.85%	91.28%
CNN-LSTM	94.65%	95.02%	94.55%

在本次消融实验的评估结果中，基于 CNN-LSTM 的模型达到了最高 94.65% 的测试集准确率，对比普通 RNN 模型的 91.19% 有 3.46% 的显著提升，这表示 CNN-LSTM 记忆单元中的门控机制能更加有效地存储和更新飞行参数与眼动数据的长期信息。进一步引入 CNN 模块处理输入数据，通过卷积层和池化层可以更好的提取数据中的局部特征，最终准确率对比普通 LSTM 模型的 93.39% 有 1.26% 的提升。此外，CNN-LSTM 对于测试集数据的平

均精确度达到 95.02%，说明模型推断的操作意图中有较高的正确决策占比，这在飞行过程中有效降低系统误判所带来的风险。

4.3 本章小结

本章基于前文采集到的飞行参数与眼动数据集，分别使用机器学习与深度学习方法进行飞行员操作意图建模。第一部分首先介绍了 HMM 基本原理，针对多维连续数据引入 GMM 替代原有发射概率矩阵，训练得到包含 9 中操作意图的模型库。通过对比，得出高斯成分 K 取 6 时模型训练性能最佳，准确率达到了 90.88%。最后为了通过不同训练数据组合的消融实验，验证 SVM 意图眼动识别对模型性能的影响。第二部分首先介绍了 RNN 的梯度消失问题，并以此引出 LSTM 的记忆单元与三种门控机制。为提升 LSTM 局部特征提取能力，采用 CNN 进行特征层融合构建 CNN-LSTM 模型。该模型在与上一部分相同的测试集上准确率达 94.65%，且通过对比评估实验可知，基于 CNN-LSTM 的模型性能优于普通 RNN 和 LSTM 模型。

5 结论与展望

5.1 结论

在现阶段的航空领域内,减少人为操作失误为保证飞行安全最重要的课题。准确推断飞行员操作意图能够在关键时刻提供有效的辅助决策信息,从而极大地减少人为失误情况的发生。本文通过分析总结现阶段国内外研究现状研究,针对于生理信号难以在不影响被试者的前提下进行采集这一问题,提出了一种以非侵入式眼动仪采集眼动数据,并结合飞机自身飞行参数的数据组合方式,分别在机器学习与深度学习算法的基础上实现操作意图建模。最后以多种模型的准确度、精确度和召回率值进行对比,验证了该方法的有效性。

本文的主要研究工作有以下几点:

(1) 在眼动数据处理方面,基于对视觉系统机理对常见眼动特征进行分析,确定了以扫视速度和相对位移作为区分意图眼动数据的特征。并使用 Tobii 眼动仪在基于 Qt 制作的意图眼动采集程序中,通过给定意图的方式采集眼动数据,之后使用线性插值法 (Linear Interpolation) 和指数移动平均 (EMA) 算法对数据补全与平滑。最后在 747 组训练数据上使用支持向量机 (SVM) 算法来构建意图眼动识别模型,其分类准确率达到 90.91%。同时对比决策树和浅层全连接网络模型分类结果,得到 SVM 在处理小样本数据时的具有一定优势的结论。此外还通过使用管径向基函数 (RBF) 核对数据进行非线性分类,得到了 92.51% 的分类准确率。但使用非线性核函数会显著增加训练的计算复杂度,综合考虑下线性核函数仍为最佳选择。

(2) 在飞行参数处理方面,以飞机飞行时的运动状态为界定条件,将操作分为单一操作与组合操作两大类、不同角度的 9 种操作。并通过观察执行操作时的飞行参数变化,确定了使用飞机横滚角、俯仰角、垂直速度和转弯率作为模型训练参数。之后,共 8 名被试者在六自由度平台上,使用 DCS World 模拟飞行软件进行数据采集实验,最终得到 1588 组原始数据。而针对于单独使用加速度或角速度数据进行姿态解算时容易出现的漂移与动态噪声干扰问题,本文使用卡尔曼滤波算法对二者数据进行融合姿态解算。最后基于一段飞机姿态数据进行验证实验,并通过均方根误差值 (RMSE) 以及决定系数 R^2 进行评估,证明了该方法的有效性。

(3) 在意图推断模型搭建方面,分为使用机器学习与深度学习两种方法实现:

机器学习部分基于隐马尔可夫模型 (HMM) 进行建模。通过引入高斯函数 (GMM) 代替发射概率矩阵的方法,增强模型对连续时序数据的刻画能力。GMM-HMM 模型在 1270 组训练集和 318 组测试集上进行训练与评估。通过对比实验确定高斯成分取 6 时,模型在当前任务能够达到准确率与计算复杂度的平衡,其准确度在 150 轮训练当中最高可达 90.88%,说明该方法对于不同操作意图有较好的分类结果。最后,为了验证上文意图眼动

分类对于模型性能的影响，对不同数据集的组合方式所得结果进行消融实验评估。最终验证了当数据集为意图眼动数据+飞行参数时，GMM-HMM 模型性能最优。

深度学习的部分基于长短期记忆网络（LSTM）进行建模。与机器学习部分的数据层融合不同，此处使用卷积神经网络（CNN）提取飞行参数与眼动数据特征进行特征层融合，再传递至 LSTM 层对融合特征进行训练。此方法在解决 LSTM 对于局部特征提取能力不足的问题的同时，能有效降低其计算复杂度。最终 CNN-LSTM 模型在相同的测试集上得到 94.65% 的准确率，相比普通的 RNN 和 LSTM 模型有 1.26% 和 3.46% 的提升，同时优于机器学习方法的评估结果。在实际任务当中，需要充分权衡两种方法的性能与训练负担，做出相对平衡的选择。

5.2 展望

本文将飞行参数与眼动数据作为操作意图表征向量，分别使用机器学习与深度学习两种方法实现飞行员操作意图推断。但在进行研究的过程中，因时间、篇幅以及实验条件限制，仍有许多不足之处需要在未来的研究中进行改进与完善：

（1）本文的实验采用模拟飞行平台进行数据采集，其舱内视线落点以显示器二维坐标系取值方式输出。而在真实飞行环境中，飞行员的视线在自由的三维空间中运动。因此，如何在三维空间中得到准确的视线落点将是接下来的研究方向。通过参考国内外相关研究现状可知，后续研究可尝试融入头部姿态运动数据来精确计算三维空间中的视线落点，从而使研究更贴合实际飞行场景。

（2）在已完成的研究中仅对较为基础的 9 种飞行操作进行分类，而实际飞行场景中的操作更为复杂多样。因此，后续研究应当对更多的飞行操作进行细致的分类，增加如空速、迎角等其他飞行参数并进行更加广泛的数据集采样。通过涵盖更全面的飞行操作与数据类型来提升模型的泛化能力。

（3）在模型改进方面，可以尝试结合其他常用的深度学习技术，例如引入注意力机制来增强网络对复杂数据中关键信息的学习能力，进而提升模型性能。

参考文献

- [1] 郑友胜,李泰安.军用飞机飞行安全影响因素研究综述[J].教练机,2012,(04):53-59.
- [2] 王君,孙宏.航空飞行事故原因分析及预防[J].物流科技,2021,44(01):81-84.
- [3] 王玉海,宋健,李兴坤.基于模糊推理的驾驶员意图识别研究[J].公路交通科技,2005,22(12):113-118.
- [4] 张肃,程启月,解瑶.不确定空情信息条件下的意图识别方法[J].空军工程大学学报·自然科学版,2008,9(3):50-53.
- [5] 王端龙,吴晓锋,冷画屏.对敌战场意图识别的若干问题[J].舰船电子工程,2004,(06):4-9.
- [6] 宋晓琳,曾艳兵,曹昊天,等.基于长短期记忆网络的换道意图识别方法[J].中国公路学报,2021,34(11):236-245.
- [7] 张晨浩,周焰,蔡益朝,等.空中目标作战意图识别研究综述[J].现代防御技术,2024,52(04):1-15.
- [8] Kyle Mahowald,Anna Ivanova,Idan Blank,et al.Dissociating language and thought in large language models.[J].Trends in cognitive sciences,2024,28(6):517-540.
- [9] 王超,孙喆喆,徐飞,等.结合 CNN 和 BiGRU 的双通道短文本意图识别算法[J].计算机系统应用,2024,33(05):136-143.
- [10] 郭云雪.基于深度学习的人机对话中短文本意图识别[D].哈尔滨:哈尔滨理工大学,2021.
- [11] 马晗,唐柔冰,张义,等.语音识别研究综述[J].计算机系统应用,2022,31(01):1-10.
- [12] Zhang Linhao, Ma Dehong, Zhang Xiaodong, et al. Graph LSTM with Context-Gated Mechanism for Spoken Language Understanding[J]. Proceedings of the AAAI Conference on Artificial Intelligence, 2020, 34(05): 9539-9546.
- [13] 周新宇.基于神经网络的汉语 asr 识别对话短文本意图匹配[D].北京:北京邮电大学,2021.
- [14] Stefan S, Florian F. Aircraft Pilot Intention Recognition for Advanced Cockpit Assistance Systems [C]. International Conference on Augmented Cognition. Toronto, Canada: Springer International Publishing, 2016: 231-240.
- [15] Strohal Michael, Reiner Onken. Intent and error recognition as part of a knowledge-based cockpit assistant[J]. Applications and Science of Computational Intelligence, 1998 (3390): 287-299.
- [16] 周旺旺,姚佩阳,张杰勇,等.基于深度神经网络的空中目标作战意图识别[J].航空学报,2018,39(11):200-208.
- [17] Kim I H, Kim J W, Haufe S. Detection of braking intention in diverse situations during simulated driving based on EEG feature combination[J]. Journal of Neural Engineering, 2015, 12(1): 55-66.

- [18] Zhang Chi, Wang Hong, Fu Rongrong. Automated detection of driver fatigue based on entropy and complexity measures[J]. IEEE Transactions on Intelligent Transportation Systems, 2014, 15(1): 168–177.
- [19] 李玉祥. 基于 EEG 信号的人类意图识别方法研究[D]. 成都: 电子科技大学, 2023.
- [20] 王一男. 基于隐马尔科夫模型的驾驶员换道驾驶意图识别方法研究[D]. 吉林: 吉林大学, 2020.
- [21] 聂玉洁. 基于眼动信息的意图识别[D]. 济南: 山东大学, 2023.
- [22] 江佳运, 孙有朝, 晏传奇. 基于 GASVM-HMM 算法的飞行员操控意图识别[J]. 航空计算技术, 2023, 53(01): 43–47.
- [23] Ernest N, Carroll D, Schumacher C. Genetic Fuzzy based Artificial Intelligence for Unmanned Combat Aerial Vehicle Control in Simulated Air Combat Missions[J]. Journal of Defense Management, 2016, 6(1): 1–7.
- [24] 杨雨田, 杨杰, 李建国. 基于 EMEBN 的空中目标战术意图识别方法[J]. 火力与指挥控制, 2022, 47(05): 163–170.
- [25] Chen Zhigang, Wu Xiaofeng. A novel multi-timescales layered intention recognition method[J]. Applied Mechanics & Materials, 2014, 644–650: 4607–4611.
- [26] 贾苏元, 徐金钰, 王钰. 基于自适应神经网络模糊系统(ANFIS)的空中目标意图分类[J]. 电子测量技术, 2016, 39(12): 62–66.
- [27] 滕飞, 刘曙, 宋亚飞. BiLSTM-Attention: 一种空中目标战术意图识别模型[J]. 航空兵器, 2021, 28(05): 24–32.
- [28] 彭俊榕. 基于动作目标预测的飞行员操作意图识别研究[D]. 广汉: 中国民用航空飞行学院, 2024.
- [29] Lea Steffen, Daniel Reichard, Jakob Weinland, et al. Neuromorphic Stereo Vision: A Survey of Bio-Inspired Sensors and Algorithms[J]. Frontiers in Neurorobotics, 2019, 13: 28.
- [30] 冯成志. 眼动人机交互[M]. 苏州: 苏州大学出版社, 2010(第七章).
- [31] Jan Theeuwes, Artem Belopolsky, Christian N.L. Olivers. Interactions between working memory, attention and eye movements[J]. Acta Psychologica, 2009, 132(2): 106–114.
- [32] Boshra Rober, Kastner Sabine. Attention control in the primate brain[J]. Current Opinion in Neurobiology, 2022, 76: 102650.
- [33] 陈勇. 视觉神经系统的注意机制研究[D]. 长沙: 国防科学技术大学, 2009.
- [34] 柳忠起, 袁修干, 刘伟, 等. 模拟飞机降落过程中的眼动和认知研究[J]. 航天医学与医学工程, 2002, (05): 379–380.
- [35] Christophe Lounis, Vsevolod Peysakhovich, Mickaël Causse. Visual scanning strategies in the cockpit are modulated by pilots' expertise: A flight simulator study[J]. PLoS One, 2021, 16(2): e0247061.

- [36] 蒋光毅,王长元,刘洲洲.视线追踪联合脑电的飞行员操纵意图检测方法[J].西安工业大学学报,2024,44(01):23-31.
- [37] 张美玉.基于管制员眼动行为的注意力分配研究[D].南京:南京航空航天大学,2019.
- [38] Christopher J.C. Burges.A Tutorial on Support Vector Machines for Pattern Recognition.[J].Data Mining and Knowledge Discovery,1998(2):121-167.
- [39] 张学工.关于统计学习理论与支持向量机[J].自动化学报,2000,(01):36-46.
- [40] Li Miaoyi,Zhu Ningrui.Research on the Method of Artificial Intelligence for Identifying Urban Land-Use Types Based on Areas of Interest (AOI) and Multi-Source Data[J].Land,2024,13(12):2024-2040.
- [41] Koen van de Merwe,Henk van Dijk,Rolf Zon.Eye Movements as an Indicator of Situation Awareness in a Flight Simulator Experiment[J].The International Journal of Aviation Psychology,2012,22(1)78-95.
- [42] 严荣慧.基于眼动特征的轨道交通驾驶员驾驶疲劳检测研究[D].苏州:苏州大学,2017.
- [43] 潘以方,周莹,柯黎,等.眼肌性视疲劳[J].中国实用眼科杂志,1996(11):678-680.
- [44] Song Mengchuang,Li Lina,Guo Jintao,et al.A new method for muscular visual fatigue detection using electrooculogram[J].Biomedical Signal Processing and Control.2020,58:101865.
- [45] S B Kotsiantis.Decision trees:a recent overview[J].Artificial Intelligence Review,2011,39:261-283.
- [46] 张汝麟.飞行控制与飞机发展[J].北京航空航天大学学报,2003(12):1077-1083.
- [47] 金易.军用飞机的种类及其用途[J].交通世界,1996(04):27.
- [48] 荆继洪.“人丁兴旺”的苏-25 家族[J].航空世界,2001(10):30-33.
- [49] 朱立成,孙青,端军红,等.基于机动动作类型识别的飞行员飞行训练质量自动评估方法[J].系统工程与电子技术,2023,45(12):3932-3940.
- [50] Wang Menglong,Wang Hua.An adaptive attitude algorithm based on a current statistical model for maneuvering acceleration.[J].Chinese Journal of Aeronautics,2017,30(3):426-433.
- [51] 吴叶丽,行鸿彦,侯天浩,等.基于改进自适应扩展卡尔曼滤波的高精度姿态解算[J].探测与控制学报,2023,45(06):69-76.
- [52] 何磊,宣晓刚,罗小虎,等.基于 NCS-ESKF 算法的飞机姿态估计[J].仪器仪表学报,2024,45(10):295-304.
- [53] Li Qiang,Li Ranyang,ji Kaifan,et al.Kalman Filter and Its Application[C].International Conference on Intelligent Networks and Intelligent Systems(ICINIS).Tianjin,China:IEEE,2015:74-77.
- [54] 王鹏,余未,倪屹.基于旋转矩阵的 MEMS-IMU 传感器安装误差校准算法[J].空天预警研

- 究学报,2024,38(06):420-425.
- [55] L.R. Rabiner. A tutorial on hidden Markov models and selected applications in speech recognition[C]. Proceedings of the IEEE. San Francisco, CA, USA: Morgan Kaufmann Publishers. 1989, 77(2): 257-286.
- [56] A. P. Dempster, N. M. Laird, D. B. Rubin. Maximum Likelihood from Incomplete Data Via the EM Algorithm[J]. Journal of the Royal Statistical Society, 1997, 39(1): 1-22.
- [57] 于扬, 梁军, 陈龙, 等. 基于高斯混合隐马尔科夫模型与人工神经网络的紧急换道行为预测方法[J]. 中国机械工程, 2020, 31(23): 2874-2882+2890.
- [58] 杨丽, 吴雨茜, 王俊丽, 等. 循环神经网络研究综述[J]. 计算机应用, 2018, 38(S2): 1-6+26.
- [59] Alex Graves, Jürgen Schmidhuber. Framewise phoneme classification with bidirectional LSTM and other neural network architectures[J]. Neural Networks, 2005, 18(5): 602-610.
- [60] Felix A. Gers, Jürgen Schmidhuber, Fred Cummins. Learning to Forget: Continual Prediction with LSTM[J]. Neural Computation, 2000, 12(10): 2451-2471.
- [61] 徐昕. 头动眼动数据融合的视线方向算法研究与应用[D]. 西安: 西安工业大学, 2022.
- [62] 周飞燕, 金林鹏, 董军. 卷积神经网络研究综述[J]. 计算机学报, 2017, 40(06): 1229-1251.
- [63] Nitish Srivastava, Geoffrey E. Hinton, Alex Krizhevsky, et al. Dropout: a simple way to prevent neural networks from overfitting[J]. Journal of Machine Learning Research, 2014, 15(1): 1929-1958.