



西安工业大学

专业学位硕士 学位论文中期检查报告

论 文 题 目 多模态生理信号融合下飞

行员认知负荷评估研究

姓 名 杨浙涵

学 号 2406310892

导 师 姓 名 王长元 职称 教授

企业导师姓名 吴斌 职称 高工

学 院 计算机科学与工程学院

领 域 名 称 计算机技术

2026 年 6 月 25 日

说 明

- 1.本表可以在计算机上填写、打印，手工填写时须字迹清楚且不得涂改。
- 2.表中所列项目必须全部填写，不留空白。
- 3.本表用 A4 纸正反面复印。
- 4.中期检查报告由本人如实填写，校内外导师对报告给出评审意见。
- 5.本表仅为一个格式，个别栏目不够填时，可重新打印排版或附页。

学位论文题目：多模态生理信号融合下飞行员认知负荷评估研究			
中期检查时间	2026 年 07 月 02 日	开题报告时间	2026 年 6 月 25 日
1.论文工作进展情况：（说明论文工作是否按中期报告预定的内容及论文计划进度进行，如存在与中期报告内容不相符的部分，请说明其原因） 一、理论研究进展（按计划完成） （1）文献调研与理论体系构建 在文献调研方面，已阅读认知负荷评估相关文献约 20 篇，主要用于梳理飞行任务中认知负荷的定义、诱发方式和评价指标；阅读眼动、心电、肌电等多模态生理信号处理相关文献约 15 篇，重点学习各类信号的预处理、特征提取和融合方法；阅读机器学习分类算法和深度学习融合模型相关文献约 15 篇，重点关注 SVM、TCN、GRU、注意力机制和模态融合方法。 （2）核心技术原理学习 围绕本研究所需的核心技术，已完成多模态生理信号处理和认知负荷识别方法的学习。在模型构建方面，学习了基于机器学习的静态特征分类方法以及基于深度学习的原始信号输入建模方法。 二、实验研究进展（按计划完成） （1）多模态数据整理与预处理 目前已完成 Eye、ECG 和 EMG 多模态生理信号的数据整理与预处理工作。经过数据清洗、无效片段剔除和连续窗口序列构建后，最终形成用于 low/high 认知负荷识别的有效样本，其中 low 类和 high 类样本数量较为接近，为后续分类实验提供了数据基础。 （2）融合模型设计与实验 在完成多模态特征构建的基础上，已基于 SVM 和 XGBoost 等传统机器学习模型开展认知负荷二分类基线实验。在传统机器学习基线基础上，进一步设计并实现了基于原始信号输入的眼动主导多模态深度融合模型。模型整体由三支 TCN 编码模块、可靠性感知门控模块、眼动主导跨模态注意力模块、BiGRU 时间建模模块、时间注意力模块和上下文门控分类模块组成。 （3）智能识别系统原型规划 结合专业学位论文的应用导向，下一阶段将在已有模型基础上进一步设计飞行员认知负荷智能识别系统原型。系统拟包括数据输入、预处理、模型推理、认知负荷状态输出和结果可视化等基本功能，用于实现对 low/high 认知负荷状态的自动识别。当前已完成算法模型和实验流程的主要设计，后续将继续完善系统功能和可视化展示模块。			

2. 已完成的研究内容及阶段性成果：

本文围绕“多模态生理信号融合下飞行员认知负荷评估研究”展开，整体研究框架如图所示。首先，针对单一模态难以全面表征认知负荷状态、多模态关联建模不足以及生理信号复杂多变、个体差异明显等问题，本文分别从数据表征、融合建模和跨被试泛化三个方面提出研究思路。在数据层面，构建眼动、心电和肌电多模态生理信号采集与样本构建流程；在模型层面，设计多模态认知负荷识别模型，分析不同模态之间的互补关系；在验证层面，通过跨被试实验和模型稳健性分析评估模型在未知被试上的识别能力。最终，本文希望形成面向飞行任务的飞行员认知负荷高低智能识别系统，为飞行员认知状态评估提供方法基础。




图 2.1 整体研究框架图

本文整体研究流程分为四层递进模块。首先开展多模态生理信号采集与预处理工作。第二，搭建认知负荷标签体系，针对无法直接观测的潜在认知负荷状态，以眼动、心电、肌电的生理变化作为外在表征，结合主观认知负荷测评量表，划分出低、高两类离散负荷标签。第三，构建基于特征层融合的传统机器学习识别模块。最后，搭建基于 TCN-BiGRU 的深度时序建模模块。完整实现了模拟飞行场景下基于多模态生理信号的飞行员认知负荷识别研究。



图 2.2 研究路线图

2.1 实验设置和数据采集

2.1.1 试验平台搭建

飞行环境仿真部分将 Steam 中的 DCS World 作为飞行仿真平台，以模拟飞行驾驶座舱为实验环境，该系统整合了屏幕式眼动仪与模拟飞行软件，实现了眼动数据与生理信号的高精度同步采集。该平台由硬件及软件两部分组成，如图 2-1 所示。主要包括了用于模拟飞行体感的六轴全动平台底座、进行模拟环境展示的三联显示器、进行飞行操作的飞行摇杆、飞行脚舵以及油门控制器、数据采集仪器和主机等。



图 2-1 模拟飞行实验平台

2.1.2 实验设备选择与配置

(1) 设备选取

心电设备：在心电数据采集，使用了同步测量采集系统所对应的配套无线心电采集设备，该采集设备能够用于记录心脏从感受到刺激至趋于平静的电活动变化过程。

肌电设备：在进行肌电信号的采集，本研究所选用的采集设备是 ErgoLAB 同步测量采集系统配备的 EMG 无线肌电采集仪器。

眼动设备：采用 Tobii 公司生产的 Tobii Eye Tracker 眼动仪，设备内设置有红外光源，红外光照射到眼睛后，会反射回设备中的摄像头，摄像头捕捉反射光，通过算法分析眼动数据。



(a) 无线心电采集仪器 (b) 无线肌电采集仪器 (c) Tobii Eye Tracker 眼动仪

图 2-2 多生理信号采集设备

(2) 实验设计

本研究采用被试内实验设计，在模拟飞行任务条件下采集飞行员多模态生理信号数据。如图 2-3 所示：



图 2-3 飞行模拟图

本次人机环境下的模拟飞行实验中，招募选取 12 名志愿者作为研究对象，年龄为 20-26 岁，身高为 165cm 到 180cm 之间。所有模拟实验均在室内进行，环境温度通过新风系统控制到 $25 \pm 5^{\circ}\text{C}$ ，湿度控制在 $45 \pm 10\%$ 。要求实验参与人员在过去的 24 小时内保证不少于 8 小时睡眠，在实验开始前 5 小时内不能摄入咖啡因、含茶类饮品，或者其他能够导致神经兴奋的物质。

五边飞行是飞行训练中的典型基础任务，主要包括离场段、侧风段、下风段、基准段和进场段五个航段，任务过程中涉及起飞、爬升、转弯、平飞、下降、对准跑道和着陆准备等典型操作。五边飞行任务流程如图 2-4 所示，任务具体要求如表

2-1 所示。




图 2-4 五边飞行实验示意图

表 2-1 五边飞行任务要求

阶段	航线	任务要求
起飞	离场段	航向设定为 95° ，起飞后立即收起起落架，爬升至 1000 米高度
巡航	侧风段	保持 1000 米左右高度稳定飞行，根据轨迹烟雾左转至 5° 航向
	下风段	维持高度约 1000 米，沿航向 275° 飞行，观察风向指示进行微调
	基准段	保持 1000 米高度，左转至 185° 航向，准备进入降落阶段
降落	进场段	对准跑道方向 95° ，离地 300 米时打开降速伞，50 米时放下起落架

从飞行任务要求来看，模拟飞行过程中被试需要持续感知并控制飞行高度、速度和航向等关键飞行状态，同时还需要完成随机触发的事件检测任务。上述任务要求会增加被试在飞行操作过程中的信息处理强度和认知资源占用。在标签构建方面，本文不直接将生理信号本身作为标签依据，而是结合飞行任务表现对认知负荷状态进行标注。实验是对被试者在飞行操作类任务中的飞行表现作为飞行绩效，也就是飞行精度，用它来进行评估模拟飞行实验中不同的时间范围下被试者的认知负荷，将其作为同步测量采集系统采集到的生理数据的标签数据，由此来进行各生理信号的状态评估，形成数据集。具体的数据采集过程如下：




图 2-5 实验流程图

本文以 10 s 为窗口长度、5 s 为滑动步长，对同步采集的 Eye、ECG 和 EMG 生理信号进行切分，并根据同一时间窗口内的认知负荷标签构建样本。经数据清洗、无效片段剔除和连续窗口序列构建后，最终获得有效序列样本 6033 个，其中 low 类样本 2915 个，high 类样本 3118 个。该数据集作为后续飞行员认知负荷二分类识别实验的数据基础。

2.2 多模态生理信号预处理与特征构建

2.2.1 眼动信号预处理与特征提取

眼动信号能够反映被试在模拟飞行任务过程中的视觉注意分配和信息加工状态。实验过程中，本文采用屏幕式眼动仪采集被试在飞行任务中的眼动数据，主要记录视线注视点坐标、瞳孔大小、注视事件、眨眼事件以及对应时间戳等信息。眼动仪输出的注视点坐标能够描述被试视线在屏幕上的空间位置，瞳孔大小能够反映视觉加工和认知负荷变化，注视事件和眨眼事件则能够用于分析视觉注意稳定性和注意调节状态。如图 2-6 为部分眼动原始数据：

gaze_orig:	gaze_orig:	gaze_orig:	gaze_orig:	gaze_orig:	gaze_orig:
32.329071	6.86863708	-24.42496	-33.06171	2.16285708	-26.48502
32.329071	6.86863708	-24.42496	-33.06171	2.16285708	-26.48502
32.332458	6.86863708	-24.42531	-33.06171	2.16285708	-26.48502
32.332458	6.86863708	-24.42546	-33.06123	2.16285708	-26.48502
32.332458	6.86863708	-24.42546	-33.06123	2.16285708	-26.48502
32.332687	6.86863708	-24.42624	-33.06018	2.16285708	-26.48502
32.334548	6.8664551	-24.42749	-33.05742	2.16233825	-26.48502
32.334548	6.8664551	-24.42749	-33.05742	2.16233825	-26.48502
32.336013	6.86593627	-24.4292	-33.05725	2.16233825	-26.48518
32.336013	6.86593627	-24.4292	-33.05725	2.16233825	-26.48518

图 2-6 部分原始眼动数据

原始眼动数据在采集过程中容易受到眨眼、视线短时丢失、头部轻微移动和设备跟踪不稳定等因素影响，导致瞳孔序列中出现缺失值、异常尖峰和短时突变。因此，在提取眼动特征前，需要先对原始眼动信号进行清洗。首先对原始瞳孔信号中的缺失值进行检测，对于短时缺失片段采用线性插值方式进行补全；随后对明显偏离局部趋势的异常值进行抑制，并采用平滑方法降低局部高频波动对特征计算的影响。设连续缺失片段前后的有效值分别为 (x_{k-1}) 和 (x_{k+m}) ，当第 (k) 到第 $(k+m-1)$ 个采样点缺失时，可采用线性插值进行补全：

$$x_{k+i} = x_{k-1} + \frac{i+1}{m+1}(x_{k+m} - x_{k-1}), \quad i = 0, 1, m-1$$

其中， (m) 表示连续缺失点数量， (x_{k+i}) 表示插值后的眼动数据值。




图 2-7 眼动数据预处理对比图

由图 2-7 可以看出，原始瞳孔信号中存在一定的缺失片段和局部异常波动，经过缺失补全、异常值抑制和平滑处理后，瞳孔序列整体更加连续，局部突变得到削弱，信号变化趋势更加稳定。眼动窗口级特征可表示为：

$$x_j^{\text{eye}} = [\text{FTR}_j, \text{PupilMean}_j, \text{PupilStd}_j, \text{BlinkRate}_j]$$

其中， FTR_j 表示第 j 个窗口内注视时间占比， PupilMean_j 和 PupilStd_j 分别表示瞳孔均值和瞳孔标准差， BlinkRate_j 表示眨眼率。如表 2-2 所示：

表 2-2 常用眼动特征表

特征名称	特征含义	人体生理或认知状态对应含义
fixation_time_ratio	注视总时长占窗口总时长的比例	反映被试对视觉目标的持续关注程度
pupil_mean	时间窗口内瞳孔直径均值	瞳孔扩张通常与认知负荷升高、注意投入增强和精神紧张有关
pupil_std	时间窗口内瞳孔直径标准差	反映瞳孔波动程度和认知状态变化
blink_rate	单位时间内眨眼次数	反映疲劳、困倦和视觉注意状态变化

2.2.2 心电信号预处理与 HRV 特征提取

心电信号主要反映飞行员在任务过程中的自主神经系统调节状态。当认知负荷升高时，飞行员的生理唤醒水平和心率变异性可能发生变化，因此 ECG 信号可作为认知负荷识别的重要辅助模态。原始 ECG 信号通常存在基线漂移、工频干扰和运动伪迹等问题，若直接进行 R 峰检测，容易导致 RR 间期估计不准确。因此，本文首先对原始 ECG 信号进行滤波处理，以削弱低频漂移和高频噪声，保留心电信号中的主要 QRS 波群结构。

ECG 信号滤波前后的对比如图 2-8 所示：




图 2-8 心电信号滤波对比图

由图 2-8 可以看出，原始 ECG 信号存在一定程度的基线波动和噪声干扰，经过滤波处理后，心电波形更加平稳，R 峰结构更加清晰。该处理有助于提高后续 R 峰检测和 RR 间期计算的准确性。在完成滤波后，本文进一步对心电信号进行 R 峰检测。R 峰是 ECG 信号中与心搏周期密切相关的关键波峰，相邻 R 峰之间的时间间隔可构成 RR 间期序列。R 峰检测结果如图 2-9 所示。




图 2-9 心电信号 R 峰检测图

相邻 R 峰之间的 RR 间期计算公式为：

$$RR_i = t_{i+1}^R - t_i^R$$

其中， t_i^R 表示第 i 个 R 峰出现的时间， RR_i 表示相邻两个 R 峰之间的时间间隔。基于 RR 间期序列，本文在窗口级 ECG 特征构建时采用固定长度窗口进行计算，窗口长度为 10s，滑动步长为 5s。在该短窗设置下，RR 均值主要用于反映局部心率变化，RMSSD 和 SDNN 作为候选特征用于描述短时 RR 间期波动。后续实验中将根据特征筛选结果确定最终进入模型的 ECG 特征。进一步提取 RMSSD 和 SDNN 等心率变异性特征：

$$RMSSD = \sqrt{\frac{1}{N-1} \sum_{i=1}^{N-1} (RR_{i+1} - RR_i)^2}$$

$$SDNN = \sqrt{\frac{1}{N-1} \sum_{i=1}^N (RR_i - \overline{RR})^2}$$

其中， N 表示窗口内 RR 间期数量， $\overline{RR}$ 表示 RR 间期均值。RMSSD 用于描述相邻心搏间期变化，SDNN 用于描述窗口内 RR 间期整体波动程度。本文将心电窗口级特征表示为：

$$x_j^{ecg} = [RRMean_j, RMSSD_j, SDNN_j]$$

下表是常见的心电信号相关特征总结：

表 2-3 常用心电特征表

特征名称	特征含义	人体生理或认知状态对应含义
heart_rate	单位时间内心跳次数	心率升高通常与紧张、压力增强和认知负荷升高有关
rr_mean	相邻 R 峰间期均值	RR 间期缩短通常对应心率升高，可能反映压力或认知负荷增加
sdnn	RR 间期序列的标准差	反映总体心率变异性，数值降低可能表示压力增大或自主神经调节减弱
rmssd	相邻 RR 间期差值平方均值的平方根	主要反映副交感神经活动，下降可能表示紧张或认知负荷升高

2.2.3 肌电信号预处理与时频域特征提取

肌电信号主要反映飞行员在操纵飞行设备过程中的肌肉激活水平和动作控制负担。在飞行任务中，操纵杆、油门杆和相关控制动作会引起前臂肌肉活动变化，因此 EMG 信号能够从运动执行层面补充刻画认知负荷状态。由于原始 EMG 信号容易受到高频噪声、工频干扰和运动伪迹影响，本文在特征提取前先对肌电信号进行去均值、滤波和噪声抑制处理。肌电信号预处理前后的对比如图 2-10 所示：




图 2-10 肌电信号预处理对比图

可以看出，原始 EMG 信号波动较为剧烈，局部存在明显噪声干扰。经过预处理后，信号中的无效噪声成分得到削弱，有效肌电活动变化更加清晰。该处理为后续提取 RMS、MAV 等时域特征以及 MPF、MF 等频域特征提供了基础。

在时域特征方面，本文主要提取均方根值 RMS 和平均绝对值 MAV，用于描述窗口内肌肉活动幅值和能量水平：

$$\text{RMS} = \sqrt{\frac{1}{N} \sum_{i=1}^N x_i^2}$$

$$\text{MAV} = \frac{1}{N} \sum_{i=1}^N |x_i|$$

其中， x_i 表示窗口内第 i 个 EMG 采样点， N 表示窗口内采样点数量。除时域特征外，本文还从频域角度提取肌电特征。图 2-11 展示了肌电信号功率谱及频域特征计算过程。平均功率频率 MPF 反映功率谱的频率重心，中值频率 MF 表示将功率谱总能量划分为相等两部分的频率点。




图 2-11 肌电信号功率谱及频域特征计算图

MPF 计算公式为：

$$\text{MPF} = \frac{\sum_{k=1}^K f_k P_k}{\sum_{k=1}^K P_k}$$

其中， f_k 表示第 k 个频率点， P_k 表示对应功率谱密度。MF 满足：

$$\sum_{f=0}^{\text{MF}} P(f) = \frac{1}{2} \sum_{f=0}^{f_{\max}} P(f)$$

本文将肌电窗口级特征表示为：

$$x_j^{\text{emg}} = [\text{RMS}_j, \text{MAV}_j, \text{MPF}_j, \text{MF}_j]$$

常见肌电信号以及含义如下表所示：

表 2-4 常用肌电信号特征表

特征名称	特征含义	人体生理或认知状态对应含义
rms	肌电信号平方均值的平方根	反映肌肉激活强度，数值越大表示肌肉活动越强
mav	肌电信号绝对值的平均值	反映肌肉收缩水平和整体肌电强度
mf	肌电功率谱中将总功率分为两等份的频率	肌肉疲劳时中值频率通常下降
mpf	肌电功率谱频率加权平均值	反映肌电频谱重心，肌肉疲劳时可能下降

2.2.4 多模态时间对齐与窗口级样本构建

由于眼动、心电和肌电信号由不同设备同步采集，不同模态之间存在采样率和数据格式差异，因此不能直接按照采样点进行拼接。本文基于时间戳对三类信号进行统一对齐，并按照固定长度窗口构建样本。

本文设置窗口长度为 ($L=10,s$)，滑动步长为 ($s=5,s$)。对于某一飞行试次，设其起始时间为 t_0 ，则第 j 个时间窗口可表示为：

$$W_j = [t_0 + j \cdot s, t_0 + j \cdot s + L)$$

其中， t_0 表示当前飞行试次的起始时间， L 表示窗口长度， s 表示窗口步长。本文采用 10 s 窗口是为了保证 ECG 和 EMG 等生理信号在单个窗口内具有相对稳定的统计特征，同时采用 5 s 滑动步长可以在增加样本数量的同时保留相邻窗口之间的连续变化信息。其次在每个窗口内分别提取眼动、心电和肌电特征，并将其组合为窗口级多模态样本：

$$x_j = [x_j^{\text{eye}}, x_j^{\text{ecg}}, x_j^{\text{emg}}]$$

其中， x_j^{eye} 、 x_j^{ecg} 、 x_j^{emg} 分别表示第 j 个窗口内的眼动、心电和肌电特征。

为了减少不同特征量纲差异对模型训练的影响，对窗口级特征进行标准化处理。为避免信息泄露，正式实验中标准化参数仅由训练集计算，再应用于验证集和测试集。标准化公式为：

$$z = \frac{x - \mu_{\text{train}}}{\sigma_{\text{train}}}$$

其中， μ_{train} 和 σ_{train} 分别表示训练集中对应特征的均值和标准差。

在完成时间窗口切分和连续窗口序列构建后，本文最终保留 6033 个有效序列

样本用于实验。其中，low 类样本 2915 个，占比 48.32%；high 类样本 3118 个，占比 51.68%。两类样本数量较为接近，说明最终实验数据不存在明显类别不平衡问题。

2.3 基于机器学习的多模态认知负荷研究

为验证所提取多模态生理特征对认知负荷状态的基础区分能力，本文首先构建传统机器学习模型作为基线实验。机器学习实验主要采用支持向量机（SVM）和极端梯度提升树（XGBoost）两类模型，分别在眼动、心电、肌电单模态特征以及不同模态组合特征上进行 low / high 认知负荷二分类实验。

本文使用的机器学习输入特征为筛选后多模态关键特征。为了分析不同模态之间的互补性，实验分别构建 Eye、ECG、EMG 三种单模态输入，Eye+ECG、Eye+EMG、ECG+EMG 三种双模态输入，以及 Eye+ECG+EMG 三模态融合输入。

在模型设置方面，SVM 采用 RBF 核函数进行非线性分类，XGBoost 采用梯度提升树结构进行分类。为避免不同特征量纲差异对模型训练造成影响，所有特征均在训练集上计算标准化参数，并将相同参数应用于验证集和测试集。模型超参数仅在训练被试内部划分的验证集上进行选择，测试被试不参与模型调参，以避免信息泄露。具体实验设置如表 2-5 所示：

表 2-5 机器学习模型参数设置

模型	主要参数设置	调参方式
SVM	kernel=RBF, C 和 gamma 作为主要调节参数	在训练被试内部验证集上选择
XGBoost	n_estimators、max_depth、learning_rate、subsample 等作为主要调节参数	在训练被试内部验证集上选择

实验采用 LOSO 留一被试验证方式。每次选取 1 名被试作为测试集，其余被试作为训练与验证数据。在每一折中，测试被试的数据完全不参与训练、标准化参数计算和超参数选择，从而保证实验结果能够反映模型对未见过被试的泛化能力。评价指标包括 F1、Macro-F1 和 AUC。本节主要展示不同模态组合下的 AUC 对比结果，结果如下表所示：

表 2-6 机器学习各模态 AUC 对比表

模态	模型	AUC(%)
眼动	SVM	68.71
	XGBoost	67.93
心电	SVM	55.60
	XGBoost	54.19
肌电	SVM	61.64
	XGBoost	61.15
眼动 + 心电	SVM	69.86
	XGBoost	68.85
眼动 + 肌电	SVM	71.56
	XGBoost	70.48
心电 + 肌电	SVM	61.29
	XGBoost	60.70
眼动 + 心电 + 肌电	SVM	72.43
	XGBoost	71.54

为了更直观地展示，绘制如下柱状图：




图 2-12 机器学习各模态 AUC 对比图

从图中可以看出，不同模态组合下 SVM 与 XGBoost 的性能变化趋势基本一致，说明不同生理模态对认知负荷识别的贡献规律较为稳定。单模态实验中，眼动模态表现最好，SVM 和 XGBoost 的 AUC 分别达到 68.71% 和 67.93%，明显高于心电和肌电，说明眼动特征对认知负荷变化具有更强的敏感性。双模态实验中，

眼动+肌电组合取得最佳结果，其中 SVM 的 AUC 达到 71.56%，说明肌电能够对视动提供有效补充，两者具有较强互补性。三模态融合后模型性能进一步提升，SVM 在眼动+心电+肌电输入下达到最高 72.43%，表明多模态融合能够有效提高认知负荷识别性能。然而，三模态相较于眼动+肌电的提升幅度有限，说明心电模态边际贡献相对较小。

2.4 基于原始信号输入的眼动主导多模态深度融合模型

2.4.1 模型总体结构

本文所构建的深度学习模型主要由原始多模态信号输入模块、三支 TCN 模态编码模块、可靠性感知模态门控模块、眼动主导跨模态注意力模块、BiGRU 时间建模模块、时间注意力模块以及上下文门控分类模块组成。模型整体结构如图 2-13 所示。




图 2-13 模型整体结构图

2.4.2 原始信号输入与三支 TCN 编码

由于 Eye、ECG 和 EMG 三类原始生理信号的采样率、通道数和信号形态存在差异，若直接在采样点层面对不同模态进行拼接，将导致序列长度不一致和计算冗余增加。因此，本文首先基于时间戳对三类信号进行统一窗口划分，设置窗口长度为 10 s、滑动步长为 5 s，并在每个窗口内对不同模态进行降采样处理。降采样后，单个窗口内 Eye、ECG 和 EMG 分别保留 250、160 和 160 个采样点。设第 t 个时间窗内三类模态信号分别为： $x_t^{\text{eye}}, x_t^{\text{ecg}}, x_t^{\text{emg}}$ 。降采样后，三类模态在连续窗口序列中的输入形式可表示为：

$$X^{\text{eye}} \in \mathbb{R}^{T \times 6 \times 250},$$

$$X^{\text{ecg}} \in \mathbb{R}^{T \times 1 \times 160},$$

$$X^{\text{emg}} \in \mathbb{R}^{T \times 2 \times 160}$$

其中，样本标签采用最后一个时间窗对应的认知负荷标签。由于 Eye、ECG 和 EMG 在采样率、通道数和信号形态上存在差异，本文不在采样点层面对三类模态

进行直接拼接，而是分别保留各模态的原始时序结构，并通过独立编码分支提取模态特征。为了增强模型对不同时间尺度生理变化的表征能力，本文将普通单尺度 TCN 编码器改进为多尺度残差 TCN 编码器。对于每一种模态 $m \in \text{eye}, \text{ecg}, \text{emg}$ ，分别设置卷积核大小为 3、5、7 的并行 TCN 分支，用于提取短时局部波形、中等尺度变化和较长局部趋势：

$$H_m^{(k)} = \text{TCN}_k(X_m), \quad k \in 3, 5, 7$$

其中， TCN_k 表示卷积核大小为 k 的残差 TCN 分支， $H_m^{(k)}$ 表示该尺度下提取到的模态特征。不同尺度分支具有不同局部感受野，因此能够从同一模态信号中提取互补的时序模式。




图 2-14 TCN改造结构图

为避免简单拼接多尺度特征造成冗余，本文进一步引入尺度注意力机制，自适应学习不同卷积尺度的重要性。尺度权重计算为：

$$\alpha_m = \text{Softmax}(W_s[H_m^{(3)}; H_m^{(5)}; H_m^{(7)}])$$

最终得到模态 m 的多尺度融合表示：

$$F_m = \sum_{k \in 3, 5, 7} \alpha_m^{(k)} H_m^{(k)}$$

经过多尺度残差 TCN 编码后，Eye、ECG 和 EMG 被映射到统一维度的特征空间：

$$F_{\text{eye}}, F_{\text{ecg}}, F_{\text{emg}} \in \mathbb{R}^{T \times d}$$

该模块的主要作用是使模型在保留各模态独立结构的同时，从多个局部时间尺度提取原始生理信号的动态变化模式，为后续可靠性引导的眼动主导跨模态融合提供更充分的基础表征。

2.4.3 可靠性感知门控与眼动主导跨模态注意力

在原始生理信号采集过程中，不同模态的信号质量会随时间变化。眼动信号可能受到眨眼、视线丢失和瞳孔检测失败的影响；ECG 和 EMG 也可能受到运动伪迹、个体差异和操作幅度变化的干扰。如果直接对三类模态进行拼接或赋予固定权重，低质量模态可能会影响融合结果。因此，本文设计可靠性引导的眼动主导跨模态注意力机制，使模型在融合 ECG 和 EMG 辅助信息时，同时考虑特征相关性和当前模态可靠性。

首先，本文从当前时间窗的原始信号中构建可靠性特征：

$$q_t = [q_t^{\text{valid}}, q_t^{\text{eye}}, q_t^{\text{ecg}}, q_t^{\text{emg}}]$$

其中， q_t^{valid} 表示当前眼动窗口内有效采样点比例，可用于描述眼动信号质量； q_t^{eye} 、 q_t^{ecg} 、 q_t^{emg} 分别表示当前时间窗内 Eye、ECG 和 EMG 原始信号的幅值统计量，例如均方根值，用于反映各模态信号强度。可靠性特征经过门控网络后生成三类模态的可靠性权重：

$$g_t = \sigma(\text{MLP}(q_t)) = [g_t^{\text{eye}}, g_t^{\text{ecg}}, g_t^{\text{emg}}]$$

随后利用可靠性权重对三类模态特征进行调节：

$$\tilde{F}_t^m = F_t^m \odot (0.5 + g_t^m), \quad m \in \text{eye, ecg, emg}$$

其中采用 $(0.5 + g_t)$ 的形式可以使调节因子处于 $[0.5, 1.5]$ 范围内，避免某一模态被完全抑制，同时允许模型根据当前信号质量增强可靠模态、削弱低质量模态。




图 2-15 门控网络结构图

在跨模态融合阶段，本文以 Eye 表征作为 Query，以 ECG 和 EMG 表征作为 Key 和 Value。与普通跨模态注意力不同，本文进一步将 ECG 和 EMG 的可靠性权重引入注意力分数，构建可靠性偏置：

$$A_t = \text{Softmax} \left(\frac{Q_t K_t^T}{\sqrt{d}} + \lambda b_t \right)$$

其中， b_t 由 g_t^{ecg} 和 g_t^{emg} 生成，用于表示辅助模态在当前时间窗下的可靠性偏置， λ 表示偏置强度系数。

该设计使注意力权重不仅取决于 Eye 与 ECG、EMG 之间的特征相关性，也受辅助模态信号质量的影响。当某一辅助模态可靠性较高时，其注意力贡献会被增强；当其可靠性较低时，其影响会被削弱。

根据注意力权重得到辅助模态上下文表示 c_t 后，本文进一步通过融合门控控制眼动主导表示与辅助模态上下文之间的比例：

$$z_t = s_t \odot \tilde{F}_t^{\text{eye}} + (1 - s_t) \odot c_t$$

其中， z_t 为第 t 个时间窗的跨模态融合表示。该模块保留了 Eye 模态在飞行视觉任务中的主导作用，同时使 ECG 和 EMG 的辅助信息选择受到可靠性约束。相比简单拼接和普通 EyeQ 注意力，可靠性引导注意力能够在信号质量波动时更稳定地进行多模态融合。




图 2-16 跨注意力机制改编结构图

2.4.4 BiGRU 时间建模与上下文门控分类

认知负荷状态并不是单个时间窗内孤立出现的，而是随着飞行任务阶段、操作压力和生理响应变化而逐渐演化。因此，在得到每个时间窗的跨模态融合表示后，本文进一步采用 BiGRU 对连续窗口之间的时序依赖进行建模。

设连续 T 个时间窗的跨模态融合表示为 $Z = [z_1, z_2, \dots, z_T]$ ，将其输入双向

GRU，得到双向隐藏状态为：

$$\mathbf{h}_t = [\vec{\mathbf{h}}_t; \overleftarrow{\mathbf{h}}_t]$$

其中， $\vec{\mathbf{h}}_t$ 和 $\overleftarrow{\mathbf{h}}_t$ 分别表示前向和后向 GRU 的隐藏状态。通过 BiGRU，模型既能够利用前向历史窗口信息，也能够利用后向相邻窗口信息，从而更充分地捕捉短序列中的认知负荷动态变化。

在 BiGRU 输出后，通过时间注意力机制对不同时间步进行加权汇聚，得到序列级表示 r 。该过程使模型能够自动关注对认知负荷判断更关键的时间窗口，而不是简单采用最后一个时间步或平均池化结果。

考虑到飞行任务具有明显的阶段性，同样的生理响应在任务开始、中间和结束阶段可能具有不同含义，本文进一步引入 run 内位置上下文信息，对时间注意力得到的序列表示进行调节。




图 2-18 上下文门控分类模块结构图

本文构建位置上下文向量：

$$\mathbf{p} = [p^{\text{start}}, p^{\text{end}}, p^{\text{center}}, p^{\text{duration}}, p^{\text{order}}, p^{\text{remain}}]$$

其中，各分量分别描述当前序列在完整 run 内的起点、终点、中心位置、持续时间比例、顺序比例和剩余进程比例。该上下文仅反映样本在任务过程中的相对位置，不直接包含标签信息，因此不会造成标签泄露。上下文门控网络根据位置上下文生成门控向量：

$$g_p = \sigma(W_p p + b_p)$$

随后对序列表示进行调节：

$$r' = r \odot (1 + g_p)$$

其中， r' 表示融合上下文信息后的最终序列表示。最后，将 r' 输入全连接分类器，输出样本属于 high 认知负荷状态的概率：

$$\hat{y} = \sigma(W_o r' + b_o)$$

其中， $\hat{y} \in [0,1]$ 表示模型预测当前样本属于高认知负荷状态的概率。通过该设计，模型不仅能够利用多模态生理信号本身，还能够结合当前样本在飞行任务中的相对位置进行判断，从而提升跨被试识别的稳定性。

2.5 原始信号输入模型实验结果与分析

为验证原始信号输入深度融合模型的有效性，本文采用 LOSO 跨被试验证，可以避免同一被试数据同时出现在训练集和测试集中，使测试过程更接近实际应用场景，即利用已有被试数据训练模型，并对新的未知被试进行认知负荷识别。因此，虽然 LOSO 设置通常比随机划分更困难，但其结果更能反映模型在真实跨个体场景下的泛化能力。具体而言，每次实验留出 1 名被试作为测试集，其余被试用于训练和验证，循环完成 12 名被试的测试，最终统计整体性能。




图 2-19 模型在不同测试被试上的AUC分布

如图 2-19 所示，模型在不同测试被试上的 AUC 存在一定波动，说明生理信号个体差异会影响模型识别效果；但整体来看，多数被试仍保持较高 AUC，表明本文提出的原始信号输入深度融合模型在严格跨被试设置下仍具有较好的识别能力。

2.5.1 不同模态组合对比

为分析 Eye、ECG 和 EMG 对认知负荷识别的贡献，本文在 TCN-BiGRU 基线模型下比较了单模态、双模态和三模态输入条件下的模型性能，结果如表 2-7 所示：

表 2-7 TCN-BiGRU 基线模态组合对比

模态组合	F1	Macro-F1	AUC
Eye	77.57%	75.68%	82.89%
ECG	55.18%	53.23%	52.73%
EMG	62.98%	61.11%	64.87%
Eye+ECG	77.85%	76.87%	81.99%
Eye+EMG	81.38%	79.91%	87.20%
ECG+EMG	66.21%	62.35%	61.01%
Eye+ECG+EMG	82.02%	80.93%	88.03%




图 2-20 基线模态组合对比柱状图

可以看出，Eye 单模态性能明显优于 ECG 和 EMG，说明眼动信号对认知负荷变化更为敏感。双模态中，Eye+EMG 现较好，说明肌电信号能够为眼动模态提供有效补充。三模态融合取得最高 AUC，表明 Eye、ECG 和 EMG 之间存在一定互补性，多模态融合能够提升认知负荷识别效果。

2.5.2 模块消融实验

模态组合实验基础上，本文进一步比较 R0-R3 不同模型配置下的最终系统性

能，结果如表 2-8 和图 2-21 所示：

表 2-8 R0-R3 对比

模型	F1	Macro-F1	AUC
R0: Concat 原始基线	82.02%	80.93%	88.03%
R1: EyeQ Cross-Attn	84.91%	84.00%	91.63%
R2: EyeQ + Context Gate	84.25%	83.58%	92.94%
R3: EyeQ + Reliability Gate + Context Gate	86.10%	85.50%	93.01%




图 2-21 R0-R3 对比柱状图

R0 为三模态简单拼接基线模型，R1 在 R0 基础上引入 EyeQ Cross-Attn 后，F1 提升至 84.91%，Macro-F1 提升至 84.00%，AUC 提升至 91.63%，说明眼动主导的跨模态注意力能够有效建模 Eye 与 ECG、EMG 之间的互补关系，相比简单拼接具有更好的融合效果。

R2 在 R1 基础上加入 Context Gate 后，AUC 进一步提升至 92.94%，表明 run 内位置上下文信息能够增强模型对 low/high 认知负荷状态的概率区分能力。虽然 R2 的 F1 和 Macro-F1 相比 R1 略有下降，但 AUC 提升明显，说明该模块主要改善了模型的整体排序能力和判别稳定性。

最终，R3 在 R2 基础上加入 Reliability Gate 后取得最优结果，实验结果表明，EyeQ Cross-Attn、Context Gate 和 Reliability Gate 能够分别从模态交互、任务上下文和信号质量三个方面提升模型性能。

3.存在问题及解决途径：

虽然目前论文工作整体推进较为顺利，已完成多模态数据预处理、特征构建、原始信号输入模型设计以及初步实验验证，但在研究过程中仍存在以下几个方面的问题，需要在下一阶段继续完善。

（1）在前期实验中可以发现，随机窗口级划分下模型性能相对较高，而在 LOSO 跨被试验证等更严格划分方式下，模型性能会出现一定下降。这说明生理信号存在明显个体差异，模型在面对未见过被试时仍存在泛化难度。因此，如何提升模型在严格跨被试场景下的稳定性，是后续需要重点解决的问题。

（2）从当前单模态实验结果可以看出，ECG 单模态性能明显低于 Eye 和 EMG，说明心电信号在当前特征表达和模型编码方式下，对 low/high 认知负荷的区分能力仍然不足。其原因可能包括：ECG 对短时间窗口内认知负荷变化的响应不如眼动和肌电直接；心率变异性等有效信息需要更稳定的 R 峰检测和较长时间窗口支持；同时，心电信号容易受到个体差异和噪声影响，导致跨被试泛化难度较高。因此，如何增强 ECG 模态的信息表达能力，是后续需要重点改进的问题。

解决方法：

（1）下一阶段将继续以 LOSO 等严格被试划分结果作为论文主结果，避免因窗口随机划分造成被试信息泄露。同时，进一步优化模型训练策略，包括正则化、早停机制、阈值选择、概率平滑和模型轻量化设计等，以提升模型在未知被试上的稳健性和泛化能力。

（2）下一阶段将从 ECG 信号处理、特征构建和模型融合三个方面进行优化。进一步完善 ECG 预处理流程，提高心电特征质量，将手工特征与深度学习卷积特征结合输入模型。在模型层面可尝试增强 ECG 分支表示能力，例如增加 ECG 分支编码维度、引入 ECG 专用注意力模块，或在融合阶段通过可靠性感知门控避免 ECG 被简单弱化，使其在与 Eye、EMG 融合时发挥更稳定的辅助作用。

4.下一阶段工作计划和研究内容：

根据目前研究过程中存在的问题，下一阶段将围绕模型泛化能力提升、对照实验补充等方面继续开展工作，具体安排如下：

- 1.2026 年 7 月至 8 月：完善改进当前深度学习模型，提高模型泛化能力。
2. 2026 年 9 月至 10 月：增加其他种类神经网络模型的对照实验。
3. 2026 年 11 月至 12 月：将所有实验内容进行总结分析，完成毕业论文初稿。
4. 2027 年 1 月至 3 月：对关键技术成果进行总结分析，完成毕业论文。

5.学校导师意见:

签名:

年 月 日

6.企业导师意见

签名:

年 月 日

中期考核小组成员	姓名	职称	单 位	签 名

7.小组对论文工作的意见:

学院盖章:

年 月 日

注：签名应是手工填写。